119 局所発話速度変化予備抽出ツールの音声対話データベースへの適用

松村 真言 広重 真人 荒木 健治 栃内 香次
北海道大学大学院工学研究科

1 はじめに

自由会話音声において強い表現手段の一つであると考えられる意図的話速変化の研究を行なうに際し、話速変化を豊富に含むサンプルを数多く用意する必要がある。本稿では既存のHMM音声認識ツールおよび学習済パラメータ、さらにあらかじめ与えた書き起こしテキストを用いて音素境界を推定し、発話速度変化を予備的に抽出するツールを構築する。これらにより予備抽出された音声データは、事後に目視を含む詳細な手法で再度話速分析し、話速研究に活用する。

本稿では局所的話速変化箇所を多く含むサンプルを実際に数多く収集するにあたり、RWCP対話音声データベース[1]を用いた。このデータベース中の音声に対して発話速度の予備抽出を行ない、求められた仮の発話速度から大きな話速変化が含まれていると考えられる箇所を推定した。この話速変化箇所の推定には、話速の知覚を考慮した可変閾値[2]を用いた。

2 データベース音声における音素境界推定

RWCP音声対話データベース[1]中の対話音声に対して、HTKと学習済HMMパラメータセット[2]、およびデータベースに収録された書き起こしテキストを用いておおまかな音素境界を定める。今回実験に用いた音声は男性2話者の対話音声で、音声の収録は主にスタンドマイク2台を用いて行なわれたため、相手話者の音声の重畳や雑音も含まれている。

データベースより発声単位、ローマ字記述、言語・音響的区切りが与えられているので、それぞれをサンプルの区切り情報、書き起こしテキスト、sp(ショートポーズ)モデル位置情報として利用し、連続した約7分の対話音声データに対して音素の強制割付を行なった。ここで、サンプル数は2話者合計390個であり、サンプルあたりの平均モーラ数は約7.2モーラであった。

3 話速変化箇所の推定

3.1 話速変化箇所の推定

音素の強制割付を行なったサンプルに対して、音素をモーラにまとめてモーラ単位での話速を求め、話速変化の大きな箇所があるかを推定する。推定に際し、話速の知覚を考慮した可変閾値[2]を導入する。この可変閾値は聞き手の注意レベルに相当し、持続長の長いモーラが連続したときにはその遅さに慣れていき、遅い箇所の直後では伸長の判断に鈍感になる話者の知覚の性質を仮定している。モーラ持続長がこの動的閾値を大きく超えた場合に、局所的伸長として知覚されると考える。どの程度閾値を超えているかをモーラ持続長曲線と可変閾値曲線とで囲まれる領域の面積(以下「閾値超過面積」と記す)で表し、この面積が大きい箇所に知覚可能な局所的伸長が含まれているものとみなす。また、話者の意図的話速コントロールは主に伸長に含まれると考え、短縮しているモーラ、すなわちモーラ持続長が注意レベルよりも下回るモーラに関しては検出対象外として閾値超過面積は0とした。すべてのモーラについて閾値超過面積を算出し、面積ごとに該当するモーラの度数を算出した。度数分布を表1に示す。

ここで、全てのサンプルにおいて、閾値超過面積がサンプル内で最大となるモーラの閾値超過面積をそのサンプルのスコアとして出力する。ただし、サンプルの最終モーラは文末に相当すると考えられ、大きなフレーズ末伸長がたびたび観測されたため、閾値超過面積が最大となるモーラがサンプルの最終モーラに相当する場合、閾値超過面積の次点をそのサンプルのスコアとした。また、モーラ数の少ない短いサンプルに関しては、話速変化研究対象として望ましいサンプルである可能性が低いと考えられるため、サンプルのモーラ数が9モーラ以下の288サンプルを除外し、残りの102サンプルに対してスコアを求め、話速変化箇所の推定を行なった。

表1: 全モーラに対する閾値超過面積毎の度数分布

総モーラ数(全390サンプル中)	2813
面積 100000(msec^2)以上	105
面積 100000～50000(msec^2)	108
面積 50000～20000(msec^2)	204
面積 20000～10000(msec^2)	159
面積 10000～2500(msec^2)	363
面積 2500～1(msec^2)	415
面積 0	1459

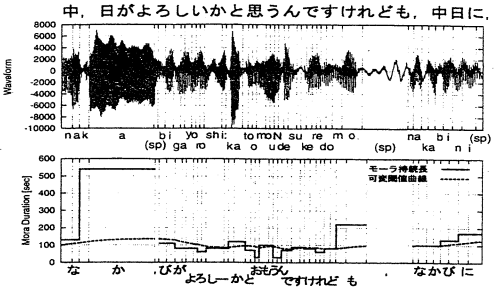


図1: モーラ持続長と可変閾値曲線の例

3.2 結果および考察

スコアごとの当該サンプルの度数分布を表2に、モーラ持続長と可変閾値曲線の例(スコア値:約221,748)を図1に示す。スコアの大きなサンプルの多くでは、閾値超過面積が最大となったモーラはspの直前のモーラであった。このsp直前のモーラは、任意に伸長するフレーズ末モーラに該当するため、必ずしも意図的伸長に該当するとはいえない。よって、フレーズ末モーラを除いた場合でのスコアも求める必要があると考えられる。また、単一モーラ毎に求めたスコアの値では音素境界推定時の誤差の影響を大きく受けるため、フレーズに区切り、各フレーズ内のそれぞれのモーラでのモーラ持続長曲線と可変閾値曲線とで囲まれる領域の面積の総和をもとにフレーズ単位でのスコアを求めることも検討する必要がある。

表2: サンプルのスコア毎の分布

10モーラ以上の総サンプル数	102
スコア 50000(msec^2)以上	32
スコア 20000～50000(msec^2)	30
スコア 5000～20000(msec^2)	28
スコア 5000未満(msec^2)	12

4 まとめ

本稿では、HMMを用いた発話速度変化の予備抽出手法を、対話音声データベースに対して適用し、粗い音素セグメンテーションを行っておおまかな話速を求め、局所的話速変化が生じていると考えられるサンプルを予備抽出した。この局所話速変化箇所の推定には話者の知覚の性質を考慮した可変閾値を用い、伸長の度合いを閾値超過面積として表した。

今後は、モーラ単位で求めたスコアの妥当性を考慮するとともに、フレーズ単位でのスコアを求め、これらから局所的話速変化を含むサンプルの抽出をさらに検討する予定である。

参考文献

[1] 『RWCP音声対話データベース』,http://www.rwcp.or.jp/people/toyoura/rwcdb/speech/index.html
[2] 高丸他, "発話速度概形近似モデルにおける話速変化近似関数の検討", 音講論,3-Q-6,pp.353-354(2001-03)
[3] 名古屋大学板倉研究室,『A standard HMM set of Japanese phonemes.』http://www.itakura.nuee.nagoya-u.ac.jp/