124 帰納的学習を用いた意味解析規則の自動獲得手法の性能評価

渋木 英潔 荒木 健治 栃内 香次
北海道大学大学院工学研究科

1 はじめに

機械翻訳や対話処理などの高度な自然言語処理を行うためには，形態素や構文などの統語的情報だけではなく，深層格などに代表される意味的な情報の利用が必要であると考えられる．しかしながら，現在のところそのような意味的情報が誰にでも利用できる形で整備されているわけではない．意味的情報を人手で作成することは莫大な労力がかかり，さらに作成者の主観による影響を大きく受ける．それゆえ，人手を介すことなくコーパスからこれらの情報を自動的に学習することが望ましい．以上の背景から，我々は帰納的学習を用いて，単語境界，内容語と機能語のタグ，依存関係という統語的な情報だけが付与されたコーパスから意味的情報を自動的に獲得する手法を提案している [1]．本手法で獲得する意味的情報とは，深層格，意味解析規則，分類シソーラスである．また，統語的情報を自動的に獲得するための先行研究 [2] が存在するが，現段階では精度的に十分でない．それゆえ，本稿では統語的情報が付与されたEDRコーパスを利用し提案手法の性能について評価する．

2 実験

コーパスから250文をランダムに選択し，その内の50文をテストデータとし，残りの200文をトレーニングデータとした．200文のトレーニングデータ1文あたりの平均依存関係数は8.4である．また，トレーニングデータの50文と100文のサブセットを作成し同様の実験を行った．今回の実験では，予備実験の結果から尤度が11位以下の結果を枝狩りしながら解析を行った．客観的な評価を行うために，EDRコーパスの格フレームを正解として正誤を判断した．評価は，尤度が1位である結果の各依存関係に対して行い，出力された深層格がEDRの深層格と一致する依存関係を正解とした．ただし，EDRコーパス中には，文中に明示されていながら格フレーム中では省略されているもの，あるいは，その逆に格フレーム中だけに出現するものがあり，それらの依存関係は無効なものとして評価の対象から除外した．また，主辞を含む文節が異なる場合も無効な依存関係とした．正解率は，次式により計算される．

$$\text{正解率 [\%]} = \frac{\text{正解依存関係数}}{\text{有効依存関係数}} \times 100 \qquad (1)$$

Table 1 実験結果

文数	依存関係	正解率
50	391	41.5%
100	831	44.3%
200	1,676	44.6%

表1に実験結果を示す．左から順に文数，依存関係数，正解率である．トレーニングデータ数の増加に伴い精度が上昇している．文献 [3] では，事前に用意された多くの格パターンとシソーラスを用いて，既に設定された深層格を割り当てる実験を行い，EDR日本語共起辞書に対して80.3%の精度を達成している．文献 [3] とは条件が大きく異なるが，我々の結果は，彼らの半分程度の精度しか達成されていない．200文の学習データから作成された深層格のクラスタ数は32個であり，1クラスタあたりの平均深層格数は52.1個だった．従って，ランダムに深層格を割り振った場合に比べて，40%以上という結果は明らかに正しくクラスタリングされていることが分かる．しかしながら，改善の余地がある．本手法には数多くのパラメータがあるが，今回の実験では調整を行っておらず，これが低精度の原因と考えられる．それゆえ，精度の向上のためにパラメータを最適化することが必要である．

3 まとめ

今後の課題として，パラメータの最適化が挙げられる．また，先行研究と統合してタグなしコーパスから意味解析規則を自動的に獲得したいと考えている．

参考文献

[1] 渋木英潔, 荒木健治, 栃内香次, “帰納的学習を用いた括弧つきコーパスからの意味解析規則の自動獲得手法の性能評価,” 信学技報, NLC2001-32, July 2001.

[2] 渋木英潔, 荒木健治, 栃内香次, “帰納的学習を用いたタグなしコーパスからの統語規則の自動獲得手法,” 信学論 (D-II), vol.J83-D-II, no.10, pp.2003–2016, Oct. 2000.

[3] 大石亨, 松本裕治, “格パターン分析に基づく動詞の語彙知識獲得,” 情処学論, vol.35, no.11, pp.2597–2610, Nov. 1995.