126 帰納的学習を用いた汎用的な情報抽出手法

塚原 卓人 荒木 健治 栃内 香次
(北大工)

1. はじめに

計算機の普及に伴い、計算機上で文書を扱う機会が増えている。そこで、大量の文書を読む際の膨大な時間と労力を軽減するために、文書から必要な情報を抜き出す情報抽出[1]の研究が行われている。従来の情報抽出はユーザがどのような情報を抜き出すのか、その内容及び抽出方法をあらかじめ与えておき、それに当てはまる情報を文書から抜き出すというものであるため、ユーザが必要とする情報が文書の内容によって変わる場合には有効ではない。そこで、本稿では帰納的学習[2]を用いることで、ユーザが文書からどのような情報を必要としているか及びその抽出方法を学習し、汎用的な情報抽出を実現する手法を提案する。また、その手法を用いて実験を行い、その有効性について考察する。

2. 提案手法

本手法では、過去にユーザがどのような情報を必要としたのかをルール辞書に蓄え、それをもとに新たな文書に対して情報抽出を行う。処理の流れは図1に示す。

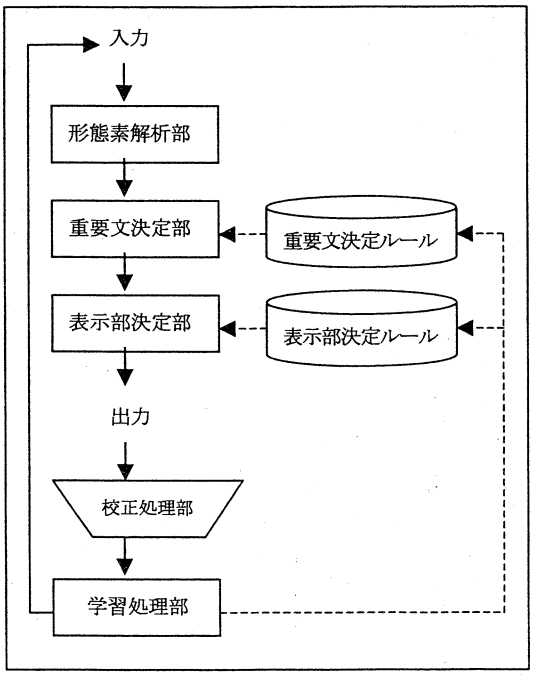


図1

まず、入力された文書に対して形態素解析ツール茶筌[3]を用いて形態素解析を行う。次に、一文ごとにその文の状態を表すパラメータを与え、重要文決定ルールと比較して一文ごとの重要度計算を行い、重要文を決定する。ここで、重要文とは、ユーザが必要とする情報を含む文と定義する。ユーザが必要とする情報は過去にユーザによって行われた校正結果からシステムが推測する。そして、過去に行った情報抽出の出力結果から作られた表示部決定ルールを参考にして、決定した重要文から表示部分を決定し、出力する。さらに、出力結果に対してユーザが校正処理を行い、その結果からシステムが新たにルールを自動的に学習する。

3. 概要

3．1 重要文決定

重要文の決定は状態パラメータを用いて行う。状態パラメータとは入力文書中の一文ごとの状態を表すもので、表1に示す9つの要素について設定された数値からそれぞれ当てはまるものを選び、それを並べた9桁の数字である。重要文決定ルールには表2のように過去に扱った文書の重要文の状態パラメータが蓄えられている。入力文書中の一文ごとに重要文決定ルールを参照し、その文の状態パラメータと一致するルールの重要度を用いてその文の重要度を計算する。ルールの重要度はそのルールと一致した文が重要文になった確率である。また、重要文決定ルールは状態パラメータ同士の共通部分をとったものも新たにルールとして持つ。表2における１ｘ１ｘ０ｘｘｘｘなどがそれで、このルールは１１１２００１２０と１０１００１００１からできたものである。ｘは差異部分を表す。このようなルールの場合、数字の部分だけが一致すればよいので使用頻度が高い。ルールの中に数字の部分が何個あるかをそのルールのレベルと呼ぶ。例えば１ｘ１ｘ０ｘｘｘｘは数字が3個なのでレベルは3となる。

表1 状態パラメータの要素の内容

[0]：文の位置、	[1]：段落
[2]：段落中の位置、	[3]：前文との接続関係
[4]：箇条書き、	[5]：日時表現
[6]：文のタイプ、	[7]：キーワード
[8]：文中の名詞・動詞	

表2 重要文決定ルール

状態パラメータ	重要度
１１１２００１２０	0.8
１０１００１００１	0.5
１ｘ１ｘ０ｘｘｘｘ	0.333
２３１１１０１１１	1.0
ｘｘ１ｘｘ０１ｘｘ	0.75

表３　表示部決定ルール

重要文：巨人(名詞-固有名詞-組織)江藤(名詞-固有名詞-人名-姓)智(名詞-固有名詞-人名-名)内野（名詞-一般)手(名詞-接尾-一般)((記号-括弧開)３(名詞-数)１(名詞-数))（記号-括弧閉)

出力結果：巨人(名詞-固有名詞-組織)江藤(名詞-固有名詞-人名-姓)

重要文：＊（名詞-固有名詞-組織）＊(名詞-固有名詞-人名-姓)＊(名詞-固有名詞-人名-名)＊（名詞-一般)＊(名詞-接尾-一般)((記号-括弧開)＊(名詞-数)＊(名詞-数))（記号-括弧閉)

出力結果：＊(名詞-固有名詞-組織)＊(名詞-固有名詞-人名-姓)

文の重要度の計算を、式(1)に示す。

$$\text{文の重要度}=\frac{\sum\{a\times b\times c\}}{\sum c} \qquad \cdots\ (1)$$

a：ルールの重要度　b：一致した要素の重み

c：ルールのレベル

式(1)より、文の重要度は、その文の状態パラメータと一致するルールの重要度とレベルによって決まる。レベルの高いルールほど文の重要度に強く影響する。また、状態パラメータの要素ごとに重み付けがされており、どの要素が重要文決定に影響するかも変化する。この重要度計算を行い重要度の高い文を重要文と決定する。どの程度を重要文とするかは過去の重要文の重要度と重要文の数、要約率をもとにシステムが決定する。

３．２　表示部決定

表示部決定ルールには表３のように過去に扱った文書の重要文と実際に校正された表示部分とが対で蓄えられている。表示部決定ルールにもルール同士の一致部からなるルールが新たに蓄えられる。また、形態素のみが一致する場合もルールとして抽出する。表示される部分は必ずしも文である必要はなく、ユーザの校正結果によって決定する。表示部決定ルールと一致する部分はそのルールと同じ形になるが、一致するルールがない場合、重要文がそのまま出力される。

4. 評価実験および考察

今回はユーザの必要な情報の傾向を学習しやすいように実験対象の文書の分野を限定した。今回はスポーツニュース 30 文書（総文字数 16864 文字）[4]に対して実験を行い、その精度の評価を行った。1 文書あたり平均 17.8 文含まれており、最小 4 文、最大 45 文であった。また、1 文書あたりの平均文字数は 562.1 文字で、最小 128 文字、最大 1231 文字であった。まず、文書中の情報を必要な情報、どちらでもよい情報、不要な情報の３つに分け、必要な情報がすべて表示されているかについて評価し、さらに不要な情報が含まれていないかについて評価した。結果を表４に示す。回数を重ねることで、必要な情報の決定については精度の向上が見られた。しかし、不要な情報を表示することも増大した。

表４　評価

文書番号	1～10	11～20	21～30	合計
A	2 (1)	5 (1)	6 (1)	13 (3)
B	5 (2)	4 (1)	4 (1)	13 (4)
C	3 (1)	1 (0)	0 (0)	4 (1)

A:必要な情報がすべて含まれている文書

B:必要な情報が一部抜けている文書

C:必要な情報が含まれていない文書

（）内の数字は不要な情報が含まれていない文書

5. おわりに

今回の実験で必要な情報の抽出については精度の向上が見られた。しかし、まだ十分とは言えず、必要な情報すべてを抽出できたものは６割程度であった。必要な情報が一部抜けているというのは問題である。また、今回は実験に扱う文書の量が不十分なため表示部決定ルールの適用があまり見られず、重要文をそのまま出力するケースが目立った。表示の見易さについてはまだ評価する段階には至らなかった。実験を重ね、表示部決定ルールの有効性について検討する必要がある。今後は、必要な情報の的確な抽出と見やすい表示の二つの問題を解決し、後に実験対象の分野を広げ、汎用的なものを目指す。

参考文献

(1) 長尾真、黒橋禎夫、佐藤理史、池原悟、中野洋、“言語情報処理”岩波書店、1998.

(2) 荒木健治、“帰納的学習を用いた自然言語処理の有効性について、信学技法、TL99－41、pp. 33－40、2000.

(3) 松本裕治、北内啓、山下達雄、平野善隆、“日本語形態素解析システム『茶筌』version 2.0 使用説明書”、NAIST Technical Report、NAIST-IS-TR99008、April 1999.

(4) 日刊スポーツ　http://www.nikkansports.com