129 帰納的学習を用いた言い換え文生成手法の提案

鹿島 啓吾（北大工） 荒木 健治（北大工） 栃内 香次（北大工）

1．はじめに

自然言語は一つのことを表す表現が複数存在するという特徴をもつ。逆に、複数の異なる表現が同じ意味内容を示すことがある。ある表現を別の表現に変換する処理は言い換えと呼ばれる。現在、言い換えの研究は盛んに行われている。これまでに提案されている言いかえ処理の手法では国語辞典や構文解析の結果の知識、もしくは言い換えのルールを用意して、言い換えを行うというあらかじめ用意された知識を用いる手法が多い[1][2][3]。そのため、どの程度の知識を用意すればよいのか、また用意されたパターン以外の状況ではうまく処理を行うことができないといった問題点がある。

そこで本稿では実例よりそこに内在する規則を獲得することができる帰納的学習[4]を用いた言い換え文生成手法を提案する。本手法では形態素解析の知識だけを用いて言い換えシステムを作成した。以下で本システムの処理過程を示すとともにそれを用いた実験を通じて本手法の性能評価を行い実験結果から考察を行う。

2．処理過程

本システムでははじめに形態素解析ツールＪＵＭＡＮ[5]を用いて入力文の形態素解析を行う。次にそれまでに獲得されルール辞書に蓄えられている言い換え文生成ルールに基づき言い換え文を生成し出力する。複数の言い換え文が生成されたときはすべて出力する。言い換え文が生成できなかったときは人手で言い換え文を入力する。入力文と言い換え文の組を対としこの対とそれまでに獲得されている言い換え文生成ルールから新たな言い換え文生成ルールを獲得しルール辞書の更新を行う。

2．1．言い換え文生成ルール獲得処理

はじめに入力された二つの文を対としたルールを生成する。次にルールが蓄えられているルール辞書から取り出されたルールの対と比較を行い単語列および形態素解析結果の共通部分、差異部分を抽出する。この文の組の差異部分を変数化したルールおよびこの対より差異部分を抽出したルールの生成、獲得を行う。ここで、共通部分は一致率が50%以上のときに抽出している。さらにこのときに生成されたルール同士、ルール辞書に蓄えられたルールとも同様の処理を行ってルールを獲得し、新たなルールが生成されなくなるまで行う。処理手順を以下に示し例を表１に示す。

1．選択
　・50%以上の共通部分を有したルールのペアを抽出
2．生成
　・差異部分を抽出し、変数へ置き換える
3．生成された新たなルールを加え１，２の処理を繰り返す
4．新たなルールが生成されない場合終了

また、言い換えに有用なルールを獲得するためにルール対で共通の名詞が存在した場合、この名詞を変数化したものを新たなルール対とし同様の帰納的学習を行った。この例を表２に示す。この処理により変数化していない文の対同士では獲得できないルールを獲得することができる。

表１：ルール獲得の例

(a)入力文から直接獲得したルール
昼飯 は 何 を 食べ ます か：昼御飯 は 何 に し ます か
晩御飯 は 何 を 食べ ます か：夕食 は 何 に し ます か
君 は 何 が 好きです か ：あなた は 何 が 好み です か
君 は 何 が 好きです か：君 は 何 が 好み です か
(b)帰納的学習により獲得したルール
＠０ は 何 を 食べ ます か：＠０ は 何 に し ます か
＠０ は 何 が 好きです か：＠０ は 何 が 好み です か
昼飯：昼御飯
晩御飯：夕食
君：あなた
君：君
(c)再帰的に獲得したルール
＠０ は 何 ＠１：＠０ は 何 ＠１
を 食べ ます か：に し ます か
が 好きです か：が 好みです か

表２：共通名詞を変数化後のルール獲得例

(a)入力文の組
彼女 が 彼 を 殴った：彼 が 彼女 に 殴ら れた
猫 が 魚 を 食べた：魚 が 猫 に 食べら れた
(b)共通名詞を変数化したルール
＊０ が ＊１ を 殴った：＊１ が ＊０ に 殴ら れた
＊０ が ＊１ を 食べた：＊１ が ＊０ に 食べら れた
(c)帰納的学習により獲得したルール
＊０ が ＊１ を ＠０：＊１ が ＊０ に ＠０ れた
殴った：殴ら
食べた：食べら

2．2．言い換え文生成処理

獲得したルールを変数部に代入して左辺で入力文と同じ文を作成し、同じ処理を右辺で行うことによ

り言い換え文を生成する。この例を表３に示す。

３．実験と評価

作成したシステムが適切な言い換え文を生成できるかどうかを確認するために実験を行った。

３．１．実験方法

実験は入力文を５０文用意して行った。今回入力文として、中学一年生向けの英語の参考書[6]から例文を利用した。ルール辞書は空の状態からはじめて、適切な言い換え文が生成されているかどうかを評価する。言い換え文が生成されないときは第一著者が言い換え文を入力した。

表３：言い換え文生成例

入力文：君は何を食べますか
(a)言い換え文生成ルール抽出
@0 は 何 を 食べ ます か：@0 は 何 に し ます か
君：あなた
君：君
(b)変数部への代入
君 は 何 を 食べ ます か：あなた は 何 に し ます か
君 は 何 を 食べ ます か：君 は 何 に し ます か
(c)生成された言い換え文
①あなたは何にしますか
②君は何にしますか

３．２．評価方法

言い換えの評価は再現率，適合率で行う。

$$\text{再現率} = \frac{\text{言い換え文を出力した回数}}{\text{入力した文の回数}}$$

$$\text{適合率} = \frac{\text{適切な言い換え文が生成された数}}{\text{生成された言い換え文の数}}$$

再現率は文を入力したとき言い換え文が出力された割合、適合率は出力された言い換え文が適切である割合を表す。適切かどうかの評価基準は第一著者が文法的、意味的に正しいかを判断して決定した。

３．３．実験結果

入力５０文中、言い換え文が生成されたのは２２回であった。今回の実験では複数の文が出力されることはなかった。また適切でない文が３文出力された。表４に実験結果、図１に入力に伴う評価１の推移を示す。

図１：入力に伴う言い換え文生成回数

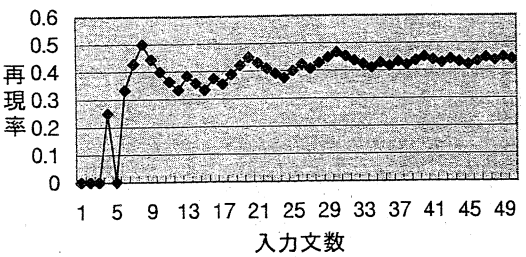


表４：実験結果

出力あり		出力なし
適切な文	不適切な文	
19	3	28

４．考察

今回の実験の結果、再現率は 44%（22/50）、適合率は 86%（19/22）となった。入力文が増加するにつれ再現率は最初は上昇するが途中からは 45%付近で収束している。このことは入力文が少ないために、言い換え文が生成される際に適用されたルールは共通の名詞を変数化し生成されたルールが主であり、帰納的に学習した共通部分や差異部分のルールがあまり適用されなかったことによるものと思われる。適合率の結果は高い値が得られた。これは今回適用されたルールが主に共通名詞を変数化したルールであったことから考察して共通名詞を変数化することは有用である考えられる。今後、本システムで用いた帰納的学習による言い換え文生成の有効性を確かめるためには入力文を増やし実験を行う必要性があると思われる。

５．おわりに

本稿では帰納的学習を用いた言い換え文生成手法を提案した。今回はルールを組み合わせて文全体が一致した場合に言い換え文を生成した。しかし言い換えの目的によっては文の一部、文末の表現などといったある部分に注目をし，そこから言い換えのルールを抽出したりできるのではないかと考えられる。今後は言い換えの目的に対応したルールの獲得方法、適用方法についての考察、また入力文の数を多くして実験量を増やす必要性あると考えられる。

参考文献

[1]鍛冶伸裕，黒橋禎夫，佐藤理史：国語辞典に基づく平易文へのパラフレーズ，信学技報，NLC22-35，pp.167-174(2001).

[2]佐藤理史：論文表題を言い換える，情報処理学会論文誌，Vol.40，No.7，pp.2937-2945(1999).

[3]近藤恵子，佐藤理史，奥村学：格変換による単文の言い換え，情報処理学会論文誌，Vol.42，No.3，pp.465-477(2001).

[4]荒木健治：帰納的学習を用いた自然言語処理の有効性について，信学技報，TL99-41，pp.33-40(2000).

[5]松本祐治，黒橋禎夫，宇津呂武仁，妙木裕，長尾真：日本語形態素解析システムＪＵＭＡＮ使用説明書 version2.0，京都大学工学部長尾研究室(1994).

[6]学研：要点ドン！中１英語，学習研究社，(2001).