131　帰納的学習を用いた機械翻訳手法における数字表現の割り当て方法について

松原雅文　荒木健治　栃内香次
北海道大学大学院工学研究科

1　はじめに

世界規模のネットワークの発達により，さまざまな言語を母国語とする世界中の人たちとの距離が近くなった現在，コミュニケーションツールとして機械翻訳システムの需要が高まってきている．高精度な機械翻訳システムを実現するために我々は，表層的な情報から学習を行うことが可能な帰納的学習による機械翻訳手法を提案している [1]．一方，我々はすでに，情報が縮退した数字表現からその失われた情報を復元し漢字かな混じり文に変換する，帰納的学習を用いた数字漢字変換手法を提案し，その有効性を確認している [2]．この手法において 1 つの数字表現は複数の漢字かな混じり文に対応しており抽象度が増している．そこで，この数字表現の持つ抽象度の高さを利用した機械翻訳手法を，我々は提案する [3]．この抽象度の高い数字表現に帰納的学習を適用することにより，字面上で一致する文字数が増加するので，獲得可能な翻訳ルール数を増加させることができると考えられる．ここで，原言語，目的言語テキストへの数字表現の割り当て方法は，本手法の翻訳精度に直接的に大きな影響を与える．そこで本稿では，数字表現の割り当て方法について比較，検討した結果を評価実験結果から述べる．

2　処理概要

本手法の処理過程を Fig.1 に示す．本手法においては，入力された英語文は，まず対応する数字表現に変換される．変換された数字表現は，日本語文に対応した数字表現に翻訳され，さらに日本語文に変換され，最終的な翻訳結果となる．翻訳結果に誤りが含まれている場合，使用者により校正が行われる．ここで与えられた校正済み翻訳結果をもとに，学習処理が行われ，辞書が更新される．この更新された辞書を用いて次回からの翻訳が行われるので，これら一連の処理を繰り返すことにより，次第に翻訳精度は上昇していく．

3　評価実験

3.1　数字の割り当て

前後の文字の出現状況が類似している文字は，意味的に類似しており，このような文字に同一の数字を割り当てることにより，効率よく学習を行うことができると考えられる．そこでこの仮定に従い，予備実験を行った結果から，アルファベットを 9 種類の数字に，かなを 20 種類の数字にそれぞれ割り当てることとした．

3.2　実験データおよび評価方法

実験には，旅行者用英会話文の場面「機内」のデータ（入力文数 345 文，入力文字数 9,193 文字）を用いた．1 文ずつ入力を行い，Fig.1 の処理に従い英日翻訳を行った．初期状態を一定に保つため，実験は辞書が空の状態から行っている．なお，実験結果の評価は以下に示す

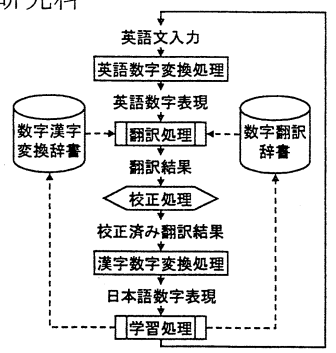


Fig. 1　処理過程

式 (1)(2) により行った．

$$\text{再現率} = \frac{\text{正翻訳文字数}}{\text{校正済み翻訳結果文字数}} \quad (1)$$

$$\text{適合率} = \frac{\text{正翻訳文字数}}{\text{翻訳結果文字数}} \quad (2)$$

3.3　実験結果

実験の結果，全体の再現率は 22.8[%]，適合率は 75.7[%] となり，実験終了時に獲得された翻訳ルール数は 359 となった．携帯電話等で一般的に用いられている数字の割り当て方法に従い，同様の実験を行った場合の再現率は 20.9[%]，適合率は 75.8[%]，獲得ルール数は 344 であったので，本稿における数字表現の割り当て方法により，学習効率が向上し，再現率において約 2 ポイントの向上が確認された．

4　まとめ

本稿では，帰納的学習を用いた機械翻訳手法における数字表現の割り当て方法について検討した．本手法において，数字表現の割り当て方法は翻訳精度に大きな影響を与える．そこで，前後の文字の出現状況を考慮した数字表現の割り当て方法を提案し，実験を行った．その結果から，携帯電話等で一般的に用いられている数字の割り当て方法に従う場合に比べて，再現率で約 2 ポイントの向上が確認された．今後は，さらなる翻訳精度の向上に向けて，数字表現の割り当て方法について検討を進める予定である．

参考文献

[1] 越前谷博, 荒木健治, 桃内佳雄, 栃内香次：“実例に基づく帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性,” 情処学論, Vol.37, No.8, pp.1565–1579(1996).

[2] 松原雅文, 荒木健治, 桃内佳雄, 栃内香次：“文字情報縮退方式を用いた帰納的学習によるべた書き文の数字漢字変換手法の有効性について,” 信学論 (D-II), Vol.J83-D-II, No.2, pp.690–702(2000).

[3] 松原雅文, 荒木健治, 栃内香次：“数字表現からの帰納的学習を用いた機械翻訳手法の有効性について,” 信学技報, TL2000-46, pp.49–56(2001).