132 帰納的学習を用いた多言語単語分割における学習機能の評価

王 忠建 荒木 健治 栃内 香次
北大工

1 はじめに

インターネットの普及によって様々な言語のテキスト情報が急増している．従って情報検索，機械翻訳などの言語処理技術が多言語に対処できることが望まれる．これらの言語処理技術はすべて単語を基本単位として行われているため単語の間にスペースを入れる習慣のない言語ではまず文を単語に分割する必要がある．そこで，我々はこのような言語を対象として多言語に対処できる単語分割手法を提案し，その有効性を既に確認した[1][2]．本手法では帰納的学習を用いて文字列の共通部分，差異部分を再帰的に抽出し，単語として最も確からしいものを単語とし，文を単語に分割する．ここで帰納的学習とは共通部分と差異部分を再帰的に抽出することにより単語を獲得し，それらの単語を用いて文を単語に分割することである．本稿では本手法の学習機能について評価実験を行った結果について報告する．

2 処理過程

まず，辞書に存在する既に獲得された語を用いて文を単語に分割する．分割候補が複数個ある場合尤度評価関数の値の高いものを優先して用いる．次に，分割されなかった文字列に対して帰納的学習を用いて未知語を推測し，推測された語を用いて分割する．ユーザが分割結果の正誤を判定し，分割の誤り，未分割などの校正処理を行う．システムが校正した結果と分割結果とを比較することによりフィードバック処理を行い，登録された単語の頻度，正分割度数などを更新する[2]．

3 評価実験

学習機能を評価するために2つの実験を行った．実験1は本手法のアルゴリズムで帰納的学習を用いて共通部分，差異部分を抽出することにより未知語を推測し，分割を行った実験である．実験2は共通部分，差異部分を抽出せず，文を入力して，分割結果の誤りを校正して分割を行った実験である．

実験には中国語のSinicaコーパスからの建築学分野のデータと経済学分野のデータ，総単語数180,000単語を用いた．改善率の式(1)を用いて評価を行った．正分割率1と正分割率2はそれぞれ実験1，実験2の正分割率である．

実験1の実験2に対する正分割率の改善率の推移を図1に示す．正分割率の改善率の推移から，本手法の学習の効果が確認された．実験の初期には辞書が空のためシステムが未知語を推測することにより分割を行うため改善率が大きかった．帰納的学習を用いることにより単語を獲得し，処理した単語数の増加に従って改善率が低下していることが分かる．また，分野が変化するとき，共通部分と差異部分の抽出がある場合とない場合の相違が表れている．分野が変化するとき，実験1の実験2に対する正分割率の改善率が大きく変化する．これは対象分野が変化するため新語などが出現し，学習機能によりこれらが獲得されていることが示されている．実験の初期の20,000単語を処理したときの正分割率の平均改善率は20.4%である．図1における実験の最初と分野が変化するときの正分割率の改善率の大幅な増加からも本手法の学習機能の有効性が示されている．

$$\text{改善率 [\%]} = \frac{\text{正分割率 1} - \text{正分割率 2}}{100 - \text{正分割率 2}} \times 100 \qquad (1)$$

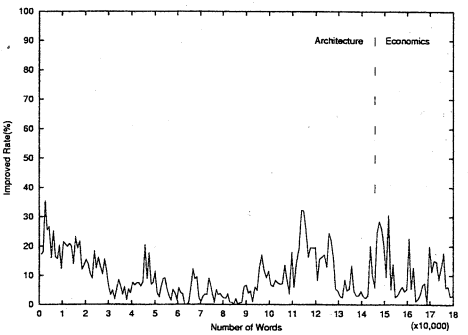


Fig. 1 改善率の推移

4 まとめ

本稿では本手法の学習機能を評価する実験を行った．学習ありと学習なし2通りの実験結果の比較により本手法の学習機能が有効であることが示された．今後，本手法の未知語推測能力について他手法との比較実験を行う予定である．

参考文献

[1] 荒木健治, 栃内香次, “帰納的学習による語の獲得および確実性を用いた語の認識,” 電子情報通信学会論文誌, D-II Vol.J75-D-II, No.7, pp.1213-1221,July 1992.

[2] 王 忠建, 荒木 健治, 栃内 香次, “帰納的学習を用いた単語分割手法の多言語に対しての汎用性の評価”, 電子情報通信学会技術研究報告, TL2000-44, pp33-40(2001).