1—P—15

明瞭度を制御した規則合成の提案と基礎的検討*

◎藤原　敬記　広重 真人　荒木 健治　栃内 香次（北大・工）

1. はじめに

現在多くの音声合成の研究がなされており[1][2]、合成音声の明瞭性・自然性の向上を目指している。中・小規模の市販規則合成システムなどでは実用上の要求もあり、合成音声のすべての部分について明瞭性を高くするためにすべての音素がはっきりし、文末などでなめらかさを感じられないことが多くある。

しかし日常の自由会話においては、すべての文節を明瞭に発話しているのではなく、重要性の低い文節や文末の文節などは、はっきりと発話されない傾向がある。人間は発話内容の重要性などに応じて、F0・パワー・発話速度・調音位置(スペクトル形状)などを用いて、明瞭性を柔軟に制御していると考えられる。この明瞭性は連続的に変化し、人間の発話の流暢なリズムを形成する１つの要因と考えられる。明瞭性の連続的な変化の音声合成での実現をめざして本研究では、従来あまり扱われなかった「不明瞭」な部分の音韻的・韻律的な特徴にも注目し、合成システムへの導入を検討する。本稿では、音声の明瞭度を韻律要素のひとつに位置付け、F0や発話速度などと同様に、明瞭度も発話内容に従って変化することを規則合成に導入する構想を述べる。さらに、明瞭度に関係するパラメーターとして母音スペクトルの中立化の強さと音源パワーを F0 変化に従って制御して既存合成音声を後処理加工する試みについて述べる。

2. 基本的な考え方

本研究における基本的考え方を簡単に述べる(図 1)。従来より音声は分節的な音韻要素と超分節的な韻律要素におおまかに分類されるが、音韻の調音結合などは分節にまたがって発生し、音韻要素のなかの韻律的な要素と考えることができる。韻律要素には従来よりF0、パワー、発話速度などが挙げられているが、これらに上記の韻律的な音韻要素を加え、音韻要素にも韻律的な制御を加えることにより、発話全体としての了解度を損なわずに滑らかな発話が実現できる可能性があると考える。すなわち、韻律的に緊張の高い状態として、大きな声、高い声、発話速度の大きな変化および「音韻のはっきりとした」発話を考え、緊張の低い状態として、小さな声、低い声、変化の少ない発話速度および「中立的な構音状態からから余り変化しない」発話を考える。この緊張の高低遷移が人間の音声の自然なリズム構成の一つの要因であると考える。人間は文意了解への寄与の少ない部分については緊張の度合いを下げることもあり、この緊張の低い部分は従来の一般的な明瞭性の観点からは不明瞭な音声に属すると考えられる。本研究は合成音声にこの不明瞭さを積極的に取り入れる試みである。

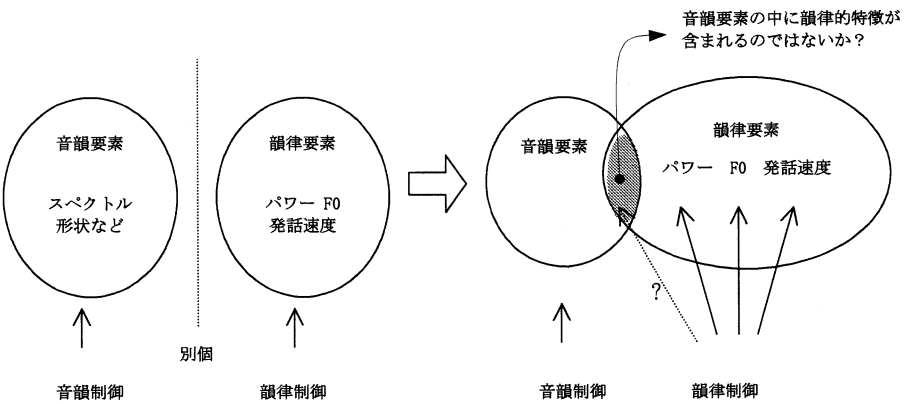


図 1. 本研究における基本的な考え方

* "A proposal and a fundamental study of clarity contorol in rule synthesis", By Noriki Fujiwara, Makoto Hiroshige, Kenji Araki and Kojji Tochinai (Hokkaido Univ.)

3. 予備実験

上記考え方の合成音声への導入に先立って、実際の人間による口をあまりはっきりとは動かさない不明瞭な発話の特徴を確認した。日本語を母国語とする成人男性 1 名に、数種類の句・短文を、数段階の「あいまいさ」で発話させ、無響室で DAT に 48kHz で収録したものを 12kHz にダウンサンプリングした。従来より人の発話する「あいまい」な音声には、パワーの減少、母音の中立化、無声・有声の切り替えの省略、発話速度の増大、F0 の平坦化などがあると言われているが、本予備実験においてもこの傾向が強く存在することが確認された。

4. 合成音声加工実験

明瞭性を制御する第 1 歩として、予備実験で確認された傾向を参考にし、F0 の変化に同期してパワーと母音の中立化の強さを制御した。

「Visual Speech Creator」(NTT-IT(株)製)[3]で作成した数種類の音声を、ESPS/waves+ の簡単なフォルマント分析・合成器を用いて再合成した。再合成の際、フォルマントと音源 rms パワーを、以下のように加工する。

音源パワーは、オリジナルの音源パワーに加工乗数 r_{pow} を乗じて求める。この加工乗数 r_{pow} は F0 の上下動に比例して変化するように定められ、音声サンプル中の F0 の最大値で 1.0 、最小値で x ($x = 0.8, 0.7, 0.5$ の 3 種類)をとるようにする。

フォルマントは、F0 の低下に伴って、中立的な母音のフォルマントに引き寄せられるように加工する。まず、中立的な母音として、損失のある一様音響管の周波数応答[4]を参考にしながら、予備実験で得られた実音声の中立的母音の特性を設定した(F1=481, F2=1342, F3=2203, F4=3316[Hz])。各時点で観測された各フォルマントを f_i、加工後の各フォルマントを f_i'、中立母音の各フォルマントを $f_{i\text{-}lazy}$ (共に $i = 1,2,3,4$)として、式(1)によりフォルマント加工を行う。r_{for} は r_{pow} と同様に F0 の上下動に比例して変化する加工乗数で、F0 の最大値で 1.0 、最小値で $x(x = 0.7, 0.5, 0.3)$ をとる。

$$f' = f_{i\text{-}lazy} + (f_i - f_{i\text{-}lazy}) \times r_{for} \quad (i=1,2,3,4) \quad (1)$$

これらの制御・加工をパワーのみ、フォルマントのみ、パワーとフォルマントの 3 種類について行った。フォルマントを制御していない音声と制御した音声のスペクトルの一部を図 2 に示す。

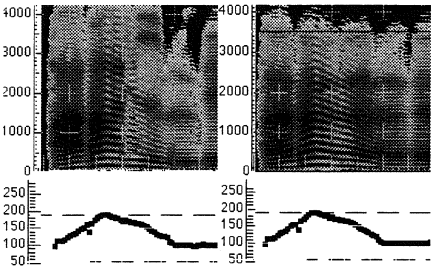


図 2. フォルマントの制御を行っていない音声(左)と制御を行った音声(右)のスペクトルと F0

5. 結果

結果を非公式聴取により予備評価した。本稿の実験では簡単なフォルマント合成器を用いたため、全般に音質は不充分であったがパワーを制御した音声には文節末等に若干の自然性の増加が認められた。また、フォルマントを制御した場合には、F0 の低下に従って各音韻の際立ちが減少し、若干ながらなめらかさが増大した。フォルマント、パワーの両方を制御した場合にはその両方の効果が認められた。$r_{for} = 0.7$, $r_{for} = 0.5$ の組み合わせが最も良好であった。

6. おわりに

流暢なリズムをもつ人間の発話では、明瞭性も制御されているという考えを述べ、明瞭度を韻律要素として考慮することを提案した。予備実験により、数種類の句・短文について「あいまい」発話の韻律的特徴を調査し、従来知見の存在を具体的に確認した。実際に F0 に同期したパワーとフォルマントの制御により既存合成音声を加工し、わずかながら自然性の増加が認められた。

今後は、F0 の平坦化などを考慮し F0、パワー、スペクトル形状および発話速度を韻律情報をもとに変化させることを予定している。

謝辞

音声合成の際、日本音響学会第 68 回技術講演会で使用された NTT-IT(株)製「Visual Speech Creator」を使わせていただきました。深く感謝致します。

参考文献

[1] 西沢信行, 峯松信明, 広瀬啓吉, "波形編集を併用したフォルマント音声合成-VCV 音声に関する検討-", 信学技法, SP2001-20, pp. 35-42

[2] 広瀬啓吉, "音声技術", 情報処理学会誌, 38 巻, 11 号, 1997

[3] NTT-IT(株), "Visual Speech Creator 操作説明書"

[4] L. R. Rabiner/R. W. Schafer(鈴木久喜訳), 「音声のディジタル信号処理(上)」, コロナ社(1983)