情報抽出におけるフレームの帰納的学習

The Inductive Learning of a Frame on Information Extraction

塚原卓人　荒木健治　栃内香次
Takuto Tsukahara　Kenji Araki　Koji Tochinai
北海道大学大学院工学研究科
Graduate School of Engineering, Hokkaido University

1．はじめに

計算機の普及，インターネットの発展に伴い，計算機上で文書を扱う機会が増えている．そこで，大量の文書を読む際の膨大な時間と労力を軽減するために，文書から必要な情報を抜き出す情報抽出[1]の研究が行われている．従来の情報抽出は，ユーザが必要としている情報及び抽出方法をあらかじめ与えているので，ユーザの必要とする情報が扱う文書によって変化する場合には有効ではない．本稿では，帰納的学習[2]を用いることで与えられた文書からユーザの要求する情報を予測して抽出する手法を提案する．提案手法は，過去にユーザが必要とした情報よりフレームについて学習を行う汎用的な情報抽出手法の実現を目指したものである．本稿では，本提案手法の性能評価実験を行い，その有効性について述べる．

2．処理過程

本手法の処理過程を Fig.1 に示す．本手法では，過去にユーザが正解として与えた抽出結果から，重要文決定ルールとフレーム決定ルールという二つのルールを獲得する[3]．重要文決定ルールとは，抽出すべき情報を含んでいる文を選び出すためのルールであり，フレーム決定ルールはその選ばれた文から情報抽出を行うためのルールである．まず，入力文書に対して形態素解析ツール茶筌[4]を用いて形態素解析を行う．次に重要文決定ルールを用いて抽出すべき情報を含む文を選び出す．続いて，フレーム決定ルールを用いて選ばれた文から情報抽出を行う．その際，当てはまるフレームがない場合は文のまま抽出を行う．

重要文決定ルールは，文中のキーワードや位置情報などの特長から，文の状態を数字列で表したものをルール辞書に蓄える．

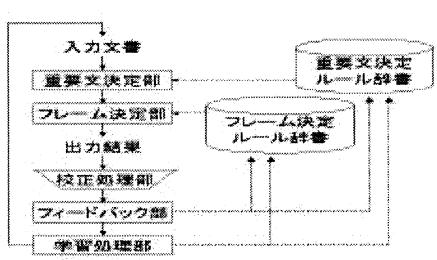


Fig.1　処理過程

フレーム決定ルールは，校正処理で与えられた抽出結果とその情報を含む原文をセットとし，品詞の付いた状態でルール辞書に蓄えられる．ルールの優先度は単語，品詞，品詞の詳細な分類の一致度を計算して決定する．

3．性能評価実験

3．1　実験方法

本手法の性能を評価する実験を行った．実験では朝日新聞ホームページ[5]よりスポーツニュース１００文書（総文数８１８文）を用いた．評価は再現率と適合率を用いて行う．

3．2　実験結果及び考察

１００文書について実験を行ったうち，学習が安定したと見られる最後の３０文書について再現率と適合率を求めた結果，再現率は８２．６［%］，適合率は７６．０［%］となった．この結果より，必要な情報を含む重要文の抽出において本提案手法は有効であると考えられる．しかし，重要文の抽出は正しく行われたが，当てはまるフレームが無いために文のまま抽出されたものも多かった．フレーム決定ルールの適用条件及び一般化についての再検討も必要である．

4．まとめ

本稿では，帰納的学習を用いた情報抽出手法を提案し，その性能評価実験を行った．実験の結果，必要な情報を含む重要文の抽出について有効性を示すことができた．今後は，フレーム決定ルールの適用条件の緩和及び一般化の改善を進める予定である．

参考文献

[1]長尾真，黒橋禎夫，佐藤理史，池原悟，中野洋，“言語情報処理”岩波書店，1999
[2]荒木健治，“帰納的学習を用いた自然言語処理の有効性について，信学技法，ＴＬ 99-41，pp.33-40，2000.
[3]塚原卓人，荒木健治，栃内香次，“帰納的学習を用いた汎用的な情報抽出手法”，平成１３年度電気関係学会北海道支部連合大会講演論文集，126，pp.151-152，2001.
[4]松本裕治，北内啓，山下達雄，平野善隆，“日本語形態素解析システム『茶筌』version2.0 使用説明書”，NAIST Technical Report，NAIST-IS-TR99008，April1999.
[5]アサヒ・コム　http://www.asahi.com