学習型機械翻訳手法 GA-ILMT における翻訳遷移ネットワークに基づく翻訳ルールの自動階層化の有効性について

越前谷　博[†]・荒木健治[††]・桃内佳雄[†]・栃内香次[††]

Effectiveness of Automatically Layering Translation Rules based on Translation Transition Networks in GA-ILMT

Hiroshi ECHIZEN-YA[†], Kenji ARAKI[††], Yoshio MOMOUCHI[†] and Koji TOCHINAI[††]

我々は，学習能力に基づく機械翻訳手法として，遺伝的アルゴリズムを適用した帰納的学習による機械翻訳手法（GA-ILMT）を提案している。GA-ILMT では，翻訳例のみを知識源として，そこから翻訳に必要な翻訳ルールを自動的に獲得する。そして，獲得された翻訳ルールのみを用いて翻訳を行う。したがって，より良い翻訳を行うためには，GA-ILMT に基づくシステム自身に高い学習能力が備わっていなければならない。そこで，我々はこれまでの GA-ILMT に不足していた，文全体の構造を捉えた翻訳を行う能力を GA-ILMT に与える。解析的な知識を明示的に与えることなく，学習という観点から文全体の構造を捉えた翻訳を行う場合，汎用的な翻訳ルールから具象的な翻訳ルールへと翻訳ルールを階層化することが有効と考えられる。そこで，翻訳ルールを階層化するために，システムは汎用的な翻訳ルールから具象的な翻訳ルールへと翻訳ルールが推移していく過程，すなわち，翻訳過程を遷移ネットワークで表現する。本論文では，システム自らが翻訳ルールを階層化するために翻訳遷移ネットワーク（TTN）を生成し，文全体の構造を捉えた翻訳を行う手法を提案する。

We previously proposed a method of machine translation using inductive learning with genetic algorithms(GA-ILMT) based on learning capability. Without any analytical

† 北海学園大学工学部電子情報工学科
† Dept. of Electronics and Information, Hokkai-Gakuen University
†† 北海道大学大学院工学研究科
†† Division of Electronics and Information, Hokkaido University

knowledge, GA-ILMT acquires translation rules from only given translation examples and uses these rules to translate. In the present paper, we propose a method that performs translation by recognizing the structure of whole sentences without any language-dependent knowledge. In this new method, GA-ILMT layers multiple translation rules to formulate a translation rule that represents the basic structure of the whole sentence by automatically generating a translation transition network(TTN) constructed from multiple translation rules.

1. はじめに

近年，インターネットが急速に日常生活へ浸透している。それに伴い，多くの機械翻訳ソフトが製品化されている。しかし，ユーザの要求を十分に満たす機械翻訳システムの実現には至っていない。現在の商用化されている機械翻訳システムに最も多く取り入れられている手法は，文法規則を詳細に記述することで翻訳を行う，解析型機械翻訳手法［1，2］である。この手法では，多様な言語現象をすべてカバーできるような文法規則を，予め人手で記述することの困難さが問題となる。また，翻訳対象の分野が変化した場合，文法規則が複雑化し，メンテナンスが困難になる。そうした問題点を回避するために，用例や実例を利用することにより翻訳を行う，コーパスベースの機械翻訳手法が研究されている。この手法では，複雑な文法規則を使用せずに翻訳例を追加していくことにより，翻訳精度の向上を図っている。コーパスベースの機械翻訳手法の代表的なものとしては，類似した翻訳例を模倣利用することで翻訳を行う，実例に基づく機械翻訳手法［3，4］と大規模な対訳コーパスに対する統計的な分析により翻訳を行う，統計に基づく機械翻訳手法［5］が挙げられる。しかし，これらの手法では，複雑な文に対処するために解析的な知識を付与したコーパスを準備しなければならない。また，実用化に向けては，大量のコーパスが必要になるといった問題点を抱えている。更に，文脈自由文法（Context Free Grammar）を軸にし，用例を補助的なものとして用いる，パターンベースの機械翻訳手法［6］も提案されている。しかし，この手法は，解析型機械翻訳手法と同様，十分な文法規則を記述することの困難さが残る。そこで，コーパスから翻訳規則を自動獲得する手法［7］が提案されている。しかし，その場合も解析的な知識が付与されたコーパスの使用を前提としているため，解析型機械翻訳手法の問題を根本的に解決するものとはなっていない。したがって，これまでの機械翻訳手法の問題点は大きく二つに分類できる。一つは，文法規則に依存する機械翻訳手法［1，2，6，7］が抱える，多様な言語現象に対処可能な文法規則を人手で与えることの困難さである。もう一つは，文法規則を使用しない機械翻訳手法［3，4，5］が抱える，汎用的な文法規則を持たないことによる膨大な量のコーパスの必要性である。

我々は人間の持つ言語獲得能力を工学的に実現することにより，このような問題を解決できると考えている。すなわち，翻訳に必要な規則は与えられた翻訳例のみから，システム自らが学習能力により獲得していくため，規則を人手で与える必要がない。また，学習により汎用的な規則を獲得するため，膨大な量のコーパスを必要としない。しかし，このような機械翻訳システムを実現するためには，システム自身に十分な学習能力が備わっていなければならない。そこで，我々は高い学習能力を有する機械翻訳システムの実現という観点から，従来より遺伝的アルゴリズムを適用した帰納的学習による機械翻訳手法[8]を提案している。以後，本手法を本論文ではGA-ILMT（Machine Translation Using Inductive Learning with Genetic Algorithms）と呼ぶ。更に，本論文では，このGA-ILMTの学習能力の向上をもたらすものとして，解析的な知識を明示的に与えることなく，文全体の構造を捉えた翻訳を行う手法を提案する。

GA-ILMTでは与えられた翻訳例のみから，帰納的学習により翻訳ルールを自動獲得し，それらを用いて翻訳を行う。また，遺伝的アルゴリズム[9]の適用により，システムは与えられた翻訳例を基に，試行錯誤を繰り返しながら新たな翻訳例を自動生成する能力を模倣できる[8]。このようにGA-ILMTが有するのは学習能力のみであり，翻訳に用いるすべての規則は自動獲得される。したがって，GA-ILMTに基づくシステムを用いて翻訳を行う場合，予め辞書を準備する必要がない。また，翻訳例を与える場合にも，解析的な知識を付与する必要がない。このような条件のもとで高い翻訳精度を実現できた時，それは人間の持つ言語獲得能力の工学的な実現へ大きく前進したことを意味する。

本論文において，我々は，このような観点から更なるGA-ILMTの学習能力の向上を行う。すなわち，それはシステム自らが文全体の構造を捉えた翻訳を行う能力を持つということである。従来のGA-ILMTでは，獲得した翻訳ルールを最大限に活用した翻訳という点において十分ではなかった。それは，文全体の構造を捉えた翻訳を行う能力が不足していたためである。そこで，我々は翻訳ルールを自動階層化することにより，文全体の構造を捉えた翻訳を行う手法を提案する。翻訳ルールの階層化は，汎用的な翻訳ルールと具象的な翻訳ルールがリンクしている翻訳遷移ネットワークという表現形式を用いて行う[10, 11]。翻訳遷移ネットワークは，文全体の構造を表す汎用的な翻訳ルールから原文に近い具象的な翻訳ルールへと翻訳ルールが階層化されていく過程を状態の推移として捉えたものである。この翻訳遷移ネットワークは，システム自らが生成する。したがって，言語固有の知識を用いることなく，学習能力の向上により，翻訳ルールを自動階層化することができる。そして，その結果，翻訳ルールをより一層有効利用した翻訳が可能となる。

また，提案手法の有効性を確認するために行った性能評価実験では，中学1年生レベルの原文を実験データ[16, 17]として用いた。これは，今回の実験の目的を実用性の評価を行うも

のではなく，提案手法が学習能力の向上という観点から有効であるかどうかを確認するための第一段階として位置付けているためである。本提案手法は，文全体の構造を捉えた翻訳を行う能力の実現であり，実用的なデータに対しても有効な手法であると考えられる。しかし，複雑な構造を持った実用的な文の翻訳に対しては，提案手法の導入のみでは十分に対処することは困難である。したがって，それを補うには多くの解析的な知識を明示的に与えなければならない。我々は，実用文の翻訳に必要な知識に対しては，システムの持つ学習能力に基づき，自動的に獲得していくものと考えている。したがって，この問題は，今後，学習という観点から解決していく予定である。

2．GA-ILMT について

2.1　GA-ILMT の基本構成

図1に GA-ILMT の基本構成を示す。翻訳部（Translation Process）では，原文が入力されると，それまでに獲得された翻訳ルールを用いて訳文を生成する。その訳文に誤りが含まれている場合には，人手により校正を行う。フィードバック部（Feedback Process）では，生成された翻訳結果と正しい訳文を比較することにより，翻訳部で使用された翻訳ルールを評価し，淘汰処理を行う。そして，学習部（Learning Process）では，遺伝的アルゴリズムの基本操作である交叉や突然変異を適用し，新たな翻訳例を自動生成する。更に，すべての翻訳例を対象に帰納的学習を行い，翻訳ルールを自動獲得する。獲得された翻訳ルールは逐次，翻訳ルール辞書に登録される。本論文では，この GA-ILMT の基本構成に基づき英日機械翻訳システムを

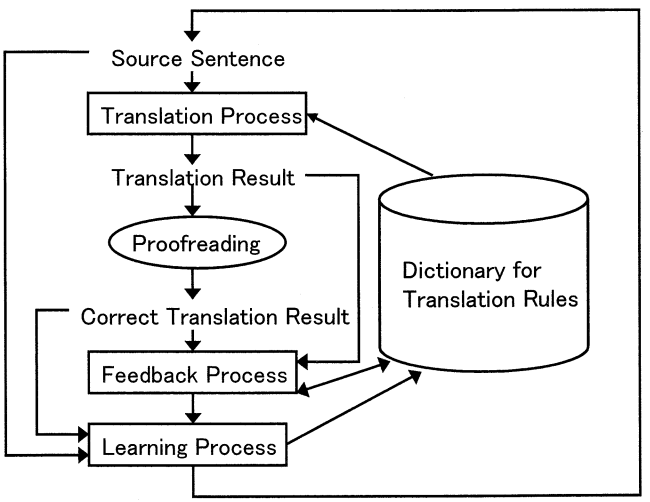


図1　GA-ILMT の基本構成

構築し，性能評価実験を行った。

2.2 学習部

学習部では，始めに，翻訳例に対して遺伝的アルゴリズムの基本操作である交叉と突然変異を適用し，新たな翻訳例を自動生成する［8］。そして，すべての翻訳例に対して，帰納的学習を用いて翻訳ルールを獲得する。GA-ILMTにおける帰納的学習とは，翻訳例に内在する一般的な規則を抽出することである。この帰納的学習による翻訳ルールの獲得は，翻訳例間の字面レベルで共通部分と差異部分を多段階に抽出することにより行う。図2に翻訳ルールの獲得の例を示す。図2の翻訳ルール中の"@0"のような"@"に数値を加えた部分は，他の翻訳ルールを代入することができる変数を意味している。また，本論文では，(He likes @0.；彼 は @0 が 好き です。) のように英文とその訳文が文である翻訳ルールを文翻訳ルール（sentence translation rule）と呼ぶ。それに対し，(tennis；テニス）や（tea；お茶）のように文ではなく，一つ以上の英単語と日本語単語から構成されている翻訳ルールを部分翻訳ルール（part translation rule）と呼ぶ。

更に，共通部分と差異部分の抽出を再帰的に行うことにより，一般化が段階的に進行する。図3に帰納的学習により一般化された文翻訳ルールの例を示す。このように，翻訳ルールを獲得するために翻訳例間の字面レベルで共通部分と差異部分を抽出するのは，それが計算機上で実現可能である，人間の持つ生得的な能力［12］の一つであり，学習能力の核としての役割を担っていると考えられるからである。このような方法で獲得される翻訳ルールは，言語的な情

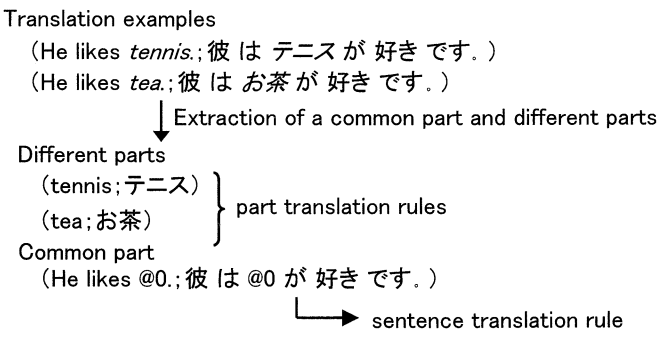


図2　翻訳ルールの獲得

(He likes @0.;彼 は @0 が 好き です。)
(She likes @0.;彼女 は @0 が 好き です。)
(@0 likes tennis.;@0 は テニス が 好き です。)
(@0 likes tea.;@0 は お茶 が 好き です。)
(@0 likes @1.;@0 は @1 が 好き です。)

図3　帰納的学習により獲得された文翻訳ルールの例

報が非常に乏しく，変数に対する制約条件などの知識を持っていない。しかし，我々は，そのような高度な表現形式を有する翻訳ルールは，予め人手により与えられるのではなく，学習によって獲得されていくべきものと考える。

2.3　翻訳部

翻訳部では，学習部で獲得された翻訳ルールを用いて翻訳結果を生成する。初めに，翻訳ルール辞書から，英文において変数を除く単語列が，原文と完全に一致する翻訳ルールを選択する。そのような翻訳ルールを原文に対して，適用可能な翻訳ルールと呼ぶ。更に，適用可能な翻訳ルール間において交叉と突然変異を行い，新たな適用可能な翻訳ルールの獲得を試みる。次いで，すべての適用可能な文翻訳ルールから，最も英文が原文と類似している文翻訳ルールを選択する。その結果，複数の文翻訳ルールが選択された場合には，その中で適応度の最も高い文翻訳ルールを選択する。更に，適応度が同じ場合には，登録順位が最上位の文翻訳ルールを選択する。部分翻訳ルールについても，同様の手順で優先順位を決定する。そして，選択された文翻訳ルールの変数に部分翻訳ルールを代入することにより翻訳結果を生成する。

2.4　フィードバック部

フィードバック部では，翻訳部で生成された翻訳結果と与えられた正しい翻訳結果を字面レベルで比較する。その結果，一致する場合，翻訳に使用された翻訳ルールの正翻訳度数を1増加させる。一致しない場合には，誤翻訳度数を1増加させる。そして，それらの値を用いて，以下の式(1)より適応度を求める。

$$\text{適応度}\ [\%]=\frac{\text{正翻訳度数}}{\text{全使用回数}}\times 100.0 \qquad (1)$$

この適応度が25.0%以下で，全使用回数が5以上の翻訳ルールは翻訳ルール辞書から消去する［8］。

3．基本的な考え方

文全体の構造を捉えることによって翻訳を行う方法は，人間が行う様々な翻訳方法の重要な一つである。そこでは，文の基本構造を表す汎用的な翻訳ルールが存在する。そして，その翻訳ルールを基点として，部分を表す翻訳ルールを組み合わせていくことで具象化が進み，最終的に訳文が得られる。このような翻訳過程は，汎用的な翻訳ルールから具象的な翻訳ルールへと翻訳ルールが階層化されていく状態の推移として捉えることができる。この時，状態間を結ぶリンクは部分を表す翻訳ルールとなる。ただし，この場合の遷移図は，翻訳過程を表現する

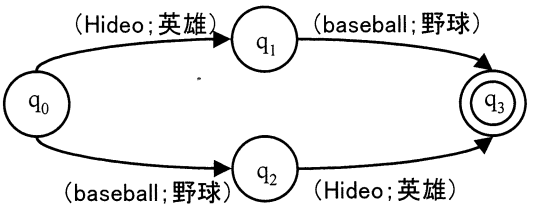


図4　TTNの例

ためにのみ用いられ，形式言語理論における入力列を順次調べていく受理機［13, 14］とは役割が異なる。そこで，本論文では翻訳過程を表現するための状態遷移図を翻訳遷移ネットワーク（Translation Transition Network）と呼ぶことにする。以後，本論文では，これをTTNと記す。図4に原文とその訳文の組（Hideo likes baseball.；英雄 は 野球 が 好きです。）におけるTTNの例を示す。

図4中のTTNの状態は以下の文翻訳ルールにそれぞれ対応している。

q_0：(@0 likes @1.；@0 は @1 が 好き です。)

q_1：(Hideo likes @0.；英雄 は @0 が 好き です。)

q_2：(@0 likes baseball.；@0 は 野球 が 好き です。)

q_3：(Hideo likes baseball.；英雄 は 野球 が 好き です。)

また，入力としては，(Hideo；英雄)，(baseball；野球)が用いられている。このようなTTNは，それまでに獲得された汎用的な翻訳ルールと具象的な翻訳ルールを用いて自動生成される。汎用的な翻訳ルールとは変数を含む翻訳ルールであり，変数の占める割合が高くなるほど，より汎用性は高くなる。それに対し，具象的な翻訳ルールとは変数を含まない翻訳ルールである。TTNを用いることで，どの翻訳ルールが文全体の構造を捉えているのかを認識できる。更に，部分翻訳ルールがどのようにリンクして，翻訳結果が導き出されるのかを捉えることができる。図4においては，状態q_0の翻訳ルール（@0 likes @1.；@0 は @1 が 好き です。）が原文とその訳文に対する基本構造となっている。また，状態q_0の翻訳ルールを基点として，(Hideo；英雄)，(baseball；野球)といった部分翻訳ルールとの組み合わせにより具象化が進み，訳文が導き出されることを認識できる。

このように適用する規則を制御するために状態遷移ネットワークを利用する試みは，トランスファー方式に基づくMuプロジェクト［15］においても既に行われている。しかし，そこでの制御は，言語固有の知識に基づき人手で生成された規則を用いて行われる。それに対して本提案手法では，システム自らがTTNを自動生成し，翻訳ルールを階層化することにより行う。したがって，我々はシステムに対し，言語固有の知識を直接与えることなく，学習能力を向上させるためのメカニズムを与えることで，文全体の基本構造を捉えた翻訳を実現する。

4．翻訳遷移ネットワークの生成とその利用

4.1　翻訳遷移ネットワークの自動生成

学習部では，正翻訳のTTNを自動生成する。以下にその処理過程を示す。

(1) 文翻訳ルールの集合を状態の集合とする。

(2) 最も汎用的な文翻訳ルールの集合を初期状態の集合とする。

(3) 最も具象的な文翻訳ルールの集合を最終状態の集合とする。

(4) 部分翻訳ルールの集合を入力の集合とする。

(5) 初期状態を現在の状態に設定する。

(6) 現在の状態の文翻訳ルールの変数に，入力として部分翻訳ルールを代入する。その代入された文翻訳ルールが状態の集合中に存在する他の文翻訳ルールと一致した場合，その文翻訳ルールを次の状態として設定する。一致しない場合には，他の入力を用いて次の状態となる文翻訳ルールを検索する。

(7) 次の状態の文翻訳ルールが最終状態の文翻訳ルールと一致するまで，(6)を繰り返す。

(8) 更に，(5)から(7)を繰り返し，すべての推移を導き出す。

例えば，原文とその訳文の組（That is Akiko.；あれ は 昭子 です。）において，以下のq_0からq_5の六つの文翻訳ルールが正翻訳に使用された場合，これらが状態となる。

q_0：(@0 is @1.；@0 は @1 です。)

q_1：(@0 is @1.；@0 は @1.)

q_2：(That is @0.；あれ は @0 です。)

q_3：(That is @0.；あれ は @0。)

q_4：(@0 is Akiko.；@0 は 昭子 です。)

q_5：(That is Akiko.；あれ は 昭子 です。)

システムは初期状態としてq_0とq_1の文翻訳ルールを選択する。また，最終状態としてq_5の文翻訳ルールを選択する。入力としては（that；あれ），（Akiko；昭子），そして（Akiko；昭子です）が選択されたとする。その結果，システムは図5に示すTTNを生成する。

4.2　ノイズの抽出

正翻訳のTTNは，正翻訳ルールのみから構成されるべきである。そうした点から図5のTTNは点線で示した誤翻訳ルールを含んでいるため不十分である。そこで，TTN中において正翻訳ルールとこのようなノイズである誤翻訳ルールを明確に分離する。GA-ILMTにおける正翻訳ルールとは，英日の対応関係の正しい翻訳ルールである。また，誤翻訳ルールとは，英日の対応関係の誤っている翻訳ルールである。

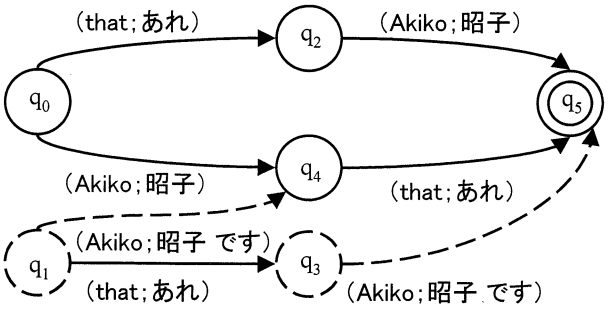


図5　(That is Akiko.；あれ は 昭子 です。) に対する TTN

4.2.1　具象的な翻訳ルールの正誤の判定

正翻訳の TTN 中に存在する具象的な翻訳ルールの正誤の判定には，**2.4** で述べた式(1)の適応度を直接用いる。具体的には，適応度が 80.0%以上の場合，正翻訳度数とは別に正確実度数 CF を 1 増加する。それに対し，適応度が 25.0%以下の場合，誤翻訳度数とは別に誤確実度数 EF を 1 増加する。したがって，図 5 の変数を含まない具象的な正翻訳ルール (that；あれ) と (Akiko；昭子)，そして，最終状態 q_5の正翻訳ルールは適応度が 80.0%以上になると，CF が増加する。それに対し，誤翻訳ルール (Akiko；昭子 です) は適応度が 25.0%以下になると，EF が増加する。

4.2.2　汎用的な翻訳ルールの正誤の判定

正翻訳の TTN 中に存在する汎用的な翻訳ルールに対しては，適応度を直接使用しても正誤の判定を十分に行うことができない。例えば，q_1の翻訳ルール (@0 is @1.；@0 は @1.) は，肯定文，否定文のどちらに使用された場合でも，入力にそれぞれ (Akiko；昭子 です)，(not Akiko；昭子 では あり ません) を代入することで正翻訳を導く。その結果，図 5 の q_1の翻訳ルールは，誤翻訳ルールにもかかわらず適応度は高くなってしまう。

そこで，汎用的な翻訳ルールに対する正誤の判定には，翻訳ルール間の一つ一つの組み合わせに着目したヒューリスティックスを適用する。ヒューリスティックスを導く際には，正翻訳の TTN は正翻訳ルールのみで構成されるべきであるという考え方から，正翻訳ルール同士の組み合わせからは常に正翻訳ルールが得られることを前提とした。そこで，実際に正翻訳ルール同士の組み合わせから正翻訳ルールが，どれだけの精度で得られるのかを調査した。始めに，実験データ [16] の最初の 100 文に対し，GA-ILMT に基づくシステムを用いて翻訳を行った。辞書は空の状態より始めた。そして，システムが行ったすべての翻訳ルールの組み合わせを対象に，正翻訳ルール同士の組み合わせから，正翻訳ルールがどれだけの割合で得られたのかを求めた。その結果，正翻訳ルールが得られる割合は 93.9%であった。したがって，正翻訳ルール同士の組み合わせから正翻訳ルールが得られるという前提の信頼性は非常に高いことを確認

できた。なお，正翻訳ルール同士の組み合わせから誤翻訳ルールが得られるのは，(I am @0.；僕 は @0 です。) と (Kayo；加代) のように個々では正翻訳ルールであっても，組み合わせの結果，意味的に誤翻訳ルールになる場合のみであった。しかし，そのような場合，生成される翻訳結果は誤翻訳と位置付けられ，(I am Kayo.；僕 は 加代 です。) の TTN は生成されない。したがって，今回の調査より，正翻訳の TTN のみを対象とした翻訳ルールの組み合わせでは，正翻訳ルール同士の組み合わせからは正翻訳ルールのみが得られたことになる。また，今回の調査では，正翻訳ルールと誤翻訳ルールの組み合わせにおいては，誤翻訳ルールが原因となり組み合わせ結果が常に誤翻訳ルールとなっていた。その結果，今回の調査に基づき，正翻訳ルールと誤翻訳ルールの組み合わせにおいては，正翻訳ルールと誤翻訳ルールの存在比率は「正翻訳ルール：誤翻訳ルール＝１：２」になることを更なる前提とした。したがって，現在の状態，入力，次の状態をそれぞれ A，B，C とした場合，今回の調査より，最終的な正翻訳の TTN における翻訳ルールの組み合わせは表１のようになる。

次に，表１の(1)から(5)の組み合わせにおいて，A，B，C のいずれか一つが未決定であり，その未決定部分を決定する規則を求める。そして，それが汎用的な翻訳ルールに対するヒューリスティックスとなる。ただし，これらのヒューリスティックスは最終的な翻訳ルールの正誤を決定するものではなく，CF 及び EF をそれぞれ１増加させるかどうかを決定するために用いる。したがって，これらのヒューリスティックスを本論文では，確実度数更新規則と呼ぶことにする。表２に確実度数更新規則をまとめる。表中の "*" は未決定部分を意味する。例えば，「A：*（未決定部分)」，「B：正」，「C：正」という翻訳ルールの組み合わせが存在した場合，確実度数更新規則 No. 1 の適用により未決定部分「A」は「正」となる。そして，A の翻訳ルールの CF が１増加する。また，表２において，確実度数更新規則 No. 4 と No. 7，No. 8 と No.14，そして，No. 9 と No.12 は A，B，C の組み

表１　正翻訳の TTN における翻訳ルールの組み合わせ

	A	B	C		A	B	C
(1)	正	正	正	(4)	誤	正	誤
(2)	誤	誤	正	(5)	誤	誤	誤
(3)	正	誤	誤				

表２　確実度数更新規則

No.	A	B	C	*	更新	No.	A	B	C	*	更新
1	*	正	正	正	CF	10	*	誤	正	誤	EF
2	正	*	正	正	CF	11	誤	*	正	誤	EF
3	正	正	*	正	CF	12	誤	誤	*	正	CF
4	*	誤	誤	正	CF	13	*	正	誤	誤	EF
5	正	*	誤	誤	EF	14	誤	*	誤	正	CF
6	正	誤	*	誤	EF	15	誤	正	*	誤	EF
7	*	誤	誤	誤	EF						
8	誤	*	誤	誤	EF						
9	誤	誤	*	誤	EF						

合わせは同じであるが未決定部分の判定結果が異なる。したがって，これら六つの規則に該当した場合には，未決定部分を一意に決定せずに未決定のままとする。

この確実度数更新規則を正翻訳のTTNに用いて，汎用的な翻訳ルールのCF及びEFを更新する。例えば，図5において，現在の状態q_4から次の状態q_5の推移に着目すると，状態q_4は汎用的な翻訳ルールで未決定部分となる。それに対し，入力の翻訳ルール(that；あれ)は適応度が高くCFが1増加し，それと同時に「B：正」となる。状態q_5の翻訳ルールも同様に「C：正」となる。ここで，確実度数更新規則No.1の適用により，q_4の翻訳ルールは「正」となり，CFが1増加する。同様に，状態q_0から状態q_4の推移に着目した場合も，q_4の翻訳ルールが「正」と判断されたことで，確実度数更新規則No.1が適用される。その結果，q_0の翻訳ルールは「正」となり，CFが1増加する。それに対し，(Akiko；昭子　です)は適応度が低下するとEFが1増加し，同時に「誤」と位置付けられる。その結果，q_3とq_1の汎用的な翻訳ルールはそれぞれ確実度数更新規則No.10とNo.13より「誤」と評価され，EFが1増加する。このような翻訳ルール間の一つ一つの組み合わせに着目したヒューリスティックスの導入により，翻訳ルールの正誤の評価精度が向上し，TTN中のノイズを分離することが可能となる。

4.3　翻訳遷移ネットワークに基づく翻訳

翻訳部では，ノイズが分離されたTTNを利用し，より高度な翻訳処理を実現する。ノイズが分離されたTTNは，正翻訳ルールの集合と見なすことができる。一つ一つの翻訳ルールはTTNの要素であったため，より高い精度で評価される。したがって，TTN中の翻訳ルールを一つ一つに分離して利用しても，TTNを有効利用することになる。以下に翻訳部で行う，TTNを用いた翻訳の処理過程を示す。

(1) 入力された原文に対し，すべての適用可能な翻訳ルールを翻訳ルール辞書中から選択する。

(2) **4.1**で述べたTTNの自動生成と同様の処理を行いTTNを生成する。

(3) 生成されたTTNを構成するすべての翻訳ルールに対して，以下の尤度評価関数を適用し，確実度を計算する。

$$確実度=\alpha\times CF-\beta\times EF+\gamma \tag{2}$$

ここでα, βはともに係数である。γは，過去に正翻訳のTTNの構成要素であった翻訳ルールに付与される定数である。

(4) TTN中のすべての推移を対象に，その推移を構成する翻訳ルールの確実度の和を求める。

(5) 確実度の和の最も高い推移を選択し，その推移の最終状態の翻訳ルールを翻訳処理に用

いる。

例えば，原文「She is my sister.」を翻訳する場合，以下の文翻訳ルールが状態であったとする。

q_0 ：(@0 is @1.；@0 は @1 です。)

q_1 ：(She is @1.；彼女 は @0 です。)

q_2 ：(@0 is my @1.；@0 は 私の @1 です。)

q_3 ：(She is my @0.；彼女 は 私の @0 です。)

q_4 ：(@0 is my sister.；@0 は 私の 姉 です。)

q_5 ：(She is my sister.；彼女 は 私の 姉 です。)

q_6 ：(@0 is @1.；@0 は @1.)

q_7 ：(She is @1.；彼女 は @0.)

q_8 ：(@0 is my @1.；@0 は 私の @1.)

q_9 ：(She is my @0.；彼女 は 私の @0.)

q_{10} ：(@0 is my sister.；@0 は 私の 姉。)

q_{11} ：(She is my sister.；彼女 は 私の 姉。)

これらの文翻訳ルールから，初期状態として q_0 と q_6 の文翻訳ルールが選択される。また，最終状態として q_5 と q_{11} の文翻訳ルールが選択される。入力としては(she；彼女)，(sister；姉)，(my @0；私の @0)，(sister；姉 です)，そして (my @0；私の @0 です) が存在していたとする。その結果，図6に示す TTN が生成される。個々の状態の右下に付与されている数値は，式(2)より得られた確実度である。システムは図6の TTN において，初期状態 q_0 及び q_6 か

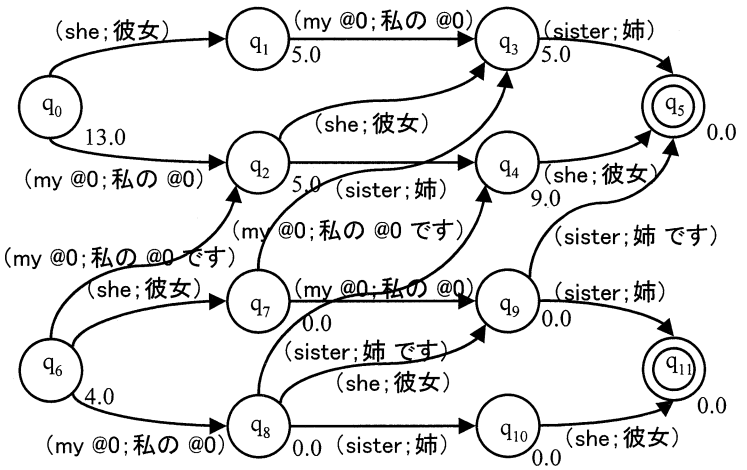


図6　翻訳部で生成された (She is my sister.；彼女 は 私の 姉 です。) に対する TTN

ら最終状態 q_5及び q_{11}までの全推移の中から確実度の和が最も高い推移を求める。その結果，q_0 → q_2→ q_4→ q_5の推移の確実度の和が 27.0 となり，最も高い値となる。したがって，この推移の最終状態である q_5の文翻訳ルールが使用され，正翻訳「彼女は私の姉です。」が導き出される。

4.4　確実度の高い部分翻訳ルールの利用

TTN 及び確実度数更新規則を用いることにより，具象的な翻訳ルールに対しても迅速な評価を行うことが可能となる。例えば，図 5 の部分翻訳ルール(that；あれ)は他の TTN 中でも使用されていたとする。その結果，確実度数更新規則の適用対象となった場合，この部分翻訳ルールの CF は図 5 の TTN だけではなく，他の TTN においても更新される。すなわち，適応度が翻訳に使用されなければ更新されないのに対して，確実度は TTN に存在し，かつ，確実度数更新規則が適用されると更新される。したがって，高い精度での評価とともに迅速な評価も可能となる。そこで，学習部では，確実度の高い部分翻訳ルールを用いて正翻訳ルールの獲得を行う。具体的には，確実度の高い部分翻訳ルールが，与えられた翻訳例中に含まれていた場合，共通部分を変数に置き換える。図 7 に確実度の高い部分翻訳ルールを用いた翻訳ルールの獲得例を示す。

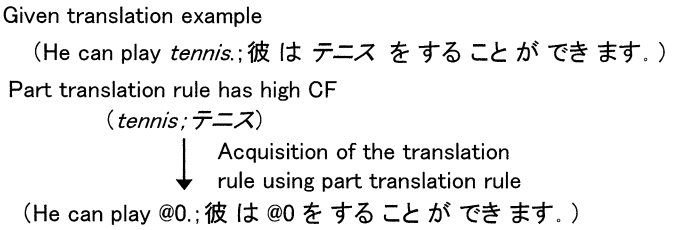


図 7　確実度の高い部分翻訳ルールを用いた正翻訳ルールの獲得

5．性能評価実験

5.1　評価基準

生成された翻訳結果は有効な翻訳と無効な翻訳に分類される。有効な翻訳は以下の二つの場合である。

①正翻訳

②未登録語を含む正翻訳

正翻訳とは構文的かつ意味的に正しい翻訳結果である。また，未登録語を含む正翻訳とは，変数を一つ含むが，その変数に名詞句及び形容詞句を代入することにより，容易に構文的かつ

意味的に正翻訳となる翻訳結果である。有効な翻訳率は上記に該当する翻訳結果の全翻訳数に占める割合である。無効な翻訳は，上記の有効な翻訳に該当しない翻訳結果であり，無効な翻訳率は，それらの全翻訳数に占める割合である。また，一つの原文に対して，複数の翻訳結果が生成された場合には，上位1位の翻訳結果のみを評価の対象とする。

5.2 実験方法

実験は，始めに，中学1年生用教科書ガイド・ワンワールド［16］に掲載されている翻訳例1,010組を学習データとして用いた。次いで，中学1年生用教科書ガイド・ニューホライズン［17］に掲載されている800文を評価データとして用いた。これらのすべてのデータは1文毎にシステムに与え，その度に，翻訳と学習を繰り返した。なお，辞書の初期状態は空より始めた。また，式(2)中の α，β，γ の値には，それぞれ，2.0，1.0，5.0を用いた。そして，**4.4**で述べた確実度の高い部分翻訳ルールの利用には，式(2)の確実度が9.0以上の部分翻訳ルールを用いた。

5.3 予備実験

式(2)中の α，β，γ に対し，最適な値を決定するための予備実験を行った。実験データには，文献[16]の翻訳例300組を用いた。辞書は空の状態から始めた。実験はEFの係数 β を1.0と固定し，CFの係数 α を変化させることで，α と β の比率と有効な翻訳率の関係を調べた。また，γ は翻訳ルールの正誤に関係なく正翻訳に使用された場合に必ず付与され，翻訳ルール辞書中の全く使用されない翻訳ルールと区別するための定数である。すなわち，γ は正翻訳に使用されたすべての翻訳ルールの確実度を，一様に底上げする役割を果たすだけということである。したがって，γ はTTN中の翻訳ルールの正誤の判定には影響せず，基本的に有効な翻訳率にも影響を及ぼすことはないと考えられる。そこで γ には固定値5.0を用いた。実験結果を表3に示す。表3より，有効な翻訳率が最も高かったのは，α が1.0と2.0の場合である。この二つの中から最適な α の値として2.0を選択した。これは，α と β の比率を2：1とすることで，正翻訳ルールが異表記の影響を受けても，容易に誤翻訳ルールと判定されないようにするためである。例えば，部分翻訳ルール（brother；兄）に対して（brother；弟）のような異表記が出現した場合，（brother；兄）のEFは増加する。しかし，CFの重み係数 α をEFの重み係数 β よりも高くすることにより，（brother；兄）が容易に誤翻訳ルールと判断されることを回避す

表3　予備実験結果

α	0.1	1.0	2.0	10.0	20.0	30.0
有効な翻訳率［%］	49.3	51.3	51.3	51.0	51.0	50.7

る。

次いで，システムが正翻訳ルールを判断する際に用いる最適な確実度を決定した。予備実験より得られた $\alpha=2.0$, $\beta=1.0$, $\gamma=5.0$ の場合において，正翻訳に使用された翻訳ルールを対象に，以下のような調査を行った。初めに，正翻訳に使用された翻訳ルールからすべての正翻訳ルールを人手で選択した。そして，その人手で判断された正翻訳ルール中に占める，システムが判断した正翻訳ルールの割合を以下の式(3)より求めた。

$$\text{正翻訳ルールの正解率}\ [\%] = \frac{\text{システムが判断した正翻訳ルール数}}{\text{人手で判断された正翻訳ルール数}} \times 100.0 \tag{3}$$

更に，誤翻訳ルールの正解率も求めた。誤翻訳ルールの正解率とは，人手で判断された誤翻訳ルール中に占める，システムが判断した誤翻訳ルールの割合であり，以下の式(4)より求めた。

$$\text{誤翻訳ルールの正解率}\ [\%] = \frac{\text{システムが判断した誤翻訳ルール数}}{\text{人手で判断された誤翻訳ルール数}} \times 100.0 \tag{4}$$

システムが正翻訳ルール及び誤翻訳ルールと判断するためのしきい値には，式(2)の確実度が 8.0, 9.0, 10.0, 20.0, 30.0 の場合の5通りを用いた。システムはこれらの確実度をしきい値として，しきい値以上の確実度を持った翻訳ルールを正翻訳ルール，また，しきい値未満の確実度を持った翻訳ルールを誤翻訳ルールと判断する。これらのしきい値を用いて正翻訳ルールと誤翻訳ルールの正解率を調べた。その結果を表4に示す。表4より，正翻訳ルールと誤翻訳ルールの正解率の平均値が最も高かった 9.0 を最適なしきい値に決定した。

表4　予備調査結果

しきい値	8.0	9.0	10.0	20.0	30.0
正翻訳ルールの正解率 [%]	87.9	86.9	72.8	38.3	26.2
誤翻訳ルールの正解率 [%]	58.5	61.5	69.6	94.0	97.7
正解率の平均値 [%]	73.2	74.2	71.2	66.2	62.0

5.4　実験結果

表5に従来のGA-ILMTの有効な翻訳率と本提案手法を導入したTTNに基づくGA-ILMTの有効な翻訳率を示す。表中の（ ）内の数値は，文数である。実験の結果，有効な翻訳率は 38.3%から 46.6%に向上した。また，図8には，100文毎のそれぞれの有効な翻訳率の推移を示す。図8より，有効な翻訳率が最初の100文を除くすべての箇所で，従来のGA-ILMTよりも高くなっていることを確認できる。このような有効な翻訳率の増加は，解析的な知識を明示的に与えることなく，翻訳例のみを知識源とする条件のもとで可能となった。したがって，

表5　有効な翻訳率

手　法	有効な翻訳率	有効な翻訳率の内訳	
従来のGA-ILMT	38.3%（306）	①	81.9%（249）
		②	18.1%（ 55）
TTNに基づく GA-ILMT	46.6%（373）	①	84.5%（315）
		②	15.5%（ 58）

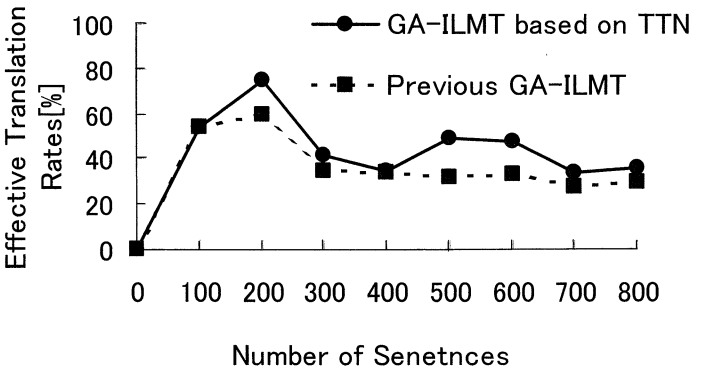


図8　有効な翻訳率の推移

これはGA-ILMTの学習能力が向上したことを示している。

5.5　考察

5.5.1　翻訳処理の精度向上について

今回の実験で，無効な翻訳から有効な翻訳へと移行した翻訳の数は102文であった。表6に，無効な翻訳から有効な翻訳へと移行した翻訳結果の例を示す。これらは提案手法が有効に働いた結果である。

TTNの利用が新たな有効な翻訳の生成に与えた効果として，翻訳処理の精度向上が挙げられる。TTNの使用により，どの翻訳ルールが基本構造を表す正しい文翻訳ルールであるかを捉え，最終的に翻訳に使用する文翻訳ルールを選択することが可能となった。例えば表6にある原文「Is this your camera?」に対する翻訳処理では，図9に示すTTNが生成された。

図9中のTTNの状態は以下の文翻訳ルールにそれぞれ対応している。

q_0：(Is @0 @1?；@0 は @1？)

q_1：(Is this @0?；これ は @0？)

q_2：(Is @0 your @1?；@0 は @1 ですか？)

q_3：(Is this your @0?；これ は @0 ですか？)

q_4：(Is @0 @1?；@0 は @1 ですか？)

表6　有効な翻訳結果の例

原　文	従来のGA-ILMTの翻訳結果	TTNに基づくGA-ILMTの翻訳結果
You have a nice pen.	あなたはすばらしいペン.	あなたはすばらしいペンを持っています.
Is this your camera?	これはカメラですか？	これはあなたのカメラですか？
Midori can make sushi.	みどりは@0おすし.	みどりは寿司をつくることができます.
They are playing basketball now.	彼らは今料理バスケットボールをしています.	彼らは今バスケットボールをしています.

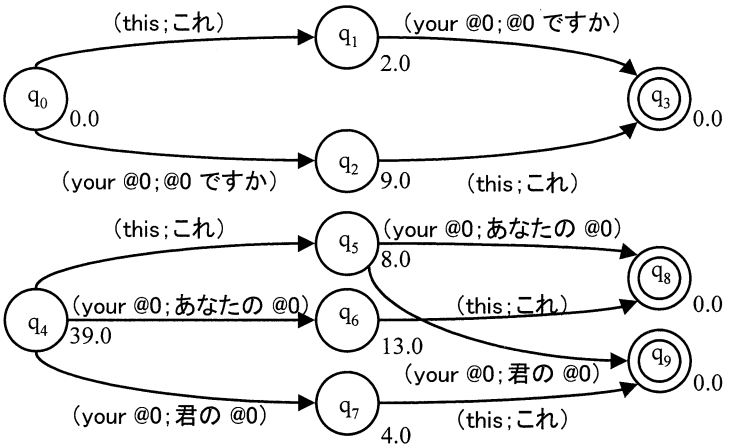


図9　(Is this your camera?；これ は あなたの カメラ ですか？) に対するTTN

q_5：(Is this @1?；これ は @0 ですか？)

q_6：(Is @0 your @1?；@0 は あなたの @1 ですか？)

q_7：(Is @0 your @1?；@0 は 君の @1 ですか？)

q_8：(Is this your @0?；これ は あなたの @0 ですか？)

q_9：(Is this your @0?.；これ は 君の @0 ですか？)

図9には，すべての推移の中から確実度の和が上位の推移を抜粋してある。また，このTTNの入力は（this；これ），（your @0；あなたの @0），（your @0；君の @0），（your @0；@0 ですか）である。図9において，最終状態の翻訳ルールq_3，q_8，q_9は，すべて英文が「Is this your @0?」である。この場合，従来のGA-ILMTでは，適応度の最も高い翻訳ルールが選択される。しかし，いずれの翻訳ルールも全使用回数が0であったため，登録順位の最上位であったq_3の文翻訳ルール（Is this your @0?；これ は @0 ですか？）が選択された。その結果，誤翻訳「これはカメラですか？」が導き出された。それに対し，TTNに基づくGA-ILMTでは，q_8の文翻訳ルール（Is this your @0?；これ は あなたの @0 ですか？）が選択された。これは，q_4の文翻訳ルール（Is @0 @1?；@0 は @1 ですか？）を初期状態とした$q_4 \rightarrow q_6 \rightarrow$

q_8の推移の確実度の和が52.0と最も高く，その最終状態がq_8の文翻訳ルールであったためである。その結果，正翻訳「これはあなたのカメラですか？」が導き出された。したがって，システムはq_4の正しい文翻訳ルールが原文の基本構造を表す翻訳ルールであるという根拠に基づいて，訳文生成を行ったと考えられる。すなわち，提案手法は文全体の構造を捉えた翻訳を実現している。そして，それは人間の持つ様々な翻訳過程の重要な一つを模倣していると位置付けることができる。このような翻訳過程は，言語固有の知識を導入することなく可能となったため，本提案手法はGA-ILMTに対し，学習能力の向上をもたらしたといえる。今回の実験で，このような翻訳処理の精度向上により，無効な翻訳から有効な翻訳へと移行した翻訳結果は72文存在した。

5.5.2　文翻訳ルールの正誤の判定について

翻訳処理の精度が向上した背景には，正翻訳のTTNを利用することによって，個々の翻訳ルールに対する正誤の評価精度が向上したことが大きな要因になっている。そこで，**5.3**と同様の手順で，文翻訳ルールを対象として，正翻訳ルールの正解率を式(3)に基づき求めた。この場合のしきい値は，予備実験より導き出された確実度9.0である。その結果，文翻訳ルールにおける正翻訳ルールの正解率は75.3%となった。一方，従来のGA-ILMTにおける正翻訳ルールの正解率は71.2%であった。従来のGA-ILMTにおいて，システムが判断した正翻訳ルールとは，適応度が80.0%以上の翻訳ルールである。従来のGA-ILMTに比べ，文翻訳ルールにおける正翻訳ルールの正解率は大きく向上したとはいえない。しかし，変数を含む汎用的な文翻訳ルールのみを対象とした場合，正翻訳ルールの正解率は60.8%から79.7%に向上した。これは，**4.2.2**で述べた従来のGA-ILMTが抱えている，汎用的な翻訳ルールに対する評価精度の低さが改善されたことを示している。この結果より，翻訳ルール間の一つ一つの組み合わせに着目した確実度数更新規則が有効に働いていることを確認できた。

5.5.3　部分翻訳ルールの正誤の判定について

部分翻訳ルールにおける正翻訳ルールの正解率は58.2%とそれほど高い割合ではなかった。この原因は部分翻訳ルールが文翻訳ルールに比べ，異表記の影響を受けやすいためである。例えば，部分翻訳ルール（car；自動車）に対し，（car；車）のような異表記が出現すると（car；自動車）の適応度は低下する。そして，この部分翻訳ルールは変数を含まない具象的な翻訳ルールであるため，**4.2.1**で述べたように適応度の低下が直接EFの増加に結びつく。その結果，部分翻訳ルール（car；自動車）の確実度は低下する。今回の実験では，確実度が9.0未満であった部分翻訳ルールの62.8%が異表記の存在する単語を有していた。しかし，従来のGA-ILMTの部分翻訳ルールにおける正翻訳ルールの正解率は52.2%であり，部分翻訳ルールについても正誤の評価精度が向上していることを確認できた。その結果，従来のGA-ILMTでは，誤った部分翻訳ルールを使用することにより無効な翻訳となっていた翻訳結果の15文が有効な翻訳

へ移行した。

5.5.4　新たな正しい文翻訳ルールの獲得について

TTN の利用がもたらした二つ目の効果は，**4.4** で述べた学習部における新たな正しい文翻訳ルールの獲得である。正翻訳ルールに対する評価精度が向上したことにより，確実度の高い部分翻訳ルールを利用した，新たな正しい文翻訳ルールの獲得が可能となった。新たな正しい文翻訳ルールの増加により，有効な翻訳へと移行した翻訳結果は 30 文であった。

5.5.5　問題点とその対策

今回の実験において，有効な翻訳から無効な翻訳へと移行した翻訳の数は 35 文であった。これは，異表記や語順の違いが原因で，正翻訳ルールを誤翻訳ルールと評価する場合が生じるためである。確実度に基づく翻訳ルールの正誤の評価が十分でない段階では，正翻訳ルールであっても，確実度が低ければ選択されないことになる。例えば，原文「I play tennis every Sunday.」に対し，「私はテニスを毎週日曜日にします。」という正翻訳をシステムが導き出しても，校正結果として語順の異なる「私は毎週日曜日にテニスをします。」を与えると，システムは生成した翻訳結果を誤翻訳として認識する。その結果，生成された翻訳結果に具象的な部分翻訳ルール（tennis；テニス）が使用されていると，この部分翻訳ルールの適応度は低下する。そして，EF が増加し，確実度数更新規則において「誤」となる。その結果，この部分翻訳ルールが，(He likes tennis.；彼 は テニス が 好き です。) の TTN の中に存在していた場合，表 2 の確実度数更新規則において「B：誤」と位置付けられる。一方，適応度の高い具象的な文翻訳ルール(He likes tennis.；彼 は テニス が 好き です。) は，「C：正」と位置付けられる。そこで，確実度数更新規則 No.10 が適用されると，汎用的な文翻訳ルール（He likes @0.；彼 は @0 が 好き です。）は「誤」と位置付けられ，確実度は低下してしまう。我々は，このような問題に対しては，解析的な知識を明示的に与えることで解決するのではなく，翻訳結果の正誤を高い精度で評価するための知識を学習により獲得することで，解決していきたいと考えている。

6．む す び

文全体の基本構造を表す汎用的な規則を認識し，それを具象化していくことで訳文を導き出す翻訳過程は，人間の持つ様々な翻訳過程の重要な一つと考えられる。本論文では，この考え方に基づき，システム自らが文全体の基本構造を捉えた翻訳を行う手法を提案した。我々は，このような翻訳過程を言語に依存した知識を与えることなく，システムの学習能力を向上させることにより実現した。このように学習能力が向上することにより，GA-ILMT に基づく機械翻訳システムは，様々な言語に対処可能な汎用性の高い学習型機械翻訳システムになり得ると考えられる。

提案手法では，文全体の基本構造を捉えた翻訳は，汎用的な翻訳ルールから具象的な翻訳ルールへと翻訳ルールを階層化することにより行う。GA-ILMT では翻訳ルールを階層化するために，汎用的な翻訳ルールから具象的な翻訳ルールへと翻訳ルールが推移していく過程，すなわち，翻訳過程を状態遷移に基づく翻訳遷移ネットワークを用いて表現する。このように，我々は文全体の構造を捉えた翻訳を，翻訳ルールの自動階層化という新たなメカニズムの導入により実現した。したがって，提案手法の導入により GA-ILMT の学習能力が向上するため，解析的な知識を持たない翻訳例のみを知識源とする条件のもとで翻訳精度を向上させることが可能となる。我々はそのことを明らかにするために，性能評価実験を行った。その結果，有効な翻訳率は 38.3%から 46.6%に向上した。したがって，提案手法が学習能力を向上させるために有効であり，その結果として翻訳精度が向上することを確認できた。今後は，更なる GA-ILMT の学習能力の向上を図り，より高い学習能力を有する機械翻訳システムの実現に向けての研究を進める予定である。また，実用的なデータにも対処可能な機械翻訳システム及び多言語間の翻訳を行う汎用性の高い機械翻訳システムの構築に向けての研究も同様に進める予定である。

謝辞

本研究の一部は，北海学園大学ハイテク・リサーチ・センター研究費による補助のもとに行われた。

参考文献

[1] 榊博史，“コンピュータ翻訳技術，”コロナ社，東京，1993.
[2] 田中穂積，“自然言語処理－基礎と応用－，”コロナ社，東京，1999.
[3] 佐藤理史，“アナロジーによる機械翻訳，”共立出版株式会社，東京，1997.
[4] 古瀬蔵，隅田英一郎，飯田仁，“経験的知識を活用する変換主導型機械翻訳，”情処学論，vol. 35，no. 3，pp. 414－425，Mar. 1994.
[5] P. F. Brown, J. Cocke, Stephen A. Della Pietra, Vincent J. Della Pietra, F. Jelinek, J. D. Lafferty, R. L. Mercer and P. S. Roossin, “A statistical approach to machine translation,” Computational linguistics, vol. 16, no. 2, pp. 79－85, 1990.
[6] K. Takeda, “Pattern-based context-free grammars for machine translation,”
[7] 北村美穂子，松本裕治，“対訳コーパスを利用した翻訳規則の自動獲得，”情処学論，vol. 37，no. 6，pp. 1030－1040，June 1996.
[8] 越前谷博，荒木健治，桃内佳雄，栃内香次，“実例に基づく帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性，”情処学論，vol. 37，no. 8，pp. 1565－1579，Aug. 1996.
[9] Goldberg,D.E, “Genetic algorithms in search, optimization, and machine learning,” Addison-Wesley, 1989.
[10] 越前谷博，荒木健治，桃内佳雄，栃内香次，“GA-ILMT における状態遷移を用いた翻訳ルールの階層化，”信学技報，TL 99－9，pp.29－36，July 1999.

[11] 越前谷博，荒木健治，桃内佳雄，栃内香次，“学習型機械翻訳手法GA-ILMTにおける状態遷移の導入について，”情処学自然言語処理研報，vol. 135，no. 23，pp. 173－180，Jan. 2000.
[12] 荒木健治，高橋祐治，桃内佳雄，栃内香次，“帰納的学習を用いたべた書き文のかな漢字変換，”信学論（D-ll），vol. J 79－D-ll，no. 3，pp. 391－402，Mar. 1996.
[13] 嵩忠雄，都倉信樹，谷口健一，“形式言語理論，”コロナ社，東京，1988.
[14] J. ホップクロフト，J. ウルマン著，野崎昭弘，高橋正子，町田元，山崎秀記訳，“オートマトン言語理論計算論1，”サイエンス社，東京，1984.
[15] J. Nakamura, J. Tsujii and M. Nagao, “Grammar writing system(GRADE) of Mu-machine translation project and its characteristics,” Proc. 10 th Coling, California, USA, pp. 338－343, July. 1984.
[16] “教科書ガイド教育出版版ワンワールド1，”日本教材，東京，1991.
[17] “教科書ガイド東京書籍版ニューホライズン1，”あすとろ出版，東京，1991.