社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
TL2002-7,NLC2002-7(2002-05)

携帯端末での中国語入力における帰納的学習を用いた数字漢字変換手法の有効性について

松原　雅文†　　荒木　健治†　　栃内　香次††

† 北海道大学大学院工学研究科　〒060-8628 札幌市北区北 13 条西 8 丁目
†† 北海学園大学大学院経営学研究科　〒062-8605 札幌市豊平区旭町 4-1-40
E-mail: †{matuhara,araki}@media.eng.hokudai.ac.jp, ††tochinai@econ.hokkai-s-u.ac.jp

あらまし　本稿では，携帯電話等の小型端末において，中国語文の迅速な入力を可能とする手法を提案する．本手法では，携帯電話等に装備されている少数の数字キーでのピンイン入力を可能とするために，1 つの数字キーに複数のアルファベットを割り当てている．さらに，迅速な入力を可能とするために，アルファベット 1 文字の入力を 1 打で行うこととした．このため，入力された数字列は意図した中国語文の他にも複数の中国語文に対応することとなり，曖昧性が増大している．しかしながら，本手法においては，帰納的学習の持つ高い適応能力を利用してこの曖昧さを解消している．評価実験の結果，65[%] 程度の変換精度が得られ，中国語に対して帰納的学習を用いた数字漢字変換手法の有効性が確認された．

キーワード　帰納的学習，数字漢字変換，ピンイン，携帯端末，中国語

Effectiveness of Number-Kanji Translation Method Using Inductive Learning on Mobile Terminal for Chinese

Masafumi MATSUHARA†, Kenji ARAKI†, and Koji TOCHINAI††

† Graduate School of Engineering, Hokkaido University,
Kita 13 Nishi 8, Kita-ku, Sapporo-shi, 060-8628 Japan.
†† Graduate School of Business Administration, Hokkai-Gakuen University,
Asahimachi 4-1-40, Toyohira-ku, Sapporo-shi, 062-8605 Japan.
E-mail: †{matuhara,araki}@media.eng.hokudai.ac.jp, ††tochinai@econ.hokkai-s-u.ac.jp

Abstract　We propose a method to input Chinese sentences into a mobile terminal. A user is able to input rapidly and easily because the user is able to input one Pinyin character per one keystroke in our proposed method. Some Pinyin characters are assigned to each numerical key on a mobile terminal. Therefore, the number string inputted by the user corresponds to many Chinese sentences and is ambiguous. However, our proposed method disambiguates the number string by Inductive Learning and is able to translate the number string into the Chinese sentence intended by the user. It is proved that our proposed method is effective for Chinese since the translation accuracy is about 65[%] in the result of the evaluation experiment.

Key words　Inductive Learning, Number-Kanji translation, Pinyin, Mobile terminal and Chinese

1. まえがき

近年，中国でも日本と同様に携帯電話が普及している．端末の高性能化も手伝い，SMS（ショートメッセージサービス）と呼ばれる携帯電話間でのメッセージの送受信も盛んに行われている．これに伴い，携帯電話のような小型端末上で中国語文を入力する機会が増大している．中国語には数万語の漢字が存在するので，これを直接入力するのは困難である．

そのため，パソコンにおける中国語入力にはさまざまな手法が存在するが，これらは大きく 2 つに分けられる．ひとつは，字形を利用した手法で，代表的なものに「五筆字型法」がある．日本語の部首に相当する，字根と呼ばれる単位に漢字を分割し，分割した字根を組み合わせることにより，漢字を入力する手法である．字根は約 200 個存在し，これを 25 種類に分類し，キーに割り当てている．そのため，この手法で入力を行うためには，すべてのキー割り当てを覚える必要があり，一般にはあまり普及していない．もうひとつの入力手法は，発音を利用した「ピンイン法」である．これは，ローマ字アルファベットで中国語

を表記する手段である「ピンイン」を用いて入力を行う手法である．よって，発音さえ知っていれば入力が行えるため，広く一般に普及している．携帯電話でのメールの入力等を考えると，誰もが簡単に入力できる必要がある．よって，ピンイン法は携帯電話での中国語入力に対しても適当であると考えられる．

しかしながら，ピンインはアルファベットにより入力されるので，最低でも 26 個のキーが必要となる．携帯電話はその大きさの制約から多数のキーを装備するのは困難である．そのため，文字循環指定方式によりアルファベットを入力するのが普通である．この方式においては，1 つの数字キーに複数のアルファベットを割り当てており，それを押した回数により文字を確定する．例えば，数字キー “7” にはアルファベット “pqrs” が割り当てられており，“r” を入力するためには，“7” のキーを 3 回押す必要がある．そのため，中国語 “**日本**” に対応するピンイン “*riben*(注1)” を入力するためには，3+3+2+2+2=12 の打鍵数が必要となり，迅速なピンイン入力は困難である．携帯電話普及率がさらに上昇し，メール等で中国語文を入力する機会の増大が予想されることから，携帯電話のような小型端末で迅速，かつ手軽に中国語文を入力できる手法が望まれる．

携帯電話で迅速なピンイン入力を可能とする手法に T9(注2) がある [1]．この手法においては，ピンインを迅速に入力するために，アルファベット 1 文字の入力を 1 打で行うことが可能である．しかしながら，その変換単位は単漢字であり，文単位での変換を考えた場合，変換のために多くの打鍵数を必要とする．よって，中国語文を迅速に入力するためには，単語等のより長い単位での変換が望まれる．

単語は漢字の組み合わせにより構成されるので，その種類は膨大な数になる．そのため，すべての単語をあらかじめシステムに与えることは，現実的に不可能である．また，中国語においても日本語と同様に，個人，あるいは分野を限定すれば小容量の辞書で高い変換精度を実現できるものと考えられる [2] [3]．特に，携帯電話のような小型端末では，その記憶容量の制限から，個人，あるいは分野に適合した必要最小限の単語を用いて変換を行うことが望ましい．

我々はすでに，日本語のかな漢字変換を対象としてではあるが，現在の対象に適合した単語に相当するセグメントを自動的に獲得し，変換を行うことが可能な手法を提案している [4]．この手法においては，入力されたかな文字列とそれに対応する校正済み変換結果の組から，かな文字列は共通部分になる，という特性に着目し，セグメントを自動的に獲得している．すなわち，共通部分を決定し，その間に挟まれる差異部分とともにセグメントとして獲得する．さらに我々は，情報が縮退した入力文字列からセグメントを獲得し，変換が可能な手法を提案している [5]．この手法においては，1 つの数字キーに複数のかな文字を割り当て，迅速な入力を可能としている．そして，かな文字の数字への対応は一意に決定可能である，という特性に着目し，同様の方法によりセグメントを獲得している．このようにして，現在の対象に適応していくことにより，少ない辞書容量で高い変換精度を実現している．しかしながら，中国語においては，かな文字のように一意に数字に対応する文字は存在しない．そのため，同様の手法によりセグメントを獲得することは不可能である．

これらの問題を踏まえて，本稿では，携帯電話等の小型端末上で，中国語文の迅速な入力を可能とする手法を提案する．本手法においても，入力文字列の情報を縮退させることにより，ピンインの迅速な入力を可能としている．また，セグメントを自動的に獲得するために，本手法においては 2 組の変換例を利用している．これまでに入力された任意の 2 組の変換例を，字面情報を用いて比較することにより，共通となる文字列を決定し，これに基づき単語に相当するセグメントを自動的に獲得していく．このようにして，かな文字が含まれない中国語文からでも，セグメントを獲得することが可能である．さらに，すでに獲得済みである確実性の高いセグメントを利用することにより，1 組の変換例からでもセグメントを獲得することができる．本手法においては，このようにして現在の対象に適合したセグメントを獲得し，変換を行っている．本手法に基づいた実験システムを作成し，評価実験を行った結果，65[%] 程度の変換精度が得られ，本手法の有効性が確認された．

表 1　数字とアルファベットの対応関係

Table 1　Correspondence of number to alphabet.

1:*space*	2:abc	3:def
4:ghi	5:jkl	6:mno
7:pqrs	8:tuv	9:wxyz
*:	0:	#:*punctuation*

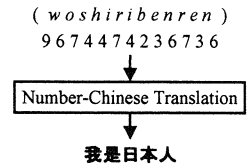


図 1　変　換　例

Fig. 1　Translation example.

2.　数字漢字変換手法の概要

本手法において，使用者は携帯電話等の小型端末に装備されている，少数の数字キーを用いてピンイン入力を行う．少数のキーのみでのピンイン入力を可能とするため，各キーには複数のアルファベットが割り当てられている．数字とアルファベットの対応関係を表 1 に示す．一般的な携帯電話等での文字の割り当てと同様の割り当てになっており，使用者は特別な訓練なしに，手軽に入力を行うことができる．さらに，ピンイン 1 文字の入力を 1 打で行うことにより，迅速な入力を可能としている．よって，1 打で入力された数字 1 文字は，複数のピンインに対応しており，曖昧性が増大している．本手法においては，この情報が縮退した数字列の曖昧さを排除し，使用者が意図した中国語に正しく変換することを目指している．本手法の変換例を図 1 に示す．なお，中国語 “**我是日本人**” に対応する日本語は “私は日本人です” である(注3)．

一般にピンインと漢字は一対多の関係にある．例えば，ピンイン “*ren*” は漢字 “**人**”, “**任**” などに対応している．さらに本手法の入力において，“*ren*” に対応する数字列は “736” となる．そのため，この数字列に対応する漢字は上記の他に “**盆** (*pen*)”, “**森** (*sen*)” などが存在することとなり，ピンイン文字列に比べ，さらに曖昧さが増している．この数字列の持つ曖昧さを解消し，使用者が意図した中国語文に正しく変換するために，本手法においては，「最近使用した単語はまた使用される可能性が高い.」というデータの局所性に基づき，1 文の入力が完了するたびに，随時，学習を行うことにより，現在の対象に動的に適応してい

(注1)：中国語の漢字は**ゴチック体**で，ピンイン文字列はイタリック体で表す．

(注2)：開発元は Tegic Communications Inc. である．

http://www.tegic.com/

(注3)：中国語文は普通，分かち書きされない．また，中国語は孤立語と呼ばれ，人称や格などによる語形変化が一切なく，語順により文法機能を表す言語である．

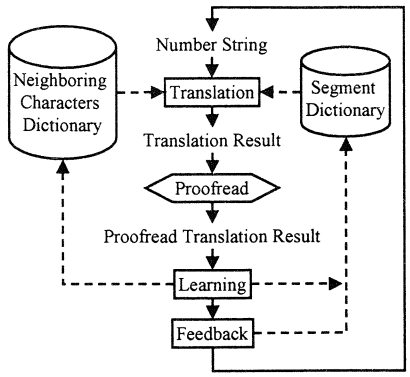


図 2 処理過程

Fig. 2 Processes.

表 2 セグメント辞書の構造

Table 2 Structure of the segment dictionary.

数字列	中国語	*CF*	*EF*
74866464	**説明**	5	0
6364	**能**	4	2
:	:	:	:

く．このようにして，対象を自動的に限定することにより，数字列の持つ曖昧さのために発生する変換候補の重複を抑えている．なお，本手法は種々の対象に適応可能であるので，汎用性も保持している．また，処理の過程で，変換に使用したセグメントの正誤を判定し，そのセグメントのゆう度を自動的に更新することにより，次回から現在の対象に適合した正しいセグメントを優先的に適用可能である．このような処理を文が入力されるたびに繰り返すことにより，システムは自動的に現在の対象に適応し，次第に変換精度を向上させることができる．

3. 処理過程

本手法の処理過程を図 2 に示す．図 2 に示されるように，変換，校正，学習，フィードバックの順に処理が行われる．

3.1 変換処理

本手法での入力は，携帯電話等に装備されている数字キーにより行われる．本処理過程では，この入力された数字列を中国語へと変換する．

3.1.1 辞書

本手法ではセグメント辞書と隣接文字列辞書の 2 つの辞書を用いて変換を行う．セグメント辞書の構造を表 2 に示す．このように，ピンイン数字列とそれに対応する中国語文字列の組が登録されており，これを用いて変換が行われる．なお，表 2 において，*CF*(**F**requency of **C**orrect Translation) は正変換度数，*EF*(**F**requency of **E**rroneous Translation) は誤変換度数を表しており，これらの値は，**3.4** のフィードバック処理により更新される．さらに，セグメント辞書は，セグメントの獲得状況とその正変換率に基づいて階層構造を有している．確実性の高い階層から，MS(The **M**ost Certain **S**egment), CS(**C**ommon **S**egment), S1(**S**egment **O**ne), RS(**R**emained **S**egment), LS(The **L**east Certain **S**egment) である．セグメント辞書の階層を図 3 に示す．図 3 中の *CR*(**R**ate of **C**orrect Translation) は正変換率であり，*CF*, *EF* に基づいて計算される．正変換率 *CR* を式 (1) に示す．

$$CR = \frac{CF}{CF + EF} \tag{1}$$

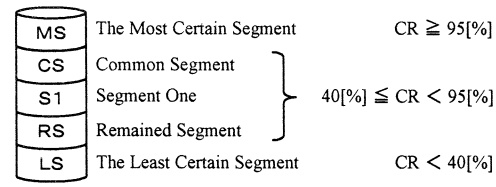


図 3 セグメント辞書の階層

Fig. 3 Rank in the segment dictionary.

表 3 変換処理例

Table 3 Example of the translation process.

入力数字列（ピンイン）	
967443298374364 (*woshidaxuesheng*)	
セグメント辞書	
数字列	中国語
96744	**我是**
98374364	**学生**
32	**法**
:	:
変換結果	
我是法学生	

このように辞書を階層化し，変換の際に上位階層のセグメントから順に適用することにより，処理の効率化を図っている．

隣接文字列辞書には，これまでに入力された中国語文が登録されている．これを用いて文字列の隣接度合 *ND*(**D**egree of **N**eighboring Characters) を n-gram 統計により計算する [6]．この文字列の隣接度合 *ND* は，変換候補重複の際のゆう度評価に利用される．これにより，隣接する文字列とのつながりを考慮した変換が可能となっており，同音異表記語にも対処可能である．

3.1.2 セグメントの変換

入力数字列に対して適用可能な数字列をセグメント辞書中から検索し，検索された数字列をそれに対応する中国語文字列に置き換えることにより，変換が行われる．ここで，数字列の文字数が少ない，短いセグメントは必然的にその適用範囲が広くなり，適用の際の確実性が低くなるものと考えられる．よって，ある一定以上の長さをもつセグメントを優先的に使用するものとした．すなわち，数字列の長さが閾値以上であるセグメントを上位階層のものから順に適用し，適用できるセグメントがなくなった時点で，数字列の長さが閾値未満のセグメントを適用していく．なお，変換の際に適用可能なセグメントが重複した場合には，ゆう度評価関数 *LEF*(**L**ikelihood **E**valuation **F**unction) により，各セグメントのゆう度を評価し，最ゆうなセグメントを決定する．ゆう度評価関数を式 (2) に示す．

$$LEF = ND + \alpha \times CR - \beta \times ER \tag{2}$$

α, β: 係数

式 (2) により，前後の文字列との隣接の度合いが強く，正変換率が高く，誤変換率が低いセグメントが優先的に選択される．

変換処理の例を表 3 に示す．表 3 において，セグメント辞書中の数字列 “96744”,“98374364”,“32” は入力数字列に対して適用可能である．これらは，他の変換候補と競合した際に，ゆう度評価関数 *LEF* により最ゆうと判断されたセグメントである．よって，それぞれの数字列を “**我是**”,“**学生**”,“**法**” に置き換えることにより，中国語文への変換が行われる．なお，セグメ

表 4　S1 の抽出例

Table 4　Example of the extraction of S1.

変換例	
数字列（ピンイン）	中国語
967443298374364	**我是 大学生**
(*woshidaxuesheng*)	
9674474236736	**我是 日本人**
(*woshiribenren*)	
抽出される S1	
共通部分	96744：**我是**
差異部分	3298374364：**大学生**
	74236736：**日本人**

表 5　MS を利用した抽出例

Table 5　Example of the extraction by MS.

変換例	
数字列	3254329426539835 4748
中国語	**大力発展 科学 技術**
セグメント辞書	
MS	53983：**科学**
抽出される S1	
3254329426：**大力発展**，54748：**技術**	

ントの長さ制限のため，短い数字列である “32：**法**” の変換は最後に行われている．

3.2 校正処理

変換結果に誤りが含まれている場合，人手により校正が行われる．校正は誤り部分に対してのみ行われるので，校正に要するコストは最小限に抑えることができる．また，誤りの訂正は入力のために必須の行為であり，本手法の学習処理のために行われるものではない．よって，本システムの操作性を煩雑にするものではない．

3.3 学習処理

入力数字列，校正済み変換結果の組と，これまでに入力された変換例とで字面上の比較を行うことによりセグメントを獲得する．

3.3.1 S1 の抽出

入力された変換例と，これまでに入力された任意の変換例とを比較することにより共通部分を決定し，差異部分とともにセグメント S1 として抽出する．ある数字列，中国語文字列が両方の変換例において共通に出現している場合，この数字列，中国語文字列は共通部分とみなされ，対応関係にあるものと判断される．これにより，共通部分に挟まれた差異部分の対応関係も確定することができる．このようにして，共通部分，差異部分をセグメント S1 として抽出する．ここで，1 文字の中国語文字を共通部分として抽出すると，最終的にすべてのセグメントが 1 文字に分解されてしまう可能性がある．これを避けるために，中国語文字列の長さが 2 文字以上で，最長となる文字列を共通部分とすることにした．これに合わせて，数字列は 4 文字以上のものを共通部分とする．これは，中国語において，ピンイン 1 文字で構成される漢字の種類は少ない，というヒューリスティクスによるものである．

S1 の抽出例を表 4 に示す．　表 4 において，数字列 “6744”，及び漢字 “**我是**” はともに両方の変換例において出現している．よって，これらを共通部分として決定し，残りの差異部分とともに S1 として抽出する．

表 6　MS を利用しない抽出例

Table 6　Example of the extraction without MS.

変換例	
数字列	中国語
325432942653983	**大力発展 科学**
9472653983	**自然 科学**
抽出される S1	
共通部分	2653983：**科学**
差異部分	32543294：**大力発展**
	947：**自然**

表 7　CS, RS の抽出例

Table 7　Example of the extraction of CS and RS.

辞書中の S1	
数字列	中国語
3298374364	**大学生**
98374364	**学生**
抽出されるセグメント	
CS	98374364：**学生**
RS	32：**大**

表 8　フィードバック処理の例

Table 8　Example of the feedback process.

変換結果	**我是 法 学生**
校正済み変換結果	**我是 大 学生**

3.3.2 MS を利用した抽出

S1 の抽出処理においては，字面上の比較により共通部分を決定するために 2 組の変換例を必要とした．そのため，共通部分を含む 2 組の変換例が存在しない場合にはセグメントを抽出することができない．よって，本手法においては，MS 階層のセグメントを利用して学習を行うことにより，学習効率の向上を図っている．MS 階層のセグメントにおいて，数字列と中国語文字列の対応関係は確実性が高いものと考えられる．よって，この MS 階層のセグメントの対応関係が決定しているものとみなし，セグメントの抽出を行う．これにより，1 組の変換例からでもセグメントの獲得が可能である．また，共通部分を含む 2 組の変換例が存在する場合であっても，MS 階層のセグメントを利用した方が，より高精度でセグメントの獲得を行うことができるものと考えられる．よって，この MS を利用した抽出処理は，実際には **3.3.1** の処理の前に行われる．

表 5 に MS を利用した抽出の例を示す．セグメント辞書中の MS 階層には，“53983：**科学**” が登録されている．よって，“53983：**科学**” の対応関係が確実であるものとして，残りの差異部分を S1 として抽出する．このように，1 組の変換例からでもセグメントを正しく抽出することが可能である．

一方，MS を利用せずに S1 の抽出を行った場合の例を表 6 に示す．この場合，**3.3.1** の処理により表 6 中の下線部分が共通部分となる．しかしながら，この共通部分は正しくは “53983：**科学**” となるべきであり，これは誤ったセグメントとなる．そのため，差異部分として獲得された S1 も誤ったセグメントとなっているが，このような誤りは，MS 階層のセグメントの利用により回避可能である．

このようにして獲得された S1 は，複数のセグメントから構成されている可能性があるので，**3.3.3** の CS, RS の抽出処理により，複数のセグメントへの分解を試みる．

表 9　実験データ

Table 9　Data of the experiment.

	文字数	文数	1 文平均
入力数字列	65,000	837	77.7
校正済み変換結果	23,699	837	28.3

表 10　評　価　例

Table 10　Example of the evaluation.

変換結果	我是32学生
校正済み変換結果	我是 大 学生

表 11　予備実験結果

Table 11　Result of the preliminary experiment.

優先文字数	2	3	4
F 値 [%]	34.6	36.3	35.5

3.3.3　CS, RS の抽出

獲得されたセグメントと，すでに辞書中に存在している任意のセグメントとを比較することにより，CS(Common Segment), RS(Remained Segment) の抽出が行われる．一方のセグメントが他方に完全に含まれる場合，含まれるセグメントは共通部分と判断され，CS として抽出される．残った差異部分は RS として抽出される．CS は複数のセグメントに共通して出現する文字列であり，単語としての確実性が高いものと考えられる．よって，CS は S1 より上位の階層とする．RS は CS として抽出されなかった残りの文字列であり，確実性が低いものと考えられるので，S1 より下位の階層とした．なお，分解された S1 は，CS, RS により復元可能なので，辞書から削除する．

CS, RS の抽出例を表 7 に示す．表 7 において，“98374364 : **学生**” は数字列，中国語文字列ともに “3298374364 : **大学生**” に含まれる．よって，CS“98374364 : **学生**”，RS“32 : **大**” を抽出し，セグメント辞書のそれぞれの階層に登録する．

3.4　フィードバック処理

本処理過程では，変換結果と校正済み変換結果とを比較することにより，変換に使用したセグメントの正誤を判断し，そのゆう度を更新する．変換結果と校正済み変換結果において，共通となる文字列に完全に含まれるセグメントは正変換と判断され，その正変換度数を 1 増加させる．変換に使用したセグメントのうちそれ以外のものは，誤変換度数を 1 増加させる．ここで更新された正変換度数，誤変換度数によりセグメントの正変換率 CR を計算し，その値に応じて辞書中のセグメントを各階層へ移動する．すなわち，$CR \geqq 95$[%] となったセグメントは，MS 階層へと移動し，$CR < 40$[%] となったセグメントは LS 階層へと移動する．また，MS，LS 階層のセグメントの正変換率が $40[\%] \leqq CR < 95[\%]$ となった場合には，そのセグメントは以前所属していた，元の階層へと移動する．このようにして，セグメント辞書の最適化を図っている．

フィードバック処理の例を表 8 に示す．表 8 において，下線部分が共通部分となる．よって，この共通部分に完全に含まれている，変換に使用したセグメント “96744 : **我是**”，“98374364 : **学生**” の正変換度数を 1 増加させる．そして，共通部分に含まれていない “32 : **法**” の誤変換度数を 1 増加させる．このようにして，変換結果に応じて辞書中のセグメントのゆう度を更新することにより，次回からの変換時に現在の対象に適合したセグメントを優先的に選択することが可能となる．

以上のように，文が入力されるたびに，変換，校正，学習，フィードバック処理を繰り返すことにより，現在の対象に適合した辞書が自動的に生成され，次第に変換精度の向上が期待できる．

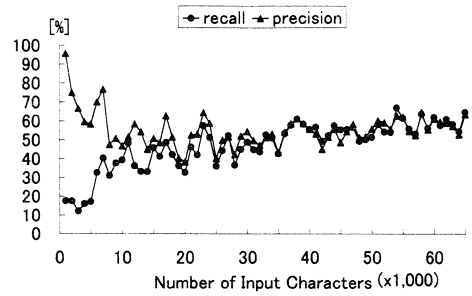


図 4　再現率，適合率の推移

Fig. 4　Changes in the recall and the precision.

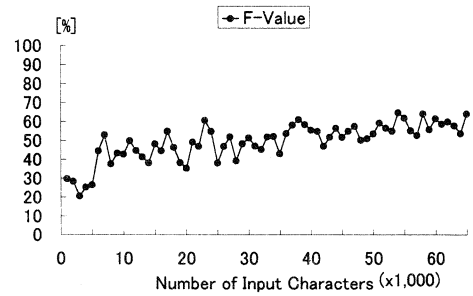


図 5　F 値の推移

Fig. 5　Change in the F-measure.

表 12　平均変換精度

Table 12　Means of the translation rates.

	再現率 [%]	適合率 [%]	F 値 [%]
全体	47.0	55.5	49.5
後半 1 万文字	58.7	58.1	58.4

表 13　獲得されたセグメント数

Table 13　Number of the extracted segments.

MS	CS	S1	RS	LS	合計
122	565	337	1,395	438	2,857

4.　評 価 実 験

3. の処理過程に基づき実験システムを作成し，評価実験を行った．

4.1　実験データおよび実験手順

Sinica コーパス(注4) [7] から主題が “**工程**” であるデータを抜粋し，実験データとして用いた．本手法は個人使用の多い携帯電話等での中国語文の入力を想定している．個人での使用においては，ある程度入力される文の分野は限定されるものと考えられる．よって，この分野限定を再現するために，一定の主題に関するデータを実験データとして用いた．実験データを表 9 に示す．1 文ごとに入力を行い，**3.** に示す処理過程に従い処理を行っている．実験は辞書が空の状態から行った．辞書にあらかじめ単語を与えた場合，あらかじめ与える情報が変換精度に直接，大きな影響を与えてしまう．よって，さまざまな対象に動的に適応可能な本手法の適応能力を確認するために，本評価実験では辞書の初期状態は空にしている．

(注4)：以下に公開されている中国語コーパスである．
http://www.sinica.edu.tw/

また，ゆう度評価関数である式 (2) の係数は文献 [5] と同様に $\alpha = 0.1$，$\beta = 0.5$ とした．

4.2 評価方法

入力文字数 1,000 文字ごとに式 (3)(4) に示す再現率，適合率により評価を行った．また，再現率と適合率を統一的に評価するために，F 値での評価も行っている．F 値を式 (5) に示す．

$$\text{再現率} = \frac{\text{正変換文字数}}{\text{校正済み変換結果文字数}} \tag{3}$$

$$\text{適合率} = \frac{\text{正変換文字数}}{\text{変換結果文字数}} \tag{4}$$

$$F\text{ 値} = \frac{(1+b^2)\cdot\text{適合率}\cdot\text{再現率}}{b^2\cdot\text{適合率}+\text{再現率}} \tag{5}$$

なお，式 (5) において，再現率，適合率の重みを均等にするために，b の値は 1 に設定している．

評価の例を表 10 に示す．表 10 において，正変換文字は共通文字列である下線の部分になる．なお，変換結果中の数字列 "32" は未変換であったことを表している．よって，この場合の各評価式の値は以下のようになる．

$$\text{再現率} = \frac{4}{5} = 80.0[\%] \quad \text{適合率} = \frac{4}{4} = 100.0[\%]$$

$$F\text{ 値} = \frac{2\cdot 100.0\cdot 80.0}{100.0+80.0} = 88.9[\%]$$

4.3 予備実験

3.1.2 のセグメントの変換の際に優先する文字数を決定するために，予備実験を行った．表 9 と同様のデータのうち，入力数字列 10,000 文字のデータを用い，F 値による評価を行った．実験結果を表 11 に示す．この実験結果から，F 値が最大となった 3 文字を変換時の閾値とした．

4.4 実験結果

再現率，適合率の推移を図 4 に，F 値の推移を図 5 に示す．また，各平均変換精度を表 12 に示す．実験終了時に獲得されていた，各階層ごとのセグメント数を表 13 に示す．

4.5 考　　察

4.5.1 変換精度について

図 4，図 5 から分かるように，入力データの増加に伴い，変換精度が上昇している．これは，本手法の学習能力により，対象に適合したセグメントが獲得された結果である．適合率については，実験の初期の段階では非常に高い値を示している．これは，実験の初期の段階では獲得されたセグメント数が少ないため，適用可能なセグメントが限られており，変換候補の重複がほとんど起こらなかったためである．獲得セグメント数が増えるに従って，変換候補の重複が起こりやすくなるため，次第に適合率は低下している．しかしながら，実験の後半ではまた適合率の上昇が確認できる．これは，変換候補重複の際のゆう度評価が有効に作用した結果である．このように，本手法の高い適応能力により，最終的に，F 値で 65[%] 程度までの上昇が確認された．また，この F 値の上昇からも分かるように，再現率，適合率の一方を犠牲にして他方を向上させているのではなく，両方の精度を向上させていることが確認できる．

4.5.2 獲得セグメントについて

表 13 から分かるように，RS 階層に所属するセグメント数がもっとも多くなっている．これは，数字列と中国語文字列の対応関係を誤って獲得しているセグメントが，数多く存在していたためである．対応関係を誤ったセグメントは，同一の中国語文字列に対して長さの異なる複数の数字列を持つ場合がある．このように，正しくは同一であるはずのセグメントが複数存在することにより，RS 階層のセグメント数の増加を招いていた．RS 階層のセグメントは，あるセグメントから確実性が高い CS セグメントを抽出した際に残った部分である．そのため，この抽出元となるセグメントに誤りが含まれている場合に CS セグメントが正しく抽出されると，必然的に残ったセグメントは誤ったものになる．そのため，RS 階層には誤りセグメントが数多く存在する結果となった．しかしながら，セグメントの適用は上位の階層から行われ，また，RS 階層中の誤りセグメントが変換に使用された場合，フィードバック処理により誤りと判断され，そのセグメントのゆう度は低下していくものと考えられる．よって，本手法の変換精度を大幅に低下させるものではない．

5. むすび

本稿では，携帯電話等の小型端末上で迅速，かつ手軽に中国語文を入力可能な手法を提案した．中国語の入力方法には，広く普及しているピンイン法を採用することにより，手軽な入力を可能としている．ピンインを入力するためには，多数のキーが必要となるので，これを携帯電話等の少数のキーで実現するために，文字列の情報を縮退させて入力することとした．結果として迅速な入力が可能となる反面，入力文字列の曖昧さは増大している．よって，この曖昧さを排除し，使用者が意図した正しい中国語文に変換する必要がある．これを実現するために，本手法においては帰納的学習の持つ高い適応能力を利用している．これまでに入力された変換例の字面情報のみから，単語に相当するセグメントを自動的に獲得可能なので，個人，あるいは現在の対象に動的に適応可能である．具体的には，2 組の変換例を利用することにより，中国語におけるセグメントの獲得を可能としている．本手法に基づく実験システムを作成し，評価実験を行った結果，65[%] 程度の F 値が得られ，本手法の有効性が確認された．

本稿の評価実験においては，校正は何らかの方法により行われるものとしてきた．しかしながら，実際の使用においては，校正処理も携帯電話上で使用者により行われる必要がある．よって，今後は，校正を含めた手法全体の打鍵数の評価を行う予定である．

謝辞　なお，本研究の一部は文部科学省科学研究費補助金（第 14658097 号）によって行なわれている．

文　　献

[1] Cliff Kushler, "AAC USING A REDUCED KEYBOARD," Proceedings of CSUN98, Los Angeles, America, March 1998.

[2] 栃内 香次, 斎藤 康, "適応型変換辞書を用いるかな漢字変換," 情処学論, Vol.24, No.2, pp.209–213, Mar. 1983.

[3] 栃内 香次, 岡沢 好高, "適応変換辞書方式かな漢字変換システムの性能測定," 情処学論, Vol.26, No.4, pp.733–739, Jul. 1985.

[4] 荒木 健治, 高橋 祐治, 桃内 佳雄, 栃内 香次, "帰納的学習を用いたべた書き文のかな漢字変換," 信学論 (D-II), Vol.J79-D-II, No.3, pp.391–402, Mar. 1996.

[5] 松原 雅文, 荒木 健治, 桃内 佳雄, 栃内 香次, "文字情報縮退方式を用いた帰納的学習によるべた書き文の数字漢字変換手法の有効性について," 電子情報通信学会論文誌 (D-II), Vol.J83-D-II, No.2, pp.690–702, February 2000.

[6] M. Nagao, S. Mori, "A New Method of N-gram Statistics for Large Number of n and Automatic Extraction of Words and Phrases form Large Text Data of Japanese," PROCEEDINGS of COLING 94, Vol.1, Kyoto, Japan, pp.611–615, Aug. 1994.

[7] "中央研究院平衡語料庫的内容説明," Technical Report no.95-02, 中文詞知識庫小組, 1995.