社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
HIP2002-61 (2003-01)

N-gramを用いた帰納的学習によるユーザの行動予測

徐 金安† 荒木 健治† 栃内 香次‡

† 北海道大学大学院工学研究科

〒060-8628 札幌市北区北 13 条西 8 丁目

Phone & Fax: 011-706-7389

‡ 北海学園大学大学院経営学研究科

〒062-8605 札幌市豊平区旭町 4-1-40

Phone: 011-841-1161 ext.634 Fax: 011-824-7729

E-mail: †{xja,araki}@media.eng.hokudai.ac.jp, ‡ tochinai@econ.hokkai-s-u.ac.jp

あらまし 我々はそれぞれのユーザに動的に適応可能な行動予測手法の開発を目指し，N-gramを用いた帰納的学習によるユーザの行動予測手法を提案している．本手法においては，帰納的学習によりユーザの状態履歴から，その内在している因果関係を持つルールを自動的に獲得し，さらにN-gramと統合することによりその獲得状況及び予測精度に基づく確実性の高いものより順に予測する．よって本手法では，データ履歴，ルール辞書などを予め用意する必要がなく，システムが獲得されたデータから，ユーザの嗜好や習慣に合うルールを自動的に生成し，予測結果を校正した情報を用いることにより予測能力が向上する．本研究は，N-gramと実例よりそこに内在している規則を獲得する帰納的学習を統合し，新たなPoint-Line Based Prediction Systemを構築した．実験の結果高い予測精度が得られ，高い動的適応能力も示された．

キーワード 帰納的学習，N-gram，行動予測，動的適応，Point-Line Based Prediction

Action Prediction for a User Using Inductive Learning with N-gram

Jin'an XU† Kenji ARAKI† Koji TOCHINAI‡

† Graduate School of Engineering, Hokkaido University

Kita 13, Nishi 8, Kita-ku, Sapporo, 060-8628, JAPAN

Phone & Fax: +81-11-706-7389

‡ Graduate School of Business Administration, Hokkai-Gakuen University,

Asahimachi 4-1-40,Toyohira-ku, Sapporo, 062-8605 JAPAN

Phone:+81-11-841-1161 ext.634 Fax:+81-11-824-7729

E-mail: †{xja,araki}@media.eng.hokudai.ac.jp, ‡ tochinai@econ.hokkai-s-u.ac.jp

Abstract We have proposed a method to predict a user action using Inductive Learning with N-gram. This method acquires rules from the state history automatically by its learning capability, and the acquired rules express the user's habit and tastes. Therefore the system is able to adapt dynamically to each user. The user must proofread the errors of prediction results. However, the erroneous conversion decreases by the system's dynamic adaptation. This paper unified N-gram and Inductive Learning which built the new Point-Line Based Prediction system. The high prediction accuracy of the experiment were gotten and better dynamic adaptation capability was also shown.

Keyword Inductive Learning, N-gram, Action Prediction, Adaptability, Point-line Based Prediction

1. はじめに

世界規模の情報技術の発達に伴い，人にやさしい柔軟なヒューマンインタフェースを持つ知的なシステムの必要性が高まってきている．このようなシステムを開発する際，最も重要なことはユーザの行動や意図などをどのように予測していくのかという点だと考えられる．行動や意図はユーザごとに異なるため，予測するための知識を事前に与えておくことは困難である．それゆえ、我々は各々のユーザに動的に適応可能な行動予測手法の開発を目指し，N-gramを用いた帰納的学習[1]によるユーザの行動予測手法を提案している．

これまで提案された様々なユーザの行動予測システムは，大別して統計的なアプローチや解析的なアプローチによるもの分けられる．統計的なアプローチは，データを解析する方法によってPoint-Based Prediction System [2][3]とLine-Based Prediction System [4][5]に分類される．Point-Based Prediction Systemにおける多くの提案手法は，マルコフモデルや最尤推定アルゴリズムなどを用いることにより，データの規則性を解明し，その規則性に基づいて予測を行うというものである．このような単なる統計的なアプローチにおいては，高い精度を得るために膨大なデータが必要であり，システムの動的適応性が低いという問題点も残る．また，データが少ないと，予測された確率の信頼性が低いという弱点も存在する．さらに，確率的に最大となる予測を行うだけでは，例外となる事例に対処できない．

また，Line-Based Prediction Systemにおける手法は，時系列データをN-gramで解析する方法が多くの研究者によって提案されている．しかし，N-gramを用いるだけでは，その予測精度が与えられたデータのサイズに依存してしまい，予測となる目標の出現頻度が少ない時に，予測が不能となってしまう，いわゆるデータスパースネスの問題が生じる．N-gramを用いるだけでは，同じように統計的な手法の問題を抱え込むことになる．

一方，解析的なアプローチにおいては，事前に予測するためのルールを与える必要があるが，各々のユーザに対し，全てのルールを用意するのは不可能であり,大規模なルールの作成にも多くの労力が必要となる．

これらの問題を根本的に解決するためには，システムが与えられたデータから自分自身で予測ルールを学習していく方法が考えられる．これを実現するために我々は，実例のみから学習を行うことが可能である帰納的学習によるユーザの行動予測手法を提案している，すでに帰納的学習による自然言語処理の有効性は証明されている[6,7,8,9].我々は，この手法を用いて，システムが与えられたデータから，差異部分，共通部分を再帰的に抽出することにより予測ルールを獲得していくことができる．このように，システムがユーザの嗜好や習慣に合うルールが自動的に獲得され，予測を行う際に，そのユーザの振舞いに合うようにシステムが動的に適応可能となっている．さらに，我々は人間の行動の一意性と規則性という特徴から，N-gramを用いた帰納的学習によるユーザの行動予測手法を提案することにより，適切な尤度評価関数を用いて，そのルールを選択する際に，確実性の高い順にルールを自動的に選択するというシステムを開発した．

このようにシステムは提案した手法により人間の行動や状況などを反映するデータから,その人間の習慣や嗜好などをルールとして獲得し,その人間に合った適切な振舞いをすることができる．特定の人間に特化された情報は,自動的にその意図を認識する手助けになり,提示すべき情報の選択や,インタラクションを開始するきっかけを決めるのに役立つと考えられる．

一方，情報理論や統計学などでは，古くからデータから因果関係を抽出し，データに含まれる情報の量を測るための数理的手法を蓄積してきた[10]が，それは，大規模なデータから因果関係を抽出することである．本論文では，帰納的学習による少数のデータから因果関係を持つルールの抽出することについても述べる。

本手法では，データ履歴やルール辞書などを予め用意する必要がなく，ユーザの行動予測における少ないデータからは予測が困難であるという問題を解決することも図っている．このようなシステムを開発することにより，現在の高度情報化社会が抱えている複雑で使いにくい機械やプログラム作成の重労働といった種々の問題を解決し，人にやさしい柔軟なシステムを開発できると考えている[1]．本手法に基づくシステムの学習能力と高い適応能力により，ユーザに適切なヒューマンインタフェースを提供することができると考えられる．

本稿では，帰納的学習によるユーザの行動予測手法，及びN-gramを用いた帰納的学習によるユーザの行動予測手法の概要についてそれぞれ述べ，さらに二つの手法に基づくシステムを作成し実験を行った結果からそれぞれの提案した手法の有効性を述べる．

2. システムの設計と基本的な概念

我々はそれぞれのユーザに動的に適応可能な行動予測手法の開発を目指し，より汎用的なシステムを実現するために，従来の行動予測システムの研究とは異なり，システムを一つの学習する部屋と見なす．すなわち，部屋に人間のような学習能力を持たせ，その工学的な実現方法や原理を探索することが目的である．分析を容易にするために，システムは8つの人工要素と5つの自然要素からなると仮定する．人工要素とは，テレビや電気などのような人間の行動により状態が変えられる要素である．自然要素とは曜日，明るさ，温度などのような人間の行動に依存しない要素である．表1に示されたそれぞれの要素は，予め与えられた幾つかの値を持つ．ここでシステムは部屋の状態を自動的に獲得することができると仮定しているが，現在の実世界認識技術の進歩により，これらの状態を獲得することが可能であると考えられる．

2.1. システムの要素における記号化

本システムにおける人工要素(ART)は，ドア(D)，テレビ(TV)，テレビ番組(P)，カーテン(Cu)，電気(L)，エアコン(AC)，電話(TEL)，ベル(BELL)からなる．その状態を次の式の順番で記号化する．

$ART_k^n = |D_k^n|TV_k^n|P_k^n|Cu_k^n|L_k^n|AC_k^n|TEL_k^n|BELL_k^n|$ *1

本システムにおける自然要素(N)は,曜日(W)，時(H)，分(M)，明るさ(B)，温度(T)からなる．同じように以下の式で記号化する．

$N_k^n = |W_k^n|H_k^n|M_k^n|B_k^n|T_k^n|$

以上のように，記号化された自然要素と人工要素の状態列を用いて，部屋の状態(S)が次のように表現することができる．

$S_k^n = N_k^n || ART_k^n$ *2

2.2. 因果関係を持つルール

我々は日常生活に行われている様々な行動においては，生活している環境の中で総合的な条件のもとで思考により行動している．それは、暗然的に人間の頭に有する知識を利用し，予測を行い，そして行動を決定するということである．その中に，人間の行動になる原因が存在していると考えられる．例えば，暗くなったら電気をつけるというようなことを，我々は帰納的学習を用いて，ルールとして獲得する．このようなルールは因果関係を持つルールと定義する．この因果関係を利用し，本システムにおいては，ユーザがある動作をする時に，その動作の直前にある部屋の状態(S_k^n)がその動作の原因であると考えられる．そこで，ユーザの動作における変更された人工要素の状態をユーザの反応(REA_k^n)と記述すれば，$C_k^n \rightarrow REA_k^n$のようなルールを獲得することができる．ここにある$REA_k^n$は人工要素の状態のみで表現することができる．

一方，人間は必ずしも，このような因果関係を用いて行動をするわけではないが，それは，人間が頭にパターンマッチングや最尤推定，ロジック論理など複合的な知能を有しているからである．もちろん，ほかにも存在している様々な関係を工学的に表現できると考えられるが，本論文では，因果関係を持つルールの獲得について試みる．

3. 基本的な考え方

ここで，実際の例を用いて，帰納的学習によるルールの獲得とN-gramの利用方法について述べる．

3.1 帰納的学習によるルールの獲得

ここで，実際の例を用いて，帰納的学習によるルールの獲得方法について述べる．まず，我々はデータ履歴から獲得された最も具体的なルールを初期ルールとし，再帰的に獲得されたルールを抽象化されたルールと定義する．例えば:"電話を取ると，テレビが切れる"というルールを獲得する際に

データの例1：

S_1^1 =|Monday|7:31|750|24||Doff|3ch|News|Con|Loff|Aoff|**Ring**|Boff|

S_1^2 =|Monday|7:31|750|24||Doff|**3ch**|**News**|Con|Loff|Aoff|**Teon**|Boff|

S_1^3 =|Monday|7:31|750|24||Doff|**Toff**|**None**|Con|Loff|Aoff|Tcon|Boff|

データの例2：

S_2^1 =|Tuesday|10:03|800|28||Doff|1ch|News|Con|Loff|Aoff|**Ring**|Boff|

S_2^2 =|Tuesday|10:03|800|28||Doff|**1ch**|**News**|Con|Loff|Aoff|**Teon**|Boff|

S_2^3 =|Tuesday|10:03|800|28||Doff|**Toff**|**None**|Con|Loff|Aoff|Tcon|Boff|

ここでは，データの例1からS_1^1とS_1^2の差異部分と共通部分を抽出することにより，初期ルール(S_1^1 →Tcon)を獲得することができる，同じように，S_1^2とS_1^3から初期ルールを(S_1^2→|Toff|Nonc|)も獲得される．また，データの例2から，初期ルール(S_2^1→Tcon)と初期ルール(S_2^2→|Toff|Nonc|)を獲得することもできる．

---

*1: "n"はデータ履歴に登録されたデータの順番を示す，"k"は日付けを示す．"|" は要素間の状態の区切り記号である．

*2 "||" は自然要素と人工要素を分類する記号である．

表 1. 各要素が持つ値

ELEMENT	SETTING VALUE
Day of Week	Monday, Tuesday, Wednesday, Thursday, Friday, Saturday, Sunday
Time	hh & mm
Brightness	50lux, 100lux, 150lux…1400lux, 1450lux, 1500lux
Temperature	16℃, 17℃, 18℃…33℃, 34℃, 35℃
Door	Doff, Don
TV	Toff, 1ch, 2ch…58ch, 59ch, 60ch
TV-program	None, Sport ,News, Music, Film, …,Cartoon, Economics
Curtain	Coff, Con
Light	Loff, Lon
Air conditioner	Aoff, 16℃, 17℃, … 33℃, 34℃, 35℃
Telephone	Teoff, Ring, Teon
Bell	Boff, Bon

このように抽出された初期ルールは，適応能力を付与するために，抽象化処理を加える必要がある。そこで，我々は，初期ルール(S_1^2→|Toff|None|)と初期ルール(S_2^2→|Toff|None|)の差異，共通部分を抽出することにより，ルールの抽象化処理を行う．抽象化されたルールは以下のように表現される：

|@0|@1|@2|@3||Doff|@4|**News**|Con|Loff|Aoff|**Teon**|Boff|
→|**Toff**|**None**|

ここで， @0, @1, @2, @3, と@4 は変数である．

3.2 N-gram の利用方法

帰納的学習では，データの差異部分と共通部分を利用することで，ユーザの動作のスクリプトを抽出することができる．例えば，上記のデータの例 1 から，Ring→~~3ch|News~~Teon→Toff|None がスクリプトとして抽出される．

このようなスクリプトは，典型的な事情列[11]を一つの枠の中にまとめた記憶構造であり，人間が日常行っている定型化された行動を，時間の流れに沿った事象の連鎖の形式で表現したものである．

人間は多くのスクリプトを持っており，ある状況に直面すると，その状況に適したスクリプトを選択し，そこに書かれた事情に従って物事が進行するであろうと予測しながら行動を進めていくと考えられる．

我々は，N-gram を用いて獲得されたスクリプトを解析し，その解析結果をルールの評価式に加え，予測を行う際，システムが確実性の高いルールを自動的に選択することができる．

N-gram を用いた予測システムでは，N の値の変化によりシステムの予測精度と実用性が変わる。これについて多くの研究者たちは，N の変化により予測精度と実用性における研究を行った．その結果，bi-gram を利用する場合，よりよいバランスが取られるここが示されている[5]．一方，人間の動作は，一つづつ行うという順序性がある．これらの特徴により，本システムにおいては bi-gram を用いて解析する．

4. 処理過程

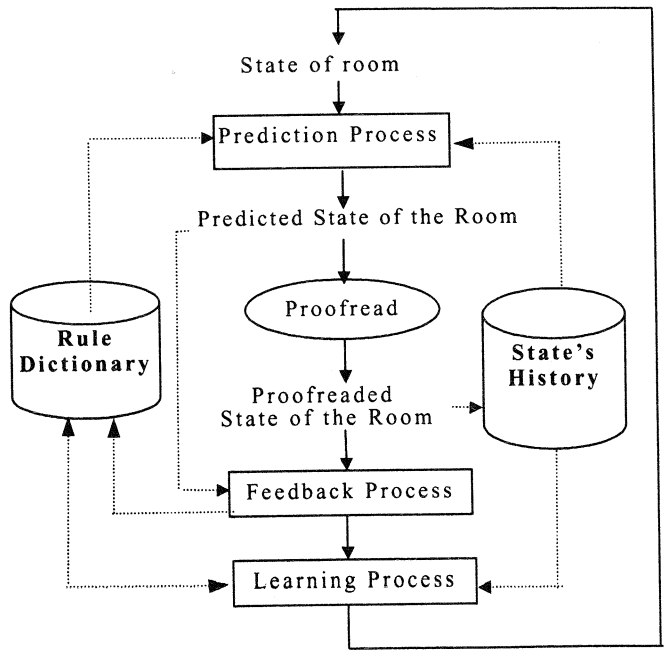


図 1：処理過程

帰納的学習を用いたユーザの行動予測手法と N-gram を用いた帰納的学習を用いたユーザの行動予測手法の処理過程を共に図 1 に示す．本章では，二つの手法の処理について述べる．

二つのシステムは図 1 に示されたように，予測処理，校正処理，フィードバック処理と学習処理からなる．

4.1 予測処理

予測処理においては，二つの手法は同じように状態履歴とルール辞書を参照し、パターンマッチングにより予測を行う．予測処理を行う際に，ユーザの動作における自然要素の状態変化量は，各々の動作に応じて，表 2 に示す固定値を持ち，データ履歴を参照しながら,状態の変更を行う．

表 2　ユーザの行動における状態変化量

ELEMENT	ACTION	VALUES
Brightness	Don (Doff)	±50 lux
Brightness	Con (Coff)	±250 lux
Brightness	Lon (Loff)	±500 lux
Air conditioner	X℃	X℃
Temperature	Ton (Toff)	±1℃

4.2 校正処理

校正処理においては，二つの手法ともに同様である．予測された結果がユーザの意図と一致する時に，その状態を状態履歴に登録する．予測された結果がユーザの意図と一致しない時にユーザは校正を行い，校正された結果を状態履歴に登録する．続いて，フィードバック処理に進む．

4.3 フィードバック処理

予測する際に予測ルールが競合する場合，ルールごとに保有している正予測頻度(CF)，誤予測頻度(EF)，正予測率(CR)，誤予測率(ER)に基づいて尤度評価が行なわれ，最適なルールが決定される．

フィードバック処理においては，ルールの尤度の更新と表 3 に示すルールの属する階層の処理を行う．それと同時に，正予測頻度(CF)，誤予測頻度(EF)，正予測率(CR)，誤予測率(ER)の更新も行う．

帰納的学習によるユーザの行動手法にける尤度評価関数(CEF: Credibility Evaluation Function)を式 1 に示す．

$$CEF = AF + \alpha \times CF - \beta \times EF \quad \bullet\bullet\bullet \ (1)$$

ここで，AF は予測頻度，α,β は係数を表している．

N-gram を用いた帰納的学習によるユーザの行動予測手法においての尤度評価関数(CEF)を式 2 に示す．

$$CEF = \lambda P(A_{n+1} \mid A_n) + \omega CR - \mu ER \quad \bullet\bullet\bullet \ (2)$$

ここで，λ,ω,μ は係数を表している．$P(A_{n+1} \mid A_n)$ は bi-gram による隣接動作の条件付き確率を示す．

正予測率(CR)と誤予測率(ER)の定義を式 3 と式 4 を示す．

$$CR = \frac{CF}{CF + EF} \quad \bullet\bullet\bullet (3)$$

$$ER = \frac{EF}{CF + EF} \quad \bullet\bullet\bullet (4)$$

表 3　ルール辞書の階層化

NAME OF RANK	THE RATE OF THE CORRECT PREDICTION
Most (M)	CR≥90%
High (H)	70%≤CR<90%
Common(C)	30%≤CR<70%
Least (L)	CR<30%

4.4 学習処理

帰納的学習によるユーザの行動予測手法においては，2.3 節に述べたように，初期ルールの獲得とルールの抽象化処理を行う．

N-gram を用いた予測手法では，次のような処理を行う．初期ルールの獲得とルールの抽象化処理，日々ごとにユーザが行った動作のスクリプトの獲得，N-gram による隣接動作 $P(A_{n+1} \mid A_n)$ の解析，解析した結果をルール辞書に登録する．

以上のように辞書を更新していくことで，対象に動的に適応することが可能となっている．

4.5 ルールの抽象度

帰納的学習によるルールの再帰的処理を行う際に，ルールが抽象化され，その適応能力が上昇する．しかしながら，ルールを抽象化しすぎると，正予測率が低下してしまう．このため適切な抽象度を与えなければならない．本システムにおいては，人工要素と自然要素がそれぞれの特徴を持つ．このため,ここでは，二つの抽象度を定義する．式 5 と式 6 に示す．

$$Dan = \frac{X}{N} \times 100\% \quad \bullet\bullet\bullet (5)$$

$$Daa = \frac{Y}{M} \times 100\% \quad \bullet\bullet\bullet (6)$$

ここで，Dan はルールの自然要素における抽象度，X は自然要素部分を含まれる変数の数，N は自然要素の数，Daa は人工要素における抽象度，Y は人工要素部分に含まれる変数の数，M は人工要素の数である．

5 評価実験

以上で述べた，帰納的学習を用いたユーザの行動予測手法，及びN-gramを用いた帰納的学習によるユーザの行動予測手法の有効性を確認するために，図1に述べた処理過程に基づいたシステムを作成し，評価実験を行った．

5.1 実験データ及び実験手順

ユーザの行動予測システムの評価方法については，従来より，難しい課題となっている．それは，人間の行動は生活している環境に存在する総合的な条件に依存しているからである．特に，我々は提案した各々のユーザに対して動的に適応可能な行動予測手法の評価では，複数のユーザの行動履歴を収集する必要があると考えられるが，そのようなデータを収集するのは人々のプライバシーに関わってしまう．また，実際の「学習する部屋」システムを作ってデータの収集を行うのは，技術上や費用上の問題が生じる．そのため，我々は，第一著者の実際の生活に基づいてデータの収集を行った．9週間に渡って945個の人工データを収集した．

実験は一つのデータ単位で行った．すなわち，まず，一つのデータを入力し，処理過程に従い予測を行い，ユーザの校正処理により変更されたシステムの状態をデータ履歴に登録する．そして，フィードバック処理と学習処理により，ルール辞書を更新する．更新された辞書を用いて，次の行動予測を行う．このように入力，予測を1つのデータごとに繰り返して，実験を進めていく．以下に示す正予測率(CPR: Corrected Prediction Rate)により評価を行った．

$$CPR=\frac{\text{正しく予測された結果}}{\text{予測された結果}}\times 100\% \quad \bullet\bullet\bullet(7)$$

評価方法としては，ユーザの動作は一意的であるという特徴を持ち，予測結果となるユーザの動作は必ずデータに記録されるようにするわけではないが，少なからず評価者の主観が入ってしまう．手法の有効性を確認するために，我々はクローズのデータで評価を行う．すなわち，データを入力しながら，予測結果を評価する．この評価方法は最善とは言えないが，ある程度客観的にシステムの学習能力と適応能力を評価することができる。

帰納的学習を用いたユーザの行動予測手法の実験においては，4.3節に記述された尤度評価関数の式1を用いて，実験を行う．尤度評価関数の係数α,βは予備実験によりにそれぞれ2と5としている．

N-gramを用いた帰納的学習によるユーザの行動予測手法においては，4.3節に説明した尤度評価関数式2を用いて，実験を行う．尤度評価関数λ,ω,μは曜日実験によりそれぞれ100，1，10としている．

二つのシステムにおいては，ルールの抽象化処理が行われる際に，予備実験によりDan，Daaそれぞれ0.6と0.5としている．これは，抽象化されたルールの適応能力と予測精度のバランスを取るために，システムに,異なる抽象度を与えて,よりよい予測精度が得られたものである．

なお，本手法はあらゆるユーザに動的適応可能であるので，各々のユーザにおいて初期状態を一定に保つため，データ履歴とルール辞書は空の状態から実験を行った．

5.2 予備実験による尤度評関数の係数の決定

尤度評価関数を最適化するために,予備実験を行った．実験のデータは収集した9週間分945個を用いた．Greedy Methodで尤度評価関数の係数を変化させ最大のCPRが得られる最適な係数を求めた．例えば前述の尤度評価式2の場合,まず，λ,ωに初期値を与え，μを変化させ,予測率が最大となるμの値を求める．そして，λ,ωをそれぞれ最適化する,このように繰り返す,予測精度が安定している際,尤度評価式の係数が決められる．

5.3 実験結果

実験の結果を図2に示す．入力データ1日分ごとに，二つの手法について同じデータを入力し，それぞれのCPRを用いて評価している．

帰納的学習を用いたユーザの行動予測手法においては，平均予測精度は49.16%，第九週目の平均予測精度は65.57%であった．週ごとに得られた平均予測精度を表4に示す．

N-gramを用いた帰納的学習によるユーザの行動予測手法においては，平均予測精度は60.10%,第九週目の平均予測精度は82.8%であった．週ごとに得られた平均予測精度を表5に示す．

ルールの抽象化処理を行う際，自然要素の差異，共通部分の判定基準として，時間は10分，温度が2度，明るさは50Luxの範囲は同一のものと考えられた．

なお，二つの実験終了時にルール辞書に登録されたルール数は，同じく3788であった．

6 考察

表4と表5の予測精度から，二つの手法においてともに第一週と第二週の予測精度が低いという結果が明らかになっている．これは，データ履歴やルール辞書が，空の状態から始めたためである．これ以外，第7週においては，それぞれ49.57%と53.30%で，それぞれ，第6週目と第8週目の平均予測精度よりも低いという結果も示されている．第二週目の平均予測精度は，N-gramを加えた手法においては逆に0.93%低下していることが示された．これは，N-gramによる解析はこの段階で安定していないことが原因と考えられる．

表 4　帰納的学習を用いたユーザの行動予測手法における週平均予測精度(IL)

Weeks	1	2	3	4	5	6	7	8	9
CPR (%)	21.14	34.43	48.71	54.57	50.71	56.00	49.57	61.71	65.57

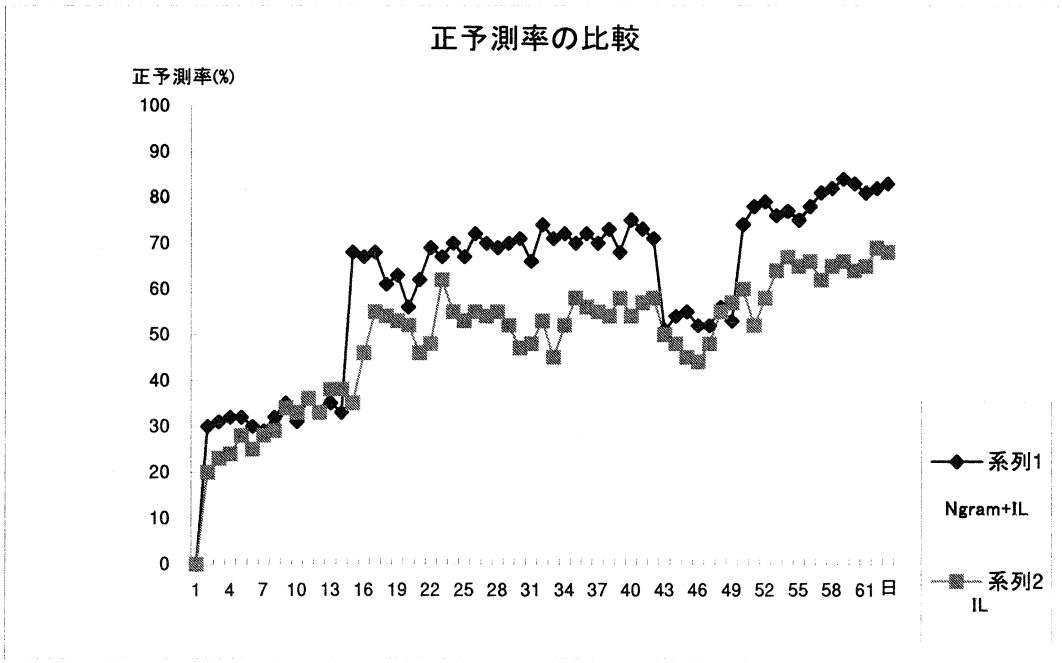
表 5　N-gram を用いた帰納的学習によるユーザの行動予測手法における週平均予測精度(N-gram-IL)

Weeks	1	2	3	4	5	6	7	8	9
CPR (%)	26.30	33.50	63.00	64.20	68.30	71.80	53.30	77.50	82.80

表 6　週ごとに第 7 週のデータとの類似度

Weeks	1	2	3	4	5	6	8	9
Sim (%)	35.60	46.70	50.00	53.30	42.80	46.70	76.30	78.50

図 2:　予測精度の推移



この結果を分析するために，データの類似度を分析する必要がある．以下の式 8 を用いた．他のデータと第 7 週のデータ間の類似度を表 6 に示す．

$$Sim\ (T_x, T_y) = \frac{T_x \bullet T_Y}{|T_x \| T_y|} = \frac{T_x \bullet T_y}{\sqrt{T_X \times T_y}} \bullet\bullet\bullet (8)$$

ここで，$Sim(T_x,T_y)$は類似度を表す，T_x,T_yは一週間におけるデータの数，$|T_x| \bullet |T_y|$は，それぞれ，与えられた自然要素における共通しているデータ数である．

図 2 から示されるように，二つの手法ともに，学習していくほど，その予測精度が高くなっていく．特に，二つの手法を比べると，N-gram を用いた帰納的学習によるユーザの行動予測手法の予測精度が優れていることが示されている．

第一週目の結果においては，使用された尤度評価関数の違いにより予測精度に多少の影響が生じるが，予測性能が上々に上がっていくことが示されている．第二週目の予測結果において，N-gram を使用した手法の予測精度がやや低いのは，この段階では，主に，帰納的学習によるユーザの行動予測が行われているからであると考えられる．

帰納的学習によるユーザの行動予測手法を用いることにより，従来のN-gramアルゴリズムにおけるデータスパースネスの問題を解決することができると考えられる．

また，表6の類似度に示されたように，第一週目から，第6週目まで，互いに類似度が高いことが分かる．この期間では，ユーザは一定のスタイルで生活していることが示されている．さらに，第7週から第9週目のデータの類似度から，新しいスタイルで生活していることがわかる．これらのデータの類似度と対応している予測精度の結果から，システムが動的にユーザの新生活スタイルに適応していることが分かる．その生活スタイルが変更された段階で予測精度が一時的に落ちるが，学習するとともに，予測精度はまた上昇していく．

この性能を用いることにより，システムが実用的になる可能性が示された．例えば，お年よりや体の不自由な方に，本手法による介護システムを用いることで，ユーザの生活習慣や嗜好などに応じてルールを獲得し，そのユーザの行動と意図を推測して，様々な便利な機能が提供できる．さらに，適切な予測精度の閾値を求めれば，ユーザは生活スタイルが変化した場合や、危険な状態に陥った場合に，その状態を知ることができると考えられる．

なお，N-gramを用いた帰納的学習によるユーザの行動予測手法においては，その予測精度はユーザの生活習慣の規則性に依存する可能性がある．ユーザの生活にあまりにも規則性がない場合，予測精度に悪い影響が生じるかもしれないが，これは今後の課題とする．

7 おわりに

本稿では，帰納的学習を用いたユーザの行動予測手法，及びN-gramを用いた帰納的学習によるユーザの行動予測手法を提案した．二つの手法における予測効果とシステムの動的適応能力を確認するために実験を行った．実験の結果，二つの手法はそれぞれ49.16%と60.10%の平均予測精度が得られた．これらの行動予測手法により，システムはユーザに動的に適応可能であることが確認された．さらに，データ履歴とルール辞書は空の状態から得られた実験の結果であるということにより，各々のユーザに動的に適応可能であることも示された．

今後の課題として，異なるユーザに対する有効性の確認，複数のユーザにおけるシステムの有効性の確認，そして最大エントロピーアルゴリズムを用いることによる予測精度の向上などが挙げられる．

文 献

[1] 荒木健治、栃内香次：帰納的学習を用いた自然言語処理の有効性について 信学技報 TL 99-14, pp33-40 (2000年).

[2] Davison.B and Hirsh.H: *Probabilistic online Action Prediction* In Proceedings of the AAAI Spring Symposium on Intelligent Enviornments, Technical Report SS-98-02, pp.148-154:, Stanford University, California, AAAI Press 1998.

[3] Nir Friedman and Zohar Yakhini. *On the sample complexity of learning Bayesian networks*. In Proceedings of the Twelfth Annual Conference on Uncertainty in Articial Intelligence (UAI{96}), pp. 274-282, San Francisco, CA, 1996.

[4] Z. Su, Q. Yang, and H. Zhang. *A prediction system for multimedia pre-fetching on the Internet*. In Proceedings of the ACM Multimedia Conference 2000. ACM, pp.3-11, Los Angeles, CA, USA.October 2000.

[5] Z.Su,Q.Yang,Y.Lu,and H.Zhang.*Whatnext: A prediction system for web requests using n-gram sequence models*. In Proceedings of the First International Conference on Web Information System and Engineering Conference, pp. 200-207, Hong Kong, June 2000.

[6] 荒木健治，栃内香次：帰納的学習による語の獲得および確実性を用いた語の認識、電子情報通信学会論文誌 D-II,Vol.J75-D-II, No.7,pp.1213-1221(1992年)

[7] 荒木健治，高橋祐治，桃内佳雄，栃内香次：帰納的学習を用いたかな漢字変換、電子情報通信学会論文誌 D-II,Vol.J79-D-II, No.3,pp.391-402(1996年).

[8] 松原雅文，荒木健治，桃内佳雄，栃内香次：文字情報縮退方式を用いた帰納的学習によるべた書き文の数字漢字変換手法の有効性について，電子情報通信学会論文誌 D-II, Vol.J83-D-II, No.2, pp.690-702（2000年）.

[9] 王忠建，荒木健治，栃内香次：帰納的学習を用いた単語分割手法の中国語への適用とその性能評価，電子情報通信学会論文誌 D-II, Vol.J85-D-II, No.1, pp.56-65（2002年）.

[10] 山西健司：情報論的学習理論の現状と展望，情報処理 Vol.42 No.1, pp9-15(2001年).

[11] 田中穂積：自然言語処理-基礎と応用-，社団法人電子情報通信学会編(1999年).