59 電子メイルにおける共通部分を用いた帰納的学習による返信文自動生成手法の改良

植松 智* 荒木 健治 栃内 香次
(北大工)†

1 はじめに

現在,電子メイルによる情報のやり取りや意思の疎通が頻繁に行われている.しかし、この電子メイルに対する返信文の作成は多大な労力と時間を要する.そこで,この問題を解決するために,受信メイルに対する返信文を自動的に作成するシステムの需要が増大している.

ここで,受信メイルに対する返信文の生成をおこなうシステムは対話システムの応用として考えることができる.ところが、これまで研究開発されてきたシステムの多くは,応答文を生成する規則があらかじめ与えられ組み込まれている[1][2].そのため,用意されたパターン以外の状況,ユーザ,内容に適した応答の生成が困難であるという問題点がある.

そこで,本研究では実例からそこに内在する返信文生成ルールを動的に獲得することができる,共通部分を用いた帰納的学習[3]による電子メイル返信文自動生成手法を提案する.これは,形態素解析によって得られた形態素の字面情報とその品詞情報から生成ルールを獲得し,この生成ルールを用いて返信文を生成する手法である.本研究では,実験を通じて本手法の性能評価を行い本手法の有効性に対する考察をおこなう.

2 処理概要

まず,受信メイルを形態素解析ツール JUMAN[4]を用いて形態素解析をする.この解析結果を用いて,受信メイルを品詞付き文字列の形にして後の処理を行う.次に獲得されている生成ルールをもとに返信文の生成をおこなう.このとき,適用できる生成ルールが複数ある場合には,尤度計算をおこない最も尤度の高い生成ルールを用いる.さらに,適用できる生成ルールがある場合には,生成ルールの複数適用を行う（図１参照）.また,出力された返信文に対してユーザが校正処理を行い最終的な返信文を完成させる.

このとき,そのまま用いた生成ルールの尤度を上げ,修正・削除された生成ルールの尤度を下げるフィードバック処理を行う.これにより誤った生成ルールは使われにくくなり,正しかった生成ルールが使われやすくなる.完成された返信文も JUMAN で解析を行い,受信メイル・返信文の組から生成ルールの獲得を行う.最後にこの組をメイル対データに保存する.ここで,メイル対データとは,入力された受信メイルと返信文の組を保存しておくテキストデータのことである.各処理の詳細を以下に示す.

２．１ 生成ルール獲得処理

入力された受信メイル・返信メイルの組と,メイル対データに保存されている受信メイル・返信メイルの組を用いて,受信側同士・返信側同士形態素単位での比較を行う.ここで,それぞれに一致する自立語を含んだ品詞付き文字列が存在した場合,これを生成ルールとして獲得する.また,自立語の一致があった場合,その他の部分で品詞のみが一致している部分も同時に獲得する（図２参照）.

（受信メイル）（ルール一回目の適用）
/映画：名詞/って：助詞/何：名詞/が：助詞/好きです：形容詞/か：助詞/？：記号/

（生成ルール）（仮に尤度最大とする）
（受信） /映画：名詞/__/＊：名詞/__/＊：形容詞/__
（返信） /僕：名詞/は：助詞/__/＊：名詞/__
↓（追加適用していく）
（以下の処理は省略）

図１：生成ルール適用例

図１において,受信メイル・生成ルール中の下線部は字面および品詞が一致している部分,破線部が品詞だけが一致している部分,また生成ルールの受信部全てが一致しているとき,その生成ルールが適用できる.さらに,生成ルール返信部中の＊の数だけ追加で生成ルールを適用していく.ただし,このときは追加適用の条件として,返信部＊に代入する部分より前の品詞が一致していることが条件となる.

（受信 入力）
/どんな：指示詞/映画：名詞/が：助詞/好きな：形容詞/の：助詞/？：記号/
（受信 メイル対データ）
/映画：名詞/は：助詞/何：名詞/が：助詞/好きです：形容詞/か：助詞/？：記号/
（受信 一致部分）
/映画：名詞/__/＊：形容詞/__

（返信 入力）
/僕：名詞/は：助詞/サスペンス：名詞/系：名詞/が：助詞/好き：形容詞/か：助詞/な：助詞/。：句点/
（返信 メイル対データ）
/僕：名詞/は：助詞/ドラマ：名詞/が：助詞/好きだ：形容詞/よ：助詞/。：記号/
（返信 一致部分）
/僕：名詞/は：助詞/__/＊：形容詞/__

（生成ルール）
（受信部） /映画：名詞/__/＊：形容詞/__
（返信部） /僕：名詞/は：助詞/__/＊：形容詞/
正適用回数__回 ； 誤適用回数__回 ；

図２：生成ルール獲得例

２．２ 生成ルールの尤度計算

生成ルールの尤度計算は以下の計算式でおこなう。

$$\text{尤度} = \alpha \times CF + \beta \times EF + \gamma \times AG \quad (1)$$

(CF:正適用回数,EF:誤適用回数,AG:品詞一致スコア
本手法では$\alpha=3$,$\beta=5$,$\gamma=2$で行った.)

*uematsu@media.eng.hokudai.ac.jp
†札幌市北区北 13 条西 8 丁目北海道大学工学部

尤度の計算では,正適用回数の比重よりも誤適用回数に比重を置いた.これは生成ルールを選択する際,誤適用回数が出来る限り少ないものを選ぶようにするためである.そのため,係数のパラメータではαよりもβを大きくした.また,受信メイルと生成ルール受信部との一致も尤度に加えた.ここで$\gamma=2$としたのは,正適用回数・誤適用回数ほど比重を置かないが,品詞一致の多さを尤度にある程度反映させるためである.

3 実験

3.1 実験結果

実験に用いるデータは,実際に著者がメイルでやりとりしたメイル対を７９組任意に選んだ.本手法を再現率・適合率という値で評価する.それぞれ以下の計算式で算出するものとする.各入力に伴う生成ルールの獲得数の推移を図３に,再現率と適合率の推移を図４に示す.

$$\text{再現率} = \frac{\text{生成ルールが適用されたメイル数}}{\text{入力されたメイル数}} \quad (2)$$

$$\text{適合率} = \frac{\text{生成ルールが正適用された回数}}{\text{生成ルールが適用された回数}} \quad (3)$$

3.2 評価方法

再現率の計算はメイル単位でおこなう.入力された受信メイル中の文のうち一つでも生成ルールの適用があった場合には,生成ルールが適用されたメイルの個数として加算する.

また,適合率は以下の四種類に分類し１～３を正適用として４を誤適用として評価した.

1. 出力したものが本来の返信文に入っていてそのまま使えたもの
2. 出力したものを一部分削除することで使えるもの
3. 本来の返信文には含まれないが追加しても問題のないもの（省略主語や挨拶表現の追加）
4. 出力したものが完全にまちがっているもの

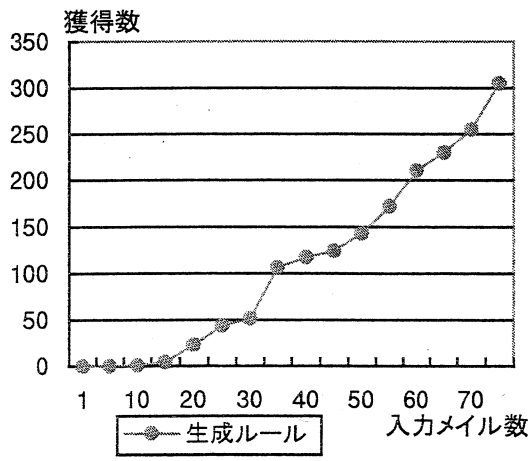


図３：生成ルール獲得数の推移

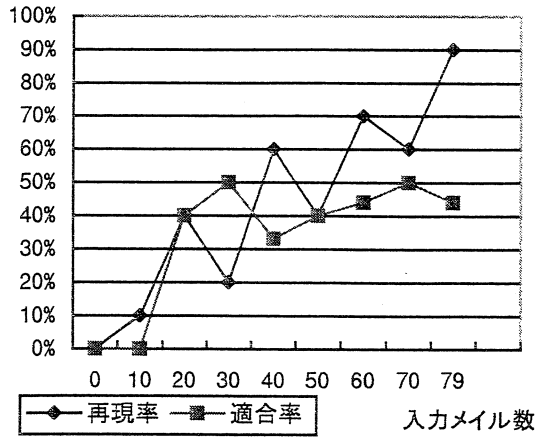


図４：再現率・適合率の推移

4 考察

実験の最終的な結果,獲得された生成ルールは３２６個,再現率は 88.9%,適合率は 44.4%となった.再現率は獲得された生成ルールが増えるにつれて上昇している.それに対して適合率は,生成ルールの増大にかかわらず,あまり上昇していない.これは,獲得された生成ルールに誤った生成ルールが数多く存在していたことや,生成ルールの選択がうまく出来ていないことなどが原因と考えられる.誤った生成ルールが獲得されてしまうのは、生成ルール獲得の際、文同士の対応関係を考慮しないで全ての文同士で生成ルールの獲得を行っているためと考えられる。また生成ルールの選択がうまくいっていないのは、パラメータの不足が考えられる。そのため、出現頻度といった統計的な情報の利用などを考慮していく必要がある。

5 おわりに

本手法では,実験の結果適用された生成ルールの半分以上が誤適用となってしまった.しかし,適合率は入力に伴い上昇して行くことが判明した.そこで,今後の予定としては,誤った生成ルールを獲得しないようにすることや,生成ルールの選択方法・適用の際の閾値の設定などを行い,適合率の上昇を図る予定である.

参考文献

[1] 人工知能学会（編）:人工知能ハンドブック.オーム社(1990)

[2] Weizenbaun,J:ELIZA-A Computer Program for the Study of Natural Language Communication Between Man and Machine Communications of the Association for Computing Machinery vol9,No1,pp,36-45(1996)

[3] K.Araki and K.Tochinai : "Effectiveness of Natural Language Processing Method Using Inductive Learning" ,Proceeding of the IASTED International Conference ARTIFICIAL INTELLIGENCE AND SOFT COPUTING , pp.295-300,2001,Cancun,Mexico.

[4] 黒橋禎夫,長尾真:日本語形態素解析システム JUMAN,version3.61,1999.