56 帰納的学習による入力文予測を用いた補助中国語入力手法

烏日那＊ 荒木健治 栃内香次
(北大工)

1 はじめに

近年計算機の普及に伴ない高速な中国語入力システムの開発が期待されており，それに対する研究[1]も盛んに行われている．通常の中国語ピンイン入力システムは，ピンイン入力，ピンイン漢字変換，語候補から選択するというように構成されている．同音異義語が多いため，連続入力ができないという欠点がある．また，打鍵数が多いため，高速な入力もできない．そこで，ピンイン漢字変換を精度よく行い，入力スピードを向上させるために入力を支援するシステムが必要である．こういったシステムを入力補助システムと呼ぶ．我々は中国語ピンイン入力において入力の打鍵数を減らし，変換を精度よく行うための入力補助方式として，帰納的学習[2]による入力予測を用いた補助中国語ピンイン入力手法を提案する．本手法では，既に入力された文の字面情報より学習を行い，新しい単語を出現頻度の高い順に優先度付きで辞書に登録する．システムは予め与えられた漢字辞書及び獲得された単語辞書を用いてピンイン入力ごとに次の入力を予測する．学習により獲得した単語辞書に基づいて予測するので，ユーザに動的に適応できるという特徴がある．また，予測システムは変換を精度よく行うという効果があるだけでなく，打鍵数を減らす効果もある．試作システムを作成し，実験を行った結果，本方式の有効性が確認された．

2 システムの概要

全体の流れを図１に示す．

2.1 変換処理

まず，入力されたピンインは変換処理で，漢字辞書を用いて同音漢字列に変換される．変換は一文字を単位として行う．漢字辞書は，予めシステムに与えられている．その辞書は中国語基本漢字をもとに作成されており，漢字の最近使用された情報によって決められた優先度情報を持っている．優先度が高い字から当てはめることにより，ピンイン漢字変換が行われる．同音字が複数の場合優先度の一番高い字を出力し，それとともにすべてを選択候補として出力する．変換が正しくなかった場合，校正処理を行う．

＊wrn@media.eng.hokudai.ac.jp
北海道大學大学院工学研究科

これは，人手により同音字列から正しい漢字を選択し，変換結果を訂正する過程である．

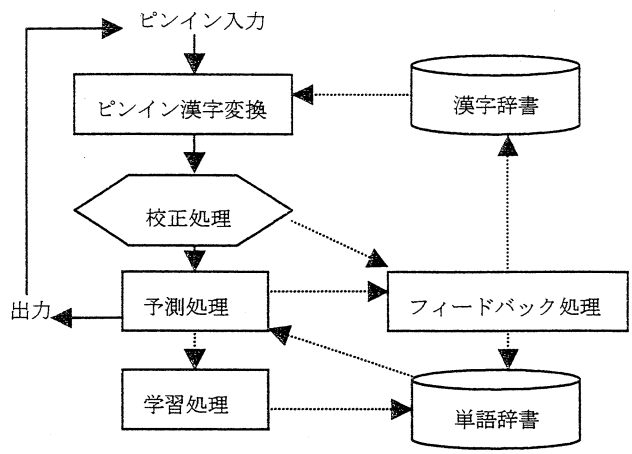


図１ 処理の流れ

2.2 予測処理

変換処理で正変換された漢字を用いて単語辞書を参照し，当てはまる単語を出現確率の高い順に10個出力する．次に，正しい語を手動で選択し，その正予測頻度数を１増加させる．辞書に登録されている単語の優度値（V）を次の式（1）により決定する．

$$V = \alpha * A + \beta * B \quad \cdots\cdots(1)$$

A: 正予測頻度数
B: 単語の優先度数
α, β: 係数（試作システムでは$\alpha = \beta = 0.5$）

2.3 学習処理

学習処理では，入力したピンインと対応する校正済み変換結果の字面情報により，帰納的学習を用いて語を獲得する．この際，ピンイン及び漢字がそれぞれ２文字以上一致する場合，それを語として抽出し，Ｓ１と呼ぶ．さらに，Ｓ１から再帰的に抽出を行い，一致した部分をＳ２として抽出し，残りの部分をＳ３として抽出する．これらの優先度数はＳ２，S1，Ｓ３の順である．それらを単語辞書に登録する．優先度数の定義を表１に示し，語の抽出例を表２に示す．

表１：登録する単語の優先度数

項目	S1	S2	S3
優先度数	2	3	1

2.4 フィードバック処理

正変換された漢字,或いは校正処理で選ばれた漢字の優先度を一番高くし,次回の変換に役立てる.一方,予測の結果から選ばれた予測語候補の優度情報を単語辞書に記録し,次回の予測に役立てる.このように,フィードバック処理により,辞書の活性化を目指し,システムをユーザに動的に適応させる.

表2:語の抽出例

ピンイン	··· kao jiu zhi neng ji suan ji de fa zhan ……ren gong zhi neng de zui xin yan jiu ……ji suan ji ye ……zhi neng ji suan ji de yan jiu ……
漢字	……考究智能計算机的発展……人工智能的最新研究……計算机業……智能計算机的研究……
S1	(zhi neng)智能 (zhi neng ji suan ji)智能計算机 (ji suan ji)計算机 (yan jiu)研究
S2	(zhi neng)智能 (ji suan ji)計算机
S3	(ji suan ji)計算机 (zhi neng)智能

3 評価実験

処理のプロセスに基づき,試作実験システムを作成し,評価実験を行った.学習処理における単語の獲得によって入力語の予測を行った場合と,予測なしに直接変換する場合の変換スピード及び打鍵数を比較した.実験に用いた中国語の論文はそれぞれ同一著者同一分野の2つの文章[5],同一著者異なる分野の2つの文章[6],異なる著者異なる分野の2つの文章[7]である.実験は,中国語の 6,870 個の基本漢字を含む漢字辞書を作成し,単語辞書は空の状態から行った.変換単位は1文字,学習単位は1段落,変換の正変換率と予測の正予測率の評価を行った.以下に示す式 (2) と式 (3) により評価を行う.

正変換率=正変換漢字数/入力漢字総数*100%……(2)

正予測率=正予測文数/予測総数*100% ……(3)

4 考察

実験結果を表 3 に示す.入力文数の増加により,辞書の登録語数が増加し,正変換率及び正予測率が向上しているので,学習機能の有効性が確認された.また,異なる著者異なる分野の2つの文章,同一著者同一分野の2つの文章を用いた実験の正変換率及び正予測率が向上している結果から,システムがユーザに動的に適応していると考えられる.

表3:実験データ

項目	文字数	辞書登録語数	正変換率(%)	正予測率(%)
異なる著者 異なる分野	5,000	324	27.3	19.4
	4,000	506	29.6	17.8
同一著者 異なる分野	5,000	332	25.7	21.1
	4,000	573	31.3	19.0
同一著者 同一分野	5,000	315	27.5	23.7
	4,000	607	35	27.2

5 まとめ

本稿では,中国語ピンイン入力システムの補助方式として,帰納的学習による入力文予測を用いたユーザに動的に適応する補助中国語入力手法を提案し,その実現方法について述べた.同音字候補の自動選択の精度を向上するために,辞書に優度情報を与え,フィードバック処理により,漢字の優先度を変更し,正しい自動選択を行う.また,フィードバック処理により,単語辞書の優度数を変更し,予測の精度を向上する.試作システムを用いて行った実験結果から本手法の有効性が確認された.今後は,実験システムを改善すると共に,実験規模を拡大し,評価する予定である.

参考文献

[1] Liu Changsong, Wu Zhenjun, Qiao Chunlei, Li Yuanxiang: Intelligent Association For Chinese Input Using Statistical Method. Journal of Chinese Information Processing Vol.14 No.1.pp32-38.(1999).

[2] 荒木 健治,高橋 祐治,桃内 佳雄,栃内 香次: 帰納的学習を用いたべた書き文の仮名漢字変換,電子情報通信学会論文誌(D-II),J79-D-II,No.3,pp.391-402(1996).

[3] 蓮井 洋志,西野 順二,小高 知宏,小倉 久和:日本語入力における平仮名文字列の予測.第53回情処学講演論文集. pp.2/125-126.

[4] Masui , T. An efficient text input method for pen-based computers. In proceeding of the ACM conference on Human Factors in ComputingSystems(CHI' 98)(April1998), Addison-Wesley, pp.328-335.

[5]ZHANG YALE:"21 世紀知能計算機", "計算機未来展望".

[6]ZHAO LEI:"中国語入力方法", "HNC 理論概要".

[7]XIE GUOZHONG:"人民幣日本円", MIAO CHUANJIANG:"自然言語理解新概念"