54 再帰チェーンリンク型学習による対訳コーパスからの対訳語ペアの自動獲得手法

越前谷博 †* 荒木健治 ‡ 桃内佳雄 † 栃内香次 ‡
(学園大工)† (北大工)‡

1 はじめに

機械翻訳システムにおいて，翻訳時に対訳辞書に登録されていない用語が出現する状況，すなわち，未登録語の問題をどのように解決するかは，翻訳品質の向上の観点から非常に重要である．この未登録語の問題に対しては，近年，対訳コーパスから対訳語ペアを抽出する研究が盛んに行われている．これらは，統計処理によるアプローチ [1] と言語知識を利用するアプローチ [2][3] に大きく分けることができる．しかし，これらのアプローチはそれぞれ問題を抱えている．統計処理によるアプローチでは，良質な対訳辞書を作成するためには，大規模な対訳コーパスが必要となる．更に，このアプローチでは，解析的な知識を用いてあらかじめ対訳コーパスを加工することを前提としている．一方，言語知識を利用するアプローチでは，基本的な対訳辞書の使用に基づくため，その基本対訳辞書の精度に大きく依存してしまう．また，これら二つのアプローチは共に，特定の言語に特化した手法であるため，汎用性は低くなる．このような問題点に対し，我々は，少量の対訳コーパスから，形態素辞書や対訳辞書などの解析的な知識に依存することなく対訳語ペアを自動獲得する手法として，再帰チェーンリンク型学習による対訳コーパスからの対訳語ペアの自動獲得手法を提案する．

2 再帰チェーンリンク型学習による対訳語ペアの獲得

本稿における再帰チェーンリンク型学習とは，ある対訳コーパス中の対応関係が決定されると，システムがそれをもとに，他の対訳コーパスから次々と連鎖的に対訳コーパス中の対応関係を決定する手法である．Fig.1 に，英日の対訳コーパスを対象とした再帰チェーンリンク型学習による対訳ペアの抽出処理の具体例を示す．

Fig.1 は，部分レベルの対訳ペアとして（dog ; イヌ）が存在することにより，文レベルの対訳ペアとして（The @0 is not liked by them. ; その/@0/は/彼ら/に/好か/れ/て/い/ませ/ん.）が獲得され，更に，この文レベルの対訳ペアにより，部分レベルの対訳ペアとして（Ishikari River ; 石狩川）が獲得されたことを示している．なお，連鎖的な対訳ペアの獲得処理において，(dog ; イヌ）のような起点となる対訳ペアの獲得は，学習型機械翻訳手法である，遺伝的アルゴリズムを適用した帰納的学習による機械翻訳手法 [4] を用いて行う．このように再帰チェーンリンク型学習では，部分レベルの対訳ペアと文レベルの対訳ペアが連鎖的に交互に獲得されていく．このような処理は，それぞれの対訳ペアが有する対訳コーパスからの切り離し部分の位置情報に基づき行われる．処理１では，部分レベルの対訳ペア A（dog ; イヌ）の持つ，英文からは “dog” を，訳文からは “イヌ” を抽出するという情報に基づき，システムは対訳コーパス１より文レベルの対訳ペアとして（The @0 is not liked by them. ; その/@0/は/彼ら/に/好か/れ/て/い/ませ/ん.）を獲得する．処理２では，この文レベルの対訳ペア B の持つ，英文では “The” の右側から “is” の左側までが，日本語訳文では “その” の右側から “は” の左側までが抽出部分であるという情報を利用し，新たな部分レベルの対訳ペアを獲得する．この例では，日本語訳文に関しては，対訳コーパス２の日本語訳文に “その” が存在しないため，“は” の左側から文の先頭までが抽出部分となる．その結果，対訳コーパス２の英文から “Ishikari River” を，日本語訳文から “石狩川” を抽出し，部分レベルの対訳ペア C（Ishikari River ; 石狩川）を獲得する．そして，獲得された部分レベルの対訳ペアが対訳語ペアとなる．このように，再帰チェーンリンク型学習では，個々の対訳ペアの持つ抽出部分の情報に基づき連鎖的に対訳ペアを獲得していく．したがって，再帰チェーンリンク型学習を用いることで，解析的な知識に依存することなく対訳語ペアを獲得することが可能となる．

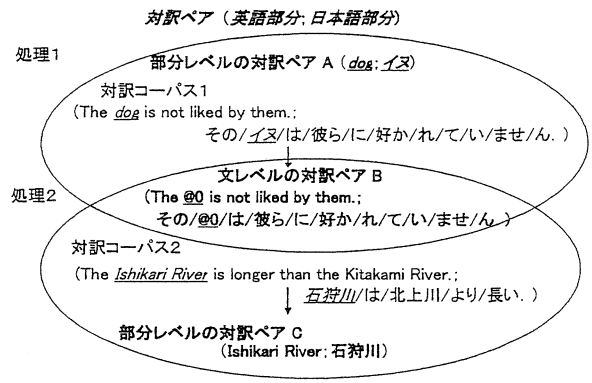


Fig. 1 再帰チェーンリンク型学習による対訳ペア抽出の具体例

3 処理過程

再帰チェーンリンク型学習により獲得される対訳ペアは部分レベルの対訳ペアと文レベルの対訳ペアの２種類であり，それらは交互に獲得される．最初に，Fig.1 の処

*chi@eli.hokkai-s-u.ac.jp
札幌市中央区南 26 条西 11 丁目北海学園大学工学部

理1に示す，部分レベルの対訳ペアを用いた，文レベルの対訳ペアの獲得の処理過程を述べる．

(1) 対訳ペアの英語部分とその日本語部分が共に対訳コーパスの英文とその日本語訳文と包含関係にある部分レベルの対訳ペアを選択する．

(2) 対訳コーパスの英文とその日本語訳文のそれぞれにおいて，重複する部分を変数に置き換える．そして，それらを一つのペアとすることで文レベルの対訳ペアを獲得する．

次いで，Fig.1の処理2に示す，文レベルの対訳ペアを用いた，部分レベルの対訳ペアの獲得の処理過程を述べる．

(1) 対訳コーパスとの間で，共通部分の存在する文レベルの対訳ペアを選択する．本手法では，字面レベルで1語でも共通の単語が存在する時，それが共通部分となる．

(2) 共通部分が文レベルの対訳ペア中の変数部分と隣接する場合，以下のいずれかの処理を行う．

- 文レベルの対訳ペアの変数部分が共通部分に挟まれている場合，対訳コーパスの英文とその日本語訳文中の共通部分で挟まれている部分を抽出する．
- 文レベルの対訳ペアにおいて，変数部分の右側のみに共通部分が存在する場合，対訳コーパスの英文とその日本語訳文中の共通部分の左側から文の先頭までを抽出する．
- 文レベルの対訳ペアにおいて，変数部分の左側のみに共通部分が存在する場合，対訳コーパスの英文とその日本語訳文中の共通部分の右側から文の末尾までを抽出する．

(3) 対訳コーパスの英文とその日本語訳文のそれぞれから抽出された部分を組み合わせることで，部分レベルの対訳ペアを獲得する．

4 性能評価実験

4.1 実験方法

初めに中学1，2年生用の英語テキスト[5][6][7][8][9]に掲載されている対訳コーパス2,856組を再帰チェーンリンク型学習を備えたシステムに与え，対訳ペアを自動獲得させた．同時に，同様の対訳コーパス2,856組の英文をA社より市販されている商用機械翻訳システムに翻訳させた．その結果，商用機械翻訳システムにおいて，対訳辞書に登録されておらず，翻訳されなかった英単語を抽出した．そして，それらの未登録語を対象に，再帰チェーンリンク型学習により，どれだけの対訳語ペアが獲得されたのかを調査した．

4.2 実験結果と考察

商用機械翻訳システムを用いた翻訳結果において，未登録語数は37個であった．そして，その37個の未登録語に対し，再帰チェーンリンク型学習により獲得できた対訳語ペアの数は23個であった．したがって，商用機械翻訳システムで出現した未登録語の62.2%に対し，再帰チェーンリンク型学習により対訳語を獲得することができたことになる．また，その対訳語ペアの獲得推移に着目すると，前半の未登録語数19個に対して獲得できた対訳語ペアの数は10個，後半の未登録語数18個に対し獲得できた対訳語ペアの数は13個であった．したがって，前半と後半とでは対訳語ペアの獲得精度は52.6%から72.2%へと大きく向上していることが確認できた．これは，再帰チェーンリンク型学習により，学習の進行に伴い連鎖的な対訳ペアの獲得処理がより効果的に行われていることを示している．

4.3 おわりに

本稿では，対訳コーパスから対訳語ペアを学習能力に基づき獲得する，再帰チェーンリンク型学習による対訳語ペアの自動獲得手法を提案した．再帰チェーンリンク型学習を用いることにより，対訳コーパスを効率良く使用できるため，膨大な量の対訳コーパスを必要とすることなく対訳語ペアを自動獲得できる．更に，再帰チェーンリンク型学習により獲得された対訳ペアそのものが，他の対訳コーパスからの対訳語ペアを獲得する際の情報源となるため，解析的な知識に依存することなく対訳語ペアを獲得することが可能である．今後は，より実用面を重視し，専門分野における未登録語の解決に向けての研究を進める予定である．

参考文献

[1] 北村美穂子，松本祐治：対訳コーパスを利用した対訳表現の自動抽出，情報処理学会論文誌，Vol.38, No.4(1997).

[2] 熊野明，平川秀樹：対訳文書からの機械翻訳専門用語辞書作成，情報処理学会論文誌，Vol.35, No.11(1994).

[3] 梶博之，相薗敏子：共起語集合の類似度に基づく対訳コーパスからの対訳語抽出，情報処理学会論文誌，Vol.42，No.9(2001).

[4] 越前谷博，荒木健治，桃内佳雄，栃内香次：実例に基づく帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性，情報処理学会論文誌，Vol.37，No.8(1996).

[5] 教科書ガイド教育出版版ワンワールド1，日本教材，東京(2001).

[6] 教科書ガイド教育出版版ワンワールド2，日本教材，東京(2001).

[7] 教科書システム問題集2，朋友出版，東京(2001).

[8] 教科書ワーク2，文理，東京(2001).

[9] 教科書トレーニング2，新興出版社，大阪(2001).