14 枝分かれするネットワークを用いた前方照応解析

山田憲司* 荒木健治 栃内香次

(北海道大学大学院工学研究科)†

1 はじめに

言語理解において文脈解析は不可欠であり，文脈解析ではある単語について先行詞があるのかないのか，またどの単語が先行詞なのかを解析する照応解析が必要となる．この照応解析は対話システムや高品質の機械翻訳システムを実現するために必要になってくる．例えば，ある文中の「そこで」という単語の翻訳を行う際に，この単語が特定の場所を指している代名詞であるのか，それとも文の前後を接続する接続詞であるのかを判定するためには照応解析を行って先行詞の有無をはっきりさせることが必要となる．ところで，照応解析を行う際，従来の手法では先行詞の探索範囲をあらかじめ決定しなければならないという問題点が存在する．つまり従来の手法では，あらかじめ先行詞が存在すると推定される文の範囲をｎ文前までと決定しておかなければならないため，もし先行詞がｎ文前よりさらに前に出現していた場合には先行詞を見つけ出すことができない．また，従来の手法では先行詞を探索する範囲をｎ文前までというように文単位で決定しなければならないという問題点も存在する．文単位で先行詞の探索を行うことは，文中に存在する単語を文脈における焦点を考慮せずに一様に扱ってしまうことになる．

本研究では，枝分かれするネットワークを用いて意味構造から前方照応の照応解析を行う手法を提案する．

本手法では，竹内らの枝分かれするネットワーク［1］［2］構造を用いて意味構造および照応関係を一緒に扱うことにより，文脈を１つのネットワークで表現することができる．本手法のネットワークでは，単語の表記や概念そして文脈中における単語の実体をノードと，それらのノード間の関係をリンクとそれぞれ対応させる．そして，ノードをリンクで接続することによって，意味構造や文脈を表現する．

本手法のネットワークでは，ネットワーク中の全てのノード，リンクが活性値を持つ．ここで，ノードの活性値はそのノードが表す単語への関心の高さつまり焦点を表し，リンクの活性値はそのリンクが接続するノード同士の接続の強さを表す．

本手法で，照応解析を行うには，まず解析の対象となる単語を表すノードの活性値を高くする．そして，そのノードの活性値をノードに接続しているリンクの活性値による影響を考慮しながら他のノードに伝播させていく．この活性値の伝播を活性値の変動が収束するまで繰り返す．そしてその結果，活性値が高くなったノードを調べることで照応解析を行う．

ここで，ネットワーク中の概念をあらわすノードを，シソーラス［4］を用いて階層的に接続することにより，単語の概念の類似性を用いて照応解析を行うことができる．

本手法では格構造を表現しやすくするために，竹内らのリンクを分岐させたネットワーク構造［1］［2］を用いた．これにより，格構造を構成する名詞，動詞，格概念あらわすノードを直接結合することが可能になり，格構造を明確に表現できる．また，本手法では意味構造を入力として解析を行うが，このとき本手法で枝分かれするネットワークを用いることにより，竹内らの手法［3］によって意味構造解析を行った結果をそのまま入力として解析を行うことができる．

ネットワークを用いて照応解析を行う理由は，文脈を１つのネットワークとして表し，照応解析をそのネットワーク上で活性値を伝播させることによって行うという方式を取ることにより，解析型の解析手法においてｎ文前までを解析の対象とするといった制約にとらわれずに解析を行うことができるためである．

今回，解析の対象を前方照応としたのは，まずこの手法の有効性を実証するために解析の対象を絞ったためである．ただし，将来後方照応についてもこの手法を改良することにより解析を行いたいと考えている．

2 ネットワークの構造

本手法のネットワークにおいて，ノードは単語の表記，概念，または文脈中における単語の実体に対応する．

ノードには以下の３種類が存在する．

・単語ノード～単語の表記に対応するノード
・概念ノード～単語の概念に対応するノード
・実体ノード～文脈中における単語の実体に対応するノード

*kenjiy@media.eng.hokudai.ac.jp
†札幌市北区北 13 条西 8 丁目北海道大学工学研究科

そして，ネットワークは存在する単語ノードの種類によって，単語ノードを含む単語層，概念ノードを含む概念層，そして実体ノードを含む文脈層の３つの層に分けられる．

リンクは，単語ノードとその単語の概念に対応する概念ノード間，上位・下位概念を表す概念ノード間，意味構造を表す概念に対応する概念ノード間，文脈を表す単語の実体に対応する実体ノード間等に張られる．

ネットワーク中のすべでのノード，リンクはそれぞれ活性値を持ち，この活性値を伝播させることによって照応解析を行う．

2.1 ノードについて

ノードには単語ノード，概念ノード，実体ノードの３種類が存在する．

単語ノードは単語の表記を表し，本文中では「本」を表すノードは"本"と記述する．

概念ノードは単語の概念を表すものと意味構造における格の概念を表すものの２つのタイプが存在する．単語の概念はシソーラス［4］における分類番号を用いて表し，本文中ではこのノードを分類番号で"1.3160"のように記述する．格の概念は Fillmore の深層格［5］に対応するもの１１種類（表1）を用いてあらわし，本文中ではその格を示す略語によって"OBJ"のように記述する．

実体ノードは文脈においてその単語の実体が存在することを表す．そのため，１つの存在につき１つの実体ノードしか作成されない．よって，入力文に対して照応解析を行った結果，ある単語Ｗ１の先行詞が別の単語Ｗ２と解析された場合には，この２つの単語ごとに実体ノードを作成するのではなく，１つの実体ノードで２つの単語を表すようにする．本文中では実体ノードであることを断わった上で単語ノードと同様の表記を用いて記述する．

2.2 リンクについて

リンクはノード間を接続し，それが示す意味は接続するノードの種類によって異なる．

概念層では，単語の概念を表す概念ノード間を接続するリンクは，接続した概念の上位・下位を表現する．また，単語の概念を表す概念ノードと格を表す概念ノードの間を接続するリンクは，格構造つまり意味構造を表す．

単語層では，単語ノードとその単語に対応する概念層の概念ノードをリンクで接続することにより，単語の概念と表記を対応付ける．

文脈層では，文脈中における単語の存在を表す実体ノードとその単語を表す概念ノードを接続することにより，その単語の実体と概念・表記を対応付ける．また，実体ノード間を接続することによって，文脈を表現する．

本文中ではノードＡとノードＢを接続するリンクを｛Ａ－Ｂ｝と記述する．

2.3 格構造の表現

格構造は概念ノードとその間に張られたリンクによって表現する．

動詞概念ノード"Ｖ"と格概念ノード"Ｃ"をリンクで｛Ｖ－Ｃ｝と接続することによって動詞概念"Ｖ"が格Ｃを取ることを表し，このリンクを分岐させて名詞概念ノード"Ｎ"と｛｛Ｖ－Ｃ｝－Ｎ｝のように接続することにより格構造を表現する．

ここで，動詞Ｖ，名詞Ｎ，格Ｃからなる格構造を「Ｖ→Ｃ（Ｎ）」と表すとすると，格構造「読む→OBJ（本）」をネットワークで表すと図１のようになる．

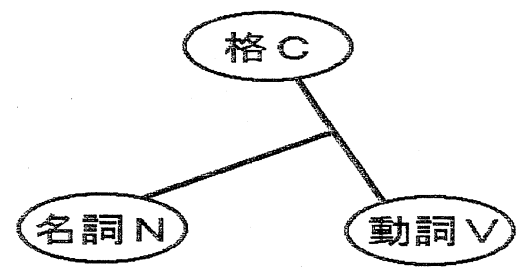


図１．格構造の表現

2.4 文脈の表現

文脈は実体ノードとその間に張られたリンクによって表現する．

ある単語の実体ノードＥ1 とＥ２が存在しその間の格がＣである場合，この格構造は接続するノードが実体ノードであるという点を除いて，２．３で示した格構造の表現と同様に表される．

ただし，２つの格構造「動詞Ｖ１→格Ｃ１（名詞Ｎ１）」と「動詞Ｖ２→格Ｃ２（名詞Ｎ２）」について照応解析を行った結果，名詞N1 が名詞Ｎ２の先行詞であると解析された場合には，この２つの名詞の実体は１つであるので，これを１つの実体ノードで表す．

ここで，２つの格構造「読む→OBJ（本）」と「書く→OBJ（それ）」が入力され，照応解析を行った結果，「それ」の先行詞が「本」であると解析された場合にはネットワークは図２のようになる．

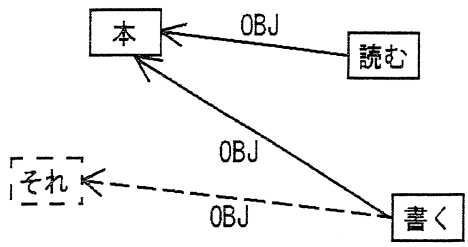


図2．文脈の表現

3 照応解析アルゴリズム

3.1 活性値

本手法のネットワークではネットワーク中のすべてのノード，リンクが活性値を持つ．ノードの活性値はそのノードが表す単語の概念や実体への関心の強さ，つまり焦点を表現する．

ところで，人には古い物事に比べ新しい物事により強く関心がいくという傾向があると考えられる．そこで，そのような傾向を模して，ノードの活性値を時間の経過とともに少しずつ減少させる．式（1）は時間sの経過とともに活性値が減衰率αで減衰することを表す．

$$V(s)=\alpha V(s-1) \quad \cdots (1)$$

ただし，sは新しい入力文が入力されるごとに増加する値とする．今回は$\alpha=0.9$とした．リンクの活性値はそのリンクが接続するノード間の結合の強さを表現する．

3.2 活性値の拘束条件

活性値の伝播を確実に収束させるために，活性値の正規化を行う．式（2）はある時間tにおける活性値$V(t)$の総和が一定であることを表す．

$$\sum V(t)=Const \quad \cdots (2)$$

3.3 活性値の伝播

本手法では，ネットワーク中のノードの活性値を伝播させることにより照応解析を行う．

まず，解析の対象となる単語のノードの活性値を高くする．次に，この活性値を接続しているリンクやさらにその先に接続されている別のノードの活性値と相互に作用し伝播させる．ここで，相互作用するのは隣接するノード，リンクの間のみであり，距離が2つ以上離れているノード，リンクとは相互作用しない．これは相互作用する範囲を拡大することによる計算量の増加を抑えるためや，活性値は伝播していくので範囲を2に限定しても範囲を3以上に設定した場合と同様の効果が期待できるという理由によるものである．

時刻tにおけるあるノード（またはリンク）xの活性値$Vx(t)$は，xに隣接するノード（またはリンク）を$\bar{x}$と表すと以下の式（3）で求められる．式（3）はある時刻tの活性値$V(t)$が時刻$t-1$の自らの活性値と隣接するノード，リンクの活性値から求められることを表す．

$$Vx(t)=Vx(t-1)+\sum Wx\bar{x}\times V\bar{x}(t-1) \quad \cdots (3)$$

ここで$Wx\bar{x}$はxと$\bar{x}$の間の結合強度であり，今回の手法では1.0とした．$V\bar{x}$はxに隣接するノード（またはリンク）$\bar{x}$の活性値である．

活性値を伝播させた結果，最も活性値が高くなったノードを，解析の対象名詞の照応解析結果とする．ここで，対象の名詞に先行詞が存在しない場合を考慮し，活性値を伝播させた結果，一定の閾値を超える活性値を持つノードが存在しなかった場合は，先行詞が存在しないものとする．このとき用いる閾値を活性値存在判定閾値と呼ぶ．

3.4 ネットワークの更新

3．3によって照応解析を行った結果をもとに，単語の実体を表す実体ノードとそれらの間の格構造を表すリンクをネットワークに登録する．

実体ノードの登録は以下のように行う．ある単語W1において，先行詞W2が存在すると解析された場合は，単語W1について新しく実体ノードを作成せずに，解析された先行詞W2を表す実体ノードを単語W1の実体ノードとする．そして，単語W1の実体ノードに接続するリンクは先行詞W2の実体ノードに接続する．一方，先行詞が存在しないと解析された場合には，この単語W1自体が唯一の実体となるため，単語W1を新しい実体ノードとしてネットワークに登録する．実体ノードの登録を行った後，3．1で示した活性値の更新を行う．

4 実験

本手法に基づいた実験システムをWindows上にC++を用いて作成した．

4.1 入力文

入力文には英語教材[6]の「花咲か爺さん」和訳文より22文(意味構造90組，総文字数181文字)．この入力文を用いた理由は，この英語教材自体がそれほど高度な内容ではなく，その和訳文であるため，文が平易に書かれているからである．

4.2 初期状態

システムの初期状態においては，各ノード，リンクの活性値は全て正で等価とした．

4.3 実験結果

実験結果を図３に示す．実験結果の評価は以下のように行った．入力文中の各単語には，先行詞が存在するものと存在しないものがあるため，これらを解析する場合を区別して評価する．まず，先行詞が存在しない単語の場合については，「先行詞がない」と解析された場合を正解析，「先行詞がある」と解析された場合を誤解析とする．次に，先行詞が存在する単語の場合については，「先行詞がない」と解析された場合を誤解析，先行詞が正しいかはともかく「先行詞がある」と解析された場合を未解析，「先行詞がある」と解析され更にその先行詞が正しいものである場合を正解析とする．各解析率は以下の式（４）で計算する．

$$解析率 = \frac{各条件に適合した単語数}{解析した単語数} \times 100 \quad \cdots (4)$$

4.4 考察

実験の初期段階において解析が成功している理由は，入力文の先頭であり先行詞がない単語を，ネットワーク中にもまだ実体ノードが他に存在していないため「先行詞がない」と解析しているためである．

正解析率を上昇させるためには，３．３で示したノード（リンク）間の結合の強さを表す重みを，今回は 1.0 で固定としたが，この値を接続するノードやリンクの参照回数などを考慮して変動させることが考えられる．また今回，活性値の値は，時間の経過と共に一定の割合で減少するようにしているが，この活性値の減少のさせ方についても検討する必要があると考えられる．さらに，今回は活性値の伝播は，概念を表すノードや実体を表すノードの区別無く一様に行ったが，これをノードの種類を区別して活性値の伝播を行うことも考えられる．

5 まとめ

本稿では，枝分かれするネットワークを用いて意味構造から前方照応の照応解析を行う手法を提案した．システムを作成して実験を行った結果，正解析率は 12.5％と低かったが，活性値の伝播方法をノードの種類により変更することや，接続の重みを考慮して活性値の伝播を行うことにより，改善できることが 6．3％程度確認された．今後の課題としては，活性値を発散させずに適当な値で収束させる方法を適用することが考えられる．

参考文献

[1] 竹内俊行，荒木健治，栃内香次，枝分かれするネットワークを用いた格構造解析手法の性能評価，信学技報，NLC99-3 15-22，May 1999.

[2] 竹内俊行，荒木健治，栃内香次，枝分かれするネットワークを用いた格構造解析システムへの頻度情報の導入とその評価，情報研報，NL134-10 pp.71-78，1999.

[3] [竹内俊行，荒木健治，栃内香次，Marker Passing 形式のパーザにおける力学的制約を用いた意味吊り上げモデルによる格構造解析手法，電子情報通信学会論文誌 D-Ⅱ Vol.183-D-Ⅱ No.12 pp.2755-2766，2000.

[4] 国立国語研究所，分類語彙表，秀英出版，1964

[5] C.Fillmore（著），田中春美，船城道雄（訳），格文法の原理，三省堂，1980.

[6] 遠山顕，モナ遠山，NHK ラジオ英会話入門 2001 年 2 月号，2001.

[7] BLIN Raoul，日本語の名詞句における照応計算モデル，自然言語処理 144-13，1996.

[8] 藤澤伸二，増山繁，内藤昭三，日本語文章における照応・省略現象の基本的検討，自然言語処理 85-6，1991.

[9] 村田真樹，長尾真，用例や表層表現を用いた日本語文章中の指示詞・代名詞・ゼロ代名詞の指示対象の推定，自然言語処理 108-7，1995.

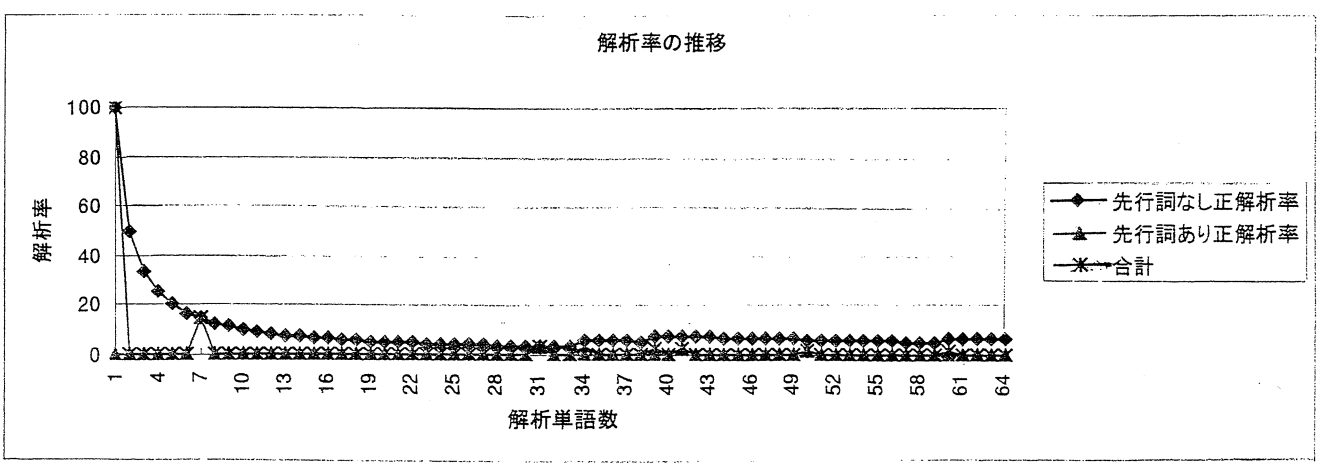


図３．実験結果