1 帰納的学習を用いた文字情報縮退方式による日本語入力システムへのヒューリスティックス導入の有効性

竹内俊行* 荒木健治 栃内香次
(北都システム株式会社)† (北大工)

1 はじめに

近年, 携帯電話の性能が著しく向上している. 携帯電話によるメールはもはや当然であり, メール機能を持たない携帯電話は皆無といえる程である. しかし, 携帯電話ではその携帯性を重視するため本体が小型であり, キーの数が少ない. そのため, 日本語の入力はパソコンなどと比較して非常に手間がかかるものとなっている.

現在の携帯電話の文字入力では文字循環指定方式が主流となっている. この方式では, 「1」キーが「あいうえお」(ア行), 「2」キーが「かきくけこ」(カ行) というように対応しており, それぞれのキーを押した回数によって,「1」キーを1回で「あ」, 2回で「い」というように文字を指定する。例えば, 「こんにちは」と入力する際には「2222200055446」と入力する必要がある。

このような手間を軽減するために文字情報縮退方式による文字入力手法がすでに提案されている [1]. 我々は, この論文の手法にヒューリスティックスを導入することにより変換精度の向上を行ない, さらに, ユーザーインターフェイスとの兼ね合いや, システムの軽量化などを検討している.

本稿では, Windows 上でシミュレーションしたシステムを用いて, 変換精度や打鍵数などから, 導入したヒューリスティックスの有効性を検討する.

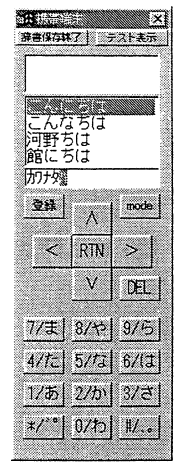


Fig. 1 Windows 上にシミュレートした携帯端末

2 システムの概要

Windows アプリケーションとしてシステムを構築した. システムの概観を図 1に示す. 一般の携帯端末に近いデザインとなっている. ディスプレイ部分は 3 分割されており, 上段は確定した文が表示されるメイン画面, 中段が入力中の文字列に対応する変換候補表示画面, 下段が入力中の文字列が表示される入力画面となっている.

システムの処理の概要を図 2に示す. ユーザーの入力は変換部へ送られる. 変換部ではユーザーが変換候補の選択や変換範囲の指定などを行なう. 文字列を確定するとその文字列がメイン画面に送られる. 学習部では入力された文字列と最終的に確定された文字列を用いて学習を行ない, 学習辞書の内容を更新する.

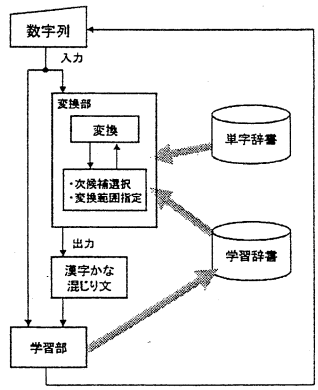


Fig. 2 システムの概要

2.1 文字情報縮退方式

文字循環指定方式では, 「2」キーがカ行に対応し, それを押した回数で「か」「き」「く」「け」「こ」を指定する. しかし, 文字情報縮退方式では「2」キーでカ行を指定するのみで, 同じキーを複数回押して文字を決定するということはく, システムが最も適当な文字の組合せを自動的に決定する. 「こんにちは」であれば「20546」と入力するだけで, それに該当する文字列のうち, 最も適当な語, ここでは「こんにちは」が候補として選択される.

また, 文字情報循環指定方式では, 同一行の文字を連続して入力する際, カーソルを進めるといった例外的な処理が発生し, それも操作を煩雑にする一因であった. 例えば, 「企画」と入力したい場合には, 「22→2→222」[1] と入力する必要がある. しかし, 文字情報縮退方式では一打で 1 文字を決定できるので, 例外的なカーソルキーの入力は必要なく, 「222」というキー入力で「企画」と

*takeuchi@hscnet.co.jp
†札幌市厚別区大谷地東 1 丁目 3 番 23 号

[1]「→」はカーソルキー

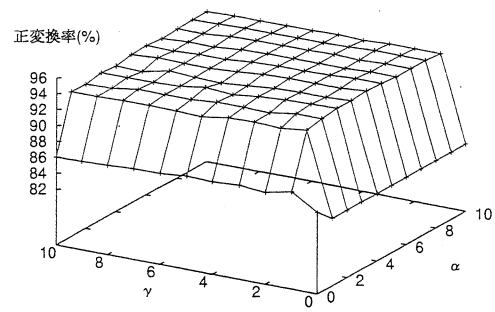


Fig. 3 尤度評価関数の予備実験

いう候補が出力される.

2.2 変換部

入力に対して複数の変換候補が存在する場合には, 語の確からしさを評価する指標を用いる. この指標として尤度評価関数 PEF を以下のように定義し, この値が大きなものから順に第1候補, 第2候補として変換に使用する.

$$PEF = \left(\frac{\alpha AF + \beta CF - \gamma EF}{\alpha AF + \beta CF + \gamma EF}\right) \times LEN \quad (1)$$

ここで, AF は語の出現頻度, CF は正変換度数, EF は誤変換度数, LEN は語の文字長を表す. また α, β, γ は係数であり, 予備実験より $\alpha = 1, \beta = 1, \gamma = 1$ という値を最適値として得ている. この予備実験の結果を図3に示す. この実験では, $\beta = 1$ に固定しておき, α, γ の値をそれぞれ 0 ~ 10 と変化させて, 正変換率の変化を確認した.

この式により, 確定された文中に出現した頻度の高い語や正変換に使用された語の尤度は高くなり, 誤変換に使用された語の尤度は低くなる.

2.3 学習部

学習部では, 入力された文字列 (数字列) と確定された文字列 (漢字かな混じり文字列) を用いて帰納的学習 [1][2][3] を行ない, 新規単語を獲得する. さらに獲得された単語のパラメータの更新や, 獲得した単語に隣接する文字列の情報の更新なども行なう.

2.3.1 語の獲得

入力された文字列 (数字列) と確定された文字列 (仮名漢字文字列) から対応する部分を抽出することによって語候補を得る. 例えば, 2つの文,

入力された文 383*853861
確定された文 種々の手法

が与えられると, 「の」に対応する文字は「5」となる. そして, 「の」「5」それぞれの両側の語が対応するものとして, 「種々」と「383*8」, 「手法」と「3861」の対応が得られ, それぞれが辞書に登録されていない場合には, 新規獲得語として辞書に登録される.

また, すでに辞書に登録されている語同士でも同様の処理を行なう. この処理によって, 入力文と確定された文からだけでは分割しきれなかった部分の分割を行ない, より確実性の高い語を得ることができる.

2.3.2 フィードバック学習

すでに登録されている語のパラメータを更新する. 確定された文字列と第1候補のみからなる文字列を比較し, 第1候補による変換が正しければその語の正変換度数 CF を1増加させ, 誤っていれば誤変換度数 EF を1増加させる. これらのパラメータは式 (1) の尤度評価関数に使用され, CF の大きい単語ほど上位の候補, EF の大きい単語ほど下位の候補となる.

3 変更点

論文 [1] で発表されたシステム (以下、オリジナル) から様々な点に改良を加えたが, 最も重要な変更は以下の3点である.

3.1 尤度評価関数の変更

オリジナルの手法では語の確からしさを表す尤度評価関数は以下のような式で表現される.

$$PEF = \alpha \times CR - \beta \times ER \quad (2)$$

ここで, CR は正変換率, ER は誤変換率であり, それぞれは正変換度数 CF, 誤変換度数 EF を用いて, $CR = \frac{CF}{CF+EF}$, $ER = \frac{EF}{CF+EF}$ と表現される. また α, β は係数であり, 実験では $\alpha = 1, \beta = 5$ という値が用いられている.

これを本稿では式 (1) のように変更した. CF と EF はシステムが変換処理を行なった際に使用した語が適切であったかどうかを表し, AF は変換に使用されたか否かにかかわらずユーザが確定した文字列の中から語が獲得された回数を表す. オリジナルの手法では AF を用いていないが, これも尤度の重要な指標であると考え, 尤度評価関数に組み入れた.

オリジナルの手法, 本稿の手法ともに隣接する文字列情報の有無などによってさらに尤度が変動する.

3.2 隣接する文字列情報の変更

オリジナルの手法では隣接する文字列情報を n-gram 統計を用いて計算している. この手法は携帯電話に搭載するには処理が膨大となるため, 本稿では最近隣接した1文字を n 文字まで隣接文字として扱うこととした. 語が獲得または使用された際, その語の前後に隣接した文字をそれぞれ n 文字までスタックする. n 文字を越えた場

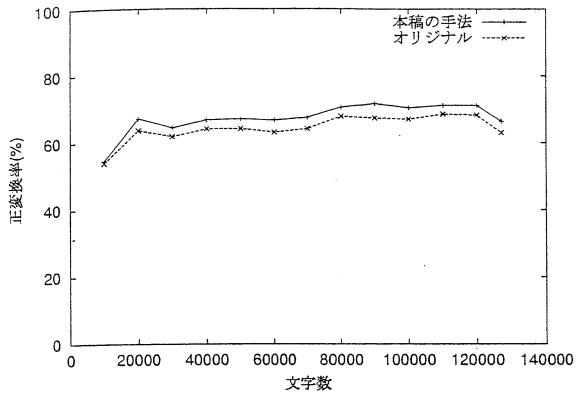


Fig. 4 隣接する文字列情報の予備実験

合は最も古い文字を削除し, 新しい文字を追加する. 語を変換する際, その語の前後に隣接している文字がスタック中に存在した場合, 語の尤度を上昇させる. 単純な処理であるが, この方法で十分な効果が得られることを予備実験で確認している. この予備実験の結果を図 4に示す. 図 4で, 実線は本節で紹介した手法を用いたものであり, 破線はオリジナルの手法によるものである.

3.3 辞書サイズの制限

オリジナル手法では辞書のサイズに特に制限は定めていないが, 携帯電話への搭載ということも考え, 辞書に登録される語数を制限した. 実験では辞書中の語数が 30,000 語以上となると尤度の低い順に 20%を削除するものとした.

仮名漢字変換において, 個人, あるいは分野を限定すれば, 3,000 語程度の辞書で十分であり, システムが適応することにより精度が向上することが確認されている [4][5]. 本稿の実験ではこの 10 倍のところに制限を置き, 辞書を十分に大きなものとしているが, 今後辞書をより小さく制限することも検討課題である.

4 実験

4.1 正変換率

オリジナルと本稿の改良を加えたシステムとで正変換率の比較実験を行なった. ここで, 正変換率は

$$\text{正変換率 (\%)} = \frac{\text{出力された正解文字数}}{\text{全正解文字数}} \times 100 \quad (3)$$

で表現される.

4.1.1 準備

入力文 Web 上で入手した携帯機器に関するコラム[2] から 36,000 文字を取得し, 入力文とした.

[2]http://k-tai.impress.co.jp/cda/article/stapa/

辞書 本システムは学習型のシステムであり, 最初に何らかの知識を与えた場合, 与えた知識に近い文は変換精度が高くなり, 遠い文は変換精度が低くなる. そのため, 辞書の初期状態を一定とするために, 実験は辞書が空の状態から始めるものとした.

4.1.2 結果

実験の結果を図 5に示す. 図 5で, 実線が本稿の改良を加えたシステムの正変換率, 破線がオリジナルの正変換率である. この実験では, オリジナルの正変換率は 55%程度だが, 改良後のシステムでは 65%以上となっており, 10%以上の正変換率の改善が見られる.

4.1.3 考察

正変換率の向上は尤度評価関数の変更による効果が最も大きく, それ以外のものでは, 一つの改良点では大きな向上は見られないが, 他の変更点と組み合わせると正変換率に対して効果があるものなどもあった.

本稿での改良を施したことにより, オリジナルと比較して正変換率は 10%以上向上し, 改良は有効であったといえる.

4.2 打鍵数

本システムと一般的な文字循環指定方式を採用した携帯電話[3]とで, 打鍵数の比較実験を行なった. 実験では, 用意した文を入力し終えるまでの打鍵数を比較する.

本システムに搭載する辞書は後述するような, ある程度学習を行なった結果得られたものである. また, 学習の効果を確認するために同様の文を 2 度入力し, 打鍵数の変化を確認した.

4.2.1 準備

入力文 複数著者による短いエッセイ[4]より, 210 文, 5,447 文字を用いた. また, これらの文の平均長は 25.9 文字であり, 最短のもので 9 文字, 最長のもので 46 文字であった.

辞書の初期状態 論文や Web 上の文書など約 38 万文字を学習させたものを用いた. 辞書には約 25,000 語が登録されていた. なお, 学習させた文書の中には入力文は含まれていない.

4.2.2 結果

実験の結果を図 6に示す. 図 6で, 実線は携帯電話端末での入力打鍵数を表す. データは図を見やすくするために携帯電話端末での入力が少ない順にソートしてある. また, エラーバーは本システムでの 1 回目, 2 回目の入力打鍵数を表しており, バーの上端が実際に入力した打鍵数（実打鍵数）, 下端が候補の送りすぎや変換範囲の指

[3]cdmaOne 端末, C202DE および C310T
[4]社内文書

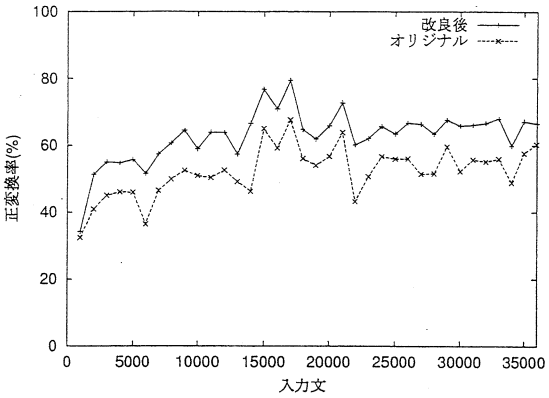


Fig. 5 正変換率の比較

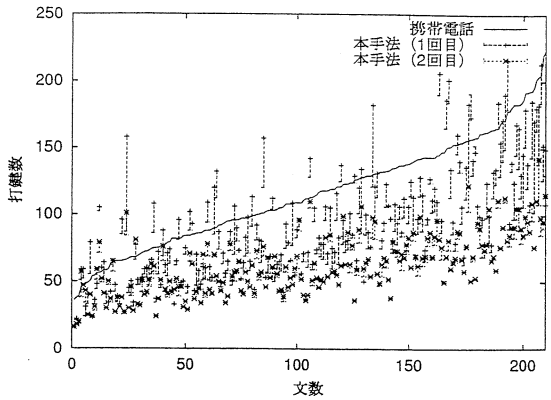


Fig. 6 打鍵数の比較

定ミスなど, ユーザのミスによる打鍵を省いた入力打鍵数（最少打鍵数）を表している.

1 度目の実験では, 実打鍵数の縮退率は 79.8%, 最少打鍵数の縮退率は 69.5%となった. 同じ文を 2 度目に入力した際には最少打鍵数での縮退率は 50.8%となった.

ここで縮退率は

$$\text{縮退率 (\%)} = \frac{\text{本システムでの打鍵数}}{\text{一般の携帯電話での打鍵数}} \times 100 \quad (4)$$

で表現されるものとする.

4.2.3 考察

1 度目の入力では, 辞書が入力文に対して全くカスタマイズされていないことや, 文の著者が複数人であることから表記にゆれがあることなどの悪条件が重なっている. にもかかわらず, 打鍵数を 75%程度まで削減することができた. 本システムを用いると, 最低でもこの程度の打鍵数の削減が可能であると考えられる.

2 度目の実験では, すでにある辞書が入力文に対してカスタマイズされている状態であり, 必要な単語などが辞書に登録されている. その状態では打鍵数を 50%程度まで削減することができた.

一般に, 全く同じ文を 2 度入力する機会は少ないが, 1 人のユーザが 1 つの携帯電話端末で入力する文は似たようなものが多い. 本実験の 2 度目の入力は, 1 度目の入力によって辞書が完全に文にカスタマイズされている状態であり, 辞書がユーザにカスタマイズされた状態に近いと考えられる. つまり, 本システムをある程度使用し, 辞書がユーザにカスタマイズされると, 入力打鍵数が 50%程度になると見込まれる.

5 まとめ

本稿では, 論文[1]のシステムを改良し, 携帯電話に搭載するための実用的なシステムとすることを試みた. オリジナルシステムの様々な点を改良することによってシステムの正変換率は 10%程度上昇した. また, ユーザーインターフェイス部分を Windows 上でシミュレーションし, 文の入力に必要な打鍵数を一般的な携帯電話と比較し, 本稿で導入したヒューリスティックスが正変換率の上昇や打鍵数の削減に効果があることを確認した.

今後は, アルゴリズムの簡略化やプログラムの最適化, また, 人手による辞書の構築や修正などを行ない, より実用的なシステムとすることを考えている.

参考文献

[1] 松原雅文, 荒木健治, 栃内香次, “文字情報縮退方式を用いた帰納的学習によるべた書き文の数字漢字変換手法の有効性について,” 信学論 (D-II), vol.J83-D-II, no.2, pp.690–702, Feb. 2000.

[2] 荒木健治, 高橋祐治, 桃内佳雄, 栃内香次, “帰納的学習を用いたべた書き文のかな漢字変換,” 信学論 (D-II), vol.J79-D-II, no.3, pp.391–402, March. 1996.

[3] K. Araki, Y. Momouchi, and K. Tochinai, “Evaluation for adaptability of Kana-Kanji translation of non-segmented Japanese Kana sentences using inductive learning,” Conference Working Papers of PACLING-II, pp.1–7, Brisbane, Australia, April 1995.

[4] 栃内香次, 斉藤 康, “適応型変換辞書を用いるかな漢字変換,” 情処学論, vol.24, no.2, pp.209–213, March 1983.

[5] 栃内香次, 岡沢好高, “適応型変換辞書方式かな漢字変換システムの性能測定,” 情処学論, vol.26, no.4, pp.733–739, July 1985.