1—P—18

発話速度推定へ向けたHMM構成の検討*

◎魯 中済　広重 真人　荒木 健治(北大・工)　栃内 香次(北海学園大・経営学)

1 はじめに

自由会話音声における発話速度の大きな変化は、聴き手の注意を引きつける韻律情報の一つであり、強調などの話者の何らかの意図を含む可能性がある。筆者等はかねてより自由会話音声における発話速度変化検出に取り組んできた[1]。大きな発話速度変化は重要な韻律情報でありながら自由会話音声の一部分にしか含まれないため、発話速度研究に必要な充分な発話速度変化を含む音声サンプルを、大量の録音音声から抽出するのは多大な労力を要する。このため筆者等は先行研究[2]において、学習済みの一般的な音素認識 HMM[3]と書き起こしテキストを用いて、強制割付機能により発話速度変化の予備抽出を試みた。しかしながら先行研究[2]では精度を得るために書き起こしテキストを必要とし、現実にはその作成の労力もかなり大きい。また自由会話音声は調音の大きななまけなどにより正確に書き起こすことが困難な箇所が多数存在する。書き起こしテキストを用いず通常の大語彙音声認識システムとして音素認識 HMM を利用することも考えられるが、自由会話音声を念頭に置いた本研究では、精度の問題が予想される。また発話速度変化抽出の観点からは、発話速度に関係する「音韻の変化」が求まればよく、「音素が何であるか」は必要ない。この点からも大語彙音声認識システムを発話速度変化検出のみに用いるのは冗長である。音素同定のみに関与する音響パラメータや HMM 構造などを省き発話速度変化検出に特化させれば、音響パラメータの計算や HMM パラメータ学習などを効率よく行うことができるので、簡素で高精度なシステムを構築できる可能性がある。本稿では、音響パラメータとして 1 次元の LPC ケプストラム変化量を用い、HMM のモデル数を「音韻変化箇所」と「音韻変化のない箇所」を表す 2 個のみとした簡単な実験システムにより音韻変化箇所の推定を行い、上述の考えの可能性について検討する。

2 音声データ

本稿で用いた音声データは ATR 日本語連続音声データベース 503 文中の話者 MMY の最初の 20 文である。サンプリング周波数 20kHz を 16KHz にダウンサンプリングして用いた。

3 音響分析

上述の「音韻の変化」を推定するためには、スペクトルが変化している箇所(「音韻変化箇所」＝韻律境界) とスペクトル変化のない箇所 (同じ韻律が継続している箇所) を容易に区別できる音響パラメータが必要である。音韻認識に用いられるメルケプストラム係数(MFCC)及びその差分は、音韻を区別する能力があるが、本稿の目的では「同じ音韻が継続している箇所」は音韻の違いによって区別しないため、音韻識別の能力は冗長である。冗長な要因は HMM の学習に困難をもたらす可能性がある。そこで、スペクトル変化量に直接対応する量として、LPC ケプストラムに基づく動的尺度[4]を用いる。

この尺度は LPC ケプストラムの各次数の係数について重みつき回帰直線を求め、回帰直線の傾きの 2 乗和によって，滑らかな変化量を得るものである。分析条件は、LPC ケプストラム：20 次元，フレーム長：20msec，フレームシフト：5msec である。

4 HMM の設計

4.1 モデル数、状態数と分布

一般の音韻認識用 HMM では HMM のモデル数は音韻数 (40 個程度) と等しいが、本稿では「音韻変化箇所」に「B」(Boundary) モデル，「音韻変化のない箇所」に「NB」(Non-Boundary)モデルを用い、モデル数は計 2 個のみとする。この「B」モデルと「NB」

---

* An examination of HMM structure for Speech rate estimation, By Lu Zhongji, Makoto Hiroshige, Kenji Araki (Hokkaido University), Koji Tochinai (Hokkaido Gakuen University)

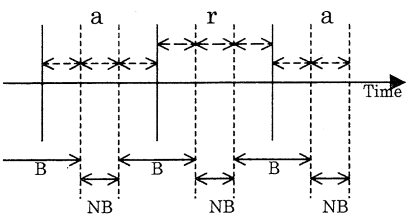


図1「B」と「NB」モデル

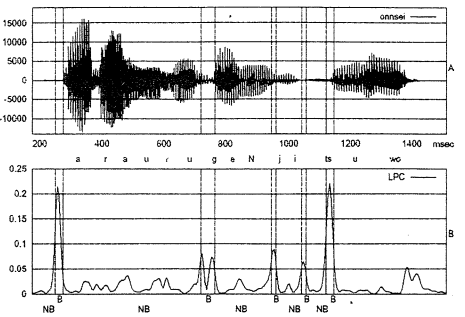


図2推定結果

モデルは必ず交互に現れるものとし、一定時間内の「B」の出現個数を推定することにより発話速度が推定できる。各モデルは1次元のLPCケプストラム動的尺度を特徴量として、状態数は5（確率分布が定義される状態数は3），連続型・単一正規分布のHMMを用いた。

5 HMMの学習

HMMの学習は、「B」モデルと「NB」モデルに相当する音声区間を音素ラベルに基づいて切り出し、Baum-Welchアルゴリズムにより行う。ATRデータベースに収録された音素ラベルの音素境界の近傍(図1に示す)を「B」区間とし、それ以外の部分を「NB」区間とした。音素境界の近傍とは、本稿では簡単に、音素境界の前後それぞれ音素長の3分の1の区間とする。

6 音韻変化箇所の推定実験

6.1 認識用文法

認識文法は、「B」モデルと「NB」モデルが交互に任意の回数出現できるものとした。

6.2 推定実験と結果

推定実験は既存のHMMツールキットHTKを用いて、上述のモデルの学習を行った後、学習済のHMMと辞書、文法ファイルを用いて音韻変化箇所の位置の推定（認識）を行った。認識に用いた音声データは学習に用いた20文と同一である。結果を図2に示す。Aは音声波形、Bは計算されたLPCケプストラム変化量である。細い縦線は認識された「B」と「NB」境界の位置である。図2において、LPCケプストラムの動的特徴量の大きく変化している部分が「B」(境界)として推定された。しかし音韻変化に対応する小さなピークの多くが認識されていない。実験結果より、音響パラメータに明確な特徴が存在すれば、変化点の位置と個数を推定可能であることが示された。

7 まとめ

本稿では，HMMによる発話速度推定へ向けて、音韻変化箇所検出に特化したHMMの構成を提案し、簡単な音韻変化箇所推定実験を行った。音響パラメータとして用いたLPCケプストラムの動的特徴量が大きな変化を示す箇所の位置と個数が推定できたことにより、HMMによる発話速度推定の可能性が示された。LPCケプストラムの動的特徴量のみでは大きな変化として観測されない音韻境界が多数存在し、検出が困難であった。このため、今後はパワーやF0などの情報も音響パラメータに加え、あわせてHMMの構造も改良を加える予定である。

謝辞

本研究の一部は文部科学省科学研究費(課題番号13750373)により行われた。

参考文献

[1] 高丸圭一,広重真人,栃内香次,"可変閾値によって検出される局所的発話速度低下箇所の評価",ASJ 2-10-16, pp.295-296 (2002-03)
[2] 松村真言,広重真人,荒木健治,栃内香次,"HMMを用いた自由会話音声における発話速度変化の予備抽出",ASJ1-10-16,pp.387-388
[3] 名古屋大板倉研究室,"A standard HMM set of Japanese phonemes." http://www.itakura.nuee.nagoya-u.ac.jp/
[4] 嵯峨山茂樹, 板倉文忠,"音声の動的尺度に含まれる個人性情報",音講論 1977.6, pp.589-590