フォルマント・パワー・F0 の後処理加工による合成音声の明瞭性制御*

◎藤原　敬記　　広重 真人　　荒木 健治(北大・工)　　栃内 香次(北海学園大・経営学)

1. はじめに

音声合成は人間と機械の情報交換において非常に重要な技術である。近年人間とコンピュータが接する場面が多くなり、その必要性もより強いものとなってきている。音声合成の研究[1]は比較的古くから行われ、現在では高品質の音声を持つ合成システムも存在する[2]。それらの研究では、合成音声の明瞭性・自然性の向上を目指しているものが多い。中・小規模の市販規則合成システムなどでは実用上の点から、合成音声のすべての部分について明瞭性を高くするためにすべての音素がはっきりしており文末などでなめらかさが感じられないことがある。

しかし日常会話などにおいては、必ずしもすべての文節を明瞭に発話しているわけではなく、重要な情報の含まれない文節や文末などは、はっきりと発話されない傾向がある。人間は発話内容の重要性などに応じて、基本周波数(以下 F0)・パワー・発話速度・調音位置(スペクトル形状)などを用いて、明瞭性を柔軟に制御していると考えられる。この明瞭性の連続的変化は、人間の発話に流暢なリズム与える一因と考えられる。明瞭性の連続的な変化の音声合成での実現をめざして本研究では、従来あまり扱われなかった「不明瞭」な部分の音韻的・韻律的な特徴にも注目し、合成システムへの導入を検討する。なお本研究での「あいまい」さとは、上述のように重要な情報の含まれない部分などの「個々の音韻ははっきりしないがなめらかである」状態を示しており、より長い発話単位（文、呼気段落など）全体で表される伝えたい内容の了解度を失うような全体に渡った「不明瞭さ」ではない。特に、文意に関わる重要な部分の明瞭性は高く保ったままである。本稿では、音声の明瞭性を制御する要素として、フォルマント、パワー、F0 を採用する。これらを用いて合成音声に後処理を行うことで人間の発話の「あいまい」な部分の音声を再現することを試みる。

2. 概要

重要な情報を含んでいる主題部分は明瞭性を高く保ち、そうでない非主題部分を「あいまい」にすることで、発話内容による明瞭性の制御を試みる。我々が行った予備実験[3]において、「あいまい」に発話した音声には明瞭に発話した音声に比べ、母音の中立化、パワーの減少、F0 の平坦化、無声・有声の切り替えの省略、発話速度の増大などが確認できた。そこで今回は「あいまい」な音声の作成には、特に顕著に観測された母音の中立化、パワーの減少、F0 の平坦化を考慮する。また、韻律要素に加え、音韻要素にも調音結合などの韻律的な制御を受ける要素があると考え[3]、フォルマント、パワーの加工には、F0 に同期した制御を行う。

3. 合成音声加工実験

「Visual Speech Creator」(NTT-IT(株)製)[4]で作成した数種類の音声に、ESPS/waves+ の簡単なフォルマント分析・合成器を用いて再合成を行った。再合成の際、フォルマントと音源 rms パワー、F0 をそれぞれ独立に以下のように加工する。パワー、フォルマントの制御は元の合成音声から求めた F0（以下原 F0 と記す）が低い部分だけ原 F0 に同期させて行う。F0 が低い部分とは、原 F0 の最大値 $F0_{max}$ と最小値 $F0_{min}$ の範囲において、原 F0 が式(1)で求まる $F0_{flag}$ よりも小さな部分である。

$$\log F0_{flag} = (\log F0_{\max} - \log F0_{\min}) \times 2/3 + \log F0_{\min} \quad (1)$$

3.1 パワー制御

音源パワーは、オリジナルの音源パワーに加工乗数 r_{pow} を乗じて求める。この加工乗数 r_{pow} は上述の原 F0 が低い部分で原 F0 の上下動に比例して変化するように定められ、音声サンプル中の $F0_{flag}$ で 1.0 、最小値で x（$x = 0.8, 0.7, 0.5$ の 3 種類)をとるようにする。

3.2 フォルマント制御

フォルマントは、原 F0 の低下に伴って、中立的な母音のフォルマントに引き寄せられるように加工する。まず、中立的な母音として、損失のある一様音響管の周波数応答[5]を参考にしながら、予備実験[3]で得られた実音声の中立的母音の特性を設定した(F1=481,F2=1342,F3=2203, F4= 3316[Hz])。各時点で観測された各フォルマントを f_i、加工後の各フォルマントを f_i'、中立母音の各フォルマントを $f_{i\cdot lazy}$（共に $i = 1,2,3,4$)として、式(2)によりフォルマント加工を行う。r_{for} は r_{pow} と同様に 原 F0 の上下動に比例して変化する加工乗数で、原 F0 が $F0_{flag}$ のとき 1.0 、$F0_{min}$ のとき $x(x = 0.7, 0.5, 0.3)$ を

---

* “Clarity control of synthesized speech by post-processing using formant,power and F0”,By Noriki FUJIWARA,Makoto HIROSHIGE,Kenji ARAKI(Graduate School of Engineering,Hokkaido University) and Koji TOCHINAI(Graduate School of Business Administration, Hokkai-Gakuen University)

とるように定める。

$$f' = f_{i\cdot lazy} + (f_i - f_{i\cdot lazy}) \times r_{for} \quad (i=1,2,3,4) \quad (2)$$

3.3 F0 制御

F0 は、$F0_{min}$ を固定して $F0_{max}$ と $F0_{min}$ の範囲を $r_{f0}(r_{f0} = 0.7,0.5,0.3)$ に縮小させる。r_{f0} は r_{pow}, r_{for} とは異なり、原 F0 に同期した加工はさせず、音声サンプル全体にわたって一定の値とする。

4. 結果

無加工の合成音声と各要素を制御した合成音声の波形等をそれぞれ図 1、図 2 に示す。加工した音声は無加工の音声と比べ、母音の中立化、パワーの減少、F0 平坦化の制御が行われているのがわかる。実際に「あいまい」に発話した音声と比較したところ先行発表[3]の結果と比較して、フォルマント、パワー、F0 の挙動をより近づけることができた。

また本実験では簡単なフォルマント合成器を用いたため、全般に音質は不充分であったが、合成音声を非公式聴取により予備評価を行ったところ、F0、フォルマント、パワーの順で「あいまい」性への影響が強かった。F0 の制御は音声全体に渡って抑揚を抑える効果があるので影響が強いと思われる。フォルマントの制御は、F0 の低下に伴い各音韻の際立ちが減少し、音韻のつながりがよりなめらかになった。パワーの制御は、F0、フォルマントの制御ほどの影響はなかったが、制御を行った音声には文末・文節末等の自然性の向上に影響することが認められた。

5. おわりに

人は明瞭性をも柔軟に制御し発話していると考え、明瞭性の連続的交替を再現するために、「あいまい」な音声の作成を試みた。今回は、明瞭性の制御に、母音スペクトルの中立化の強さ、音源パワー、F0 の平坦化を独立に制御した。

今後は、今回の実験内容を踏まえて発話内容の非主題部分はあいまいにし、主題部分には高い明瞭性を保たせ、文内で明瞭性を変化させた音声を作成することを予定している。

謝辞

音声合成の際、日本音響学会第 68 回技術講演会で使用された NTT-IT(株)製「Visual Speech Creator」を使わせていただきました。深く感謝致します。

参考文献

[1] 西沢信行,峯松信明,広瀬啓吉,“波形編集を併用したフォルマント音声合成-VCV 音声に関する検討-”,信学技法, SP2001-20,pp.35-42

[2] ニック・キャンベル,アラン・ブラック,“CHATR:自然音声波形接続型任意音声合成システム”,信学技法,SP96-7,pp.45-53

[3] 藤原敬記,広重真人,荒木健治,栃内香次“明瞭度を考慮した規則合成の提案と基礎的検討”,日本音響学会講演論文集,1-P-15,pp.381-382(2002.3)

[4] NTT-IT(株),“Visual Speech Creator 操作説明書”

[5] L.R.Rabiner/R.W.Schafer(鈴木久喜訳),「音声のディジタル信号処理(上)」,コロナ社(1983)

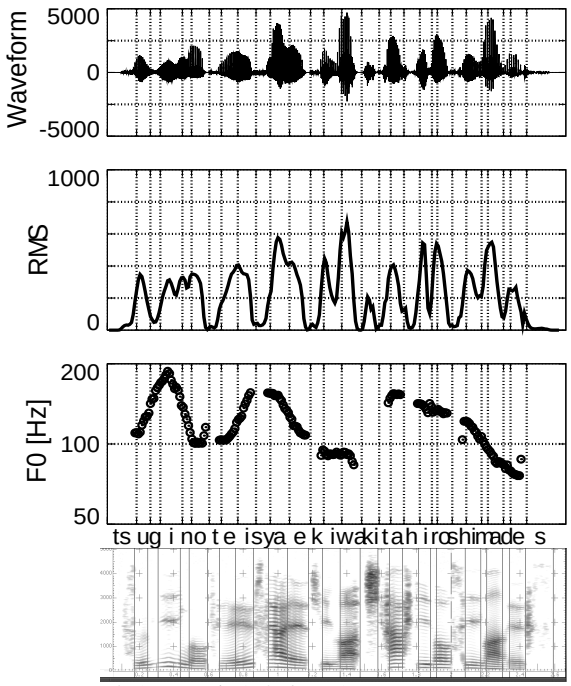


図 1 無加工の合成音声の波形、パワー、F0、スペクトログラム

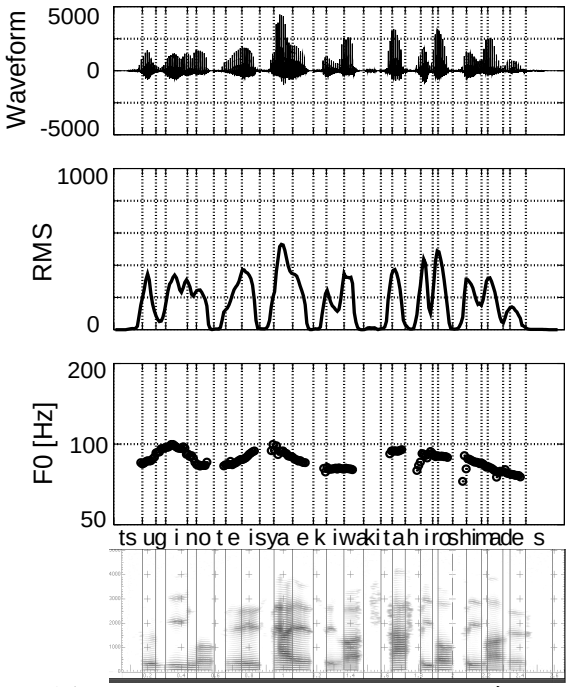


図 2 $(r_{pow}, r_{for}, r_{f0}) = (0.5,0.3,0.5)$ で加工した合成音声の波形、パワー、F0、スペクトログラム