189　アイヌ語-日本語間の対訳語獲得における再帰チェーンリンク型学習の効果的な学習について

加藤大樹† 越前谷博† 荒木健治‡ 桃内佳雄† 栃内香次†
†北海学園大学　‡北海道大学

1 はじめに

コーパスから対訳語を獲得する研究は盛んに行われており，それらは，言語知識を利用する手法 [1][2] と統計的な手法 [3][4] に大きく分けられる．言語知識を利用する手法では，基本的な対訳辞書を始めとして解析的な知識の使用を前提としている．一方，統計的な手法では，膨大な量のコーパスを必要とする．しかし，アイヌ語と日本語間の対訳語をコーパスから獲得する際，解析ツールを用いて，アイヌ語の解析的な知識を得ることは現在のところ困難である．また，大量のアイヌ語-日本語の対訳コーパスを得ることも難しい．そこで我々は，アイヌ語の解析的知識を使用することなく，さらに，少量のコーパスからでも対訳語を効率よく獲得することを目的とした，再帰チェーンリンク型学習 [5] を用いたアイヌ語-日本語間の対訳語獲得についての研究を行っている．本手法において，システムが初期状態として与えられるアイヌ語の知識は，少量の対訳語のみであり，この対訳語を起点として，アイヌ語と日本語文の対訳コーパスから対訳語を自動的に獲得していく．そのため，初期辞書の選択は本手法において重要な意味を持つと考えられる．本稿では，再帰チェーンリンク型学習の効果的な学習という観点より行った評価実験の結果について述べる．

2 概要

再帰チェーンリンク型学習では，少量の対訳語をもとにアイヌ語と日本語文の対訳コーパスからアイヌ語の解析知識を必要とすることなく対訳語を連鎖的に獲得することができる．今回獲得の対象となる対訳語は，語形変化が少ないことより実験の第一段階として適しているという観点から名詞または，形容詞，助詞，名詞から構成される名詞句に限定した．本システムでは日本語文にのみ解析知識として形態素解析ツール茶筅 [6] による品詞情報を付与している．この品詞情報は不適切な対訳語の獲得を防ぐことを目的に用いる．アイヌ語においても品詞は存在するが，我々の知る限り品詞情報を十分に付与できるツールは存在しない．そこで，本システムではアイヌ語の品詞情報に依存することなく，学習能力に基づき対訳語を獲得する．また，本手法は 1 度しか出現しない語に対しても対訳語を獲得できるという高い学習能力を有している．したがって，現状では大量の対訳コーパスを得ることが困難なアイヌ語-日本語の対訳語獲得に有効であると考えられる．

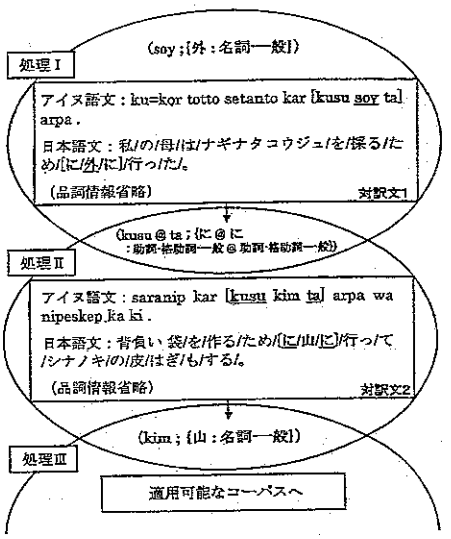


Fig. 1 対訳語獲得の具体例

3 処理過程

本システムでは対訳語と切り離しテンプレートが交互に獲得されることによって，連鎖的に対訳語を獲得していく．Fig.1 に本手法による対訳語の獲得処理の具体例を示す．

Fig.1 において，対訳辞書に（soy ; { 外 : 名詞-一般 }）という対訳語が存在するとき，対訳文 1 のアイヌ語文と日本語文のそれぞれから対訳語に対応した部分"soy"と"外"を抽出し，変数に置き換える．システムはアイヌ語と日本語のそれぞれにおいて，置き換えられた変数とその変数に隣接する語を切り離し情報として獲得する．このとき，日本語の切り出し部分には品詞情報が付与され，切り離しテンプレート（kusu @ ta ; {に @ に : 助詞-格助詞-一般 @ 助詞-格助詞-一般 }）が獲得される．この切り離しテンプレートは，アイヌ語の"kusu"と"ta"に隣接する語は日本語の「(助詞-格助詞-一般) の"に"」に挟まれる語と対応関係を持つことを意味する．ここで，日本語の切り出し部分に品詞情報をつけるのは，切り離しテンプレートをコーパスに適用するときに，字面だけで切り離し位置を探すのではなく，品詞まで考慮して切り離し位置を探すことによって，誤った対訳語の獲得を防ぐためである．この獲得された切り離しテンプレートを次に対訳文 2 に

適用する．対訳文2においてアイヌ語の"kasu"と"ta"に隣接する語は「kim」，日本語の「(助詞-格助詞-一般) の"に"」に挟まれる語は「山」である．よって，新たな対訳語 (kim ; { 山 : 名詞-一般 }) が獲得される．ここでの日本語部分の品詞情報は，獲得した対訳語が獲得対象の品詞であるかどうかを調べるために用いる．この対訳語を獲得のため用いた切り離しテンプレート (kusu @ ta ; { に @ に : 助詞-格助詞-一般 @ 助詞-格助詞-一般 }) は，名詞の対訳語から作られたテンプレートである．よって，この切り離しテンプレートは名詞，もしくは名詞句を獲得の対象とし，他の品詞の語は獲得しない．獲得された対訳語 (kim ; { 山 : 名詞-一般 }) をさらに対訳コーパスに適用することにより，新たな切り離しテンプレートの獲得が期待できる．本システムでは，このように対訳語と切り離しテンプレートが連鎖的に獲得されていく．

4 性能評価実験

4.1 実験方法

対訳コーパスは「アイヌの知恵・ウパシクマ1」[7] を用いて作成した．その際，日本語文については，文献 [7] の単語直接翻訳に基づき人手で訳文を作成した．作成した対訳文は116組となり，出現する名詞の総数は172個である．

本実験では，再帰チェーンリンク型学習を稼動させる際の起点となる対訳語として，34個の名詞対訳語を与えた．この34個の対訳語は，第1章に出現する全名詞対訳語である．これらの第1章から取り出した34個の名詞対訳語を用いた実験を実験1とする．更に我々は再帰チェーンリンク型学習のより効果的な学習という観点より，初期辞書として与える34個の対訳語の内容を変更するという追加実験を行った．実験に用いた対訳コーパスは5つの章に分かれており，章によって話の場面が移り変わる．そのため，同じ章から対訳語を与えた方が他の章から対訳語を与えるよりも効率よく利用されるという期待が持てる．そこで，初期辞書として与える対訳語の数を変更することなく，各章から出現順に7個ずつ (第5章のみ6個) 計34個の名詞の対訳語を初期辞書として与え実験を行った．この実験を実験2とする．初期辞書の与え方を変えた実験1と実験2間の対訳語の獲得数を比較し，初期辞書による学習効果の変化を調査した．

4.2 実験結果と考察

Table 1 実験結果

	初期数	獲得数	増加率
実験1	34	19	55.9%
実験2	34	22	64.7%

実験1では，システムが新たに獲得できた名詞の数は19個であり，初期状態として与えた対訳語数34個に対する増加率は55.9%となる．一方，実験2では，システムが新たに獲得できた名詞の数は22個であったので，初期状態として与えた対訳語数34個に対する増加率は64.7%となった．したがって，実験1よりも実験2の方が正対訳語増加率が8.8ポイント上昇することを確認した．獲得した対訳語の変化は，実験2では実験1で獲得していた対訳語が8個獲得されなかった．一方，実験1で獲得されなかった対訳語が新たに11個獲得された．実験1と比較し実験2の方がより多くの対訳語を獲得できたのは，実験に用いた対訳コーパスは章によって話の場面が移り変わるため，初期辞書として1つの章からの対訳語を与えるよりも，複数の章からの対訳語を与えた方がその対訳語がより効率よく利用されるようになったためと考えられる．

5 おわりに

本稿では，再帰チェーンリンク型学習において，同じ個数の対訳語を初期辞書として用いても，その内容を変えることで学習効果，すなわち対訳語の獲得数を向上させることが可能であることを評価実験の結果より述べた．今後はこのような効率的な学習という観点からの実験，更に，再帰チェーンリンク型学習の学習能力そのものを向上させるための改良を行う予定である．

参考文献

[1] 北村美穂子，松本裕治：対訳コーパスを利用した対訳表現の自動抽出，情報処理学会論文誌，Vol.38, No.4, pp727-pp736(1997).

[2] 田中貴秋，松尾義博：対訳関係のないコーパスからの複合名詞対訳表現の獲得，電子情報通信学会論文誌，Vol.J84-D-II, No.12, pp2605-pp2614(2001).

[3] Masahiko Haruno, Satoru Ikehara, Takefumi Yamazaki : Learning Bilingual Collocations by Word-Level Sorting, Proc.of COLING-96, pp525-pp530(1996).

[4] Reinhard Rapp : Identifying Word Translations in Non-Parallel Texts, 33rd Annual Meeting of ACL, pp320-pp322(1995).

[5] 越前谷博，荒木健治，桃内佳雄，栃内香次：再帰チェーンリンク型学習による対訳コーパスからの対訳語ペアの自動獲得手法，情報処理北海道シンポジウム2002, pp135-pp136(2002).

[6] 日本語形態素解析システム「茶筌 (Chasen) for Windows」(2000).

[7] 中本ムツ子，片山龍峯：アイヌの知恵・ウパシクマ1，片山言語文化研究所，新日本教育図書株式会社 (1999).