波形からの直接音声翻訳手法に関する研究

村上浩司† 荒木健治† 広重真人† 栃内香次‡
北海道大学大学院工学研究科† 北海学園大学大学院経営学研究科‡

1 はじめに

21 世紀を迎えて，外国を訪れる日本人や日本を訪れる外国人も一段と増え，いろいろな意味で諸外国との距離が近いものとなりつつある。しかしながら，言葉の壁が人との交流を阻む大きな要因となっている。旅先の国の言葉を学ぶ機会をもつことができれば良いが，一朝一夕に語学力が向上するわけではない。そこで，日本語の話し言葉と外国語の話し言葉を相互に翻訳する音声対話翻訳技術の実現が熱望されている。

一方，人間同士の情報交換において音声そのものは共通に用いられる最高品質な情報伝達媒体であり [1]，その中には言語情報だけでなく，強調などを表す韻律情報に代表されるパラ言語情報や非言語情報など，必要な情報がすべて含まれると考えられる．そのため，人間とコンピュータの間においても，情報伝達に自然言語音声を利用することは多くの利点がある．

しかしながら現在，研究開発されている音声対話翻訳手法においては，音声を直接扱うものは少なく，入力された原言語音声を文字列に変換する音声認識部，そこで得られた文字列を目標言語の文字列に変換する機械翻訳部，そして得られた目標言語の文字列を音声に変換する音声合成部の 3 つから構成 [2][3] される．ここでは翻訳の対象が言語情報しか持たない文字列を対象としているため，音声が持つ多くの他の情報を保持することができない．機械翻訳部の処理は，対象のそれぞれの言語の性質に強く依存するため，対象言語の種類と同じ数の翻訳部を用意しなければならないので，利用できる範囲に制限がある．また，それぞれの処理部は複雑に構成されるため，すべての処理の精度向上のみが全体的な精度向上の必要条件となるという問題点がある．

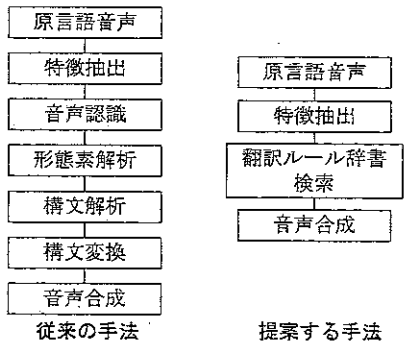


図 1: 処理過程の比較

そこで我々は，実例発話の音声特徴の時間変化に着目し，それらの間の対応関係を決定してその変換規則を帰納的学習 [4] を用いて獲得することで，文字表現を介さずに音声翻訳を実現する方法を提案 [5][6] している．この手法では言語に依存した処理が不要なために，より汎用的な音声翻訳を実現できると考えられる．

本稿では，提案する音声翻訳手法を実現するための全体的なシステム概要と，音声処理や基礎的な翻訳実験とその考察から提案手法の有効性を確認する．また，本研究では原言語に日本語，目的言語に英語を用いた．

2 基本的な考え方

翻訳の条件が，対象の 2 言語間において意味が正しく対応していることとすると，多くの音声翻訳手法のように，音声認識の結果として得られた文字列を解析することで対応関係を決定し翻訳を行うのではなく，文字に変換される前の音声特徴そのものを対象として対応関係を決定することでも翻訳が可能であると考えられる．

従来の手法と我々の手法の比較を図 1 に示す．提案手法においては，発声された音声を文字列へ変換しないため通常の音声認識のように単語や節，音素といった単位の正確な境界は必ずしも必要ではなく，比較する発話内における音声特徴の音響的な共通部分と差異部分のみに着目し，それらの対応関係を利用することが大きな特徴である．従って，音声認識における音声のセグメンテーション処理が不要となる．

また音声翻訳技術の対象音声は，基本的にテキストなどの文字言語の朗読音声ではなく，異なる言語を話す人間同士が直接対話している状況下の音声言語を対象としている．そのため機械翻訳部において，文字言語を翻訳する翻訳技術だけでは実際の音声対話中に現れる言い淀みや言い直しなどの現象や非文，省略などへの対処が困難であるため音声言語の特徴に適合した翻訳技術が必要になる．

しかし我々の手法においてはそうした現象に対しても特別な処理を行わず，音響的な共通部分や差異部分のみを扱い，出現頻度に応じて翻訳に利用するために，文法的，または意味的に解析する必要がないため，システム作成のコストが小さいという利点がある．

全体の処理過程を図 2 に示す．まず，対訳関係にある原言語および目的言語の実例発話対を入力とする．本手法においてはこれらの翻訳対を予め準備することのみが音声翻訳の唯一の条件となる．これらの発話対の

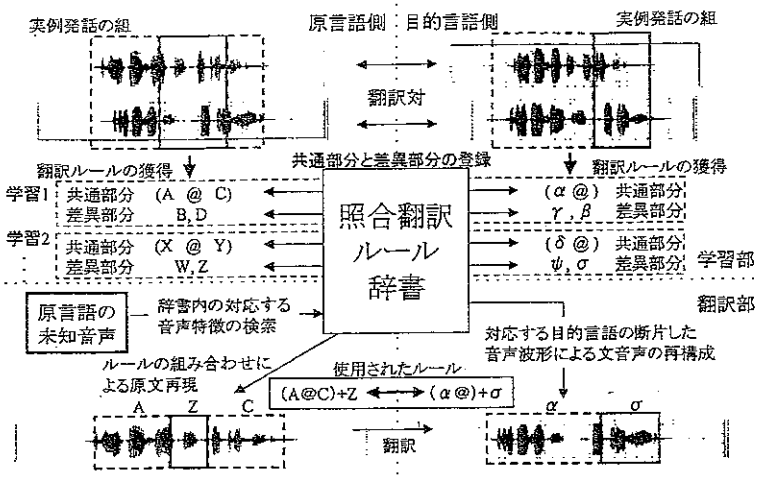


図 2: 処理過程

音声をそれぞれの言語内で組とし，それらの特徴ベクトル同士を比較することで共通部分と差異部分を抽出する．比較した発話対同様，学習 1 の時点で抽出されるそれぞれの言語での共通部分は，両言語間で対訳関係が保持されていると考えられ，差異部分も翻訳対として考えられる．そこでこれらの共通部分と差異部分の関係を翻訳ルールとして表現し，ルール辞書に登録する．このとき差異部分を変数化することで文を一般化し，共通部分と差異部分の関係を示す文ルールも獲得する．また翻訳ルールは，これらの抽出した共通部分と差異部分の発話内の始点，終点の位置情報を保持し，翻訳時の音声波形合成に用いる．こうした学習を用意した発話対のすべてに対して繰り返し行う．

翻訳ではまず，入力された原言語の未知音声を，ルール辞書に登録されているすべての翻訳ルールと比較して類似度の高いルールを選別し，それらを組み合わせて原文再現を行う．そしてここで選別された翻訳ルールの言語間の対応関係に従い，ルールの保持する目的言語側の音声特徴に対応する音声波形を，位置情報から切り出し波形合成を行うことで翻訳文として出力する．

また学習では音声特徴の比較によってだけではなく，帰納的学習を用いることによりルール同士を再帰的に比較することでも，同様に音響的共通部分と差異部分を抽出し翻訳ルールを獲得する．再帰的なルール獲得は，より少ない事例から多くの翻訳ルールを獲得することを可能とし，その結果未知音声に対しても翻訳が可能となる．

この手法に求められる能力は，各言語の固有の性質に依存せずに，意味が伝わるレベルでの翻訳精度で音声翻訳を実現することである．

表 1: 音声処理に用いたパラメータ

分析フレーム長	20msec
フレーム周期	3msec
時間窓	ハミング窓
AR 分析次数	14

3 音声処理

本手法では，実例発話を比較することで音響的な共通部分と差異部分を抽出するために，音声波形の周波数特徴の時間変化を学習データとする．本実験では，音声データとして ATR 研究所用音声データベース (SLDB)[7] を用いた．音声データは 8kHz にダウンサンプリングし，音声ツールキット SPTK[8] により音声特徴を計算した．

音声特徴はその目的により様々なものが利用されているが，我々は予備実験 [9] において最も効率よく翻訳ルールを獲得することのできた LPC ケプストラムを用いた．このとき，表 1 に示すパラメータを両言語共通して用いた．

4 発話内の共通部分探索

4.1 特徴ベクトルの比較

特徴ベクトルに変換された実例発話組を各言語で比較することで，それぞれの発話内の音響的な共通部分と差異部分を抽出し翻訳ルールを構成する．比較は両ベクトルの最小 2 乗距離計算により行われる．

音声は文字と違い，同一話者・同一内容であっても同じ発話を 2 度行うことは不可能である．その最も大きな原因として，音韻の持続長の違いがある．この持続長の違いを吸収することが音声を取り扱う処理においての大きな課題となる．

我々はこの実例発話間の速度差を正規化するために，最もよく使われている端点自由 DP 法 [10] で得られるパスに類似した結果を得る，図 3 で示す手法を用いた．比較行う音声特徴ベクトル（以下、比較ベクトル）を一定のフレーム長とフレーム周期を用いて時間軸上で切り出し，参照される音声特徴ベクトル（参照ベクトル）全体と距離計算を行う．この時に得られる 1 本の距離曲線は，ある時点で切り出された比較ベクトルと

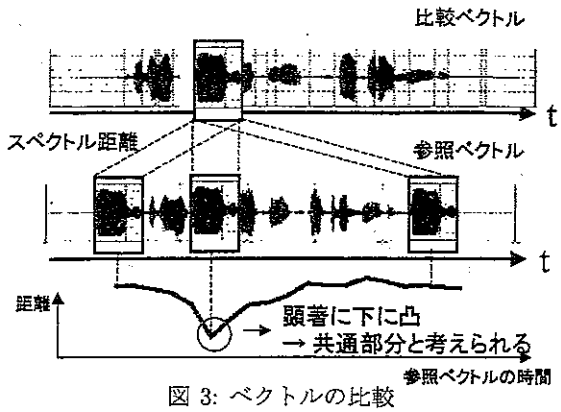


図 3: ベクトルの比較

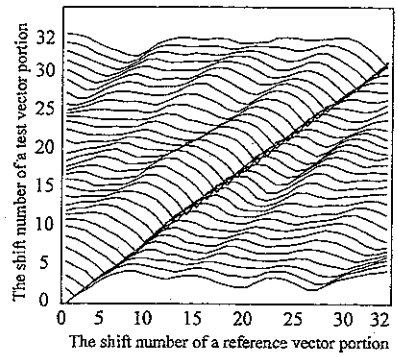


図 4: 発話間の距離 (1):"All right, Mr.Brown."

参照ベクトル全体との距離を表す.

図 4 及び図 5 に，ある時点で切り出された比較ベクトル毎に得られた距離曲線の例を示す．図 4 は同一の話者および内容の別発話を比較，図 5 は同一話者による別内容の別発話を比較した例である．

ここで，各グラフ内の距離曲線における最小距離点が，比較した切り出された 2 つのベクトルの類似度が高く共通部分になり得ると考えられるため，これら最小距離点を結んだ線が DP で得られるパスに相当する．この時，図 4 のように比較した両ベクトル全体が著しく類似していれば，各距離曲線で極端距離の小さい点が現われ，顕著に下に凸である距離点を得られる．図 5 は全く異なった内容の発話を比較しており，著しく小

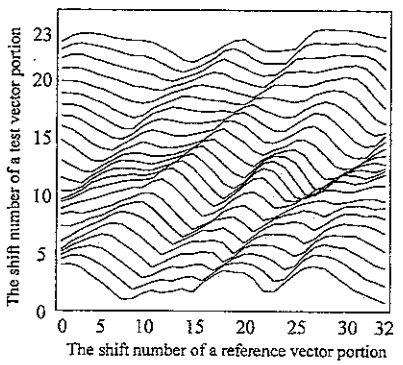


図 5: 発話間の距離 (2):"All right, Mr.Brown."-"Good afternoon."

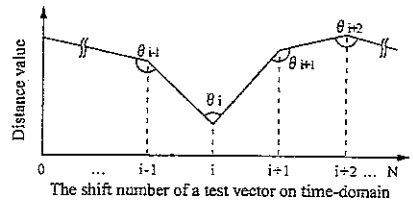


図 6: 角度計算

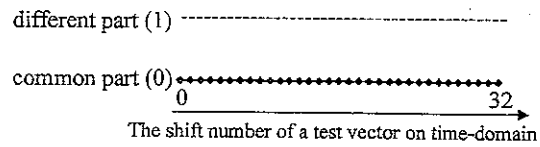


図 7: 共通・差異部分 (1):"All right, Mr. Brown."

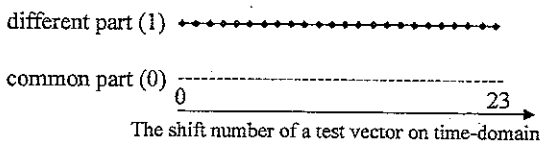


図 8: 共通・差異部分 (2). "All right, Mr. Brown." - "Good afternoon."

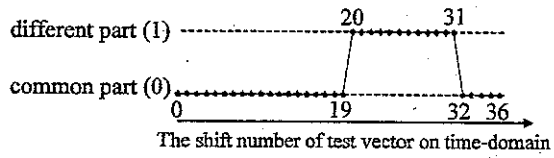


図 9: 共通・差異部分 (3):"これは雑誌です"-"これは通帳です"

さい距離点が現われていないことがわかる．次に，各距離曲線の最小距離点を評価することで共通部分もしくは際部分であるかを決定する．

4.2 共通部分決定

実例発話の比較において，共通部分と差異部分を決定するための評価を図 6 に示す方法で行う．各距離曲線に存在する最小距離点は，他の距離点に比べ顕著にその値が小さくなっていると考えられるため，距離曲線内の最小距離点 i とその前後の距離点から成る角度 θ_i に着目し，この角度が同じ距離曲線内に存在する角度の中で顕著に小さい場合，この最小距離点 i を共通部分と決定する．我々はこの手法を用いて，最小距離点の角度が最小第 2 位までのときに共通部分と決定することで，最も効率良く共通部分と差異部分を分離できることを確認した [11].

図 7 は図 4 を各距離曲線毎に評価した結果である．比較した発話は，全体が共通であると捉えられられた．一方，図 8 は図 5 を評価した結果であり，全体が差異部分と計算された．これに加え，図 9 に示すような共通部分と差異部分がそれぞれ単数または複数で同時に出現する場合がある．いずれの場合も，文字列を対象とした意味解析処理による共通部分・差異部分の抽出とほぼ同様の結果を得られた．

5 翻訳ルール獲得

実例発話を比較することで得られた音響的な共通部分と差異部分をの情報を要素として翻訳ルールを獲得し，ルール辞書に登録する．翻訳ルールは以下の情報を持つ．

- 原言語および目標言語の，抽出した単数もしくは複数の共通部分・差異部分の始点と終点
- ルールの種類：全文一致・全文差異・共通部分と差異部分の混在のうちのいずれか

このとき，原言語と目標言語側での出力されるルールの種類が違う場合，翻訳関係としての整合性が取れないためにルールとして獲得しない．

6 帰納的学習

実例や用例に基づく学習型の翻訳手法においては，翻訳ルールを獲得するために大量のデータが必要となり，高い精度の翻訳を実現させるにはあらかじめ十分な量の実例データを準備し，学習させる必要がある．

我々が適用する帰納的学習 [4] の場合，準備した学習データのみから翻訳ルールを得るのではなく，獲得した翻訳ルールの中から帰納的に学習を繰り返すことでも新たに翻訳ルールを獲得することができるため，学習用の実例データを大量に用意する必要がないという利点がある．

7 基礎実験

ATRデータベース (SLDB) 中の任意に選んだ3データセットから，発話内容を句読点分割したときに原言語と目標言語間で翻訳として対応が一意に決定される82発話を用いて翻訳実験を行った．表2に発話とルール辞書に登録された翻訳ルール数の推移を示す．

我々はここで，原言語の未知入力発話 “はい，田中様．” に対して，12個のルールが候補としてルール辞書から選ばれ，それらのルールを組み合わせることで正しい翻訳文 “OK, Mr.Tanaka.” が生成されたことを確認した．

8 考察とまとめ

音声から文字列に変換することなく原言語と目的言語の実例発話の音響特徴ベクトルを対象に，ベクトル間の距離から対応を決定することで翻訳ルールを獲得し，それらを翻訳に用いた結果，未知の音声発話入力に対して翻訳文を生成することができた．

本手法は発話音声を音素などの単位に分割せずにすべての処理を行うため，これまで音声認識の適用が困難であった種類の音声に対しても，適用することが可能であると考えられるため多方面での応用を期待できる．今後の課題としては，共通部分検索での計算コストの軽減のために新しいアルゴリズムの導入や，言い直しや無声区間の取り扱いなどを考慮する必要がある．

表 2: 発話数と獲得ルール数の推移

データセット	発話数	獲得ルール数
TTC22043	28	1,285
TTC22044	28	5,384
TTC22071	26	10,663

謝辞

本研究の一部は文部科学省科学研究費補助金（第14658097号）によって行なわれている．

参考文献

[1] J.Müller and H.Stahl, "Speech Understanding and speech translation by maximum a-posteriori semantic decoding", *Artificial Inteligence in Engineering*, Vol.13, pp373-384, 1999,

[2] T. Takezawa, T. Morimoto, Y. Sagisaka, N. Campbell, H. Iida, F. Sugaya, A. Yokoo and S. Yamamoto, “A Japanese-to-English speech translation system:atr-matrix,” Proc. ICSLP’98, pp.2779–2782, 1998.

[3] A. Lavie, A. Waibel, L. Levin, M. Finke, D. Gates and M. Gavaldà,“Janus-iii: Speech-to-speech translation in multiple languages,” Proc. ICASSP’97, pp.99–102, 1997.

[4] K. Araki and K. Tochinai, “Effectiveness of natural language processing method using Inductive Learning,” Proc. Artificial Intelligence and Soft Computing’01, pp.295–300, July, 2001.

[5] 村上，広重，荒木，栃内：”文字表現を介さない音声機械翻訳システムの構想と基礎実験”，日本音響学会講演論文集，pp.391-392(2001-10)

[6] K.Murakami, M.Hiroshige, K.Araki and K.Tochinai, "Evaluation of Rule Aquisition for a New Speech Translation Method with Waveform using Inductive Learning", *AI2002*, 2002

[7] T. Morimoto, N. Uratani, T. Takezawa, O. Furuse, Y. Sobashima, H. Iida, A. Nakamura, Y. Sagisaka, N. Higuchi and Y. Yamazaki, “A speech and language database for speech translation research,” Proc. ICSLP’94, pp.1791–1794, 1994.

[8] http://kt-lab.ics.nitech.ac.jp/ tokuda/SPTK

[9] 村上，広重，荒木，栃内：”種々の文音声データに対する音声機械翻訳システムの動作とその課題”，日本音響学会講演論文集，pp.385-386(2002-3)

[10] Silverman, H.F. and Morgan, D.P.:"The application of dynamic programming to connected speech recognition, *IEEE, ASSP magazine*, July, pp.6-25,1990

[11] 村上，荒木，広重，栃内：”直接音声翻訳システムにおける効率良い始点探索法とその評価”，日本音響学会講演論文集，pp.413-414(2002-3)