再帰チェーンリンク型学習による対訳辞書の自動構築

Automatic Generation of Bilingual Dictionary Using Recursive Chain-link-type Learning

越前谷博 †*　荒木健治 ††　桃内佳雄 †　栃内香次 †††

†(北海学園大・工学部)　††(北大・工学研究科)　†††(北海学園大・経営学研究科)

*e-mail:echi@eli.hokkai-s-u.ac.jp

1 はじめに

現在のIT社会では，インターネットを介して様々な国から瞬時に必要な情報を入手することや他国の人々とのミュニケーションをリアルタイムで行うことが可能である．しかし，その際に問題となるのが言葉の壁である．近年，この問題を解消するものとして多くの機械翻訳システムが市販されるようになった．しかし，言語は時代と共に変化するため，常に未知語が出現し続ける．更に，様々な言語に対応可能な多言語翻訳という点では，十分な機械翻訳システムが開発されているとはいえない．我々は，高性能な多言語間機械翻訳システムを実現するための第一段階として，学習機能に基づき対訳辞書を自動構築するシステムの実現に向けての研究を行っている．そこで，本稿では，システムが電子化された対訳文から自動的に対訳語を獲得する，再帰チェーンリンク型学習 [1] による対訳語の自動獲得手法を提案する．本手法は，学習機能に基づきシステム自身が対訳語を動的に獲得できるため，未知語に対処可能であると共に，様々な言語間の対訳語を一つのシステムを用いて獲得することができる．したがって，従来の解析的な基づく手法 [2] や統計に基づく手法 [3] のように静的な言語知識の使用を前提としない．更に，本手法の持つ高い学習能力により，従来の学習に基づく手法 [4] のように膨大な量の類似した対訳文を必要としない．性能評価実験の結果，本手法における対訳語の正獲得率として74.9%が得られた．したがって，我々は本手法の有効性を確認することができた．

2 再帰チェーンリンク型学習による対訳語の獲得

再帰チェーンリンク型学習では，様々な対訳文から対訳語と対訳テンプレートを連鎖的に自動獲得する．本稿での対訳テンプレートとは，対訳文中の語や句を変数化することで得られる，対訳文を一般化したものである．この対訳テンプレート内の変数とその変数に隣接する語のコロケーションを利用することで，システムは対訳語を自動的に獲得する．また，対訳文中の変数化する部分は，獲得された対訳語に基づき決定される．したがって，対訳語の獲得が対訳テンプレートの自動獲得をもたらし，対訳テンプレートの獲得が対訳語の自動獲得をもたらす．すなわち，対訳語と対訳テンプレートの自動獲得の連鎖が発生する．再帰チェーンリンク型学習による対訳語の獲得処理の概略図をFig.1に示す．

対訳語と対訳テンプレートは，それぞれ，原言語文から抽出された原部と目的言語文から抽出された目的部との組で構成される．Fig.1の処理1では，対訳語Aが存在する場合，その対訳語Aを用いて，対訳文No.1から対訳テンプレートBが獲得される．すなわち，対訳語Aは対訳文の原文からは“Z”を，その訳文からは“ζ”を抽出して良いという情報を有していると捉えることができる．Fig.1の処理2では，獲得された対訳テンプレートBを用いて，対訳文No.2から対訳語Cが獲得される．すなわち，対訳テンプレートBは，変数とそれに隣接する語のコロケーションに基づき，対訳文の原文からは“E”の右側から“H”の左側までを，訳文からは“θ”の右側から“η”の左側までを抽出して良いという情報を有していると捉えることができる．更に，Fig.1の処理3では，獲得された対訳語Cを用いて，対訳テンプレートDが獲得される．このように，再帰チェーンリンク型学習では，対訳語と対訳テンプレートが連鎖的に獲得されていく．そうすることで，一つ一つの対訳文を対象として，様々な対訳文から効率よく対訳語を獲得することが可能となる．また，Fig.1の対訳語Aのような，再帰チェーンリンク型学習を稼動させる際の起点となる対訳語や対訳テンプレートは，我々が従来より提案している学習型手法，遺伝的アルゴリズムを適用した帰納的学習（GA-IL）[5] を用いて獲得する．そうすることで，システム全体を学習メカニズムという一つの統一された枠組みで構築することができる．

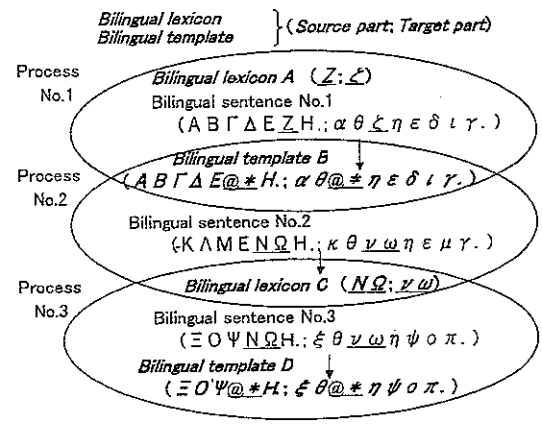


Fig. 1 再帰チェーンリンク型学習による対訳語獲得の処理概要

3 処理過程

3.1 処理の流れ

再帰チェーンリンク型学習を備えた対訳語の自動獲得システムの処理概要をFig.2に示す．

システムは対訳文が与えられると，フィードバック部において獲得された辞書中の対訳語と対訳テンプレートの正誤を自動的に決定する．その結果，正しいものと評価された場合，その対訳語または対訳テンプレートの正確実度数を1増加させ，誤ったものと評価された場合には，誤確実度数を1増加させる．また，学習部では，与えられた対訳文からGA-ILと再帰チェーンリンク型学習により，新たな対訳語または対訳テンプレートを自動獲得し，辞書に登録していく．

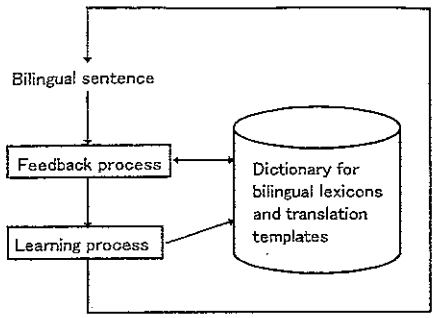


Fig. 2 処理の流れ

3.2 再帰チェーンリンク型学習の処理過程

Fig.1の処理1のような，対訳語を用いた，対訳テンプレート獲得の処理過程を述べる．

(1) 対訳テンプレートの変数に隣接する語と同じ語を持つ対訳文を選択する．
(2) 対訳テンプレートの変数に該当する部分として，対訳文中の共通部分に隣接する部分を抽出する．
(3) 抽出された部分を対訳語として辞書に登録する．その際，獲得された対訳語に対して，使用された対訳テンプレートと同じ正確実度数と誤確実度数を与える．

次いで，Fig.1の処理2のような，対訳テンプレートを用いた，対訳語獲得の処理過程を述べる．

(1) 対訳語の原部と目的部の全体と同じ部分（共通部分）を持つ対訳文を選択する．
(2) 対訳文中の共通部分を変数に置き換えることで，対訳文の一般化を行う．
(3) 抽象化された対訳文を対訳テンプレートとして辞書に登録する．その際，獲得された対訳テンプレートに対して，使用された対訳語と同じ正確実度数と誤確実度数を与える．

4 性能評価実験

4.1 実験方法

本システムを評価するための評価データとして，中学1，2年生用の英語テキスト [6][7][8][9][10] に掲載されている対訳文2,856組を用いた．これらの対訳文の英文の平均単語数は6.0である．なお，辞書の初期状態は空より行った．評価は，対訳文2,856組に含まれる全名詞数437と名詞句数26に対し，どれだけの割合で正しい訳語が得られたかを調査することにより行った．一つの語に複数の訳語が得られた場合には，フィードバック部で決定される正確実度数と誤確実度数に基づき順位付けされた訳語の上位3位までを評価の対象とした．

4.2 実験結果と考察

Table 1に，再帰チェーンリンク型学習を用いたシステムとGA-ILのみを用いたシステムの対訳語の正獲得率を示す．( ) の中の数値は獲得された正しい対訳語数である．

Table 1より，正獲得率は再帰チェーンリンク型学習を用いることにより58.7%から74.9%に増加した．これらの結果は，再帰チェーンリンク型学習が様々な対訳文から効率よく対訳語を自動獲得できるという，高い学習能力を有することを示している．GA-ILのみのシステムでは，対訳語を獲得するために，類似した二つの対訳文が数多く必要となる．それはスパースな対訳コーパスからは対訳語を十分に獲得することが困難であることを意味する．それに対し，再帰チェーンリンク型学習では，一つ一つの対訳文を対象に対訳語を次々と獲得できるため，スパースな対訳コーパスからでも効率よく対訳語を獲得することが可能である．

Table 1 正獲得率

システム	正獲得率	正獲得率の内訳	
		名詞	名詞句
本システム	74.9%(347)	75.5%(330)	65.4%(17)
GA-ILのみ	58.7%(272)	60.4%(264)	30.8%(8)

5 おわりに

本稿では，再帰チェーンリンク型学習による対訳語の自動獲得手法について述べた．性能評価実験の結果，評価データに使用した対訳コーパス中に存在する全名詞および名詞句における対訳語の正獲得率は74.9%であった．この結果は，再帰チェーンリンク型学習の有効性を示すものである．今後は，より高度なデータを用いて性能評価実験を継続する．更に，再帰チェーンリンク型学習を他のアプリケーションにも適用し，その有効性について検証する予定である．

謝辞

本研究の一部は，北海学園大学ハイテク・リサーチ・センター研究費によって行われている．

参考文献

[1] H. Echizen-ya, K. Araki, Y. Momouchi and K. Tochinai: Study of Practical Effectiveness for Machine Translation Using Recursive Chain-link-type Learning, In *Proceedings of COLING'02*, Taipei, Taiwan(2002).

[2] 北村美穂子，松本祐治：対訳コーパスを利用した対訳表現の自動抽出，情報処理学会論文誌，Vol.38, No.4(1997).

[3] P. Fung: A Pattern Matching Method for Finding Noun and Phrase Noun Translations from Noisy Parallel Corpora, In *Proceedings of the ACL'95*, Massachusetts, USA(1995).

[4] H. A. Güvenir and I. Cicekli : Learning Translation Templates from Examples. *Information Systems*, 23(6), (1998).

[5] 越前谷博，荒木健治，桃内佳雄，栃内香次：実例に基づく帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性，情報処理学会論文誌，Vol.37, No.8(1996).

[6] 教科書ガイド教育出版版ワンワールド1，日本教材，東京 (2001).

[7] 教科書ガイド教育出版版ワンワールド2，日本教材，東京 (2001).

[8] 教科書システム問題集2，朋友出版，東京 (2001).

[9] 教科書ワーク2，文理，東京 (2001).

[10] 教科書トレーニング2，新興出版社，大阪 (2001).