主題部分・非主題部分の対比を韻律加工により表現した合成音声の印象評価*

◎藤原　敬記　　広重 真人　　荒木 健治(北大・工)　　栃内 香次(北海学園大・経営)

1. はじめに

近年コンピュータの普及が著しく、人間とコンピュータが接する場面が多くなっており、また今後さらに増えると予想される。その際に、音声合成の技術は、人間と機械の情報交換において非常に有効で効率的な手段である。音声合成の研究は比較的古くから行われ、現在では高品質の音声を持つ合成システムも存在する[1]。それらの研究では多くの場合、合成音声の明瞭性・自然性の向上を目指している。しかし中小規模の市販規則合成システムなどでは、合成音声のすべての部分について明瞭性を高くするために一音一音が際立っており文末などでなめらかさが感じられないことがある。日常会話で、すべての文節を明瞭に発話していることは少なく、それ程重要だと思っていない文節や文末は、重要な情報の含まれる部分に比べ、はっきりと発話されない傾向がある。

発話内容や発話スタイルなどの影響から韻律要素・音韻要素が変化し、これが人間の発話に流暢なリズムを与えると考える。本研究では、この連続的な変化の音声合成での実現をめざし従来あまり扱われなかった「あいまい」な部分の韻律的・音韻的な特徴にも注目し、合成システムへの導入を検討する。本稿では、重要な情報の含まれる部分（以下、主題部分）と重要な情報の含まれない部分（以下、非主題部分）の対比を表す韻律要素・音韻要素としてフォルマント、パワー、F0を採用する。この韻律要素・音韻要素を後処理加工した合成音声を作成し、SD 法を用いた聴取実験で印象評価する。

2. 合成音声加工

「Visual Speech Creator」Ver.1.21,2000 年(NTT-IT(株)製)[2]で音声を作成し、ESPS/waves+の簡単なフォルマント分析・合成器を用いて再合成を行った。再合成の際に、フォルマント、音源 rms パワー、F0 を各々独立に以下のように加工する。パワー、フォルマントの制御は元の合成音声から求めた F0（以下、原 F0）が低い部分だけ原 F0 に同期させて行う。F0 が低い部分とは、原 F0 の最大値 $F0_{max}$ と最小値 $F0_{min}$ の範囲において、原 F0 が式(1)で求まる $F0_{flag}$ よりも小さな部分である。

$$\log F0_{flag} = (\log F0_{\max} - \log F0_{\min}) \times 2/3 + \log F0_{\min} \quad (1)$$

3.1 パワー制御

音源パワーは、元の合成音声の音源パワーに加工乗数 r_{pow} を乗じて求める。この加工乗数 r_{pow} は上述の原 F0 が低い部分で原 F0 の上下動に比例して変化するように定め、音声サンプル中の $F0_{flag}$ で 1.0、最小値で $r_{pow_\min}$ となるようにする。

3.2 フォルマント制御

フォルマントは、原 F0 の低下に伴って、中立的な母音のフォルマントに引き寄せられるように加工する。まず、中立的な母音として、損失のある一様音響管の周波数応答[4]を参考にしながら、予備実験[2]で得られた実音声の中立的母音の特性を設定した(F1=481,F2=1342,F3=2203,F4= 3316[Hz])。各時点で観測された各フォルマントを f_i、加工後の各フォルマントを f_i'、中立母音の各フォルマントを $f_{i\cdot lazy}$（共に $i = 1,2,3,4$）として、式(2)によりフォルマント加工を行う。r_{for} は r_{pow} と同様に原 F0 の上下動に比例して変化する加工乗数で、原 F0 が $F0_{flag}$ のとき 1.0、$F0_{\min}$ のとき $r_{for_\min}$ をとるように定める。

$$f' = f_{i\cdot lazy} + (f_i - f_{i\cdot lazy}) \times r_{for\ (i=1,2,3,4)} \quad (2)$$

3.3 F0 制御

F0 は、$F0_{\min}$ を固定して $F0_{\max}$ と $F0_{\min}$ の範囲を r_{f0} に縮小させる。予備実験で F0 は音声全体にわたって一様に平坦化していたので、パワー・フォルマントとは異なり、F0 の加工は原 F0 には同期させず r_{f0} は指定範囲内で常に一定の値とする。

今回 $(r_{pow_\min}, r_{for_\min}, r_{f0}) = (0.5, 0.3, 0.5)$ とした。

3. 聴取実験

2 の制御を非主題部分に行った音声（以下、部分加工音声）と、制御を行っていない合成音声（以下、無加工音声）を用いて聴取実験を行った。部分加工音声は分析・再合成を行っているが、簡易なフォルマント分析・合成器を用いたため、元の合成音声に比べ音質は明らかに劣化している。この音質劣化が実験に影響するのを除くために、無

---

* “Evaluation of the impression of the synthesized speech which express contrast of topic portions and non-topic portions by prosodic post-processing”, By Noriki FUJIWARA, Makoto HIROSHIGE, Kenji ARAKI (Graduate School of Engineering, Hokkaido University) and Koji TOCHINAI (Graduate School of Business Administration, Hokkai-Gakuen University)

加工音声にも一度分析・再合成を行った。

実験手法として、ある事象に対する人間のイメージを評価するために用いられる SD 法を用いた。被験者は日本語を母国語とする男子大学院生 13 名、雑音の少ない部屋で、音声をヘッドフォンにより呈示した。回答には CGI により Web ブラウザで収集した。5 文の短文について無加工音声と部分加工音声をそれぞれ短文 5 文作成し、計 10 種類の音声刺激を呈示する。ランダムに並べたそれらの音声を、練習時には 1 セット、その後の本番時には 3 セット呈示した。尺度は[5]を参考に 15 尺度(表 1)を選び、尺度呈示順を被験者ごとにランダムに変更した。音声刺激の間隔は練習時 60 秒、本番時 50 秒とした。SD 法の尺度は一対の形容詞であるが、一般的に良い印象を持つ形容詞を「positive」側、もう一方の形容詞を「negative」側とする。

4. 結果と考察

尺度ごとに平均を求め、被験者ごとに 5 種類の文で部分加工音声の方を positive に選んだ数を図 1 に示す。これを見ると、部分加工した音声が無加工の音声に比べ特に「静かな」、「落ち着いた」、「丸みのある」、「やわらかい」音声として感じられていることがわかる。これは非主題部分での制御により、音韻の際立ちを抑えるなどの効果が得られたためと考えられる。

実験後被験者から、「文末が聞き取りにくい音声がある」との意見があった。これは、加工乗数は F0 が低下するほど大きくなるので、文末の F0 低下によってフォルマント・パワーの制御が強く行われたためと考えられる。この文末の影響が、被験者に部分加工音声に対して negative な印象をいだかせたひとつの理由と考えられるので、制御に関する設定値を再検討する必要がある。

5. おわりに

主題部分・非主題部分の対比を合成音声のフォルマント・パワー・F0 を後処理加工により表現することを試みた。作成した音声を用いた聴取実験では、無加工音声よりも部分加工音声が「丸みのある」、「やわらかい」等の印象を与えることが確認された。今後はより詳細な分析を行う予定である。

謝辞

音声合成の際、日本音響学会第 68 回技術講演会で使用された NTT-IT(株)製「Visual Speech Creator」を使わせていただきました。深く感謝致します。

参考文献

[1] ニック・キャンベル,アラン・ブラック,“CHATR:自然音声波形接続型任意音声合成システム”,信学技法,SP96-7,pp.45-53

[2] 藤原敬記,広重真人,荒木健治,栃内香次“明瞭度を考慮した規則合成の提案と基礎的検討”,日本音響学会講演論文集,1-P-15,pp.381-382(2002.3)

[3] NTT-IT(株),“Visual Speech Creator 操作説明書”

[4] L.R.Rabiner/R.W.Schafer(鈴木久喜訳),「音声のディジタル信号処理(上)」,コロナ社(1983)

[5] 難波精一郎,桑野園子,「音の評価のための心理学的測定法」,コロナ社(1993)

表 1　実験で用いた尺度

尺度	positive	negative	尺度	positive	negative	尺度	positive	negative
1	人間的	機械的	6	丸みのある	とげとげしい	11	明るい	暗い
2	静かな	騒々しい	7	好ましい	好ましくない	12	美しい	汚い
3	落ち着いた	甲高い	8	はっきりした	ぼんやりした	13	冷静な	感情的な
4	溶け合った	ばらばらな	9	調和のとれた	不調和な	14	分かりやすい	分かりにくい
5	快い	不快な	10	やわらかい	かたい	15	引き締まった	たるんだ

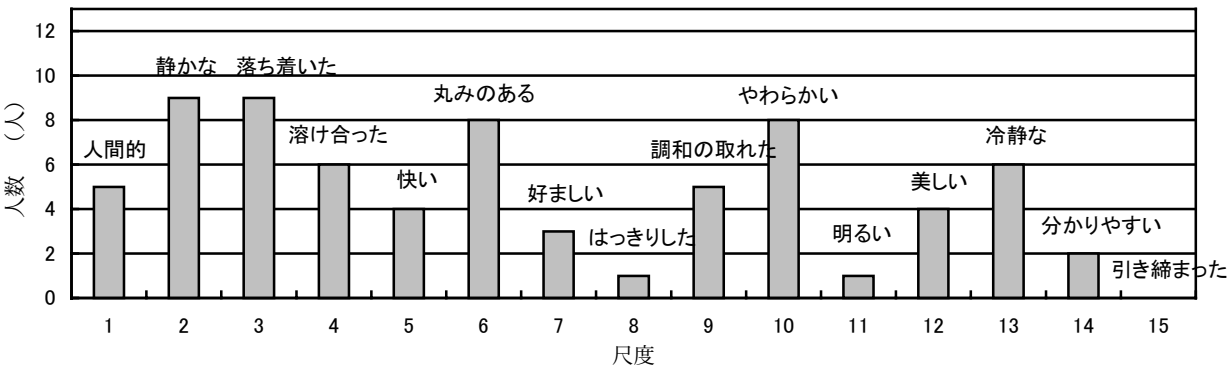


図 1　無加工音声より部分加工音声をより positive に選択した人数