情報量に基づく帰納的学習を用いた音声翻訳規則獲得手法

Acquisition Method of Speech Translation Rules by Inductive Learning based on Amount of Information

D-5-7

木村泰知[1] 荒木健治[1] 栃内香次[2]
Yasutomo Kimura Kenji Araki Koji Tochinai

北海道大学大学院 工学研究科[1]
Graduate School of Engineering, Hokkaido University
北海学園大学大学院 経営学研究科[2]
Graduate School of Business Administration, Hokkai Gakuen University

1 まえがき

近年，音声認識技術の向上に伴い，音声を用いた機械翻訳の研究が行われている．音声翻訳は，海外旅行や電話における異言語話者との会話に利用可能である．音声翻訳は一般に機械翻訳に音声認識処理と音声合成処理を付加することが多い [1]．しかし，音声認識結果には個人特有の言いまわし，間投詞，雑音などが含まれる．このような言語現象を網羅するための規則を記述することは困難である．さらに，一つのシステムを他言語へ適用するために労力がかかり，汎用性が低いという問題点がある．従来より，我々は翻訳規則の獲得する能力に着目し，帰納的学習により翻訳規則を獲得する手法を提案している．我々が提案した帰納的学習で仮定されている生得的能力とは「2つの事物に対して共通部分と差異部分を見分ける能力」である [2]．この生得的能力により汎用性の高い規則獲得を行うことが可能である．原言語の差異部分と目的言語の差異部分の対応関係を獲得することで，翻訳に適した単位の翻訳規則を獲得する．さらに，差異部分を変数化することで翻訳文を生成するテンプレートを獲得する．しかし，従来の帰納的学習では規則獲得が効率的に行えない問題が存在した．これは表層的なマッチングにより，共通部分と差異部分を定義しているためである．そこで，我々は情報量に基づく帰納的学習を用いて，音声翻訳の規則を獲得する手法を提案する．差異部分は特徴ある部分であるため，情報量が大きい部分，共通部分は頻繁に出現するため共通部分となりやすく，情報量が小さい部分と考えることができる．本手法における機械翻訳部では原言語と目的言語の並びが言語によって異なるため，差異部分を1つとする．そのため，分割数を最高3分割までとなる．本稿では，情報量に基づく帰納的学習による音声翻訳における規則獲得の方法について述べる．

2 実験

実験の目的は，話し言葉の自然発話音声・言語データベース（SLDB）から，本手法により共通部分と差異部分とに分割し，分割結果を評価することである．

獲得までの処理手順を図1に示す．実験データで単語頻度と共起頻度の計算を行い，分割点を決定する．分割するためには隣接している単語の共起頻度を利用する．共起頻度の最も低い部分を分割点とする．3分割とするために，分割点は共起頻度の最も低い2点となる．分割された部分から差異部分が決定され，差異部分と共通部分が獲得される．3分割中で最も情報量の大きい単語を含む部分が「差異部分」として抽出される．情報量の式を以下に示す．

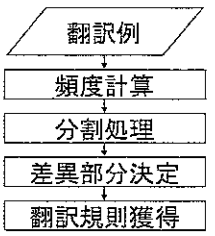


図1 処理過程

情報量 $I(x) = -logP(x)$ … (1)

$P(x) = \frac{F(x)}{N}$ であり，$F(x)$ は単語 x の出現頻度，N は総単語数である．実験データは SLDB の 3,000 文である．獲得された差異部分の規則の例を表1示す．翻訳可能な規則の獲得が確認された．

表1 獲得された差異部分の対応規則

英語	日本語
spelling of your name, please?	スペルを
T-A-N-A-K-A.	ティーエーエヌエーケイエー
right.	そう
the type of card?	カードの種類

3 おわりに

本稿では情報量に基づき，共通部分と差異部分を定義した．その結果，翻訳に利用可能な単位で原言語と目的言語の対応関係を獲得できる可能性を示した．今後は共通部分と差異部分に基づいた規則を用いて，実際に音声翻訳システムの構築を行う予定である．

参考文献

[1] 菅谷，竹澤，隅田，匂坂，山本：“音声翻訳システム (ATR-MATRIX) の開発と評価”，情処論，Vol.43, No.7, pp.2230-2241,2002.

[2] K. Araki and K. Tochinai, “Effectiveness of Natural Language Processing Method Using Inductive Learning,” Proceedings of the IASTED International Conference ARTIFICIAL INTELLIGENCE AND SOFT COMPUTING, pp.295-300, May, 2001, Cancun, Mexico.