意味解析規則の教師なし学習における深層範疇の基礎的検討

D-5-6

A FUNDAMENTAL STUDY ON DEEP CATEGORIES FOR UNSUPERVISED LEARNING OF SEMANTIC ANALYSIS RULES

渋木英潔[1] 荒木健治[2] 桃内佳雄[3] 栃内香次[4]
Hideyuki Shibuki Kenji Araki Yoshio Momouchi Koji Tochinai

北海学園大学ハイテク・リサーチ・センター[1]
High-Tech Research Center, Hokkai-Gakuen University
北海道大学大学院工学研究科[2]
Graduate School of Engineering, Hokkaido University
北海学園大学大学院工学研究科[3]
Graduate School of Engineering, Hokkai-Gakuen University
北海学園大学大学院経営学研究科[4]
Graduate School of Business Administration, Hokkai-Gakuen University

1 まえがき

自然言語においては，同じ意味内容を伝えるために幾通りかの表現を用いることが可能であり，このような多様な表現による文を単一の表現に変換する意味解析は，その後の処理において有益であることが多い．それゆえ，意味解析に必要な知識として，例えば，表層格から深層格に変換する知識を自動的に学習する手法として，大石らの手法 [1] などが行われてきた．しかしながら，大石らの手法では，学習データとして，深層格のタグが直接付与された文を用いる必要がある．このような手法では，他の分野の知識を学習するために新たなタグつき文を用意する必要があり，タグを付与する労力や分野間でのタグの揺れなどの問題が生じることから，拡張性に乏しいと考えられる．我々は，この問題を解決するために，人間が取りうる深層範疇のパターンを事前に用意し，このパターンを学習文中の表層表現と教師なしで対応付けることを試みる．それゆえ，事前に用意すべき深層範疇のパターンがどのようなものであるかを調査するために，本稿では，教師なし学習という視点より，深層範疇パターンについての基礎的検討を行う．具体的には，深層範疇パターンの種類，及び，表層表現から深層範疇パターンへの曖昧性の調査である．また，対象とする関係は，動詞と名詞の間の格情報に限定せず，全ての品詞間の関係について扱うこととした．

2 実験

今回の調査では，EDR 日本語コーパスの概念関係子を深層範疇と仮定し，以下の手順で行った．意味フレーム中に出現する形態素を自立語とし，自立語以外で品詞が記号以外の形態素を付属語とする．文節は，それぞれの自立語を中心とし，構文木を用いて付属語を最近傍の自立語に追加することで決定する．表層表現は，ある文節中の自立語以後の付属語列とした．調査の対象となる意味フレームは，main となるスロットを含み，スロット値が自立語であるスロットを main 以外に 1 つ以上含むものとした．文中に出現しない概念などをスロット値にもつスロットは調査の対象外としている．また，単一の表現に変換する際，ある意味フレーム中に複数の同じ深層範疇が存在することは問題であり，そのような意味フレームも対象外とした．以上の手順により，各スロット数における表層表現と深層範疇パターンそれぞれの種類と表層表現から深層範疇パターンへの曖昧性を調査した．曖昧性の計算は，各表層表現がコーパス中で対応した深層範疇パターンの種類を調べ，その平均により行った．表 1 に結果を示す．意味フレームが取ったスロット数の最大値は 8 であり，深層範疇パターンの総数は 6,095，表層表現は 72,531 であった．曖昧性はスロット数が 5 から 3 にかけて減少する際に大幅に上昇しており，これは，ゼロ代名詞などによる省略を考慮していないために生じたものと考えられる．また，このことから，深層範疇パターンの必須のスロット数は 4 ないし 5 であり，それ以上のスロットは任意のものであると考えられる．

3 今後の予定

本稿では，意味解析に必要な知識を教師なしで自動的に学習するために，事前に用意すべき深層範疇パターンについて，その種類及び表層表現からの曖昧性について調査を行った．調査の結果，用意すべき深層範疇パターンは数千のオーダーであり，全表層表現からの曖昧性は 1.67 であった．今後，深層範疇パターンに対する更なる調査を行い，その調査から得られた深層範疇パターンを用いた教師なし学習手法を開発する予定である．

参考文献

[1] 大石亨, 松本裕治, “格パターン分析に基づく動詞の語彙知識獲得,” 情報処理学会論文誌, vol.36, no.11, pp.2597–2610 Nov. 1995.

表 1 実験結果

スロット数	表層表現	深層範疇	曖昧性
1	9,302	41	1.46
2	20,961	432	1.89
3	26,476	1,652	1.76
4	12,920	2,404	1.43
5	2,598	1,322	1.13
6	257	227	1.02
7	16	16	1.00
8	1	1	1.00
計	72,531	6,095	1.67