論　文

機械翻訳における変換例を用いた汎用的な前処理手法

長島　康人[†]　　荒木　健治[††]　　栃内　香次[††]

A Method for Preprocessing in Machine Translation Using Examples of Transformation

Yasuto NAGASHIMA[†], Kenji ARAKI[††], and Koji TOCHINAI[††]

あらまし　機械翻訳において翻訳精度を向上させるための方法の一つに，入力文に対してあらかじめ処理を施す前処理がある．しかし従来のあらかじめ規則を与えておく解析的な手法には，規則が特定の機械翻訳システムに依存するため様々な機械翻訳システムに対して適用することができないという問題がある．この問題に対して，本論文では前処理例から学習により変換規則を獲得適用する手法を提案する．本手法では前処理の変換例から規則を獲得することによりシステムが対象となる機械翻訳システムに依存した規則を獲得することができる．本論文では実際にシステムを作成し，複数の種類のテキストを用いて実験を行いその有効性を確認した結果について述べる．

キーワード　機械翻訳，前処理，汎用性，学習

1. まえがき

近年の世界規模でのネットワークの普及に伴い，電子化された異言語文書に触れる機会が増大している．従来言語間の翻訳は人手により行われてきたが，計算機の発明に伴い計算機による機械翻訳システムの研究が行われている．機械翻訳手法には様々な手法があるが，いずれの手法を用いた翻訳結果にも訳語選択や係り受け関係の誤り，不自然な表現などがあり，満足のいくものではない [1], [2].

機械翻訳精度を向上する方法として，入力文に対してあらかじめ処理を施す前処理と，翻訳結果に対して処理を施す後処理がある．機械翻訳における後処理は，機械翻訳システムの翻訳結果を直接処理するため翻訳文の自然性の向上などに対して有効であるが，その反面，構文構造まで誤っているような翻訳結果に対してはその改善効果は少ない．一方，前処理では翻訳文の自然性の向上などは期待できないが，入力文を機械翻訳システムにとって解析しやすい形に変換するため，後処理では修正できないほど大きく誤っている翻訳文の生成を抑制することができる．現在の機械翻訳技術では，こうした後処理では修正できないような機械翻訳結果はいまだに多く存在しており，前処理はどのような機械翻訳システムにおいても重要な処理となっている．

従来行われている前処理に関する研究は，主にあらかじめ規則を与えておく解析的な手法である [3]〜[6]. しかし，これらの手法では規則が適用された場合には高い確率で翻訳品質が改善されるが，人手により矛盾なく与えられる規則には限界があるため，再現率の低さが問題となる．また，あらかじめ英語名詞句や並列表現のように特定の誤りに対して変換の規則を与えることにより書換えを行うため，翻訳結果における他の種類の誤りは改善できない．更に，それぞれの手法の問題点に加えて，従来研究の多くが抱える共通の問題点としてその汎用性が挙げられる．つまり，従来の前処理に関する研究の多くは個々の機械翻訳システムに付随して研究されているものであり，現在，既に多数存在する機械翻訳システムに対して汎用的に適用できるものではないということである．文献 [7] の研究では学習を用いることにより対象言語に関しては特定の言語に依存しない手法を実現しているが，音声翻訳システムにおける翻訳精度の改善を目的とし，音声認識

[†]（株）NTT データビジネス開発事業本部，東京都
IT Business Development, NTT DATA Corporation, Toyosu 3-chome, Koto-ku, Tokyo, 135–6033 Japan
[††] 北海道大学大学院工学研究科電子情報工学専攻，札幌市
Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkaido University, 13 Kita, 8 Nishi, Kita-ku, Sapporo-shi, 060–8628 Japan

の誤りなど音声翻訳システム特有の問題を想定しているため，適用可能な機械翻訳システムは制限されてしまう．文献 [8] の研究は前編集規則の学習手法の提案にとどまり，獲得された規則の有効性，規則適用の効果などは報告されていない．

これらの問題に対して，本論文では様々な機械翻訳システムに対して汎用的に用いることができる前処理手法を提案する．以下，本手法を用いて作成したシステムを本論文では IL-PP（Inductive Learning for Preprocessing in Machine Translation）と呼ぶ [9]．IL-PP では前処理の変換例から繰り返し学習を行うことにより，それぞれの機械翻訳システム，ユーザに適した規則を自動的に獲得する．IL-PP は徐々に対象とする機械翻訳システムに依存したものに変化していくため，本手法はどのような機械翻訳システムに対しても適応可能な汎用的な手法となる．

本論文では実際に提案手法を組み込んだシステムを作成し，複数の機械翻訳システムに対して適用実験を行い，その実験結果より本手法の有効性を確認する．以下，まず **2.** で IL-PP の処理過程について述べ，**3.** では実験を行いその手順と結果，考察を述べ本手法の有効性を示す．最後に **4.** で全体をまとめ，今後の課題について述べる．

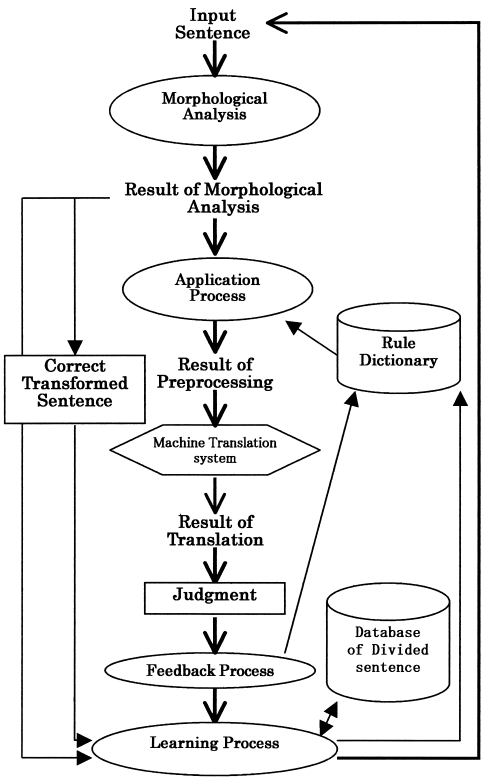


図 1　処 理 過 程
Fig. 1　Outline of process.

2. 処 理 過 程

2.1 概　　要

本手法の全体的な処理過程を図 1 に示す．図 1 において楕円で示されている処理部及び「Rule Dictionary」「Database of Divided Sentence」が IL-PP となる．ここで，本手法では特定の言語の情報を用いていないため基本的に種々の言語に適用可能であると考えられるが，本論文ではその第 1 段階として英日翻訳を対象とする．IL-PP に原文が入力されると，まず原文に対して形態素解析を行う．ここで，本手法で用いる情報は形態素解析結果のみとしている．これは，そもそも機械翻訳における誤りというものは，構文解析や意味解析の解析誤りによるものが大きいと考えられ，ここでそれらの解析結果を用いることは矛盾しているからである．続いて規則適用部において，変換規則辞書，分割規則辞書中に入力文に対し適用可能な規則が存在するか探索し，適用可能な規則が存在した場合，**2.2** で述べる適用順序に従って規則を適用する．次に変換結果を機械翻訳システムに入力し，翻訳を行う．この翻訳結果と入力文の機械翻訳システムによる翻訳結果を比較しユーザが判定を行い，フィードバック部において **2.3.1** で述べる規則の正変換度数，誤変換度数の更新を行う．その後，学習部において入力文の形態素解析結果と人手により作成された正変換文から，変換規則，分割規則を獲得する．ここで，本論文ではそのままでは誤った翻訳結果となってしまう入力文を，正しい翻訳結果となるように単語の付加，削除，文の分割を行った文のことを正変換文と呼ぶ．以下，各処理部について説明する．

2.2 規則適用部

規則適用部では，まず獲得された変換規則が保持されている変換規則辞書中に適用可能な規則が存在するか探索する．変換規則は，各規則が適用条件を保持しており，その適用条件を満たした規則が適用可能な規則となる．複数の規則が重複した場合，**2.3.2** で述べる規則適用正解率の高い規則を適用し，もし規則適用正解率が等しい場合には，獲得された時期が最も新しい規則を優先して適用する．変換規則の適用はまず訳語選択とユーザの入力誤りに関する規則から適用され

る．これは先立って行った予備実験の結果，改悪箇所の半数以上が係り受け関係改善の規則に起因していることと，訳語選択とユーザの入力誤りに関する規則は，適用された場合翻訳品質改善となる可能性が高いことが判明したからである．また，分割規則を先に適用したり，変換規則中の係り受け関係改善の規則を規則適用正解率に従って他の変換規則と同様に適用を行った場合，文中の変換操作が行われた部分には別の規則は適用されないため，訳語選択とユーザの入力誤りに関する規則が適用されず，結果として改善率の低下を招くことも確認された．なお，この予備実験の結果については付録に示す．

続いて訳語選択，ユーザの入力誤りに関する規則が適用されていない部分に対して適用条件を満たす規則を，変換規則辞書中の係り受け関係に関する規則と分割規則の中から検索する．適用可能な規則が複数存在した場合には，訳語選択，ユーザの入力誤りに関する規則と同様に規則適用正解率が最も高い規則を適用し，規則適用正解率が等しい場合には獲得された時期が最も新しい規則を優先して適用する．変換処理は，基本的に単語の付加，削除，及び文の分割からなる．もし，適用条件を満たす規則が存在しなかった場合には入力文をそのまま出力する．

2.3 フィードバック部

規則適用に対するユーザの判定結果から，規則適用部において適用された規則の正変換度数，誤変換度数を更新することにより規則の適用条件を変化させる．

2.3.1 正変換度数と誤変換度数

入力文の機械翻訳システムによる翻訳結果と，規則適用後の変換結果の機械翻訳システムによる翻訳結果を比較し，規則の適用により翻訳結果が改善された場合にはその規則の正変換度数を +1，逆に翻訳結果が誤りへ変化した場合には誤変換度数を +1 とする．また，規則の適用によって翻訳文の正誤に変化が生じなかった場合には，正変換度数，誤変換度数は変化しない．

2.3.2 規則適用正解率と規則適用条件

規則適用正解率は，以下の式によって計算される．

$$\text{規則適用正解率} = \frac{CF}{CF + EF} \times 100[\%] \qquad (1)$$

ここで，CF は正変換度数，EF は誤変換度数である．この規則適用正解率によって，以下のように規則の適用条件が決定される．ただし，この適用条件は予備実験などにより求められた最適な条件ではなく，第 1 段階として仮に設定した適用条件である．

変換規則

- 規則適用正解率 80%以上
  差異部分の一致
- 規則適用正解率 80%未満 50%以上
  差異部分及び前後 2 単語ずつの品詞の一致
- 規則適用正解率 50%未満
  差異部分及び前後 2 単語ずつの単語の一致

分割規則

- 規則適用正解率 50%以上
  分割規則の適用条件は，変換規則のように段階的に設定されておらず常に一定である．まず分割点前の品詞列の一致，次に分割点直後の単語の一致，更に規則獲得元となった 2 文のどちらかの分割処理以降の単語の付加，削除の処理が適用できることが条件となる．
- 規則適用正解率 50%未満
  規則適用正解率が 50%未満となった分割規則は分割規則辞書から削除される．

2.4 学習部

2.4.1 変換規則

変換規則は前処理前後の共通部分と差異部分を抽出することにより獲得される．差異部分の抽出は多段階の抽出も可能であるが，研究の第 1 段階として，本論文ではそのような処理は行っていない．また，変換規則の適用には差異部分の一致を条件としているため，変換規則は字面上の一致度を類似度の指標とする用例ベースの手法であるといえる．また，変換規則の適用には各規則の正変換度数，誤変換度数から計算される規則適用正解率を用いて適用条件を設定することにより，翻訳結果を悪化させるおそれのある規則の適用を抑制している．図 2 に変換規則獲得例を示す．学習部において，入力英語文の形態素解析結果と，人手により作成された正変換文を比較し，差異部分を抽出することにより変換規則を獲得する．ここで，共通部分とは 3 単語以上連続して同一である部分，差異部分とは共通部分に挟まれている部分と定義する．ただし，文頭においては特別に 2 単語以上同一な部分を共通部分とする．これは，本研究では文における単語の位置も一つの情報と考え，規則の獲得，適用に利用するためである．変換規則は，差異部分，差異部分前後の単語と品詞，正変換度数，誤変換度数からなる．なお，獲得された時点では，正変換度数 1，誤変換度数 0 ではなく，正変換度数，誤変換度数ともに 1 とする．これ

```
Input Sentence:Therefore/RB ,/, our/PRP$ proposed/VBN method/NN consists/VBZ of/IN the/DT
               analysis/NN and/CC learning/NN ./.
Correct Transformed Sentence : Therefore/RB ,/, the/DT method/VBN we/PRP proposed/VBN
               consists/VBZ of/IN the/DT analysis/NN and/CC learning/NN ./.

Difference Part :        “our proposed method” and “the method we proposed”
                                        ↓
Acquired Rule : our proposed method ⇒ the method we proposed
        Previous Part : Therefore/RB ,/,
        Following Part : consists/VBZ of/IN

RB : Adverb, PRP$ : Personal pronoun, VBN : Verb, past participle, VBZ : Verb, 3rd ps. sing. present,
NN : Noun, IN : Preposition/subord, DT : Determiner, CC : Coordinating conjunction
```

図 2　変換規則獲得例
Fig. 2　An example of acquisition a rule.

は，本論文で提案するような既存のシステムに対して付加的に処理を行う補助システムの場合は，いかに多くの正解を作るかということよりも，いかに誤りを抑えながら正解を作るかということに重点を置くべきであると考えられるからである．このような観点から，**2.3.2** で述べた規則適用正解率が初期状態において中間の適用条件である 80%未満 50%以上となるようにそれぞれの数値を設定した．

2.4.2　分 割 規 則

分割規則は分割操作を含んだ前処理例から学習を行い獲得される．変換規則では用例自体を用いているのに対し，分割規則の学習では差異部分の変数化を行い，より一般化した規則を獲得する．そのため，差異部分前後の情報を用いた変換規則では効果的な改善が難しい係り受け関係の誤りを，分割規則を適用することにより更に改善することが可能である．また，規則中に変数を含んでいるためテキストの変化の影響を受けにくく，入力テキストが変化した際に規則が適用できないという問題が起こりにくい．文の分割手法として分類木を用いた手法も考案されている [10]．文献 [10] の手法は機械翻訳の翻訳精度改善を目的とした研究ではないが，文節への分割において 96.2%の正解率という非常に高い精度が報告されている．しかし，機械翻訳における係り受け関係の改善を考えた場合，単純な文の分割だけでは改善効果が少なく，むしろ分割処理の後，主語や目的語の付加といった処理を行わなければ翻訳結果の悪化ということも予想される．また，この手法では分割点直前と直後の情報しか用いておらず，係り受け関係改善のための分割点の特定には，分割点前後の情報だけではなく，より広い範囲の情報を用いる必要があると考えられる．

分割規則は分割操作を含む正変換文が入力された場合に，以下の手順により獲得される．

（1） 分割点直後の単語が同一である文の検索
（2） 分割規則候補の生成
（3） 分割規則決定

図 3 に分割規則獲得例を示す．学習部に文の分割または “,” の付加が行われている正変換文が入力されると，分割文データベースから分割点直後の単語が同一である文を検索する．分割文データベースとは，これまでにシステムに入力された正変換文のうち，分割操作を含んだ正変換文が登録されているデータベースである．分割文データベース中から分割点直後の単語が同一である文が発見された場合，発見された文と入力された正変換文から分割点以前の形態素列の共通な部分を抽出，異なる部分を変数化することにより分割規則が獲得される．ここで形態素列とは品詞情報付きの単語列である．学習を行う範囲については，人間が文の分割を行う場合には，ある単語列に対して次に続く単語がその単語列に分類するべきか，あるいはそれ以降の単語列に分類すべきかを考え分割を行うことができるという経験則により分割点前の品詞列と分割点直後の 1 単語とした．1 組の文から獲得される規則は一つだけとし，共通部分の抽出に際して複数の候補が存在した場合には共通部分の単語数が最大となるものを分割規則として獲得する．また，分割規則同士の一般化は行わない．これは抽象化された規則の過適用による分割誤りを避けるためである．分割文データベース中の規則獲得可能なすべての文から分割規則を獲得した後，入力された正変換文を分割文データベースに登録する．各分割規則は正変換度数，誤変換度数をもつと同時に，規則獲得元となった 2 文の分割以降の単語

Input Sentence1 : In/IN a/DT text/NN ,/, there/EX exists/VBZ a/DT variety/NN of/IN surface/NN features/NNS // which/WDT can/MD be/VB considered/VBN …
A Part of Speech : IN DT NN , EX VBZ DT NN IN NN NNS // WDT MD VB VBN…

Input Sentence2 : Recently/RB ,/, there/EX have/VBP been/VBN some/DT approaches/NNS to/TO use/VB information/NN of/IN lexical/JJ cohesion/NN ,/, // which/WDT are/VBP computed/VBN …
A Part of Speech : RB , EX VBP VBN DT NNS TO VB NN IN JJ NN , // WDT VBP VBN…
"//" means divided point, and underline means common part.

↓

Acquired Rule : @1 , EX @2 DT @3 IN @4 NN @5 // which/WDT
"@1,@2,@3, ..." means Variable

RB : Adverb, PRP$: Personal pronoun, VBN : Verb, past participle, VBZ : Verb, 3rd ps. sing. present, NN : Noun, IN : Preposition/subord, DT : Determiner, CC : Coordinating conjunction,, MD : Modal , WDT : wh-determiner

図 3 分割規則獲得例
Fig. 3 An example of acquisition a rule.

Step1：入力英文の翻訳結果に誤りが存在する場合，入力英文に対して人手により正解日本語文を作成.
Step2：システムにより翻訳された翻訳文と Step1 で作成した日本語文を人手により比較し，誤っている箇所を特定.
Step3：訳語選択の誤りのうち，品詞分類としては誤っていないものを人手により修正.
　Step3.1：正解日本語文の中から訳語選択の誤りに対応する部分を，日英翻訳ソフトを用いて翻訳し，その結果を第一候補として適用.
　Step3.2：正解日本語文の中から訳語選択の誤りに対応する部分を，日英翻訳ソフトの辞書を用いて探索．複数候補が存在する場合，最も多義性の少ないものから適用.
Step4：訳語選択の誤りのうち，品詞分類まで誤っているものを修正.
　Step4.1：Step3.1 と同様
　Step4.2：Step3.2 と同様
Step5：係り受け関係の誤りを修正
　Step5.1：係り受けが誤っている箇所周辺の各句の切れ目ごとに，順次", "を付加してみる.
　Step5.2：Step5.1 同様，", "の付加の代わりに文の分割を行う.
　Step5.3：Step5.1, 5.2 により翻訳文の構造が Step1 の正解日本語文とは異なったものに変化する場合には，単語の付加を行い文構造の回復を試みる.
Step6：Step3 により修正できなかったものがあった場合，Step4, 5 によって修正可能となることがあるため，再び Step3 を行う.
以上の操作を 1 文ごとに繰り返す.

図 4 正変換文作成方法
Fig. 4 Procedure for making correct transformed sentence.

の付加，削除の処理内容も保持している．分割規則においても変換規則と同様な理由から，獲得された段階では正変換度数 1，誤変換度数 1 とする．

2.4.3 正 変 換 文

本論文において，正変換文とは対象となる機械翻訳システムを用いて翻訳を行ったときに，入力文の目標とする翻訳結果となるように単語の付加，削除，文の分割を行った文と定義する．つまり入力文が同じであっても対象とする機械翻訳システムが違う場合には正変換文も違ったものとなることがある．また，正変換文の構造は文法的に正しい必要はなく，人間から見た場合には非文法的な文である場合もある．これは，現在の機械翻訳システムが完全なものではないため，文法的に正しい文であっても正しい翻訳ができるとは限らず，逆に文法的に誤った文であっても正しい翻訳，あるいは見かけ上正しい翻訳ができる場合があるからである．図 4 に正変換文作成方法を示す．

翻訳結果における誤りのうち，本論文では改善の対象を，

1. 訳語選択の誤り
2. 係り受け関係の誤り
3. ユーザの入力の誤り

の 3 点に限定する．ここで，ユーザの入力の誤りとは "information" や "knowledge" 等の不可算名詞に対して複数形の "s" を付加しているものや，繰り返し用いられているスペルミスなど，入力時のユーザの意思と

反する誤りである．

本論文では，意味がとれる範囲においては，翻訳文の自然性に関して前処理の対象としない．これは，翻訳文の自然性という問題の改善は，同じ補助システムで考えた場合，前処理よりも後処理で行った方が格段に効果的なことが明らかであるからである [11]．

本来，翻訳結果の正誤の判定には文脈や個人の主観など様々な要素が存在するが，本論文における翻訳の評価に際してはあらかじめ目標とする翻訳結果を定め，IL-PP を適用することにより翻訳結果がユーザの与える目標とする翻訳結果と一致するように入力文を変換することを目的とする．本論文の評価実験では目標とする翻訳結果は筆者が与えた．また，本論文における誤りの改善を，訳語選択とユーザの入力誤りに関しては，翻訳結果が目標とする翻訳文の単語と一致するか，または翻訳ソフトの辞書中の類義語となった場合を誤りの改善と定義する．係り受け関係については，変換文の翻訳結果の部分構文構造が目標とする翻訳文の部分構文構造と一致するように変化した場合を誤りの改善と定義する．

3. 評価実験

本手法の有効性を示すために，実験システムを作成して性能評価実験を行った．

3.1 実験方法

評価実験は

（1） テキスト入力

（2） その段階で獲得している規則を適用

（3） 規則適用の評価

（4） 正変換文を用いて学習

の順に行う．評価と学習には同一のテキストを用いているが，評価の後に学習を行っているため，本実験は分野を限定したオープンデータによる実験といえる．実験には自然言語処理に関する 3 編の論文 [12]〜[14] それぞれ 189 文，168 文，157 文と，計算機マニュアル 392 文の計 906 文を用いた．1 文当りの平均単語数は 18.5 単語であった．IL-PP への入力のための形態素解析には「Brill tagger」[15] を，機械翻訳システムには二つの商用のシステムを用いた．これらを本論文ではそれぞれ MTA と MTB と呼ぶ．事前に備えている規則が学習に影響を与えるのを避け，初期条件を一定とするため初期状態の変換規則辞書，分割規則辞書は空の状態から行った．

3.2 実験結果

図 5 は MTA において誤り箇所 40 箇所ごとに算出した再現率，適合率の推移である．なお，再現率，適合率は以下のように定義される．

$$\text{再現率} = \frac{CTP}{WP} \times 100[\%] \tag{2}$$

$$\text{適合率} = \frac{CTP}{CTP + WTP} \times 100[\%] \tag{3}$$

ここで CTP は改善箇所数，WTP は改悪箇所数，WP は処理前の誤り箇所数である．同様に図 6 は MTB における再現率，適合率の推移である．

表 1 は MTA における実験の処理前の誤り箇所数と処理後の改善の様子である．ここで改善率とは誤りの

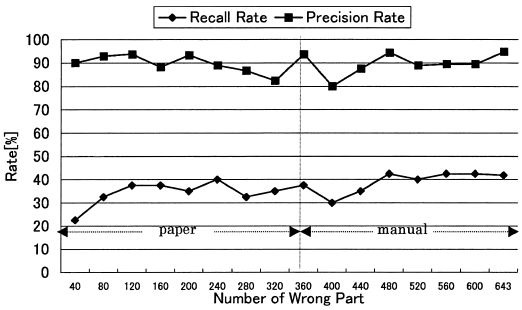


図 5 再現率・適合率の推移（MTA）
Fig. 5 The changes of recall rates and precision rate (MTA).

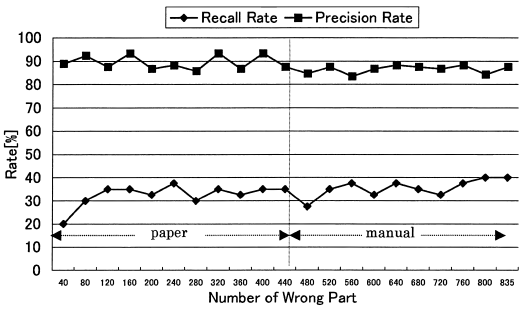


図 6 再現率・適合率の推移（MTB）
Fig. 6 The changes of recall rates and precision rate (MTB).

表 1 処理前の誤り箇所数と処理による改善数（MTA）
Table 1 The change of state of input sentences (MTA).

内訳	処理前の誤り箇所数	改善数	改善率
訳語選択	328 箇所	128 箇所	39.0%
係り受け関係	247 箇所	96 箇所	38.9%
ユーザの入力	68 箇所	33 箇所	48.5%
誤り箇所総数	643 箇所	257 箇所	40.0%

```
Input Sentence : We/PRP propose/VBP a/DT new/JJ method/NN to/TO divide/VB a/DT text/NN
        to/TO segments/NNS by/IN using/VBG these/DT two/CD types/NNS of/IN information,
        in/IN a/DT text/NN ./.
Result of Translation : 我々はテキストでこれらの２つのタイプに関する情報を使用するのによ
        ってテキストをセグメントに分割する新しい方法を提案する。
Applied Rule : PRP VBP @1 NN @2 TO @3 NNS // by/IN
 "//" means divided processing.
                                    ↓
Result of Application :  We propose a new method to divide a text to segments.
                         By using these two types of information in a text.
Result of Translation :  我々はテキストをセグメントに分割する新しい方法を提案する。
                         これらを使用するのによって、２はテキストの情報をタイプする。
```

図 7　誤変換例
Fig. 7　An example of wrong application.

表 2　処理前の誤り箇所数と処理による改善数（MTB）
Table 2　The change of state of input sentences (MTB).

内訳	処理前の誤り箇所数	改善数	改善率
訳語選択	394 箇所	138 箇所	35.0%
係り受け関係	373 箇所	118 箇所	31.6%
ユーザの入力	68 箇所	34 箇所	50.0%
誤り箇所総数	835 箇所	290 箇所	34.7%

表 3　処理後の改悪箇所数
Table 3　The number of part changed for the worse.

適用規則の内訳	MTA	MTB
訳語選択	9 箇所	8 箇所
係り受け関係	15 箇所	27 箇所
ユーザの入力	3 箇所	4 箇所
総数	27 箇所	39 箇所

種類ごとに見た再現率である．同様に表 2 は MTB における実験結果である．更に，表 3 に処理後の改悪箇所数を示す．

3.3 考　　察

全体的な結果は MTA による実験では再現率 $257/643\times100 = 40.0\%$適合率 $257/(257+27)\times100 = 90.5\%$，MTB による実験では再現率 $290/835\times100 = 34.7\%$，適合率 $290/(290+39)\times100 = 88.1\%$であった．

初期状態では辞書が空であるため精度が低いが，学習により徐々に向上していくことが確認できる．全体的な再現率はいずれの機械翻訳システムにおいても 30%を超える数字であり，特に前処理のような補助システムにおいて重要となる適合率は 90%前後の良好な値であった．このことから，本手法が複数の機械翻訳システムに対して有効であることが確認できた．また，本手法は比較的誤りの少ない，悪影響の少ない手法であるといえる．精度の推移を見てみると，図 5，図 6 ともにテキストの変わり目において 1 度精度が低下している．しかし，学習を続けることにより精度は回復して行き，最終的には低下する前よりも上昇している．このことから本手法の入力テキストに対する適応能力が確認できた．入力テキストが変化した直後の規則ごとの適用状況を見てみると，変換規則はあまり適用されていないのに対して，分割規則ではそれほど適用回数は減少していなかった．これは分割規則では規則中に変数が存在し，規則の適用にも字面の情報よりも形態素情報を用いているため，入力テキストの種類による影響が少ないためと考えられる．

誤りの種類ごとの改善率をみると，変換規則だけでは改善が難しい係り受け関係の誤りについても，分割規則を用いることによりいずれの機械翻訳システムにおいても 30%以上の改善結果となった．しかしその一方，規則を適用することにより翻訳結果が改悪される箇所も存在した．表 3 を見てみると係り受け関係改善のための規則を適用することによる改悪箇所が多い．これらの多くは，規則の適用による分割後の文が機械翻訳システムにより文と句，あるいは句と句のように認識されてしまい，その結果翻訳結果が誤ったものに変化してしまうものであった．図 7 に例を示す．この問題を解決するためにはいくつかの方法が考えられる．一つは確実に分割後の主語や目的語の補完を行うことにより，分割後の入力が文と文の形になるようにすることである．しかし，分割の後，主語や目的語の補完を常に行うと，獲得規則の差異部分が大きくなり，その分獲得される規則の適用条件が厳しくなるおそれがある．つまり再現率と適合率のトレードオフの問題となる．また，主語，目的語の推定，補完に関してはそ

れだけで一つの研究テーマとして扱われているため，別テーマとして研究を行うべきであると考え，本研究では研究の対象外としている．もう一つの解決方法は分割後の文に対して構文解析を行い，その解析結果により規則適用の可否を決定する方法である．これにより規則適用によって句となった文を無理やり翻訳することは回避可能であると予想される．しかし，この方法ではどの程度の構文構造の一致で規則適用とするかといった問題が存在する．これらの問題は今後の課題となる．

4. むすび

本論文では様々な機械翻訳システムに対して汎用的に用いることができる前処理手法を提案した．本手法では前処理のための規則を前処理例から自動的に獲得する．その際にそれぞれの機械翻訳システムにおける正変換文から学習を行うことにより，その機械翻訳システムに依存した規則を獲得していくことができる．これにより本手法では，従来の前処理研究のように特定の機械翻訳システムに対してしか適用できないという問題がない．同時に，従来のあらかじめ変換規則を与えておく解析型の手法では決められた特定の表現しか改善できないのに対して，本手法では変換例さえ与えていけば様々な表現に対して改善が期待できる．また，特定の言語の特徴を利用していないため，形態素解析が可能な言語であればどのような言語に対しても適用可能であると考えられる．実際に提案手法を組み込んだシステムを作成し，複数の機械翻訳システムに対して適用実験を行った結果，MTA を用いた実験では 40.0%，MTB を用いた実験では 34.7%の再現率であった．この値は文献 [3], [4] の前処理手法と比較しても決して劣るものではなく，これにより本手法が複数の機械翻訳システムに対して汎用的に用いることができることが示された．また，適合率ではいずれの機械翻訳システムを用いた実験でも 90%前後の値であり，本手法は比較的誤りの少ない手法であることが確認できた．

今回の実験結果より，機械翻訳システムの傾向によっては係り受け関係改善のための規則による改悪箇所が比較的多く見られた．この問題に対する解決策の検討や実際の適用などが今後の課題である．また，本論文では改善の対象となる誤りを 3 種類に限定している．しかし，本手法は今回対象とした 3 種類以外の誤りに対しても有効であると考えられ，他の種類の誤りに対する本手法の適用についても今後検討する予定である．

文　献

[1] S. Yamauchi, “A method of evaluation of the quality of translated text,” MT Summit VII, pp.564–567, Sept. 1999.

[2] 成田　一，“翻訳ソフトの性能評価,” 情処学自然言語処理研報，no.125-14, pp.123–130, 1998.

[3] 吉見毅彦，佐田いち子，福持陽仕，“頑健な英日機械翻訳システム実現のための原文自動前編集,” 自然言語処理，vol.7, no.4, pp.99–117, 2000.

[4] 木村真理子，野村浩一，平川秀樹，“日英機械翻訳前編集における日本語文分割処理について,” 情処学自然言語処理研報，96-8, pp.57–64, Jan. 1993.

[5] 白井　諭，池原　悟，河岡　司，中村行宏，“日英機械翻訳における原文自動書き換え型翻訳方式とその効果,” 情処学論，vol.36, no.1, pp.12–21, Jan. 1995.

[6] 吉見毅彦，“英日機械翻訳における自然な和文生成のための英語名詞句の書き換え,” 自然言語処理，vol.8, no.4, pp.55–70, 2001.

[7] 古瀬　蔵，山田節夫，山本和英，“頑健な多言語音声翻訳のための不適格入力の分割処理,” 情処学論，vol.42, no.5, pp.1223–1231, May 2001.

[8] 山口昌也，乾　伸雄，小谷善行，西村恕彦，“前編集結果を利用した前編集自動化規則の獲得,” 情処学論，vol.39, no.1, Jan. 1998.

[9] 長島康人，荒木健治，栃内香次，“機械翻訳の汎用的な前処理手法における係り受け関係の改善方法ついて,” 情処学自然言語処理研報，vol.2002, no.4, NL-147-3, pp.15–20, 2002.

[10] 張　玉潔，尾関和彦，“分類木を用いた日本語長文の自動分割,” 言語処理学会第 4 回年次大会発表論文集，pp.390–393, 1998.

[11] 尾崎正行，荒木健治，栃内香次，“帰納的学習を用いた自然な日本語文生成手法の評価,” 情処学自然言語処理研報，no.141-10, pp.57–62, 2001.

[12] Y. Masatomi, K. Araki, and K. Tochinai, “Acquisition system of deep case using queries and replies,” Proc. Applied Informatics 2000, pp.194–197, Innsbruck, Austria, Feb. 2000.

[13] H. Haga and Y. Miyake, “Grammar-based document structure analysis and its application to document conversion,” Proc. Applied Informatics 2000, pp.194–197, Innsbruck, Austria, Feb. 2000.

[14] K. Araki, H. Echizen-ya, and K. Tochinai, “Performance evaluation in travel English for GA-ILMT,” Proc. IASTED International Conference Artificial Intelligence and Soft Computing, pp.117–120, Banff, Canada, July 1997.

[15] E. Brill, A Corpus-Based Approach to Language Learning, Ph.D. Thesis, University of Pennsylvania, 1993.

付　　録

本手法では規則の過適用を避けるため一つの規則が適用された箇所には重複して他の規則は適用されない．このことから規則の適用順序により精度の変化が予想されるため，これらの規則の最適な適用順序を調べる予備実験を行った．実験では変換規則，分割規則という分類とともに,「係り受け関係の誤りに対する規則」,「訳語選択の誤りに対する規則」,「ユーザの入力誤りに対する規則」という分類で規則の適用順序を検討している．これは変換規則，分割規則という分類は規則の獲得方法による分類であり，規則の適用を考えた場合には改善対象による分類も考慮すべきであると考えるからである．

1. 実験方法

規則の適用順序を

（1） 変換規則，分割規則の順に適用した場合

（2） 分割規則，変換規則の順に適用した場合

（3） 訳語選択とユーザの入力誤りに関する規則，係り受け関係に関する規則の順に適用した場合

以上の 3 種類で実験を行った．入力テキストには自然言語処理に関する論文からランダムに抽出した 200 文を，機械翻訳システムには MTA を用いた．

2. 実験結果

表 A·1 に実験結果を示す．実験結果より，(3) 訳語選択とユーザの入力誤りに関する規則，係り受け関係に関する規則の順に適用した場合が最適な適用順序となる．

表 A·1　規則の適用順序による改善数と改悪数の変化
Table A·1　The change of number of improved part and part changed for the worse.

改善の内訳	(1)	(2)	(3)
訳語選択	21 箇所	16 箇所	21 箇所
係り受け関係	15 箇所	20 箇所	17 箇所
ユーザの入力	7 箇所	5 箇所	7 箇所
改悪箇所総数	5 箇所	8 箇所	5 箇所

（平成 14 年 3 月 28 日受付，12 月 15 日再受付）



長島　康人

平 12 北大・工・電子情報卒．同年同大大学院修士課程に入学．自然言語処理に関する研究に従事．平 14 同大学院修士課程修了．現在，（株）NTT データビジネス開発事業本部決済ビジネス事業部勤務．情報処理学会，言語処理学会各会員．



荒木　健治　（正員）

昭 57 北大・工・電子卒．昭 63 同大大学院博士課程了．工博．同年，北海学園大学工学部電子情報工学科助手．平元同講師．平 3 同助教授．平 10 同教授．平 10 北大・工・電子情報工学専攻助教授．平 14 同教授，現在に至る．自然言語処理，主として形態素解析，機械翻訳，音声対話処理などの研究に従事．情報処理学会，人工知能学会，言語処理学会，ACL 等各会員．



栃内　香次　（正員）

昭 37 北大・工・電気卒．昭 39 同大大学院工学研究科電気工学専攻修士課程了．現在，北大・工・電子情報工学専攻教授．主として音声情報処理，自然言語処理の研究に従事．工博．情報処理学会，日本音響学会各会員．