社団法人 電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
SP2003-68 (2003-08)

発話速度推定ための多次元音響特徴量について

Gong Xiaojuan† 広重真人† 荒木健治† 栃内香次‡

†北海道大学工学研究科 〒060-8628 札幌市北区北13条西8丁目
‡北海学園大学経営学部 〒062-8605 札幌市豊平区旭町 4-1-40
E-mail: †{gxj, hiro, araki}@media.eng.hokudai.ac.jp, ‡tochinai@econ.hokkai-s-u.ac.jp

あらまし 局所的な発話速度の変化は話者の重要な意図が含まれている可能性が高いと考えられる。本報告では、従来研究で用いられたものよりも大きな発話速度変化を含む音声データを対象として、音響特徴量と発話速度変化との関連を調べた。LPC スペクトル、パワー、F0 の動的特徴量を組み合わせた多次元音響パラメータを用い、発話速度推定への応用について検討する。その結果、提案した音響特徴量と発話速度との相関が確認され、発話速度推定への応用の可能性を示した。

キーワード 発話速度, 動的特徴量, スペクトル変化量、基本周波数、音声パワー

A study on a multi-dimensional acoustic parameter for speech rate estimation

Gong Xiaojuan†, Makoto Hiroshige†, Kenji Araki†, Koji Tochinai‡

†Faculty of Engineering, Hokkaido University N13W8, Kita-ku, Sapporo, 060-8628 Japan
‡Department of Economy, Hokkai Gakuen University 4-1-40 Asahimatchi, Toyohira-ku, Sapporo, 062-8605 Japan
E-mail: †{gxj, hiro, araki}@media.eng.hokudai.ac.jp, ‡tochinai@econ.hokkai-s-u.ac.jp,

Abstract Since local speech rate modifies acoustic cues, phones, syllables and even words, it is one of the most important prosodic cues. We propose a new measure for speech rate recognition, which are calculated based on the variation amount of LPC cepstrum, power and F0 contour. We apply it to experimental data which including large variation on speech rate. It is able to detect the variation of local speech rate.

Keyword speech rate, dynamic measure, spectrum variation, fundamental frequency, speech power

1. はじめに

局所的な発話速度の変化は話者の意図を表すヒントと考えられている[1]。日常会話において、我々が相手に重要なことをわかりやすく伝えたい場合、声を高くしたり、音量を上げたりするだけではなく、重要な部分を「ゆっくり」発声することがある。発話速度の変化が含まれている場合には、その箇所には、発話者の重要な意図が含まれている可能性が高いと考えられる。

局所的な発話速度の変化に関しては、音声認識の技術を用いて母音部分を認識した後、その結果から短い区間の発話速度を求める方法[2]が提案されている。北澤らの研究[3][4]では、非言語的特徴として、声の速さについてその変化のラベルつけを行い、物理的な量との関連を調べた。その結果、多くのラベルが実際の変化を記述していることがわかったが、ラベルと音響的変化との不一致も多いことから、音響的変化のみからでは非言語的特徴の識別は困難であるとしている。

一方、筆者等は従来より日本語会話音声の発話速度認識について研究を行っているが[5][6]、スペクトル変化量のピークを経験的アルゴリズムで検出しピークの時間頻度をモーラ速度と比較する試み[5]では、当該言語(ここでは日本語)の音韻間での音響変化量のばらつきのため結果が発話内容に依存する傾向があり、単語や文節程度の短い長さでの発話速度検出は充分な精度が得られにくかった。一方、英語(TIMIT データベース)を用いた研究例[7]では、1秒から1文全体程度の長めの部分について、スペクトル変化量に基づいて計算される量(文献[7]中では MTD)と音素速度(phone rate)との間にある程度の相関が見られることが報告されている。また、ドイツ語に関して音節速度と音素速度の線形結合による発話速度表現[8]も提案されており、局所的発話速度との高い相関性が報告されている。

筆者らは外国語などの聴取において、個々の音韻の認識が不充分でもおおまかな発話速度の変化が知覚できる(ゆっくり話されるとわかりやすいが速いとわかりにくくなる)という日常の経験を考慮し、大きな発話速度変化が含まれている場合には、音響的な手がかりのみによってもおおまかな発話速度変化検出が可能ではないかと考えた。ただし対象とする音声は充分に大きな発話速度変化が含まれている必要があり、研究の初期段階としては、日常ではめったに観測されないほど意図的に大きく発話速度を変化させた音声資料を用いる必要がある。この点において、前述の研究例[3][4]などで用いられているニュースアナウンスの音声資料は、大部分において発話速度が「変化なし」の範囲内である可能性が高く、難しい対象であったと筆者らは考える。

以上の考えに基づき筆者らはこれまで、音響特徴量としてスペクトル変化量の2秒程度での平均値を用い、音節速度との比較により発話速度変化検出への利用の可能性を示した[9]。

上述の考えと研究例をふまえ、本研究では、発話速度の変化と相関関係がある三つの音響パラメータを組み合わせた、より信頼性の高い多次元パラメータを用い、発話速度との相関を検討し、簡易な音響特徴量を発話速度指標として利用できるかどうかについて検討する。

以降、2節においては発話速度知覚の予備実験について述べる。3節においては、使用した実験データを述べ，4節では、音響特徴量の算出方法について述べる。5節では、提案する音響特徴量と発話速度の間の相関性について述べ，6節では結果について考察する。

2. 発話速度知覚に関する予備実験

まず本章では、おおまかな発話速度変化を音響変化量から推定できる可能性を示すために、未知外国語の発話速度聴取実験について述べる。母国語に比べて、未知外国語は、その言語としての側面がまだ充分に学習されていないことから、音響として聴取される可能性が高いと考える。

母国語の場合と同じように未知外国語についても大まかな速度変化が知覚可能であれば、音声の音響変化を手がかりとする発話速度推定手法が支持されたと考えることができる。

筆者ら従来の研究[9]では、当該言語未学習者を被験者とした聴取実験を行い，未学習者が未知外国語として発話を聴取するときの発話速度の知覚判断を調査した。実験結果は発話速度の知覚が話者の主観とおおむね一致することを示した。

今回は話者の言語背景による差があるかどうかについて確認するため、母語話者による話速知覚実験を以下のように行い、[9]における未知外国語の結果とあわせて以下に示す。

2.1 実験条件

2名の母語話者による読み上げ中国語の音声データ26文をランダムに組み合わせ，これを刺激音とした。最初の2文は練習として用い，残りの24文を分析に用いる。母語話者—外国人被験者の場合[9]，日本人5名，母語話者—母語被験者の場合，話者以外の中国人男性1名，女性1名である。刺激音はヘッドフォンを通じて提示した。

2.2 実験方法

ME 法[10]を用いる。被験者には一つ一つの文について速さを判断し，その速さの印象を反映すると思われる正の数を割りあてて、実験用紙にその数字を記入してもらった。また，教示文で物理

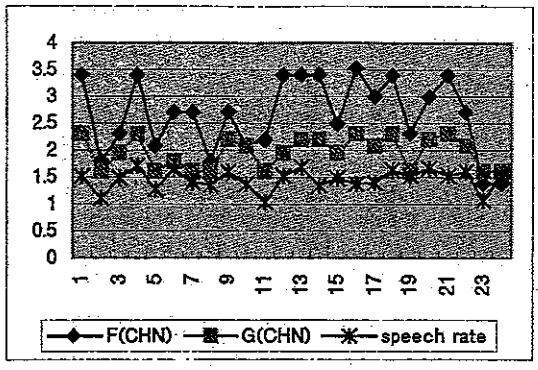


図1. 母国語被験者による聴取実験結果

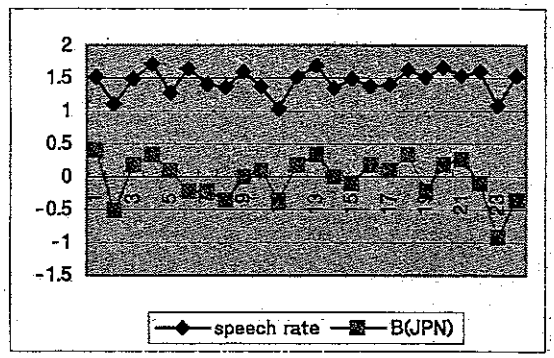


図2. 外国人被験者による聴取実験の結果

的な単位や前に提示された文に割りあてた数について考えないように指示を行った。また、一部の速さではなく，文全体の速さについて評価するよう依頼した。

2. 3 実験結果

図1に母語話者—母語被験者の実験結果(被験者2名分)を示す。図2に母語話者—外国人被験者(日本人)による実験結果(被験者1名の例)を示す。横軸は実験で使った音声データの順番，縦軸は音節速度の対数値と被験者評価値の対数値

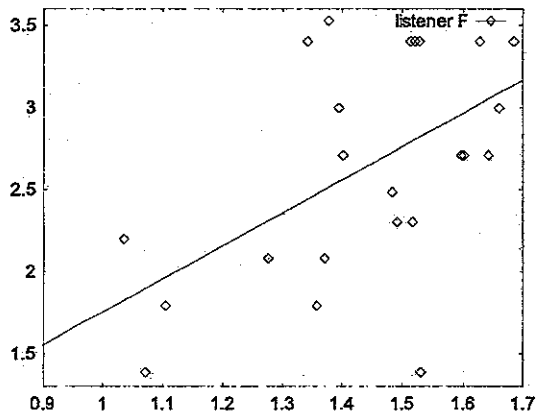


図3. 音節速度の対数と評価値の対数との関係

である。図1に示すように，音声データ間で発話速度が増加すると，母語被験者の評価値も増加する。逆に発話速度が減少すると，被験者の評価値も減少する。母語話者と当該言語未学習者(日本人被験者)と同じ知覚傾向が見られる。図3は図1中の被験者 F について音節速度の対数と評価値の対数との関係を示す。横軸は音節速度の対数値で，縦軸は被験者評価値の対数値である。ばらつきが大きいため，母語話者にしても、速さについての感覚は必ずしも物理量と一致するとはいえない。教示文で前文と比較しないように要求したが，本稿の実験の範囲内では直前の文の速さの影響も考えられる。この結果は Kluender らの研究結果[11]と一致している。

母語話者と未学習者の発話速度知覚の傾向に明確な差はなく、音響信号を主な手がかりとしていると考えられる未知外国語においても発話速度が知覚可能であることから，言語を音響信号として聴取している可能性が示された。

3. 音声データ

前述のように、音響パラメータの変動を手がかりに発話速度に対応する量を求めるには，大きな発話速度の変化または対比を含む音声データを用意する必要がある。

本稿で用意した音声データは、防音室で DAT に収録した、日本語を母語とする男性1名による読み上げ音声と中国語を母語とする男女各1名による読み上げ音声である。

Type I (日本語)：発話速度の知覚を検討するため、同じテキストで次の2つタイプの読み方を指示し，音声を収録した。タイプ A:普段より速く発声。タイプ B:普段より遅く発声。全部で8文 (4文×2タイプ) を収録した。

Type II (日本語)：局所的な発話速度の変化を検出するため、明確な発話速度の変化が含む読み上げ音声を収録した。

Type III (中国語)：明確な発話速度の変化が含む読み上げ音声(6文)を収録した。

収録した音声データは標本化周波数 44.1kHz，量子化ビット数 16 ビットで A/D 変換して実験に用いた。

4. 三次元音響パラメータの構成

LPC ケプストラム、パワー、F0 において、いずれも動的な特徴を表す動的尺度[12]を用いる。この尺度は各係数について現在時点を重視する前後4フレーム計9フレームの重みつき窓を適用し、窓内で各係数に対する回帰直線を求め、この回帰直線の傾きの2乗の次数分の総和を現在時点での変化量をするものである。単純差分と同等の変化量をよりなめらかに表すものである。

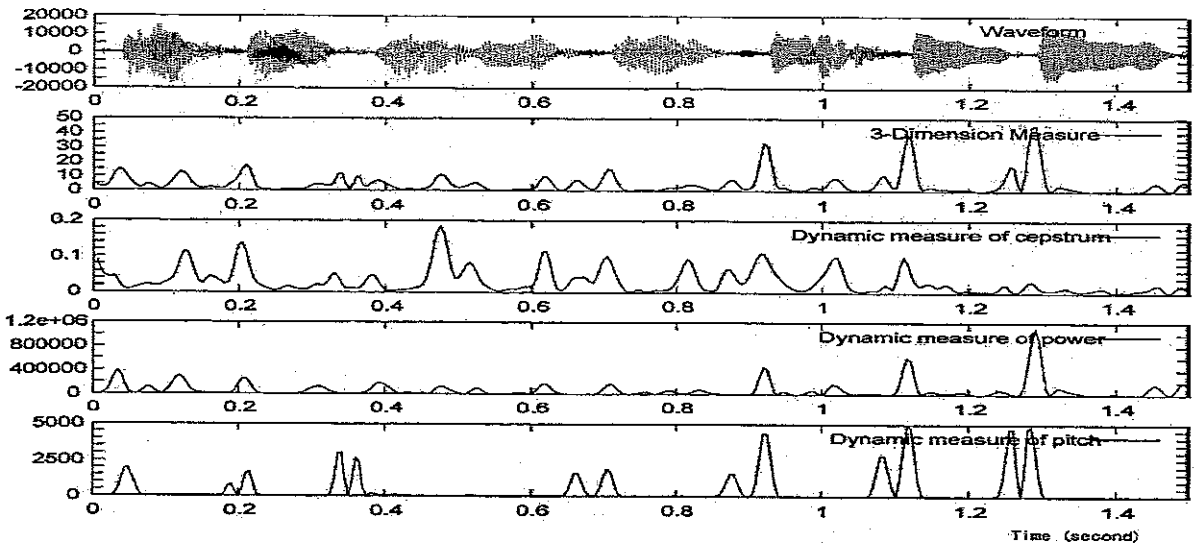


図4　三次元パラメータの例。上から波形、三次元パラメータ、LPC ケプストラム、パワー、F0 の動的尺度

4.1　LPC ケプストラム

録音したデータを 12 kHz にダウンサンプリングし，LPC ケプストラムを求める。音響分析条件を表 1 に示す。

表 1. LPC ケプストラム音響分析条件

分析窓	ハニング窓
LPC 分析	12 次
LPC ケプストラム	20 次
フレーム長	20msec
フレームシフト周期	5msec

この後 LPC ケプストラムに基づく動的尺度を求める。

4.2　パワー

パワーは Entropic 社 ESPS の get_f0 コマンド[13]によって求めた。音響分析条件を表 2 に示す。

表 2. パワー、F0 音響分析条件

分析窓	ハニング窓
フレーム長	30msec
フレームシフト周期	5msec

この後パワーに基づく動的尺度を求める。

4.3　F0

パワーと同じ分析条件で get_f0 コマンドにより求め、動的尺度を求める。

4.4　三次元パラメータの構築

音声の音響的変化は上記のそれぞれのパラメータのうちどれが 1 つで表現できることはまれであり、可能なすべてのパラメータを組み合わせる必要がある。本稿では上記の 3 つのパラメータを加算することにより組み合わせる。三つのパラメータはそれぞれのダイナミックレンジが異なるので、1 文内の当該音響特徴量の平均値が 1 となるように、正規化係数は 1 文内全体での音響特徴量の平均値の逆数と定義される。

三次元パラメータの動的特徴量は以下の式で定義される。

$$D = \omega_{cep} \sum_{i=1}^{n} a_{icep}^{2} + \omega_{pow} \, a_{pow}^{2} + \omega_{pit} \, a_{pit}^{2}, \quad (1)$$

n は LPC ケプストラムの次数，ω_{cep}, ω_{pow}, ω_{pit} はそれぞれ LPC ケプストラム、パワー、F0 の正規化係数。 a_{icep}, a_{pow}, a_{pit} は各係数において重みつき回帰直線の傾きである。

このようにして計算された三次元パラメータの例を図 4 に示す。

5.　平均音響変化量の計算と発話速度との比較

計算された動的尺度から発話速度を検出するため，比較的長めの短区間平均処理を行う。区間長を 2 秒，区間シフトを 0.5 秒とした。発話速度の変化があるデータ（Type Ⅱ）による得られた結果を図 5 に示す。短区間平均値の動きを見ると，発話速度が速い部分においてパラメータの値が大きく、遅い部分について値が小さい傾向がある。

また、Type Ⅰ のデータについて同様の値を求めた。図 6 と図 7 に示す。図 6 において、タイプ A とタイプ B の短区間平均値の動きを比較すると，発話速度が速いほうが平均音響変化量が大きく、提案パラメータの値により発話速度の区別が可能な例である。図 7 は明確に分かれていない例の一つである。

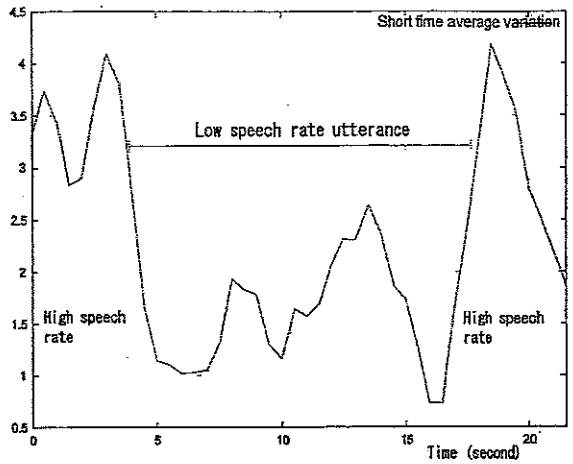


図 5. 短時間平均音響変化量を用い発話速度変化への検出

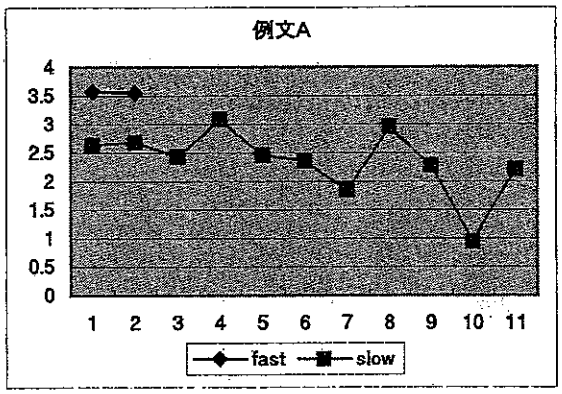


図 6. Type I の平均音響変化量計算例 1

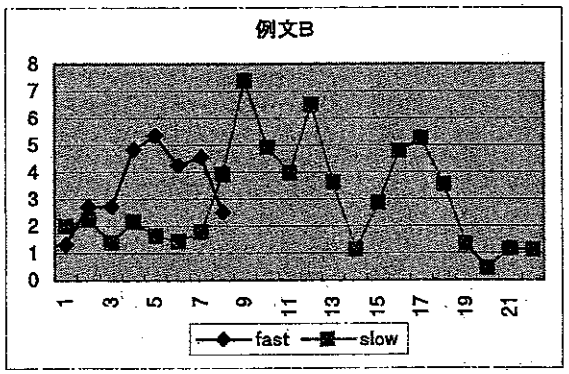


図 7. Type I の平均音響変化量計算例 2

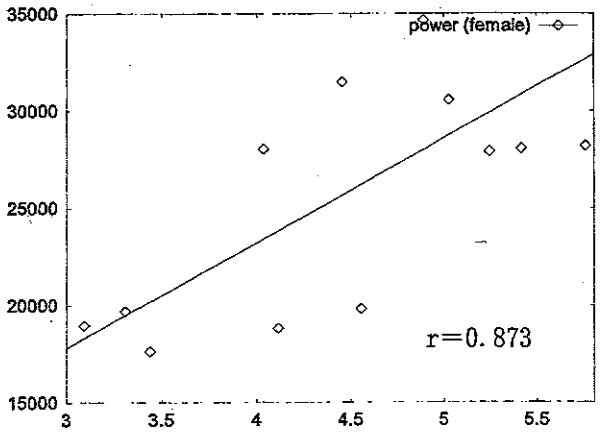


図 7. パワーの動的尺度と音節速度の相関

6. 考察

6.1 パワー、F0 と発話速度との関係

パワー、F0 の動的尺度の 2 秒間平均値と発話速度との関係の調査を行った。

F0 に関しては，発話速度知覚に有効であると報告されている[14]。本研究では有声無声の転換部分に明確なピークが現れているが、有声が連続する区間の音韻変化を求めるのは困難である。

一方、パワーについて、発話速度との高い相関(図 8)が見られるが，音韻の組み合わせによっては、しばしば異常に大きなピークが観察されるケースもある。

6.2 3 次元パラメータ

図 4 によると、もっとも変化がある箇所（3 つのパラメータがともに変化する場所）は、3 次元パラメータにもよく表されている。F0 情報のみでは表現できないピークも、パワーとケプストラムの情報により補なわれ、表現されている。発話速度への寄与が少ないと考えられるピークを軽減できる。図 5 において、明確な発話速度変化を含む Type II の音声について、速度の速い部分と遅い部分を表現し分けることができ、本稿での 3 次元パラメータによる発話速度推定の可能性が示された。また 1 文全体の発話速度の異なる Type I の音声については、図 6 の例は速度を比較的良好に区別しているが、図 7 の例では充分に区別できていない。特に発話速度が遅い部分において、各音韻の引き伸ばし時間が長いために、声のがらつき、息の音などによる音響的変化が混入しやすく、発話速度と関係しないこれらの音響変化の影響をいかに軽減するかが今後の課題である。

7.まとめ

LPC ケプストラム、パワーと F0 パラメータに基づく動的尺度の 2 秒程度の短時間平均値を利用し，速く発話された文と遅く発話された文で特徴量のふるまいが異なることを示し，発話速度検出への利用の可能性を示した。

局所的な発話速度変化を含む文では、三次元パラメータより変化箇所検出の可能性があることを示した。

今後は発話速度に変化のある音声資料について本手法をより広く適用し，変化箇所の検出と知覚との整合性について調べていく予定である。

参考文献

[1] Takamaru, Suzuki, Hiroshige, Tochinai: "A Study on Several Features of Local Speech Rate Variations in Spontaneous Conversational Speech", Proc. ITC-CSCC' 99, pp. 390-393, July, 1999

[2] 安藤彰男, 今井亨, 宮坂栄一："発話速度自動計測のための一方法", 音響春季講論, 1-Q-15, pp. 125-126, Mar 1995

[3] 小林聡, 北澤茂良："非言語的特徴の書き起こしと物理関連量" 信学技報, SP-96-51, pp. 15-22

[4] 小林聡, 北澤茂良："音声の高さ、大きさ、速さ感覚と物理関連量" 信学技報, SP-96-69, pp. 1-8

[5] 稲葉一紀, 広重真人, 宮永喜一, 栃内香次："局所的話速変化検出のためのスペクトル変化パラメータについて", 音響秋季講論, 2-P-7, pp. 315-316, Sept 1995

[6] 広重真人, 稲葉一紀, 宮永喜一, 栃内香次："局所強調朗読音声における局所話速変化検出の試み", 電子情報通信学会講論 D-255, P. 258, Sept 1995

[7] K. Samudravijaya, Sanjeev K. Singh, P. V. S. Rao: "Pre-recognition measures of speaking rate," Speech Communication Vol24, 1998, pp73-84

[8] Hartmut R. Pfitzinger:" Local speech rate perception in German speech", Proc.ICPhS 1999, Vol.2, pp.893-896, San Francisco. Aug. 1999(International Congress of Phonetic Sciences)

[9] Gong Xiaojuan, 広重真人, 荒木健治, 栃内香次: "未知外国語の発話速度検出へむけた音響変化パラメータの基礎的検討", 音響秋季講論 2002, vol. 1, 1-P-16, pp. 403-404, Sept 2002

[10] 難波, 桑野著, "音の評価のための心理学的測定法", コロナ社, 1998

[11] K. R. Kluender, J. A. Coady, M. Kiefe : "Sensitivity to change in perception of speech", Speech Communication, Vol.41, Issue 1, August 2003, pp. 59-69

[12] 嵯峨山, 板倉:"音声の動の尺度に含まれる個人性情報" 音響論 1997. 6, pp. 589-590

[13] http://www.entropic.com/esps.html

[14] Kohler, K. J.: "Parameters of speech rate perception in German words and sentences: duration, F0 movement, and F0 level", Language & Speech, 29: 115-139, 1986