社団法人　情報処理学会　研究報告
IPSJ SIG Technical Report

2003－ＮＬ－158　(25)
2003／11／7

局所着目方式によるアイヌ語－日本語名詞対訳語の抽出について

越前谷　博†　　荒木　健治††　　桃内　佳雄†　　栃内　香次†††

† 北海学園大学工学部　〒064–0926 札幌市中央区南 26 条西 11 丁目 1–1
†† 北海道大学大学院工学研究科　〒060–8628 札幌市北区北 13 条西 8 丁目
††† 北海学園大学大学院経営学研究科　〒062–8605 札幌市豊平区旭町 4 丁目
E-mail: †{echi,momouchi}@eli.hokkai-s-u.ac.jp, ††araki@media.eng.hokudai.ac.jp,
†††tochina@econ.hokkai-s-u.ac.jp

あらまし　対訳コーパスから対訳表現を自動抽出する研究が盛んに行われている．そこでは通常，原言語と目的言語の両言語に対し解析器などから得た解析的な知識の利用が前提となっている．しかし，両言語に対し必ずしも同等な解析的知識を利用できるとは限らない．また，大量の対訳コーパスが容易に入手できるとも限らない．そこで，我々は，両言語において同等な解析器の利用が困難であり，かつ，大量の対訳コーパスが存在しない状況下でも，対訳語を自動抽出可能な新たな手法を提案する．本稿では，提案手法の有効性を確認するための第 1 段階として，アイヌ語－日本語対訳コーパスを対象に，品詞の中でも出現頻度の高い名詞対訳語の自動抽出を試みた．その際には，効率良く名詞対訳語を抽出するために解析器として日本語形態素解析ツールを用いる．性能評価実験の結果，再現率 60.1%，適合率 70.1%という結果が得られ，本手法の有効性を確認することができた．
キーワード　言語学習，名詞対訳語，局所着目方式，アイヌ語－日本語

Extraction of Ainu-Japanese Noun Word Pairs Using Local Focus Method

Hiroshi ECHIZEN-YA†, Kenji ARAKI††, Yoshio MOMOUCHI†, and Koji TOCHINAI†††

† Faculty of Engineering, Hokkai-Gakuen University
Minami-26, Nishi-11, Chuo-ku, Sapporo, 064–0926 Japan
†† Graduate School of Engineering, Hokkaido University
Kita-13, Nishi-8, Kita-ku, Sapporo, 060–8628 Japan
††† Graduate School of Business Administration, Hokkai-Gakuen University
4-Chome, Asahi-machi, Toyohira-ku, Sapporo, 062–8605 Japan
E-mail: †{echi,momouchi}@eli.hokkai-s-u.ac.jp, ††araki@media.eng.hokudai.ac.jp,
†††tochina@econ.hokkai-s-u.ac.jp

Abstract　Numerous methods for extracting bilingual collocations from bilingual corpora have been developed. In general, they use analytical knowledge to both source languages and target languages. However, it is difficult to apply such analytical knowledge to various languages of the world except Japanese easily because the analytical knowledge is static knowledge. Moreover, many methods require a large corpus. However, a large corpus using various global language is often insufficient. Therefore, we propose a new method for extracting bilingual words without analytical knowledge in source language or a large corpus. In this paper, our proposed system extracts Ainu-Japanese noun words from a small corpus using only Japanese morphological analysis tool. The recall was 60.1%, and the precision was 70.1%. Therefore, we confirmed the effectiveness of our method.
Key words　Language learning, bilingual noun word pairs, Local focus method, Ainu-Japanese

1. まえがき

近年の情報のグローバル化に伴い，多言語の情報を処理することの必要性が向上している．多言語情報を処理する上で対訳辞書は重要な言語知識である．対訳辞書を構築する場合，それを人手で行うには限界がある．したがって，対訳コーパスから対訳表現を自動抽出するための研究が数多く行われている．対訳表現の自動抽出の研究は，解析的な知識に基づく解析的なアプローチ [1], [2] と大量の対訳コーパスを統計処理する統計的なアプローチ [3]～[8] に大きく分類される．様々な言語間の対訳辞書の構築を考えた場合，2つの言語において，品詞情報や構文情報などを得るための解析器を同等に利用できるものばかりではない．また，大量の対訳コーパスを容易に得られるとは限らない．そのため，様々な言語間の対訳辞書を構築する際に，2つの言語に対し同等な解析器，かつ，大量のコーパスを利用できないという条件のもとであっても，対訳辞書を自動構築可能な手法が求められる．

我々は，これまでに英語文と分かち書きされた日本語文の対訳コーパスのみから対訳語を自動獲得する学習手法 [9] を提案している．その場合，名詞対訳語の抽出において，問題点として，誤った名詞対訳語を十分に排除することができず，抽出精度が低下すること，また，使用した対訳コーパスの多くが短文であり，実用的な対訳コーパスへの適用という点で不十分であったことが挙げられる．

そこで，我々は，2つの言語に対し同等に解析器を利用できない，かつ，大量の対訳コーパスを利用できない条件のもとで，抽出精度を向上させ，さらに，実用的な対訳コーパスから対訳語を自動抽出することが可能な手法として，局所着目方式（**Local Focus Method**，略して **LFM**）による対訳語の自動抽出について述べる．本手法は，表層情報に基づき対訳文の局所部分に着目することで，解析的な知識に強く依存することなく，スパースな対訳コーパスから効率良く対訳語を自動抽出する．本稿では，我々の知る限り両方の言語に対して同等な解析器が使用できない，かつ，大量の対訳コーパスが得られないアイヌ語－日本語対訳コーパスを対象とする．また，今回は対訳語抽出の第1段階として，出現頻度の高い名詞の対訳語を抽出対象とした．その際により高い精度で名詞対訳語を抽出すめに日本語文に対しては，その使用が容易である日本語形態素解析ツールを用いると共に，アイヌ語と日本語間のコロケーションの類似性に基づくヒューリスティックスを導入する．性能評価実験の結果，再現率として 60.1%，適合率として 70.1%が得られた．したがって，本手法が原言語，目的言語の両言語に対して同等な解析的な知識を，かつ，大量の対訳コーパスを使用できない条件のもと，名詞対訳語を自動抽出するために有効であることが明らかとなった．また，対訳コーパスから名詞対訳語を自動抽出することにより，新たなより自然な訳を得ることが可能となる．

2. 局所着目方式（LFM）の概要

LFM の概要について述べる．LFM は，類似した対訳文が存在しないスパースな対訳コーパスから名詞対訳語を抽出するための手法である．そのために，LFM は常に対訳文の局所部分に着目する．具体的には，対訳文ペア間の表層レベルでの共通部分を用いる．その共通部分に基づき抽出部分を決定していく．ここでの共通部分とは，1語以上で構成される連続する語の並びである．LFM では，文中の2つの共通部分を利用する場合と1つの共通部分を利用する場合の2通りの方法を用いて名詞対訳語を抽出する．本稿では，品詞情報が付与された言語文から抽出された部分の右端の語が名詞であれば，それを名詞対訳語とする．また，本手法は，原言語として単語分割はされているが品詞情報を持たない言語，また，目的言語として解析器を用いて品詞情報を付与可能な言語を対象としている．図1に2つの共通部分を用いた処理と1つの共通部分を用いた処理の概要を示す．ここでは，解析器により品詞情報を付与可能な言語として日本語を用いて説明する．

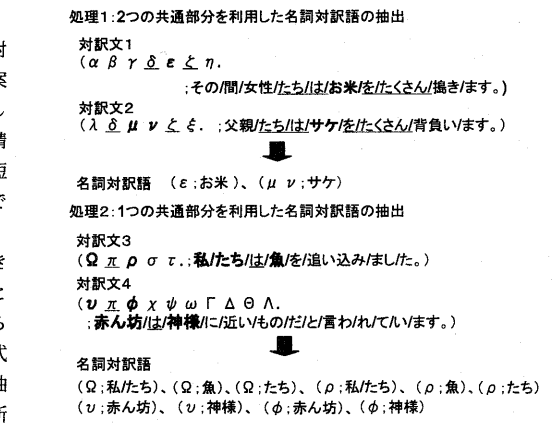


図1 局所着目方式（LFM）による名詞対訳語の抽出処理の概要

Fig. 1 Diagram of extraction process of bilingual noun word pairs using Local Focus-based Learning

図1の処理1は2つの共通部分を利用した場合の名詞対訳語の抽出処理である．対訳文1と対訳文2において共通部分として，原言語文においては “δ(注1)” と “ζ”，日本語文においては “たち/は” と “を/たくさん” が存在している．このように共通部分が2箇所存在する場合には，2つの共通部分で囲まれた部分を抽出する．また，その際には，名詞対訳語を抽出対象としているため，日本語文においては抽出対象となる部分の右端の語が名詞の場合のみ抽出する．その結果，原言語文と日本語文から抽出される部分を組み合わせることにより，対訳文1から（ϵ；お米），対訳文2から（$\mu\ \nu$；サケ）が得られる．

処理2は1つの共通部分を利用した場合の名詞対訳語の抽出処理である．対訳文3と対訳文4との間では，原言語文においては “π”，日本語文では “は” が共通部分となる．共通部部が1

(注1)：ギリシャ文字の使用は，日本語以外の様々な言語を一般化した表現として用いている．

つの場合には，2つの共通部分を利用した処理のように特定の部分が囲まれているわけではないため，複数の語で構成されている部分を抽出することは困難である．そこで，この処理では基本的には1語の名詞対訳語を抽出対象とする．具体的には，共通部分に隣接する左右の語を1語のみ抽出する．その結果，対訳文3からは "Ω" と "ρ"，"たち" と "魚" が抽出される．対訳文4からは "υ" と "φ"，"赤ん坊" と "神様" が抽出される．ここで日本語文から抽出される語については，品詞が名詞でなければならない．抽出された語を原言語と日本語とで組み合わせることにより名詞対訳語としては（Ω；魚），（Ω；たち），（ρ；魚），（ρ；たち），（υ；赤ん坊），（υ；神様），（φ；赤ん坊），（φ；神様）が得られる．

また，1つの共通部分を用いた名詞対訳語の抽出処理では，日本語文では品詞情報を利用できるため，原言語に比べ，多様な抽出処理が可能となる．具体的には，日本語文において，共通部分に隣接する語を出発点として，名詞が連結している部分を抽出する．この処理により，上述した8つの名詞対訳語以外に（Ω；私/たち），（ρ；私/たち）が得られる．

本手法では，抽出された原言語の部分と日本語の部分を組み合わせる際，全ての組み合わせにより名詞対訳語を得る．したがって，対応関係の誤った組み合わせが生じる場合がある．他言語において品詞情報を利用できない状況では，そのような全ての誤った名詞対訳語の抽出を未然に防ぐことは困難であると考えられる．我々はこのような問題に対しては，フィードバック処理やヒューリスティックスを導入し，抽出後に正しい名詞対訳語を選択することによりその解決を図る．

3. システム構成

アイヌ語－日本語間の名詞対訳語を抽出するLFMシステムの構成図を図2に示す．始めにアイヌ語－日本語間対訳コーパスから対訳文を1文ずつ取り出し，その対訳文の日本語文に対し，日本語形態素解析ツール「Chasen(注2)」を用いて単語分割するとともに品詞を得る．次いで，学習部において，新たに品詞情報を得た対訳文と既に品詞情報を持つ辞書中の対訳文を用いて名詞対訳語を抽出する．フィードバック部では対訳文を参照することにより，学習部で抽出した名詞対訳語のアイヌ語と日本語間の対応関係の正誤を評価する．その後，抽出した名詞対訳語を対訳語辞書に登録する．

4. 学 習 部

4.1 2つの共通部分に基づく名詞対訳語の抽出

2つの共通部分に着目した際の名詞対訳語の抽出処理について述べる．本処理の詳細を以下に記す．

(1) アイヌ語文間，日本語文間共に共通部分が存在する対訳文のペアを選択する．

(2) アイヌ語文，日本語文のそれぞれにおいて2つの共通部分に着目し，その共通部分間で挟まれた部分を抽出する．

(3) 抽出された日本語部分の最後の語が名詞であるかどうかを調べる．名詞の場合にのみ，次の処理(4)を行う．

(注2)：http://chasen.aist-nara.ac.jp/

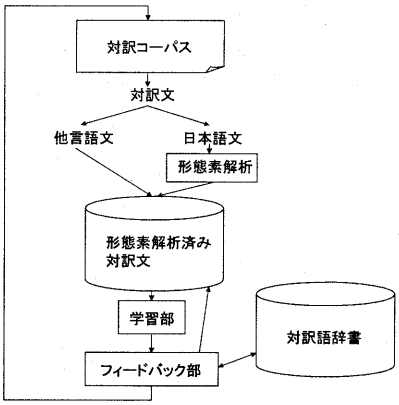


図2 システム構成図
Fig. 2 Process flow

(4) 抽出されたアイヌ語部分と日本語部分に対し，アイヌ語と日本語間のコロケーションの類似性に基づくヒューリスティックスを適用することで，文中における位置的な対応関係が適切であるかどうかを評価する．アイヌ語では述部が文末にくるなど，語順において英語などと比べて日本語との類似性が見られるため[11]，本手法ではこの特徴を利用し，「アイヌ語文のある語に対応する日本語は，日本語文においてもアイヌ語文中の位置と同じような位置に存在する」という考えに基づきヒューリスティックスを適用する．評価方法を以下に述べる．

a) アイヌ語文から抽出された部分の先頭の語が日本語文中において位置的にどの語に対応するのかを求める．位置的に対応する日本語文中の語の位置を以下の式より求める．ここで，日本語文中の対応する語をPCJ（**P**osition of the **C**orrespondence word in **J**apanese sentence）と記す．また，抽出されたアイヌ語部分の先頭の語の位置をPA（**P**osition of the first word of the part extracted from **A**inu sentence）と記す．

$$PCJ = \frac{PA \times Number\ of\ words\ in\ Japanese}{Number\ of\ words\ in\ Ainu} \qquad (1)$$

（小数点第1位四捨五入）

b) 日本語文から抽出された部分の先頭の語の位置が以下の条件を満たすかどうかを調べる．ここで，日本語文から抽出された部分の先頭の語の位置をPJ（**P**osition of the first word of the part extracted from **J**apanese sentence）とする．

$$PCJ - \alpha \leqq PJ \leqq PCJ + \alpha \qquad (2)$$

（αは定数）

(5) PJが式(2)の条件を満たす場合，抽出されたアイヌ語部分と日本語部分との間に位置的な対応関係が見られるとして，それらの組を名詞対訳語とする．

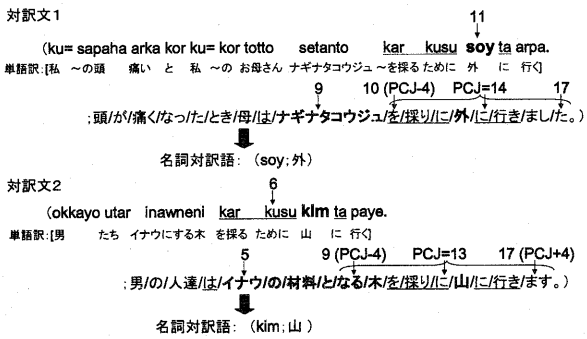


図 3　2つの共通部分に基づくアイヌ語－日本語間名詞対訳語の抽出例

Fig. 3　Example of extraction for Ainu-Japanese noun word pairs using two common parts

図 3 に本処理を用いた場合のアイヌ語－日本語間名詞対訳語の抽出例を示す．図 3 では，対訳文 1 と対訳文 2 の間において，アイヌ語文間では "kar kusu(注3)" と "ta" が共通部分である．日本語文間では，"は"，"を/採り/に"，そして，"に/行き" が共通部分である．したがって，対訳文 1 では，アイヌ語文においては，共通部分で挟まれた部分は "soy" だけとなるが日本語文においては，共通部分で挟まれた部分は "ナギナタコウジュ" と "外" の 2 箇所となる．また，これらは共に名詞(注4)であり，候補として残る．そこで，処理 (4) に基づき "soy" と "ナギナタコウジュ"，'外" とのそれぞれの位置的な対応関係を調べる．式 (1) より PCJ を求めると，"soy" は先頭の語から 11 番目に存在するため PA は 11 となり，日本語文の総語数，アイヌ語文の総語数はそれぞれ 17 と 13 であるため，PCJ は 14 (11×17/13) となる．次いで，"外" が式 (2) に該当するかどうかを調べるが，定数 α には 4 を使用する．定数 4 は予備実験を通して導き出した値である．定数 4 を用いることで，14 番目の語 "に" を中心に語数 9 の窓掛けをする．"外" の位置は 13 番目であるため PJ=13 となり，式 (2) は $14\text{-}4 \leqq 13 \leqq 14+4$ を満たす．したがって，名詞対訳語として (soy；外) が抽出される．同様に，"ナギナタコウジュ" について調べると，9 番目の語であり，式 (2) を満たさないため，名詞対訳語として，(soy；ナギナタコウジュ) は登録しない．対訳文 2 についても同様の処理を行う．その結果，対訳文 2 からは名詞対訳語として (kim；山) のみが抽出される．

4.2　1つの共通部分に基づくアイヌ語－日本語間名詞対訳語の抽出

1 つの共通部分に着目した際の名詞対訳語の抽出処理について述べる．処理の詳細を以下に記す．

(1) アイヌ語文間，日本語文間共に共通部分が存在する 2 つの対訳文を選択する．

(2) アイヌ語文において，1 つの共通部分に着目し，その共通部分に隣接する左右の 1 語を抽出する．

(3) 日本語文において，1 つの共通部分に着目し，その共通部分に隣接する左右の 1 語が名詞である場合，その語を抽出する．さらに，共通部分に隣接する語を出発点として，品詞が名詞，助詞の "の" で構成される名詞句の部分を共通部分の左右両方向より抽出する．

(4) アイヌ語と日本語間のコロケーションの類似性より，共通部分の左側から抽出されたアイヌ語部分と日本語部分同士を組み合わせる．また，共通部分の右側から抽出されたアイヌ語部分と日本語部分同士を組み合わせる．

(5) 処理 (4) より組み合わされたアイヌ語部分と日本語部分において，その抽出位置の対応関係を 4.1 節の式 (1) と式 (2) に基づき，適切であるかどうかを評価する．

(6) アイヌ語部分と日本語部分の組み合わせにおいて，その対応関係が式 (2) を満たす場合，名詞対訳語とする．

処理 (3) では，日本語文から 1 語以上の部分を抽出する場合には，「名詞+名詞+…」に加え，「名詞+の+名詞+…」の名詞句も抽出対象とした．そうすることで，アイヌ語 "wakkauskamuy" の訳語である "川/の/神様" といった抽出が可能になる．アイヌ語と日本語の名詞の関係においては，このような限定を表す名詞句がいくつか存在する．名詞句には「名詞+名詞+…」，「名詞+の+名詞+…」以外にも様々な形があるが，他の名詞句については，4.1 節で述べた 2 つの共通部分を用いる処理でその抽出を図る．処理 (4) では，アイヌ語文と日本語文において共通部分の左側同士もしくは右側同士といったように共通部分に対し同じ側に位置する抽出部分同士のみを組み合わせるという制約を入れているが，これも，4.1 節で述べたようにアイヌ語と日本語間のコロケーションの類似性に基づいている．図 4 に本処理を用いた場合のアイヌ語－日本語間名詞対訳語の抽出例を示す．

図 4 ではアイヌ語文間，日本語文間の共通部分はそれぞれ "anakne" と "は" である．アイヌ語文からは共通部分の左右に隣接する 1 語 "coka"，"cep"，"teynesi"，そして，"kamuy" を抽出する．日本語文においては，共通部分の左右に隣接する

(注3)：アイヌ語は話し言葉のみが使用されているため，その表記にはカタカナやローマ字が使用される．その場合，通常ローマ字は語の表記に，カタカナは発音を表す読み仮名として使われる [10]．

(注4)：Chasen による形態素解析の結果は未知語であった．未知語や明らかな分割誤りについては人手で校正を行った．

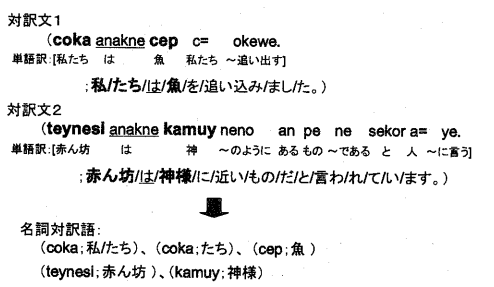


図4 1つの共通部分に基づくアイヌ語－日本語間名詞対訳語の抽出例

Fig. 4 Example of extraction for Ainu-Japanese noun word pairs using one common part

1語として，対訳文1からは“たち”，“魚”が，対訳文2からは“赤ん坊”，“神様”が全て名詞であるため抽出される．さらに，対訳文1から名詞の並びである“私/たち”が抽出される．そして，抽出された部分を組み合わせる．その際には，共通部分の左側から抽出されたもの同士，右側から抽出されたもの同士を組み合わせる．その結果，(coka；私/たち)，(coka；たち)(cep；魚)，(teynesi；赤ん坊)，(kamuy；神様)の組み合わせとなる．これらの組み合わせに対し，位置的な対応関係を調べる．この場合，全ての組み合わせが，式(2)を満たすため，全て名詞対訳語として抽出される．

5. フィードバック部

LFMシステムでは，誤った名詞対訳語に対しては抽出後，正しい名詞対訳語との差別化を行うことで対処する．例えば，図4で，正しい名詞対訳語として(coka；私/たち)，誤った名詞対訳語として(coka；たち)が抽出されることを示した．このように，あるアイヌ語部分に対して，複数の日本語部分が競合した場合を想定し，LFMシステムはフィードバック処理を行う．このフィードバック処理は名詞対訳語のアイヌ語部分と日本語部分の共起する頻度を抽出もとの対訳文以外の対訳文を参照して求めるという非常に単純な方法である．処理の詳細を以下に記す．

(1) 抽出もととなった対訳文以外の全対訳文を対象に，抽出された名詞対訳語のアイヌ語部分と日本語部分の両方が存在する対訳文の数を求め，その値を正確実度数CF（**C**orrect **F**requency）とする．

(2) 抽出もととなった対訳文以外の全対訳文を対象に，抽出された名詞対訳語のアイヌ語部分のみが存在する対訳文の数を求め，その値を誤確実度数EF（**E**rroneous **F**requency）とする．

(3) 抽出もととなった対訳文以外の全対訳文を対象に，抽出された名詞対訳語の日本語部分のみが存在する対訳文の数を求め，その値を誤確実度数に加える．

(4) 正確実度数と誤確実度数に基づき，以下の式より正評価度数CEF（**C**orrect **E**valuation **F**requency）を求める．

$$CEF = CF - EF \tag{3}$$

例えば，(coka；私/たち)と(coka；たち)の差別化を考えた場合，誤った名詞対訳語(coka；たち)のCEFが(coka；私/たち)のCEFに比べ小さくなる．(coka；たち)の日本語部分“たち”という名詞は“私”以外にも“子供/たち”，“妹/たち”など様々な名詞句に存在する．したがって，対訳文の日本語文に“たち”が数多く存在する可能性は高いが，対応するアイヌ語文に“coka”が存在する可能性はそれほど高くない．その結果，EFの値がCFを上回ることになる．それに対し，(coka；私/たち)は，“私/たち”が対訳文の日本語文中に存在する場合，対応するアイヌ語文中にも“coka”が存在する可能性が非常に高いため，CFが高くなる．また，仮に(coka；私/たち)が抽出元となった対訳文以外に全く存在しない場合には，(coka；私/たち)のCEFは0となる．しかし，(coka；たち)はEFが増加することによりCEFは負の値となるため，やはり(coka；私/たち)のCEFの値の方が高くなる．

さらに，CEFが同じ値の場合には，日本語部分の文中の位置において，PCJとの差が小さいものを選択する．PCJとの差が小さいものを選択するということは，ある対訳文から1つのアイヌ語に対して複数の日本語が選択されていた場合，位置的な対応関係がより近いものを優先するということである．例えば，対訳文(sakipe ne ya kikreppo ne ya a= koyki hi ta tunasno a= okewe yak pirka.；マス/や/ヤマベ/を/獲る/時/は/素早く/追い込み/ます．)から(sakipe；マス)と(sakipe；ヤマベ)の両方が抽出され，共にCEFの値が0の場合，“sakipe”のPCJは1となり“マス”に該当するため，誤った名詞対訳語の(sakipe；ヤマベ)ではなく，正しい名詞対訳語の(sakipe；マス)が選択される．

6. 性能評価実験

6.1 実験方法

実験データには，2つの文献[11], [12]に記載されている全10話の物語のアイヌ語－日本語対訳文287文を用いた．また，アイヌ語文においては，人称接辞と名詞を“=”を用いて連結して記述されているが，実験の際には，対訳辞書の構築の観点から，名詞対訳語としてより汎用性を持たせるため，人称接辞と名詞の間にスペースを入れている．例えば“ku=sapaha”の場合，“ku=”は人称接辞で“私の”を，“sapaha”は“頭”を意味し，文献[11], [12]では，これらの間にはスペースを入れていないが，今回の実験では“ku=sapaha”は“ku= sapaha”とする．その際の対訳文287文のアイヌ語文の平均語数は11.8語である．また，対訳文287文中には281種類の名詞が存在する．この281種類の名詞対訳語の出現頻度の平均は2.2であった．実験は，3節で述べたLFMシステムを構築し，対訳文287文を用いて行った．対訳語辞書の初期状態は空より行った．

6.2 評価方法

評価はアイヌ語の名詞語を1種類ずつ指定し，そのアイヌ語をアイヌ語部分に持つ名詞対訳語を選択する．選択された名詞対訳語の日本語部分が正しい訳語となっているかを調べる．1つのアイヌ語に複数の日本語訳が競合した場合には，5節のフィードバック部で述べたように，CEFの値が最も高く，かつ

PCJ の値に最も近い名詞対訳語を選択する．

6.3 実験結果

281 種類の名詞対訳語に対する再現率と適合率を求めた．再現率は 281 種類の名詞対訳語に対する，抽出された正しい名詞対訳語の割合である．適合率は抽出された名詞対訳語に対する，抽出された正しい名詞対訳語の割合である．実験の結果，再現率として 60.1%（169/281×100.0），適合率として 70.1%（169/241×100.0）が得られた．表 1 に抽出された正しい名詞対訳語の例を示す．

表 1　抽出された正しい名詞対訳語の例

Table 1　Examples of extracted correct bilingual noun word pairs

アイヌ語	日本語
totto	母
upas	雪
nisatta	明日
umma-ru	馬/道
anun	見知らぬ/人
onne kur	老人

6.4 考　　察

表 2　出現頻度と精度の関係

Table 2　Relations of appearence frequency and rates

出現頻度	再現率	適合率
1	53.9%(90/167)	66.7%(90/135)
2	62.3%(33/53)	70.2%(33/47)
3 以上	75.4%(46/61)	78.0%(46/59)

対訳表現の自動抽出においては，低頻度の対訳表現を抽出できるかが重要な課題である．そこで，我々は出現頻度と再現率，適合率の関係を調査した．その結果を表 2 に示す．

表 2 より，対訳コーパス中に 1 度しか出現しなかった名詞対訳語は 167 であり，これは対訳コーパス中に存在する全名詞対訳語の 59.4%である．したがって，名詞対訳語の多くが対訳コーパス中に 1 度だけしか出現していないにもかかわらず，本手法では，再現率 53.9%，適合率 66.7%という精度で抽出可能だったことがわかる．また，出現頻度が 2 や 3 以上の場合であっても，1 度目の出現時に抽出された名詞対訳語も含まれていることを考えると，本手法が低頻度の名詞対訳語であっても，効率良く抽出できていることがわかる．

また，本手法では品詞情報を持たないアイヌ語文において，どの語が名詞であるかを特定した上で名詞対訳語を抽出するのではなく，数多くの候補を抽出し，その中から正しい名詞対訳語を選択する方法をとっている．これは本手法がアイヌ語においてどの語が名詞であるのかを全く決定できないということではない．一般名詞などであればアイヌ語文に対して特定することは可能である．例えば，日本語部分が一般名詞の対訳語（ape；火）では，“火” のアイヌ語訳が “ape” であるのと同時に，“ape” の品詞を名詞と決定できる．今回の全対訳コーパスの日本語文に出現した一般名詞は 283 種類であり，そのうちの 81.6%（231）が対応するアイヌ語の訳語の品詞は名詞であった．そして，これらの一般名詞の名詞対訳語に対する再現率は 59.7%であった．したがって，本手法はアイヌ語文においてどの語が名詞であるのかを決定する際にも有効利用可能である．

本手法を他の言語を用いた対訳コーパスへと適用範囲を広げる場合には，4 節で述べたヒューリスティックスは，当然，変更する必要がある．しかし，今回のヒューリスティックスは表層レベルでの対応関係を利用したものであり，解析器を作成するよりもその労力は非常に小さいという利点がある．

7. おわりに

本稿では，対訳コーパスの原言語，目的言語の両言語に対し同等な解析器を利用できない条件で，かつ，少量の対訳コーパスから名詞対訳語を抽出可能な，局所着目方式（LFM）について述べた．少量のアイヌ語－日本語対訳コーパスによる LFM システムを用いた性能評価実験の結果，再現率 60.1%，適合率 70.1%が得られ，本手法の有効性を確認することができた．今後は，他の言語を用いた対訳コーパスに対しても LFM システムを適用し，本手法の有効性を検証していく予定である．

謝辞

本研究の一部は，北海学園大学ハイテク・リサーチ・センター研究費によって行なわれている．

文　　献

[1] 熊野明, 平川秀樹: 対訳文書からの機械翻訳専門用語辞書作成, 情報処理学会論文誌, Vol. 35, No. 11, pp. 2283–2290 (1994).
[2] 田中（石井）久美子, 梅村恭司, 岩崎英哉：第三言語を介した対訳辞書の作成, 情報処理学会論文誌, Vol. 39, No. 6, pp. 1915–1924 (1998).
[3] Kupiec, J.: An Algprithm for Finding Noun Phrase Correspondences in Bilingual Corpora, *Proc. 31st Annual Meeting of the Association for Computational Linguistic*, pp. 17–22 (1993).
[4] Haruno, M., Ikehara, S. and Yamazaki, T.: Learning Bilingual Collocations by Word-Level Sorting, *Proc. 16th International Conference on Computational Linguistics*, pp. 525–530 (1996).
[5] Smadja, F., McKeown, k. and Hatzivassiloglou, V.: Translation Collocations for Bilingual Lexicons: A Statistical Approach, *Computational Linguistics*, Vol. 22, No. 1, pp. 1–38 (1996).
[6] 北村美穂子, 松本裕治: 対訳コーパスを利用した対訳表現の自動抽出, 情報処理学会論文誌, Vol. 38, No. 4, pp. 727–736 (1997).
[7] 山本薫, 松本裕治: 統計的係り受け結果を用いた対訳表現抽出, 情報処理学会論文誌, Vol. 42, No. 9, pp. 2239–2247 (2001).
[8] 佐藤健吾, 斎藤博昭: サポートベクタマシンを用いた対訳表現の抽出, 自然言語処理, Vol. 10, No. 4, pp. 109–124 (2003).
[9] Echizen-ya, H., Araki, K., Momouchi, Y. and Tochinai, K.: Effectiveness of Automatic Extraction of Bilingual Collocations Using Recursive Chain-link-type Learning, *Proc. 9th Machine Translation Summit*, pp. 102–103 (2003).
[10] 田村すず子: アイヌ語沙流方言辞典, 草風館 (1998).
[11] 中本ムツ子, 片山龍峯: アイヌの知恵・ウパシクマ 1, 片山言語文化研究所, 新日本教育図書株式会社 (1999).
[12] 中本ムツ子, 片山龍峯: アイヌの知恵・ウパシクマ 2, 片山言語文化研究所, 新日本教育図書株式会社 (2001).