社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
SS2003-50 (2004-03)

電子メイルを対象とした帰納的学習を用いたSubjectの自動生成手法の性能評価

康　錦紅† 荒木　健治† 栃内　香次‡

†北海道度大学大学院工学研究科 〒060-8628 札幌市北区北13条西8丁目
‡北海学園大学大学院経営学部 〒062-8605 札幌市豊平区旭町 4-1-40
E-mail: †{kjh, araki}@media.eng.hokudai.ac.jp, ‡tochinai@econ.hokkai-s-u.ac.jp

あらまし　本稿では，帰納的学習を用いた電子メイルのサブジェクトの自動生成手法を提案し，性能評価実験を行った結果について述べる．ここで，我々は，メイル本文から重要文を抽出し，抽出された重要文からサブジェクトを生成する手法Aによる，品詞情報を利用しない場合と名詞だけの品詞情報を利用した場合の比較実験を行った．その結果，正抽出率が13ポイント向上することを確認した．また，重要文を抽出せずに，サブジェクトを生成する手法Bを提案し，手法Aとの比較実験を行った．その結果，正抽出率が手法Aより9．7ポイント向上することを確認した．

キーワード　電子メイル，帰納的学習，品詞情報，要約

Performance Evaluation of Automatic Generation Method of Subject Using Inductive Learning for E-mail

JINHONG KANG† Kenji ARAKI† and Koji TOCHINAI

†Graduate School of Engineering, HOKKAIDO University, Kita 13 Nishi 8 Kita-ku, Sapporo 060-8628 Japan
‡Hokkai-Gakuen Graduate School of Business Administration, 4-1-40 Asahimatchi, Toyohira-ku, Sapporo, 062-8605 Japan
E-mail: †{kjh, araki}@media.eng.hokudai.ac.jp, ‡tochinai@econ.hokkai-s-u.ac.jp

Abstract In this paper, we propose an automatic subject generation method for E-mail and evaluate its performance by experiments. In order to generate a subject, we extract an important sentence from the text of an E-mail and calculate the degree of similarity of the important sentence with the extracted important sentences what the user wrote before. The system then generates the subject based on the important sentence with the highest degree of similarity. We also try to use the part-of-speech information. The result shows that the performance of the method using the part-of-speech information is 13.0 points better than the one without using it. The improvement of 9.3 points has been achieved by using the independent part-of-speech information.

Keyword E-mail, inductive learning, part-of-speech information

1. まえがき

日進月歩のインターネットの世界で，電子メイルは仕事以外の日常生活にも頻繁に利用されている．電子メイルは手紙，電話，FAXとは異なり，一度に多くの人に情報を伝える同報性と即時性，便利性をもっている．このように電子メイルは様々な利点があるが，反面問題点も存在する．利用者の同意を得ずに広告，宣伝又は勧誘等を目的とした電子メイルを送りつけてくる，いわゆる迷惑メイルが1つの社会問題になっている．このような中で，電子メイルのしくみやマナーについて正しい知識を持つことにより，人に迷惑をかけたり，トラブルに巻き込まれることもなくなる．　電子メイルのマナーには，アドレス，サブジェクト，文書構成などがあるが，サブジェクトは，電子メイルのマナーの中でも，重要な部分として使われている．電子メイルにおいて，サブジェクトは相手に自分が伝えたい内容を表現する部分なので，情報伝達の観点から

重要な部分だと考えられる．自分が伝えたい内容を収約すれば，メイルを受け取る人がメイルの内容を見なくても，メイルの内容を把握できる．サブジェクトは受信者にとって内容を把握するための「手がかり」になるので，メイルを書くときサブジェクトを書くことが望まれる．そこで，我々はメイルの本文からサブジェクトを自動的に生成するシステムの構築を目指して本研究を行った．

電子メイルに関する研究は従来から盛んに行われている．電子メイルからの送信元の住所録情報の抽出[1]，大量に蓄積された電子メイルアーカイブから知識獲得手法を用いることによって，有用な知識を得ることを目的とした電子メイルからの知識獲得[2]，電子メイルのコミュニケーションにおけるスケジュール情報の抽出[3]，電子メイルのコミュニケーションにおける討議スレッド抽出に関する研究[4，5，6]，などが行われてきた．これらの研究はユーザが受け取ったメイルから情報抽出を行うため，「サブジェクト」が重要な情報として使用された．本研究では，従来の研究と逆に，ユーザが書いたメイルの「サブジェクト」を生成することが目的である．同じ電子メイルからの情報抽出に関する研究だが，従来の研究は受信者の立場で行った研究で，送信者の立場で行った本研究とは立場が異なる．これまで，電子メイルに関する研究では，サブジェクトを生成するといった研究は行われていない．

情報抽出[7，8]に関する研究では，元の文書から中心的な情報だけを抽出することを目的としている．また，抽出した情報をテキストという形で表現することを目的とするのが要約または抄録である．情報抽出及び要約は文書内容の理解に依存しており，人間にとっても大変な作業である．そこで，本研究では，電子メイルの内容の理解に立ち入らず，メイル本体の表記からサブジェクトを自動的に生成する手法を提案する．また，電子メイルは，書き方が人によって大きく異なるため，我々の手法は帰納的学習[9]を利用する．帰納的学習とは，ユーザが経験的にメイルの本文からサブジェクトを決定する規則を獲得し，獲得した規則を用いてメイルのサブジェクトを自動的に生成する手法である．

本稿ではメイルの本文から重要文を抽出後，抽出された重要文からサブジェクトを抽出する手法Aを提案し，品詞情報を利用しない場合と名詞だけの品詞情報を利用した場合の比較実験を行った．また，重要文を抽出せずサブジェクトを抽出する手法Bも提案し，自立語のすべての品詞情報を利用して類似度の計算を行い，名詞だけの品詞情報利用した場合との比較実験を行い，その性能評価を行った．

2．概要

手法Aでは，入力されたメイル本文に対して形態素解析[10]行い，一文ずつパラメータに変換する．変換されたパラメータを用いて重要度の計算が行われ，重要度が一番高い文が重要文として抽出される．抽出された重要文から類似度の計算によりサブジェクトが生成される．生成された結果に対して校正処理部で，ユーザが正誤判断を行い，人手で校正を行う．フィードバック処理部では，正変換度数と誤変換度数が更新され，更新されたルールの正変換度数と誤変換度数によりルールの尤度が計算される．学習部では，校正された結果とフィードバックされた結果により，新たな規則を獲得し，獲得された規則は新たなルールとしてルール辞書に追加される．

手法Bでは，入力文に対して形態素解析を行い，サブジェクト決定部で，入力された文とルール辞書中の重要文の類似度を計算し，類似度が最も高い入力文とルールによりサブジェクトが生成される．抽出された結果は手法Aと同様に，校正処理部，フィードバック部，学習部の各処理が行われる．

3．処理過程

提案した手法Aの流れを図1に示す．このように手法Aは，形態素解析，パラメータ変換処理，重要文決定処理，サブジェクト決定処理，校正処理，フィードバック処理，学習処理の順に行われる．手法Bは，形態素解析，サブジェクト決定処理，校正処理，フィードバック処理，学習処理の順であり，手法Aのパラメータ変換処理と重要文決定処理以外は同様なので，流れ図は省略する

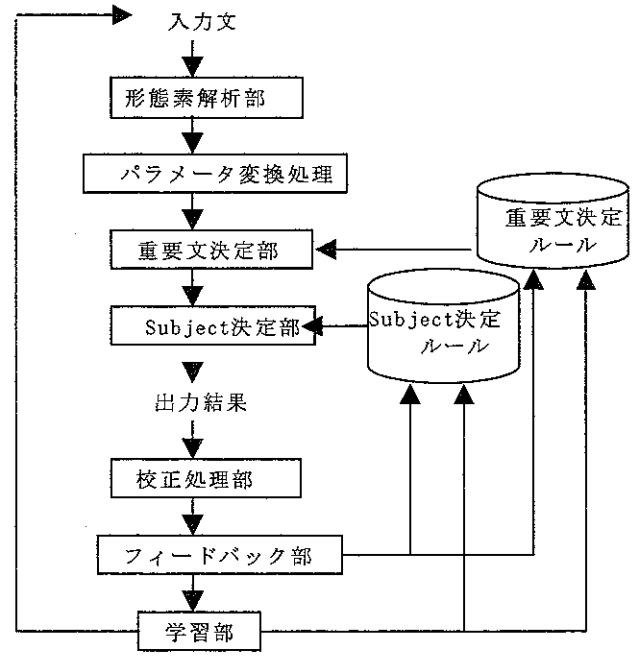


図　1　手法Aの流れ

3.1 パラメータ変換処理

3.1.1 予備実験

パラメータの変換を行うため,100 通のメイルを用いて予備実験を行った.予備実験の結果を表 1 に示す.予備実験を通じて，Subject を含む文の特徴を考察した結果，段落，段落中の位置，日時表現とキーワードとの関係が深いことが確認された．また，電子メイルの本文は標準のテキストと違い定型の書き方がないため,ここでの段落とは 1 行の空行で区切られたもので,文とは文末が記号「.」,「？」,「！」または文末が改行で区切られたものである．キーワード抽出値は名詞だけの品詞を用いて式(1)により計算された値である．

$$\text{キーワード抽出値}=\sum_{i}\frac{\text{メイル中の名詞}i\text{の重複回数}}{\text{一文中の名詞の数}} \quad \cdots(1)$$

3.1.2 パラメータ変換処理

まず，入力された文に対して，既存システム「茶筅」[11]を用いて形態素解析を行う．ここで，システムは形態素解析のみしか行わず，構文解析や意味解析などの解析は行わない．その理由は，電子メイルでは，口語的な表現が多いので，一般的ではない表現が用いられたり，文法の誤りなどの問題があるため，構文解析や意味解析を用いる方法では，解析を誤る場合が多くなるという問題が生じるからである．パラメータへの変換に使用された要素は予備実験結果により決定したものである．パラメータ決定要素を表 2 に示す．表 1 に示された要素により，入力文の一文ずつを 4 桁の数字に変換する．例えば，第一段落の一番目の文で，日時表現があり，キーワードの抽出値が 1 以下の場合のパレメータは 1113 のようになる．

表 1 予備実験結果

段落	第一段落		第二段落		第三段落	他の段落		
頻度	4		90		4	2		
段落中文の位置	一番目		二番目		三番目	その他		
頻度	94		6		0	0		
日時表現	ある		なし					
頻度	66		34					
キーワード	なし	0．33 以下	0.67 以下	1 以下	1.5 以下	2 以下	2．5 以下	3 以上
頻度	2	44	14	14	8	6	4	8

3.2 重要文決定処理

重要文決定部では，まず，パラメータを用いて重要度の計算を行い，計算された結果の内一番高い重要度に対応するパラメータを用いる文が重要文として決定される．重要文決定ルール辞書には，メイル本文の 1 文ごとの状態を表すパラメータとこのパラメータに対応する重要度が対になって保存されている．重要度の計算は式(2)により計算する．

表 2 パラメータ決定要素

```
1．　段落
1：第一段落 2：第二段落 3：第三段落：4:その他の段落
2．　段落中文の位置
1：一番目　2：二番目 3：三番目　4：その他
3．　日時表現
1：ある　0：なし
4．キーワード
0：なし　1:0．33 以下　2:0．67 以下 3：1 以下　4：1．5 以下
5：2 以下　6：2．5 以下　7：3 以上
```

重要度＝Σ(ルールの重み×要素の重み) … (2)

ここで，要素の重みとは，予備実験中の各要素の出現頻度により決定されたものであり，ルールの重みとは，ルールと一致した文が重要文となった確率である．入力されたメイル本文は 1 文ずつ重要度が与えられ，その中で重要度が一番高い 1 文が重要文として出力される．

3.3 サブジェクト決定処理

3.3.1 手法 A のサブジェクト決定処理

手法 A のサブジェクト決定部では,入力された重要文とルール中の重要文との類似度の計算を行う.その中で，類似度が一番高いルールが選択され，そのルールに基づいてサブジェクトが生成される．類似度の計算は式(3)により計算する．

$$\text{類似度}=\frac{\text{共通の単語数}}{\text{入力文の単語数}\times\text{ルール中重要文の単語数}} \quad \cdots(3)$$

サブジェクトの決定ルール辞書には，ユーザが以前に書いたメイルの重要文とサブジェクトが組みとなってルールとして登録されている．サブジェクトは以下の 2 つの方法により決定される．

1. ルール辞書中のサブジェクトが入力された重要文に含まれる場合，そのまま結果として出力される．
2. ルール辞書中のサブジェクトが入力された重要文に含まれてない場合，位置情報によりサブジェクトが決定される．

また，類似度が同じ場合，ルールの尤度により，尤度が最も高いルールが選択される．ルールの尤度は式(4)により計算される.文字列一致スコアを表 3 に示す.

表3：文字列スコア

A:	名詞	3ポイント
B:	動詞	2ポイント
C:	他の品詞	1ポインド

$$DM = \frac{(A + B + C)\text{の合計}}{\text{形態素数}}$$

$$尤度 = \frac{CF}{CF + EF} + DM \qquad (4)$$

CF:正変換度数　EF:誤変換度数　DM:文字列一致スコア

3.3.2 手法Bのサブジェクト決定処理

手法Bのサブジェクトの決定処理部では，入力されたメイル本文の一文ずつとサブジェクトルール辞書中の重要文との類似度の計算が行われる．類似度の計算は式（2）により計算される．計算された類似度の中で一番高い類似度を持つ入力文とルールが選択される．選択されたルールと文によりサブジェクトが決定される．サブジェクトの決定は手法Aと同様の方法である．

3.4 校正処理

校正処理部では，ユーザがサブジェクト決定部から出力された結果に対して正誤の判定を行う．出力された結果が実例のサブジェクトと同じ場合は正抽出と判定し，結果が出力されていない場合は未抽出と判定し，それ以外は誤抽出と判定する．また，誤った結果と未抽出結果は人手により校正を行う．

3.5 フィードバック処理

フィードバック部では，生成された結果の正誤により，変換度数が更新される，生成された結果が正しい場合，正変換度数を1増加し，誤った場合，誤変換度数を1増加する．

3.6 学習処理

学習部では，重要文の決定ルールとサブジェクト決定ルールの学習を行う．

3.6.1 重要文決定ルールの獲得

重要文決定ルールの学習はパラメータを用いて行われる．パラメータ変換処理で出力された一文ごとのパラメータとそれに対応する重要度をルールとして重要文決定ルール辞書に登録する．

3.6.2 サブジェクト決定ルールの獲得

サブジェクト決定ルールはユーザが以前に書いたメイルの重要文とサブジェクトが対になってサブジェクト決定ルール辞書にルールとして登録されたものである．ここで，重要文とは，サブジェクトを含む文である．

4. 評価実験

4.1 実験データと実験方法

本実験では，あるユーザの300通のメイルを使用した．手法Aの場合，類似度の計算では，まず，抽出された重要文とルール辞書中の重要文のすべての品詞情報を用いて計算を行い，実験を行った．次に，名詞だけの品詞情報を用いて類似度を計算して実験を行い，すべての品詞情報を用いて実験を行った場合との比較を行った．手法Bの場合，まず，50通のメイルを用いて名詞だけの品詞情報を利用した場合と自立語のすべての品詞情報を利用した場合との比較実験を行った．

4.2 評価方法

本実験においては，システムにより生成されたサブジェクトと実例のメイルのサブジェクトが全く同じ場合は正抽出とし，異なる場合は誤抽出とし，出力されない場合は未抽出と評価した．ここでの正抽出率と適合率は式（5）と（6）により計算される．

$$正抽出率 = \frac{抽出された正しい結果数}{入力数} \times 100(\%) \quad \cdots (5)$$

$$適合率 = \frac{抽出された正しい結果数}{抽出された数} \times 100(\%) \quad \cdots (6)$$

4.3 実験結果

4.3.1 手法Aによる実験結果

実験結果を表4に示す．入力された300通のメイルの内，重要文の正解数が269で，全体300通メイルの89.7%（269/300）である．また，品詞情報を利用しない場合，正抽出率は42.3%（127/300）で，名詞の品詞情報を利用した場合は55.3%（166/300）であった．再現率は，品詞情報を利用しない場合51.6%（127/246）で，名詞の品詞情報を利用した場合は47.2%(127/269)であった．

4.3.2 予備実験結果

重要文中で名詞以外の自立語の品詞情報を利用した場合と名詞だけの品詞情報を利用した場合の比較を行うために50通のメイルを用いて予備実験を行った．予備実験の結果を表5に示す．ここで，名詞だけの品詞情報を利用して類似度を計算し，サブジェクトを生成

した場合正抽出率が 56.0% (28/50) であった．また，自立語のすべての品詞情報利用して類似度を計算し，サブジェクトを生成した場合は正抽出率が 72.0% (36/50) で，正抽出率が 16 ポイント向上した．

表 4 手法 A の実験結果

	重要文数	品詞情報を利用しない	名詞の品詞情報を利用
正抽出	269	127	166
正抽出率	89．7%	42．3%	55．3%
誤抽出数	31	119	92
誤抽出率	10．3%	39．7%	30．7%
未抽出数		23	11
未抽出率		7．7%	3．7%

表 5 予備実験結果

	名詞だけの品詞情報を利用	自立語の品詞情報を利用
正抽出	28	36
正抽出率	56.0%	72．0%
誤抽出数	15	9
誤抽出率	30．0%	18．0%
未抽出数	7	5
未抽出率	14．0%	10%

4.3.3 手法 B による実験結果

手法 B による実験結果を表 8 に示す．入力された 300 通のメイル内，65.5% (195/300) が正抽出で，32.0% (96/300) が誤抽出で，3.0% (9/300) が未抽出あった．

5. 考察

今回の実験では，まずパラメータを用いて重要文の抽出を行い，抽出された重要文からサブジェクトの抽出を行った．また，サブジェクトの抽出での類似度の計算で，品詞情報を利用しない場合と名詞だけの品詞情報を利用した場合の比較を行った．300 通のメイルを使用して実験を行った結果 300 の中で 42.3% (127/300) が正抽出で，39．7% (119/300) が誤抽出で，7．7% (23/300) が未抽出であった．ここで，未抽出率

表 8 手法 B の実験結果

	重要文を抽出してない場合
正抽出数	195
正抽出率	65．0%
誤抽出数	96
誤抽出率	32．0%
未抽出数	9
未抽出率	3．0%

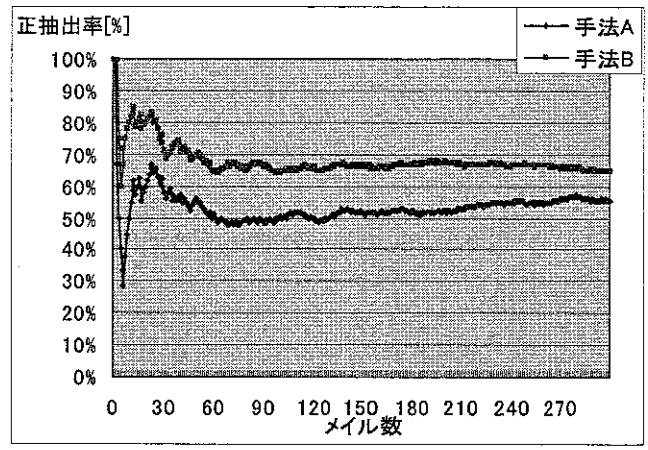


図 3 正抽出率

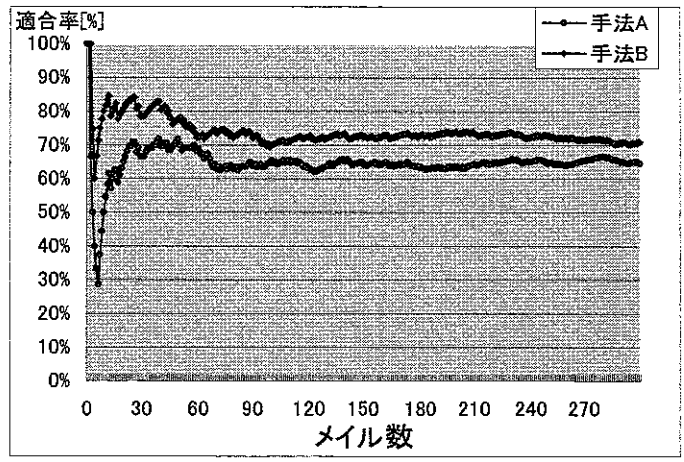


図 4 適合率

10.3%(31/300)を考慮せず，269 通の正しい重要文により考察を行った結果正抽出率が 47.2%(127/269)で，誤抽出率が 44.2%(119/269)で，未抽出率が 8.6%(23/269)であった．その原因は，すべての品詞を用いて類似度の計算を行う場合，頻繁に出現する助詞なども名詞のようにサブジェクト生成における重要な単語と同様に扱っているためであると考えられる．ここで，我々は，

メイルサブジェクトが名詞であることを考え,名詞の品詞情報を用いて類似度の計算を行い,その結果に対して考察を行った．その結果，正抽出率が 55．3% (166/300)で，品詞情報を利用しない場合より正抽出率が 13 ポイント向上した．また,予備実験により,自立語のすべての品詞情報を利用して類似度の計算を行った場合正抽出率が 72.0%(36/50)で,名詞だけの品詞情報を利用した場合，正抽出率が 50.6%(28/50)で,正抽出率が 21.4 ポイント向上したことを確認した．そこで，手法Aの重要度の誤りがサブジェクトの生成結果に悪影響を与える問題を解決するために，重要文の抽出を行わずサブジェクトを抽出する手法Bにより実験を行った．その結果，正抽出率が 65.0%で,手法 A で名詞だけの品詞情報を利用した場合より,正抽出率が 9.7 ポイント向上した．これは，以下の原因によるものだと考えられる．

1. 手法 A で重要文の誤りが 31 通あったので，サブジェクトの生成に悪影響を与えたが，手法 B の場合は重要文の抽出を行わずメイル本体から直接サブジェクトの生成を行った結果，31 通の内 61.2% (19/31) が正抽出になって，正抽出率が 7.3 ポイント向上した．
2. 手法 A で，全 300 通のメイルの 40．7% (122/300) が位置情報を利用してサブジェクトの生成が行われた．その内，75.4% (92/122) が誤りとなったが，手法 B では，10．2 ポイント減少し 67．2% (82/122) となった．300 通中では 3.3 ポイント減少した．

手法 A で,名詞だけの品詞情報を利用した場合と手法 B の正抽出率を図 3 に適合率を図 4 に示す．

6．おわりに

本稿では，帰納的学習により電子メイルからサブジェクトを自動的に生成する手法を提案した．そこで，我々は，まず，重要文を抽出した後，抽出された重要文からサブジェクトを抽出するという手法Aにおいて，品詞情報を利用しない場合と品詞情報利用した場合の比較実験により，名詞の品詞情報を利用した場合，品詞情報を利用しない場合より正抽出率が１３ポイント向上することを確認した．また，手法Bによる実験結果により，重要文の抽出を行わずに自立語のすべての品詞情報を利用した場合，正抽出率が手法 A より 9.7 ポイント向上したことを確認した．したがって,手法 B がサブジェクトの生成に適していると考えられる．

今回の問題点として，位置情報によりサブジェクトの生成を行ったものが 122 通であったが，その内，正抽出率が 32.8% (40/122) なので，この向上が今後の課題となる．また，学習データの選択の工夫も１つの問題点となった．今後の課題として，今回は，一人のユーザのメイルを利用して実験を行ったが，様々なユーザに対しての有効性を確認することが挙げられる．また，今回の実験ではサブジェクトがかなり短くて，助詞などが含まれていなかったが，ユーザにより，サブジェクトが長くなる場合，サブジェクト中で助詞が含まれる可能性が高くなるので，類似度の計算以外でも，助詞をどのように利用するのかという問題も存在する．

文　献

[1] 浅野久子，加藤恒昭，高木伸一郎，“電子メイルからの送信元住所録情報の抽出とそれを用いた住所録管理システム”，情報処理学会論文誌，Vol.39,No7,pp. 2196-2206(1998)

[2] 長谷川隆明，高木伸一郎，“電子メールコミュニケーションにおけるスケジュール情報の抽出”，情報処理学会自然言語処理研究会資料，123-10，pp.73-80(1998)

[3] 上田宏高，柳沢豊，塚本昌彦．西尾章治郎，“電子メールの傾向分析への知識獲得手法の適用”，情報処理論文誌，Vol.41,No 12，pp.3285-3293(2000)

[4] 山見太郎,村越広亨,島津明，落水浩一郎，“電子メールを利用したコミュニケーションにおける討議スレッド自動抽出手法の実装と評価”，情報処理学会，自然言語処理研究会研究報告，137-10，pp.69-76(2000)

[5] Hiroyuki Murakoshi, Akira Shimizu, and Koichiro Ochimisu.,“Construction of Delibe-Ration Structure in Email Communication.”, In Pacific Association for Computational Linguistic (PACLING' 99), PP 16-28, Aug.1999

[6] Hiroyuki Murakoshi, Akira Shimizu, and Koiciro Ochimisu. “A Method of Computing Measure for Evaluating Conversational Coherence in Email Communication.”, In International Workshop on Collaboration and Mobile Computing Society Press, Sep.1999

[7] 徳永健伸著 “情報検索と言語処理”，東京大学出版社 1999

[8] 田中穂積，“自然言語処理基礎と応用”,社団法人電子情報通信学会編，1999

[9] 荒木健治，栃内香次，“帰納的学習を用いた自然言語処理の有効性について”，信学技報 TL99-41，pp.33-40,2000

[10] 長尾真編 “自然言語処理”，岩波書店 1999

[11] 松本祐治，北内 啓，山下達勇，平野善隆，“日本語形態素解析システム「茶筅」 version 2.0 使用説明書”，NAIST Techinical Report, NAIST-IS-TR99008,1999

ミツバ綜合印刷株式会社