LE-005

一文一格の原理と規則化に基づいた深層格の自動推測手法
A Method for Automatic Inference of Deep Cases Based on the One-Instance-per-Clause Principle and Regularization

渋木 英潔 † 荒木 健治 ‡ 栃内 香次 †
Hideyuki Shibuki Kenji Araki Koji Tochinai

1. まえがき

本稿では，構文解析が行われた文に対して深層格を自動的に推測する手法を提案する．従来研究では，河原ら [1] のように，構文解析の曖昧性解消などを目的として表層格を扱う研究が盛んに行われている．しかしながら，中間言語方式の機械翻訳など，複数の言語間の情報伝達媒体としての利用を考慮した場合，表層格では不十分である．言語普遍である深層格を利用することで言語間の差異を吸収できるが，その一方で，文中で明示されていない深層格を表層格などから自動的に推測しなくてはならない．推測のための知識を人手で与える方法では，多大な労力が必要となる．それゆえ，深層格のタグが付与されたコーパスから，表層格と深層格の対応を自動的に獲得する手法として，大石ら [2] の手法などが提案されている．しかしながら，複数の言語を対象とするような場合，大石らの手法では，それぞれの言語で深層格を付与したコーパスが必要となり，労力の軽減という立場からは望ましくない．仮に，深層格推測システムを言語普遍のレベルで構築することができたならば，大幅な労力の軽減が期待できる．以上の背景から，言語普遍の知識を基に深層格を決定する知識を自動的に獲得することを最終的な目的として研究を進めている．そのための最初の段階として，本稿では，分類語彙表と EDR コーパスから計算された確率を言語普遍と仮定し，日本語を対象とした深層格の推測を行う．

次節で言語普遍と仮定する知識について述べた後，**3** 節で本手法の推測方法について述べる．**4** 節では，日本語を対象とした実験を行い，その結果と考察について述べる．**5** 節は結論である．

2. 言語普遍の知識

本手法で，言語普遍と仮定して与える知識は，概念体系と概念ごとの深層格の選好に関する知識である．これらの知識を現段階で正確に表現することは困難であるため，本稿では，概念体系として分類語彙表を，ある概念の深層格の選好を示す指標として EDR コーパスから以下の方法で計算された確率を，それぞれ近似値として用いる．まず，分類語彙表に登録されており，かつ，EDR コーパスの意味フレームに現れる単語を抽出し，5 桁の分類番号をその単語の概念とした．次に，その単語が意味フレーム中で下位範疇化されている場合，その深層格の出現回数を計算し，全深層格の出現回数で割ることにより確率化した．同様に，その単語がある単語を下位範疇化している場合の確率も計算し，前者を被下位範疇化確率，後者を下位範疇化確率と定義した．これらの確率は，次節で述べる推測過程の中で，取り得ない深層格の排除や，深層格の仮説の優先順位の決定に利用される．

3. 深層格の推測

本手法による深層格の推測は，以下の二段階で行われる．第一段階では，前節で述べた確率を用いて，取り得ない深層格を排除した後，フィルモアの一文一格の原理§に違反しないように仮説を立てて推測する．第二段階では，第一段階の結果から，深層格と一意に対応する表層格の規則を獲得し，その規則に従って再解析を行う．

まず，取り得ない深層格の排除について説明する．ある深層格に対して，係り元の概念の被下位範疇化確率，あるいは，係り先の概念の下位範疇化確率が 0 の場合，その深層格は推測候補から除外される．例えば,「太郎」や「次郎」などの概念の被下位範疇化確率が，動作主格，対象格，所有格に対してのみ 0 以外の値を持ち，その他の深層格に対しては 0 であると仮定する．また,「見る」の概念の下位範疇化確率が，動作主格，対象格，道具格，場所格に対してのみ 0 以外の値を持つと仮定する．この場合,「太郎が見る」や「次郎を見る」などの依存関係において，所有格や道具格や場所格が排除され，取り得る深層格は動作主格か対象格であると推測することができる．同様に,「双眼鏡」の 0 以外の被下位範疇化確率が対象格と道具格であると仮定すると,「双眼鏡で見る」が取り得る深層格は対象格か道具格と推測できる．その結果,「太郎が次郎を双眼鏡で見る」という文の深層格を図 1 のように絞り込むことができる．

次に，絞り込んだ状態から一文一格の原理に基づいて推測する方法を説明する．推測の流れを以下に示す．(1) 現在までの推測結果と被下位範疇化確率を用いて深層格の仮説を立てる．(2) 一文一格の原理に従って演繹的に推測する．(3) 一文一格の原理に反する場合は仮説を立てた時点まで推測結果を戻し，仮説を否定する．以上の処理を入力文中の全ての深層格が推測されるまで繰り返

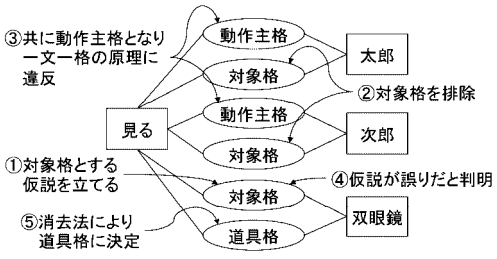


図 1: 推測の第一段階の例

†北海学園大学大学院経営学研究科, Graduate School of Engineering, Hokkaido University
‡北海道大学大学院工学研究科, Graduate School of Business Administration, Hokkai-Gakuen University

§同じ文に同じ深層格は 1 回しか現れないという原則

表 1: 各手法の正解数と正解率

	総依存関係	手法 A		手法 B		提案手法	
データ A	5,470	3,381	(61.8%)	3,455	(63.2%)	3,609	(66.0%)
データ B	3,217	2,420	(75.2%)	2,507	(77.9%)	2,578	(80.1%)
データ C	2,221	1,828	(82.3%)	1,875	(84.4%)	1,916	(86.3%)
データ D	1,598	1,383	(86.5%)	1,413	(88.4%)	1,441	(90.2%)

す．一文一格の原理に基づく推測の例を，先の例文を用いて説明する．図 1 の状態で,「太郎」や「次郎」が動作主格や対象格になる確率，あるいは「双眼鏡」が道具格になる確率よりも,「双眼鏡」が対象格になる確率が最も高いとする．この場合,「双眼鏡」を対象格とする仮説がまず成り立つ．この仮説に従うと，一文一格の原理より「太郎」と「次郎」は対象格ではないと推測される．その結果,「太郎」と「次郎」が取り得る深層格は共に動作主格のみとなり一文一格の原理に違反する．このことから,「双眼鏡」を対象格とした最初の仮説が誤りであると推測され,「双眼鏡」が取り得る深層格から対象格が除外され，消去法により道具格が「双眼鏡」の深層格であると推測できる．

推測の第一段階では，全体を通しての整合性を考慮していない．また，格助詞のような表層格に対しては，表層格から規則的に深層格を決定する手法の方が高い精度で推測できると考えられる．それゆえ，推測の第二段階では，入力文全体を通じて，ある表層格が特定の深層格と推測された割合が多数を占める場合，その表層格と深層格を対応付ける規則を獲得する．具体的に何割以上を多数とするかについては，今後詳細な調査が必要であるが，本稿では予備実験の結果から 7 割以上とした．獲得された規則と異なる深層格については，第一段階での推測結果が誤りであったと判断し，規則に従った深層格に修正する．先の例では,「太郎」と「次郎」は同じ概念であるため，確率のみで正しく推測できるとは限らない．しかしながら，入力文全体を通じて,「が」が動作主格,「を」が対象格とそれぞれ推測される割合が多ければ,「太郎が次郎を見る」も正しく推測されることが期待できる．

4. 実験

一文一格原理及び規則化の影響を調査するために以下の三通りの手法による比較を行った．第一の手法は，係り元の概念の被下位範疇化確率が最大となる深層格を選択する手法 A である．第二の手法は，推測の第一段階である深層格の排除と一文一格原理による推測のみを行う手法 B である．第三の手法が，本稿で提案した手法であり，手法 B に加えて第二段階である規則化までを行う手法である．実験で用いた文は，EDR コーパスから，係り先の品詞が動詞であること，係り先と係り元の単語が分類語彙表に登録されていること，一文一格の原理を満たしていることの 3 つの条件を満たす文を選択した．また，これらの手法が，典型的な依存関係のみを含む集合と，例外的な形式も含む集合を入力とした際にどのような違いが現れるかを調査するために，単語の出現頻度が，0，5，10，15 回以上である集合を作成し，それぞれデータ A から D とした．データ D が最も典型的な依存関係のみを含む集合であり，データ A は例外的な形式も含む集合である．評価は以下の式から計算される正解率を用いた．

$$\text{正解率} = \frac{EDR\ \text{コーパスと一致した依存関係数}}{\text{総依存関係}} \times 100.$$

それぞれのデータにおける総依存関係と各手法の EDR コーパスと一致した依存関係数及び正解率を表 1 に示す．全てのデータにおいて，一文一格原理及び規則化が有効であったことが分かる．本稿では条件を整えて実験を行ったこともあり，単純に比較を行うことはできないが，出現頻度による条件を追加することにより，深層格を明示した文から獲得する大石らの手法と同程度の精度で，構文解析しかされていない文の深層格を推測することができた．いずれのデータにおいても 4 から 5 ポイントの向上であり，データの違いによる向上の差異を確認することはできなかった．このことは，規則化により例外形式に対する確率の欠点を補うという目的が達成されなかったことを示しており改善の必要がある．また，言語普遍の知識の利用を目的としていながら，分類語彙表及び EDR コーパスから計算された確率を使用していることも問題であり調査が必要である．

5. おわりに

本稿では，概念体系と概念ごとの深層格の選好知識を言語普遍と仮定し，分類語彙表と EDR コーパスから計算された確率を近似的に用いることで，構文解析が行われた文に対して深層格を自動的に推測する手法について提案した．今回の実験では，EDR コーパスを評価データしたクローズドなものであったが，一文一格の原理を基に推測を行うことで，確率的に最大の深層格を推測する手法の正解率 61.8%を 63.2%に向上させることができた．また，推測された結果を基に，7 割以上で同一の深層格と対応する表層格を規則として獲得し，規則に従って再解析を行うことで 66.0%まで向上できることを確認した．今後の課題として，本手法が，例外形式を多く含む集合やシソーラスの未登録語を含む文に対して対処できるよう手法を改善することがあげられる．また，EDR コーパス以外のデータや日本語以外の言語でも実験を行い言語普遍性について調査する予定である．

参考文献

[1] 河原大輔, 黒橋禎夫: 用言と直前の格要素の組を単位とする格フレームの自動構築, 自然言語処理, Vol.9, No.1, pp.3–19 (2002).

[2] 大石亨, 松本裕治: 格パターン分析に基づく動詞の語彙知識獲得, 情報処理学会論文誌, Vol.36, No.11, pp.2597–2610 (1995).