E-035 種々の雑談を対象とした対話処理システムに対する応答性能の評価
Evaluation of response performance for various chat dialogue systems

木村 泰知 † 荒木 健治 ‡ 栃内 香次 ‡
Yasutomo Kimura Kenji Araki Koj Tochinai

1. まえがき

インターネットの普及や音声認識技術の向上により，Web 上での対話や電話による音声対話 [1] など，対話処理の研究が盛んに行われている．しかし，性能評価は対象ごとに異なり，評価方法が定まっていない．対話処理の対象は大きく分けてタスク指向型と非タスク指向型 [2][3] に分けられる．タスク指向型の対話処理であれば，目標が定まっているため正応答または誤応答の判断が比較的容易である．しかし，非タスク指向型の対話，すなわち，雑談のような絶対的な正解がない対話処理では，タスク指向型の評価を当てはめることは困難である．雑談における評価は，個人に依存した趣向や考え方も考慮するべきである．第３者に違和感を与えても，対話の当事者が満足していれば，正しい応答となる．このように主観的な評価を行うべき対象ではあるが，客観的な評価に近づけるために，評価の選択がどのように行われているのかを判断することを試みた．タスク指向型は絶対的な評価を行えるが，非タスク指向型では相対的な評価が適していると考えられる．

本稿では，応答を相対的に評価することで信頼性の高い正応答の評価を行う．1 入力に対して複数のシステムが応答を行い，それらの応答をユーザが評価する．複数の応答を見比べることで，客観的に正しい評価に近づける．次節で評価の処理過程を述べる．

2. 処理過程

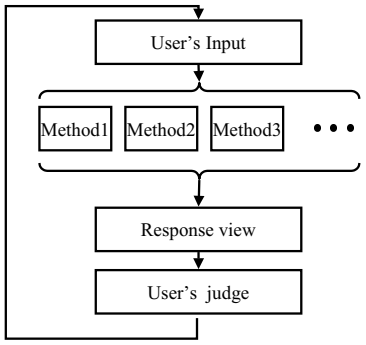


図 1: 処理過程

図 1 を用いて処理過程を説明する．ユーザの入力に対して，Method1,Method2,Method3,· · · を用いて複数のシステムが応答生成を行う．例えば, 図 2 のように各応答に対して評価する．画面にそれらの応答を表示することで，ユーザは他のシステム応答を考慮して応答評価を行うことができる．ユーザは複数の応答に対して，満足応答，正応答，誤応答の評価を行う．ここでの応答分類は，雑談を考慮しており「満足応答 > 正応答 > 誤応答」の関係で良い応答とする．例として，応答の分類例を下記に示す．

- 入力文：学校にいます
- 満足応答
  - 入力文に関連があり，対話を継続しやすい応答
  - 例：「学校の調子はどうですか」
- 正応答
  - 入力文に関連のある応答
  - 例：「いいね」
- 誤応答
  - 入力文に関連のない応答
  - 例：「あでもね．検索したら清里町で９０００くらいヒットしたよ．」

本評価方法を用いて，単独のシステムと比較する．システムと実際に対話した話者の評価と第３者が評価した結果の比較を行う．単独で評価した結果より，本手法による評価が他の被験者と一致率が高いほど，客観的な評価と考えることができる．次節では実験方法と結果について述べる．

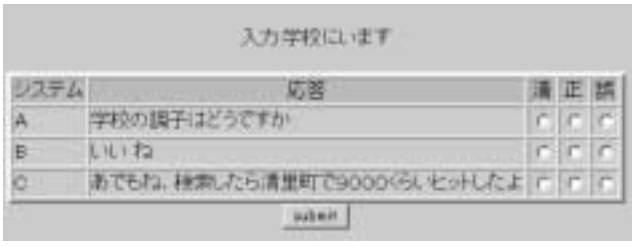


図 2: 対話の例

3. 実験

実験の目的は，単独のシステムによる評価と本評価方法を比較することである．

図 3 を用いて評価方法を説明する．ユーザは単独評価システムと本評価システムに対してそれぞれ 50 文の入力を行い，それらの応答に対して評価する．ユーザの入力とシステムの応答から構成されるデータに対して，第 3 者が応答評価を行い，その結果と被験者 A〜D の結果

†北海道大学大学院工学研究科
‡北海学園大学大学院経営学研究科

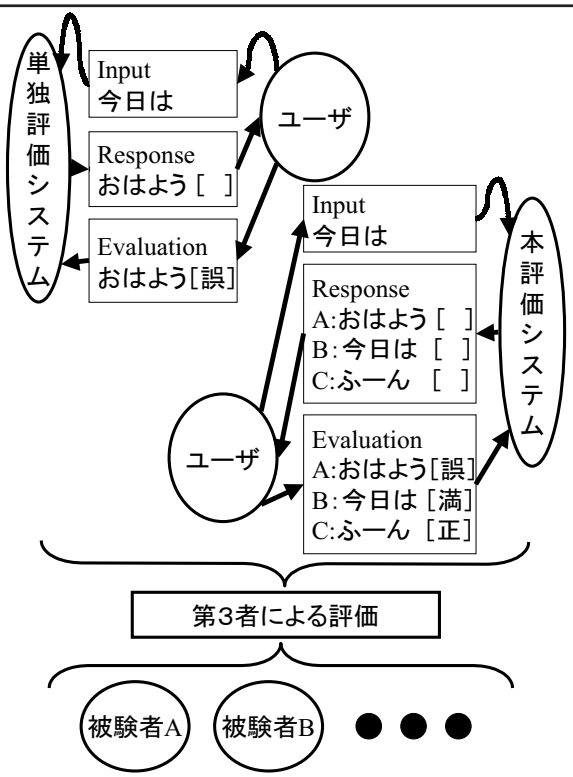


図 3: 評価方法

がどの程度一致しているかを調べる．相対的な評価を行うために，3 つの応答システムを用いて評価する方法を説明する．ここでは応答システムを以下の 3 つとする．

1. ELIZA
2. ランダム応答 1
   - 訓練データからランダムに選択
3. ランダム応答 2
   - 訓練データにおいて出現頻度の高い 20 文からランダムに選択

訓練データは大学生 3 名の対話を記録した 588 文とした．

3.1 実験結果

表 1 に実験結果を示す．実験結果より，本評価方法における第 3 者の一致率と単独のシステムにおける一致率に違いがみられた．被験者 C を除いて，本評価方法は単独のシステムの評価より高い一致率であった．この結果から，本評価システムの方が第 3 者と意見が一致しているということを示している．第 3 者との一致率が高いということは，客観性が高い評価になることを示しており，非タスク指向型の対話において有効な評価方法と考えられる．

3.2 考察

実験後，ユーザに評価のしやすさを尋ねたところ，本評価システムは比較対象があり評価しやすいという回答が得られた．この理由としては，単独システムの場合には局所的な部分だけをみる傾向があるためと考えられる．

表 1: 実験結果

	一致率	
	本評価方法	単独
被験者 A	56%	26%
被験者 B	34%	26%
被験者 C	28%	36%
被験者 D	56%	38%

つまり，システムが良い応答だけを返している場合，その中で少しでも悪い応答は誤応答と判断される．

本評価方法は比較することで誤応答と正応答の判断を補助している．つまり，他の種類の応答があるため，正誤の判定を比較的迷わずに行えると考えられる．直接システムと対話したユーザの評価と第 3 者との評価の一致率が高ければ，客観的な評価に近いといえる．

4. おわりに

本稿では，非タスク指向型の対話処理に対する評価方法を提案した．ここでは，ELIZA，ランダム応答 1，ランダム応答 2 の評価結果の評価に対して，相対的に行った場合と単独で評価した場合の違いを述べた．

一つのシステムに対して応答評価を行う場合，その応答の善し悪しは局所的なものになりやすく，本稿では他手法による応答も評価に加えることで，より客観的な評価を行えることを確認した．本稿ではテキストベースによる評価を行ったが，応答を画面に表示することで音声対話処理にも応用可能となる．今後は音声対話の評価を行う予定である．

参考文献

[1] Victor Zue, Stephanie Seneff, James Glass, Joseph Polifroni, Christine Pao, Timothy J. Hazen and Lee Hetherington, “JUPITER: A telephone-based conversational interface for weather information,” IEEE Transactions on Speech and Audio Processing, Vol. 8 , No. 1, January 2000

[2] J. Weizenbaum, “ELIZA - A Computer Program for the Study of Natural Language Comunication Between Man And Machine,” Communications of the Association for Computing Machinery,vol.9,no.1,pp.36-45,1966.

[3] 木村泰知，荒木健治，桃内佳雄，栃内香次，“遺伝的アルゴリズムを用いた帰納的学習による音声対話処理手法,” 電子情報通信学会論文誌 D-II，Vol.J84-D-II，No.9，pp.2079-2091,2001.