K-030

喉頭摘出者音声の健常者音声への帰納的学習を用いた音声変換手法の有効性の一検討

A Study of effectiveness on a Direct Speech Transform Method using Inductive Learning from Laryngectomee Speech to Normal Speech

村上 浩司 † 荒木 健治 † 広重 真人 † 栃内 香次 ‡
Koji MURAKAMI Kenji ARAKI Makoto HIROSHIGE Koji TOCHINAI

1. まえがき

今日，喉頭がんなどにより喉頭摘出手術を受けた結果，失声した人は日本で約 20000 人いるといわれている．こうした人々はもっとも身近で大切な，音声による情報伝達手段を失うことで不自由な生活を余儀なくされている．こうした喉頭摘出者は，食道発声法や電気発声法といった発声方法を習得することで筆談やジェスチュアに頼らずにコミュニケーションが可能となる．しかしながら，このような発声法による音声は，近年の音声認識技術の急速な発展の恩恵を受けることが難しい．これは，音声認識で対象とする音声があくまで健常者発声音声であり，喉頭摘出者などの障害者音声の入力は考慮されていないことが原因の 1 つと考えられる．

そこで我々は，通常の音声認識システムでは認識の対象外となる喉頭摘出者音声に着目し，その発話の内容を保持したまま直接，健常者音声に変換する音声変換手法の有効性を，変換ルール獲得実験から考察する．

2. 喉頭摘出者音声の特徴

喉頭摘出者が用いる音声として，食道発声音声および電気発声がある．これらの音声の特徴について考える．

2.1 食道発声音声

食道発声音声の音響的特徴は，健常者との音源メカニズムの違いに起因して，低い基本周波数，非常に大きなピッチと振幅の揺らぎ，大きな雑音，小さな音量などが問題点として挙げられている [1]．また，韻律及びスペクトルの両方において健常者のものとの違いが報告 [?] されている．また，より聞きやすい音声への声質改善の研究 [2, 3] が行われた．

2.2 電気式人工喉頭による発声音声

音源として用いる電気式人工喉頭は基本周波数が固定であるために，生成される音声はイントネーションやアクセントが含まれないことから，話者の意思や感情を的確に伝えることが難しく，不自然なものとなる．そのため，こうした音声の自然性を向上するために，アクセントやイントネーションを付加することのできる電気式人工喉頭が研究，開発 [4, 5] された．

表 1: Julius による単語認識結果

音声	発話数	単語認識率 [%]
健常者音声	80	65.82
食道発声音声	119	29.61
電気発声音声	107	24.32

†北海道大学大学院工学研究科
‡北海学園大学大学院経営学研究科

3. 本研究の目的と基本的な考え方

現在の音声認識技術で喉頭摘出者音声を入力とした場合，正しく認識されない原因には，そうした音声による音響モデル学習が行われていないことがある．表 1 に，健常者音声，食道発声音声，電気発声音声の認識結果を示す．ここで用いた音声データはルール獲得実験に用いたデータと同一であり，その詳細は後述する．

認識結果から，喉頭摘出者音声は健常者音声から大きな違いがあることが分かる．しかしながら，喉頭摘出者音声に特化した音声認識システムの構築は困難である．ところが，こうした音声発話サンプルを大量に録音することは，話者への大きな負担となってしまう．また上述した発声音声の音響分析結果により，音声データの音響的な品質が保証されないことでカテゴリ化された音素の整合性が的確に確保されないことなども，主たる要因と考えられる．

我々は，このように現在の通常の音声認識システムの対象外とされている音声障害者音声を直接利用することを考え，発話データの比較によって発見される音響的な共通部分と差異部分のみに着目し，音声障害者音声の発話をその内容を保持したまま健常者音声に変換する音声変換手法を提案している [6]．本手法の処理過程を図 1 に示す．

我々は発話データを音声特徴の時間変化を表すパラメータに変換し，そのパラメータ間の距離を計算することで発話を差異・共通部分に分離する．この喉頭摘出者音声の差異・共通部分は，同内容の健常者発話の比較から同様に抽出される差異・共通部分と同じ意味を保持していると考えられるため，その組み合わせを変換ルールとして獲得する．このとき，発話データ間比較からのみ変換ルールを獲得するのではなく，帰納的学習を用いて

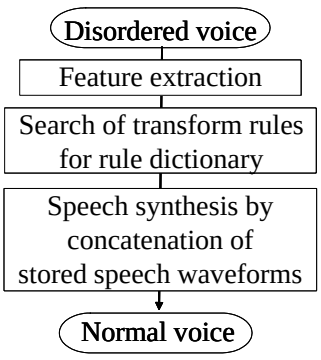


図 1: 提案する音声変換法の処理過程

表 2: 音声処理に用いたパラメータ

分析フレーム長	30msec
フレーム周期	10msec
時間窓	ハミング窓
AR 分析次数	14
ケプストラム係数	20

既に獲得されたルール同士も比較することで，少ない発話データから多くの変換ルールを再帰的に獲得することができる．このような変換ルール獲得学習により獲得された辞書内の多くの変換ルールを，入力される未知の音声障害者音声に適用し，部分的に対応する変換ルールを組み合わせることで入力音声を再現する．このとき採用されたルールが保持している部分的な健常者音声を録音編集方式で音声合成し，発話内容を保持した変換結果を出力する．

提案手法に求められる能力は，意味が伝わるレベルでの音声変換精度で音声変換を実現することである．

4. 音声処理

音声障害者音声に特化した音声分析 [7] の結果から，種々の音響パラメータを用いて，音声障害者音声と健常者音声のクラスタリング [8] により，健常者音声との違いが示されている．しかしながら我々は同時に複数の音響パラメータを用いるのではなく，周波数スペクトル分析のみを用いた比較 [2] の結果に着目した．我々は健常者音声，食道発声音声，電気発声音声を 48kHz，16 ビットで DAT を用いて無教室にて録音し，16kHz にダウンサンプリングした．表 2 で示す音声処理パラメータを健常者音声，喉頭摘出者音声に共通で用いた．本論文では音声特徴として LPC ケプストラム係数を用いた．

5. ルール獲得

ベクトルに変換された発話実例組を健常者音声側及び喉頭摘出者音声側でそれぞれ比較することで，差異・共通部分を抽出し変換ルールを獲得する．我々は発話速度差を吸収するために，端点自由 DP 法 [9] で得られるパスと類似した結果を得る手法 [10] を用いた．

獲得された差異・共通部分から作られる変換ルールは，その差異もしくは共通部分の始点および終点であるか，というルールの種類，対応する音声発話の 3 つの情報を持つ．しかし，もし健常者音声側および喉頭摘出者音声側でルールの種類が異なる場合，その発話比較においては正しく対応が決定されないため，変換ルールは獲得しない．

6. ルール獲得実験

音響的な差異・共通部分のみに着目することで，変換に利用できる適切な対応の取れるルールが獲得できるかどうか，食道発声音声と健常者音声，電気発声音声と健常者音声の 2 種類を対象として実験を行った．入力データは 3 桁の数字 27 種類，簡単な文 13 種類を各 2 回発声したものを用いた．ここでは，抽出される差異・共通部分の時間的な揺らぎを考慮するために，健常者音声側で獲得される差異・共通部分に前後 180ms および 120ms の許容範囲を導入し，その範囲内に対応が一意に決定できる部分が喉頭摘出者音声側に抽出されているかを評価した．どちらの実験に対しても共通のパラメータを用い，音声の種類に特化した処理やパラメータは導入していない．

表 3: 獲得ルール数の比較

音声データ	データ数	獲得ルール数
電気発声－健常者音声	80	2,284
食道発声－健常者音声	80	1,378

表 4: 獲得部分の対応の比較

音声データ	180ms 幅	120ms 幅
電気発声－健常者音声	1,665[73.9%]	1,315[57.6%]
食道発声－健常者音声	1,055[76.6%]	846[61.4%]

表 3，表 4 に実験結果を示す．結果から正しい対応を持つと考えられる変換ルールを多数獲得できたため，こうしたルールを組み合わせることで正しい音声変換が可能であると考えられる．食道発声音声と健常者音声間で獲得されたルール数は，電気発声を用いた場合と比べ少ない．これは食道発声音声は発声の際に息継ぎをする必要があるため，健常者音声と時間軸上で比較した場合，本実験で用意した許容範囲以上の位置で差異・共通部分が出現するためであると考えられる．

7. まとめ

喉頭摘出者の音声を健常者音声に変換するために必要な変換ルールの獲得実験を食道発声音声および電気発声音声について行い，獲得されるルールの有効性について考察した．今後は実際に音声合成を行い，聴取実験により評価を行う予定である．

参考文献

[1] 松井，野口，“食道発声音声の音源強調方式の検討，”音講論，2-6-14，pp.423-424(1996-9)

[2] 陸，中村，鹿野，“食道発声音声の改善における一考察，”信学技報 SP98-151，pp.41-46(1999-3)

[3] 秋元，大塚，粕谷，“食道発声音声の声質変換に関する検討，”音講論，2-7-9，pp.259-260(2002-3)

[4] 菊地，粕谷，“F0 制御機能を有する電気喉頭の試作，”音講論，2-10-5，pp.295-296(2002-9)

[5] 上見，伊福部，高橋，松島，“ピッチ周波数制御型電気式人口咽頭の提案とその評価，”信学論 D-II，vol.J78-D-II，No. 3，pp.571-578，1995

[6] 村上，荒木，広重，栃内，“音声障害者音声の健常者音声への帰納的学習を用いた音声変換手法の提案と基礎実験，”情報処理学会全国大会

[7] 加藤，“音声障害者音声の音響的特徴，”日本音響学会講演論文集，pp.309-310(2000-3)

[8] Daniel Callan, Ray D. Kent, Nelson Roy and Stephen M. Tasko, “Self-Organizing Map for the Classification of Normal and Disordered Female Voices,” Journal of Speech, Language, and Hearing Research, Vol.42, pp355-366, April, 1999

[9] H.F. Silverman and D.P. Morgan, “The application of dynamic programming to connected speech recognition,” IEEE, ASSP Magazine, pp.6–25, 1990.

[10] 村上, 広重, 荒木, 栃内:”文字表現を介さない音声機械翻訳システムの構想と基礎実験”，音講論，pp.391-392(2001-10)