電子メイルを対象とした帰納的学習を用いた Subject の自動生成手法における品詞情報の利用について

Use of a Part of Speech on an Automatic Subject Extraction Method for E-mail Using Inductive Learning

康　錦紅 †　　荒木　健治 †　　栃内　香次 ‡
Kang Jinhong　　Kenji Araki　　Koji Tochinai

† 北海道大学大学院工学研究科電子情報工学専攻　　‡ 北海学園大学大学院経営学研究科
† Hokkaido University　　‡ Hokkai-Gakuen University

1．はじめに

近年，インターネットの普及に伴い，電子メイルを使ってコミュニケーションを行う人が増えている．そこで，我々は電子メイルにおける Subject の自動生成に関する研究を行ってきた[1][2]．　本手法では，Subject の生成を行うために，電子メイルの本文から重要文として一文を抽出し，抽出された重要文とユーザが以前に書いたメイルの重要文の類似度を計算し，最も類似度の高い重要文に基づいて Subject を生成する．Subject 決定ルール辞書にはユーザが以前に書いたメイルの重要文と Subject 及び Subject 位置情報が組になってルールとして登録されている.ここで，重要文とは，サブジェクトを含む文である．類似度の計算式は，以下の式１によりで計算される．

$$\text{類似度} = \frac{\text{共通の単語数}}{\text{入力文の単語数} \times \text{ルール中重要文の単語数}} \quad (1)$$

メイル 100 通における予備実験を行った結果，重要文抽出の正解率は，92%であるが，重要文からサブジェクト生成をした結果，正解率が 43%であった．誤りにおける 86(=49/57)%が正しい重要文として抽出されているにもかかわらず，不正解となった．本稿では，重要文は正しいが，サブジェクト生成が誤る場合に焦点を当てる.この誤りの原因は類似度を計算する場合，頻繁に出現する助詞なども名詞のようなサブジェクト生成における重要な単語と同様に扱っているためと考えられる．例えば，以下のような例が存在した.

例：重要文：以下の日程で卒論の発表会を行います.
　　出力：卒論の発表
　　正解：卒論発表会

この例に示すように重要文中の名詞以外の品詞が Subject の生成に影響を与える．ここで,今回は品詞情報を有効に利用することを考え，品詞情報を利用して類似度の計算を行う手法を提案する．さらに類似度の情報を利用しない場合との比較実験を行った．本稿では,その実験結果と考察を述べる.

2. 処理過程

図 1 に本手法の処理過程を示す.

本手法では,Subject の決定は抽出された重要文と Subject 決定ルール辞書中の重要文との類似度を計算し,類似度がもっと高い重要文の Subject を入力された重要文の Subject として出力する.Subject が入力文に含まれた場合はそのまま Subject として出力するが,入力文に含まれていない場合,同じ位置の語を Subject として出力する.

3. 比較実験

ここでは，品詞情報を利用した場合と利用しない場合の比較実験を行う.実験データとして第一著者の 300 通のメイルを利用する．表１に実験結果を示す.

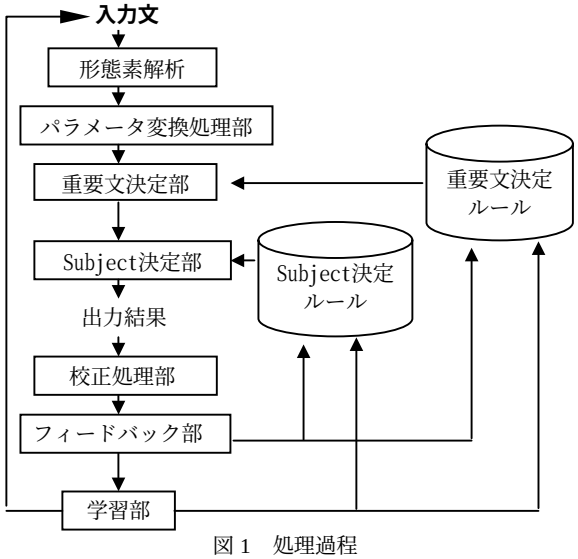

図 1　処理過程

表 1：比較実験結果

	メイル数	正しい重要文数	正しい Subject 数	誤り結果数	結果なし
手法１	300	269	127	119	23
正解率		89.7%	42.3%	39.7%	7.7%
手法２	300	269	166	92	11
正解率		89.7%	55.3%	30.7%	3.7%

ここで,手法 1 は品詞情報を利用しない場合で,手法 2 は品詞情報を利用した場合である.品詞情報の利用とは,類似度を計算するとき,名詞だけの品詞を利用したものである.比較実験の結果により,手法 2 の場合,手法１より正解率が 13 ポイント上昇した.

4.　まとめ

今回は,重要文の全ての単語を用いて類似度を計算する手法と名詞だけでの単語を利用して類似度を計算して Subject を生成する手法の比較実験を行った.その結果名詞だけの単語を利用して類似度を計算する手法の正解率が 13 ポイント上昇した.今後は名詞以外の品詞情報も利用し，重要文を用いない手法について検討を行う予定である.

参考文献:

1. 荒木健治，“帰納的学習を用いた自然言語処理の有効性について”，信学技報、TL99-41、PP.33-40，2000
2. 康　錦紅，“帰納的学習を用いた電子メイルにおける Subject の自動生成手法の提案”，情報処理学会第 65 回全国大会公演論文集（2）pp.2-17，2003