研究論文

# アイヌ語—日本語間対訳語の自動獲得における再帰チェーンリンク型学習の有効性について

加藤大樹*・越前谷博*・荒木健治**
桃内佳雄*・栃内香次***

# Validity of the Recursive Chain-link-type Learning in Automatic Acquisition of the Bilingual Words for Ainu-to-Japanese

Daiki Kato*, Hiroshi Echizen-ya*, Kenji Araki**, Yoshio Momouchi* and Koji Tochinai***

## 概　要

我々は，アイヌ語—日本語間において，機械翻訳に有効となる電子的な対訳辞書を構築することを目的とした研究を行っている．本論文では，再帰チェーンリンク型学習を用いたアイヌ語—日本語間対訳語の自動獲得手法を提案する．本手法はアイヌ語の解析的知識を必要とすることなく少量の対訳語をもとに学習機能に基づきアイヌ語文と日本語文の対訳コーパスから対訳語を効率良く獲得することができる．本手法による対訳語獲得システムとTranslation Template Learnerによる対訳語獲得システムの比較実験において，本手法は正獲得率で13.9ポイント高い結果を示し，本手法の有効性が確認された．

## 1．はじめに

近年，インターネットの普及により母国語以外の多くの言語に触れる機会が増え，その結果，さまざまな言語間の機械翻訳システムに対するニーズが高まっている．機械翻訳システムには対訳辞書が不可欠であるが，現時点において電子的に整備されていない言語が多く存在する．アイヌ語は日本人にとって身近な言語であるが，十分に電子的に整備されていない言語の一つである．電子化された対訳辞書を構築する際，それらを人手で作成するには膨大な時間と労力を必要とする．そこで，対訳語の自動獲得システムの構築を目指す．対訳語の自動獲得において，対訳コーパスもしくは対応付けされていないコーパスから対訳語を獲得する研究は盛んに行われている．それらは利用する知識源の観点から，言語知識を利用する手法[1)2)]と統計的な手法[3)4)]に大きく分類される．言語知識を利用する手法では，基本的な対訳辞書を始めとして解析的な知識の使用を前提としている．そのため，原言語，目的言語，共に形態素情報や構文解析情報，文法規則などの十分な解析的知識を必要とする．しかし，解析的知識を十分に得るために不可欠な解析ツールが存在しない言語も多く，そのような言語を対象とした場合の対訳語獲得は難しい．統計的な手法では，言語現象そのものを翻訳規則として用いるため，言語知識を利用する手法ほど多くの解析的知識は必要としない．しかし，形態素情報などの解析的知識が付与されたコーパスを用いることを前提としているのが一般的である．更に，統計処理を行うためには膨大な量のコーパスを必要とする．一方，解析的な知識を用いることなく対訳語を獲得する手法として，学習による手法[5)6)]が考えられる．しかし，従来の学習方法では，表層レベルで類似した対訳文対が必要になるという問題点がある．

* 北海学園大学大学院工学研究科電子情報工学専攻（現在：㈱NECマイクロシステム）
Graduate School of Engineering (Electronics and Information Eng.), Hokkai-Gakuen University (Present: NEC Micro Systems)
** 北海道大学大学院工学研究科電子情報工学専攻
Graduate School of Engineering (Electronics and Information Eng.), Hokkaido University
*** 北海学園大学大学院経営学研究科経営学専攻
Graduate School of Business Administration (Business Administration), Hokkai-Gakuen University

アイヌ語と日本語間の対訳語を自動獲得する際，アイヌ語において解析ツールによる解析的知識の付与が得られないため，言語知識を利用する手法および統計的な手法ではなく，学習アルゴリズムに基づく手法が有効と考えられる．また，大量の類似したアイヌ語—日本語の対訳文対を得ることが困難であるため，従来の学習による手法は不十分である．そこで，大量の対訳文対を要求しない学習による手法が求められる．我々はアイヌ語の解析的知識を必要とすることなく少量の対訳語をもとに学習機能に基づきアイヌ語文と日本語文の対訳コーパスから対訳語を効率良く獲得することができる再帰チェーンリンク型学習[10)11)]を用いたアイヌ語—日本語間対訳語の自動獲得手法を提案する．再帰チェーンリンク型学習では，獲得された対訳語に含まれている対訳文の抽出部分の情報に基づき，対訳文に対する新たな抽出部分の範囲情報である切り離しテンプレートを取得する．その結果，対訳語と切り離しテンプレートの獲得の連鎖が起こる．本手法では，日本語文にのみ解析知識として形態素解析ツール茶筅[7)]による品詞情報を付与する．この品詞情報は日本語文を分かち書きされた文にするため，更に，誤った対訳語の獲得を防ぐために用いる．今回は，語形変化が少なく実験の第一段階として適していることから，獲得の対象を名詞対訳語としている．

## 2．再帰チェーンリンク型学習

再帰チェーンリンク型学習[10)11)]とは，ある対訳文内の対応関係に基づき，システムがそれをもとに他の対訳文の対応関係を自動的に決定する学習アルゴリズムである．したがって，様々な対訳文を用いることで対応関係を次々と連鎖的に決定することができる．図1に再帰チェーンリンク型学習の概要を示す．

図1において，ブラケット内のセミコロンの左辺は原言語，右辺は目的言語をそれぞれ表す．対訳語1より，原言語〝$\xi$〟と目的言語〝D〟が共に文内に存在する対訳文1において，〝$\xi$〟と〝D〟をそれぞれ抽出する．抽出された部分を変数〝@〟に置き換え，それぞれの変数に隣接する語〝$\theta$〟と〝$\varepsilon$〟，〝A〟と〝E〟を切り出し，それを切り離しテンプレート1（$\theta$@$\varepsilon$；A@E）とする．この切り離しテンプレート1より，原言語において〝$\theta$〟と〝$\varepsilon$〟，目的言語において〝A〟と〝E〟がこの順序で文内に存在する対訳文2において，原言語文の中で〝$\theta$〟の右側から〝$\varepsilon$〟の左側までの部分〝$\omega$〟と，目的言語文の中で〝A〟の右側から〝E〟の左側までの部分〝M〟を抽出する．そして，抽出された〝$\omega$〟と〝M〟の組を対訳語2（$\omega$；M）とする．更に対訳語2を適用可能な対訳文に適用させることで新たな対訳語を獲得することができる．

このように，再帰チェーンリンク型学習では対訳語と，切り離しテンプレートの獲得の連鎖が起こることにより，スパースネスな対訳文からであっても次々と効率良く対訳語を獲得することが可能となる．

（対訳語1）　［$\xi$；D］
（対訳文1）　［$\alpha\gamma\theta\xi\varepsilon$；ADEGB］
（切り離しテンプレート1）　［$\theta$@$\varepsilon$；A@E］
（対訳文2）　［$\delta\beta\theta\omega\varepsilon\sigma$；FHAMEK］
（対訳語2）　［$\omega$；M］

図1　再帰チェーンリンク型学習の概要

## 3．品詞情報の導入

### 3.1　品詞情報の利用

再帰チェーンリンク型学習は，解析的な知識に依存することなく対訳語を獲得することが可能である．しかし，それらが全て正しいとは限らず，誤った対訳語も獲得される．そこで，誤った対訳語の獲得を減少させるための一つの方法として，品詞情報を利用するしくみについて考える．本論文では，日本語文に対してのみ形態素解析ツール茶筅[7)]によって形態素解析を行う．

### 3.2　字面と品詞情報の一致

品詞情報を用いることにより，同一字面でも品詞が異なる語を認識することができる．例えば，「学校から帰る」という文の〝から〟と，「卵のから」という文の〝から〟は品詞が異なる．前者は助詞であるのに対し，後者は名詞である．このような場合は字面では同じでも違う語として扱う．

### 3.3　獲得対訳語の選別

今回，システムの獲得の対象となる対訳語は名詞対訳語としている．そのため，名詞対訳語の選別を行う．アイヌ語名詞の訳となりえる名詞句を格助詞，並立助詞，係助詞，接続詞，副詞を含まず，かつ，文頭が接尾語ではない名詞句とする．このような品詞情報により獲得する対訳語の選別を行う仕組みをシステムに組み込む．

## 4．本手法の処理過程

### 4.1　本手法の処理概要

再帰チェーンリンク型学習を用いることにより，初期辞書として与えられた少量の対訳語をもとに，アイヌ語文と日本語文の対による対訳コーパスからアイヌ語の解析的知識を必要とすることなく名詞対訳語を連鎖的に獲得する．本手法の処理過程を図2に示す．

### 4.2　対訳語に基づく切り離しテンプレートの獲得

切り離しテンプレートは，対訳語の抽出情報を有する．以下に切り離しテンプレート獲得の処理過程を示す．

(1)　対訳文のアイヌ語文と日本語文に対し，アイヌ語部分と日本語部分が共に含まれている対訳語を選択する．

(2)　対訳文のアイヌ語文と日本語文のそれぞれにおいて，対訳語が存在する部分を変数に置き換える．

(3)　変数およびその隣接する語を抽出する．隣接する語の存在パターンは前後に隣接する語がある場合，前のみに隣接する語がある場合，後ろのみに隣接する語がある場合の3通りがある．

(4)　抽出されたアイヌ語と日本語の変数に隣接する語の組を切り離しテンプレートとして獲得する．

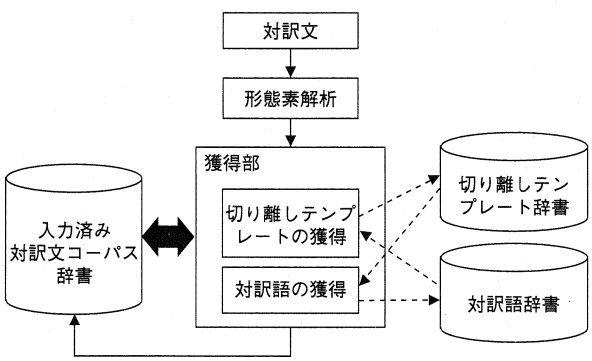



図2　再帰チェーンリンク型学習の概要

### 4.3　切り離しテンプレートに基づく対訳語の獲得

対訳語は，切り離しテンプレートの抽出情報を有する．以下に切り離しテンプレート獲得の処理過程を示す．

(1)　対訳文のアイヌ語文と日本語文に対し，アイヌ語部分の変数に隣接する語と日本語部分の変数に隣接する語が共に存在する切り離しテンプレートを選択する．

(2)　対訳文のアイヌ語と日本語のそれぞれにおいて，変数の前後に隣接する語がある場合，変数の前に隣接する語の右側から変数の後ろに隣接する語の左側までを抽出する．変数の前のみに隣接する語がある場合，変数に隣接する語の右側から文末までを抽出する．変数の後ろのみに隣接する語がある場合，文頭から変数に隣接する語の左側までを抽出する．

(3)　アイヌ語と日本語の抽出された語を対訳語として獲得する．

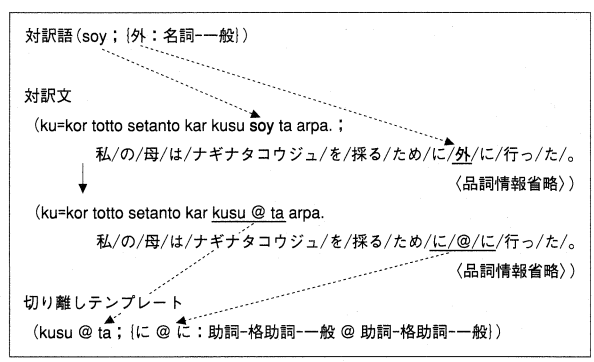



図3　切り離しテンプレート獲得の具体例

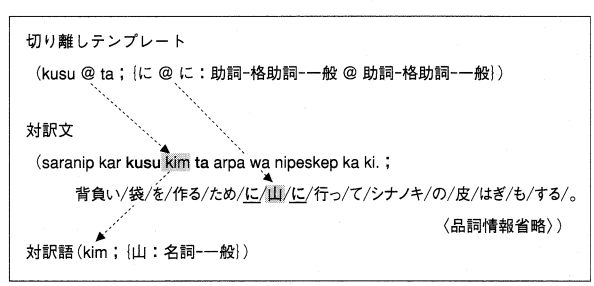



図4　対訳語獲得の具体例

## 5．性能評価実験

### 5.1 実験概要

この実験では，対訳コーパスから学習に基づき翻訳知識を獲得する手法として，Güvenir らによって提案されている Translation Template Lear-ner (TTL)[5] による対訳語獲得手法との比較実験を通して本手法の有効性を確認する．両手法において，少量の対訳辞書をもとにシステムがどの程度対訳語を獲得できるかを調査した．

### 5.2 Translation Template Learner (TTL)

TTL は，表層レベルで類似した2つの対訳文から共通部分と差異部分に基づき翻訳のためのルールを獲得する学習手法である．TTL では差異部分が一意に決定できる場合，原言語と目的言語の部分的な対応関係が得られたとして対訳語を獲得する．

(1) 差異部分が1箇所の場合の対訳語獲得

2つの対訳文を比較し，原言語部分，目的言語部分の双方において，1箇所のみ差異部分が存在する場合，その差異部分を抽出する．

例（対訳文1） [$\alpha\gamma\theta\xi\varepsilon$；ADEGB]
（対訳文2） [$\alpha\gamma\theta\omega\varepsilon$；AMEGB]

対訳文1と対訳文2において，差異部分となるのは原言語文と目的言語文共に1箇所のみである．この2つの対訳文から対訳語($\xi$；D)と($\omega$；M) を獲得する．

(2) 差異部分が複数存在する場合の対訳語獲得

差異部分が複数存在する場合は，既に獲得された対訳語を差異部分に当てはめることにより，未知の部分を1箇所に決定できる場合のみ対訳語を獲得する．

例（対訳語1） [$\alpha$；B]
（対訳語2） [$\mu$；O]
（対訳文1） [$\alpha\gamma\theta\xi\varepsilon$；ADEGB]
（対訳文2） [$\mu\gamma\theta\omega\varepsilon$；AMEGO]

対訳文1と対訳文2において，差異部分となるのは原言語文と目的言語文共に2箇所存在する．ここで，対訳語1として（$\alpha$；B），また，対訳語2として（$\mu$；O）が既に獲得済みである場合，未対応の差異部分が一意に決定できるため，対訳語（$\xi$；D）と（$\omega$；M）が新たに獲得される．

### 5.3 実験データ

対訳コーパスは，文献「アイヌの知恵・ウパシクマ1」[12] と文献「アイヌの知恵・ウパシクマ2」[13] を用いて作成した．その際，日本語文については，単語直接翻訳に基づき人手で訳文を作成した．

コーパスの詳細

| | |
|---|---|
| 対訳文の数 | 263文 |
| 1文あたりの平均語数 | 11.9語 |
| 重複無しの名詞数 | 372単語 |
| 名詞の平均出現回数 | 2.4回 |

### 5.4 初期辞書

ウパシクマ1とウパシクマ2は二つで一つの物語を構成しており，全10の章に分けられる．そのうち，初期辞書として第1章に出現する全ての名詞34個の対訳語を与えた．

## 6．実験結果

システムの評価は正獲得率と精度の2つで行った．

正獲得率＝正獲得数/名詞の総数×100
精度　　＝正獲得数/出力数×100

・獲得率

| | 名詞の総数 | 正獲得数 | 獲得率 |
|---|---|---|---|
| TTL | 338 | 0 | 0.0% |
| 本手法 | 338 | 47 | 13.9% |

・精度

| | 出力数 | 正獲得数 | 精　度 |
|---|---|---|---|
| TTL | 0 | 0 | |
| 本手法 | 88 | 47 | 53.4% |

## 7．考　察

### 7.1　再帰チェーンリンク型学習の学習能力について

対訳文「aep ka amip ka cikuni poka an yakun pirka sekor k＝unuhu en＝ye.；食べ物／も／着物／も／まき／だけ／でも／ある／なら／ば／よい／と／私／の／母／は／言う／。」から対訳語(amip；{着物：名詞－一般})を獲得する場合を例に本手法とTTLの学習能力について考察する．TTLの場合，対訳語を獲得するには，アイヌ語文の〝amip〟と日本語文の〝着物〟以外の全ての語が一致する対訳文が存在しなければならない．しかし，実際にはコーパス中にそのような対訳文は存在しないため，対訳語(amip；{着物：名詞－一般})は獲得できない．一方，再帰チェーンリンク型学習の場合，切り離しテンプレート(ka @ ka；{も @ も：助詞－係助詞 @ 助詞－係助詞})が獲得されていればよい．切り離しテンプレートは学習済みであったため，本手法では対訳語を獲得することができた．このように一文辺りの平均語数が多く，類似した文を多く含む対訳コーパスを大量に得ることが困難であるアイヌ語—日本語間の対訳語の獲得において，高い類似関係にある文を含まない対訳コーパスからでも対訳語を獲得できる再帰チェーンリンク型学習は有効な手法である．

### 7.2　再帰チェーンリンク型学習における名詞対訳語の出現回数と獲得数

| 出現回数 | 1回 | 2回 | 3回 | 4回以上 |
|---|---|---|---|---|
| 個数(個) | 19 | 8 | 3 | 17 |

本手法において，システムが獲得した対訳語が対訳コーパス内で何回出現したかを調査したところ，1回または2回しか出現していない対訳語の割合は，獲得した全対訳語の57.4%となった．これは，正獲得においては，少ない出現回数でも対訳語を獲得できるということを意味する．アイヌ語—日本語の対訳コーパスは，英語—日本語の対訳コーパスほど多くのデータが得られることを期待できず，また，用意した対訳コーパスに必ずしも同じ単語が何度も出現するとも限らない．実際，本実験で用いた対訳コーパスにおいて，各名詞単語の平均出現回数は2.4回であった．しかし，このような同じ単語の出現が何度も望めない状態からでも，本手法は対訳語を獲得できることが確認できた．

### 7.3　再帰チェーンリンク型学習における獲得数とコーパス量の相関

図5は，対訳文の20文入力ごとの獲得数と，システムがそれまでに獲得した対訳語の総獲得数を示している．グラフより，入力文数が増えるにつれ，総獲得数だけではなく20文入力ごとの獲得数も増加している．本手法ではコーパス量を増やしていくことにより，対訳語を獲得するために必要な知識である切り離しテンプレートと対訳語が蓄積されていく．よって，入力文数が増えるにつれ獲得能力は高くなる．また，新しく獲得された対訳語または切り離しテンプレートにより，既に入力済みの対訳文から対訳語および切り離しテンプレートの獲得が可能である．そのため，獲得の連鎖は対訳文が増えることでより活性化することが期待できる．このことから，入力するコーパスの量が増えるにしたがって獲得量も増えていくと考えられる．今後対訳コーパスを追加し，十分に学習が進むことにより，さらなる対訳語の獲得効率の向上が期待できる．なお，コーパスの増加に伴い処理時間の増加が考えられるが，今回の実験での処理時間はcpu 1.7 GHz，メモリ512 MBのマシンにおいて1分程度である．

### 7.4　再帰チェーンリンク型学習における品詞情報による獲得精度の向上

| | 出力数 | 正獲得数 | 精度 |
|---|---|---|---|
| 品詞情報未使用 | 114 | 48 | 42.1% |
| 品詞情報使用 | 88 | 47 | 53.4% |

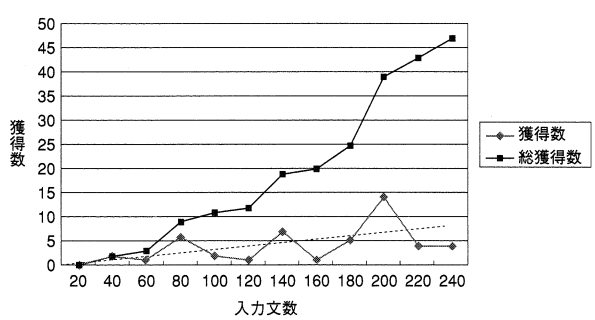



図5　コーパス量と獲得数の変化

| | | | |
|---|---|---|---|
| 差 | −26 | − 1 | +11.3 |

品詞情報を用いることで獲得できなくなった対訳語を調査したところ，(cipoyep；{混ぜ　に：動詞－自立　助詞－格助詞－一般})であった．これは，〝混ぜに〞の形態素解析結果が「名詞－一般」となるべきところを，「動詞－自立　助詞－格助詞－一般」と誤った出力がされてしまったため，格助詞を含む語として獲得されなくなってしまった．このような形態素解析結果の誤りは少なく，解析結果が正しく出力された場合は，正しく獲得される対訳語に変化はなく，誤った対訳語のみを排除できるため，品詞情報の利用が精度の向上に有効であることを確認した．

## 7.5　抽出部分が複数存在する場合

本手法における，対訳語獲得の精度を向上させるための一つの方法として，一つのアイヌ語に対して日本語の抽出部分が複数存在する場合において，アイヌ語と日本語の語順は似ていることから，アイヌ語の抽出部分の位置と日本語の抽出部分の位置が同じ場合のみを対訳語とするヒューリスティックの適用が考えられる．対訳文（orowa karns ka korkoni ka satcep ka poro su or omare wa supa.；それからキノコもフキも干し魚も大きな鍋の中に入れて煮る.）から切り離しテンプレート（ka ＠ ka；{も ＠ も：助詞－係助詞 ＠ 助詞－係助詞}）に基づき対訳語を獲得する場合，アイヌ語文において〝ka〞に挟まれる部分は〝korkoni〞と〝satcep〞の2箇所存在する．また，日本語文において〝も〞に挟まれる部分は〝フキ〞と〝干し魚〞の2箇所である．このような場合，〝korkoni〞と対応する訳が〝フキ〞なのか〝干し魚〞なのか，同様に，〝satcep〞と対応する訳が〝フキ〞なのか〝干し魚〞なのかが判断できないため，誤った対訳語も獲得する．このような場合，アイヌ語の切り離し部分の位置と日本語の切り離し部分の位置が同じもの同士を対訳語とするヒューリスティックを適用することにより，正獲得は変わらず，対訳語獲得の精度は60.3%となり6.9ポイント向上する．

## 8．おわりに

本論文では，アイヌ語―日本語対訳コーパスから，アイヌ語において解析ツールによる解析的知識の付与が得られない状況において，システムが自動的に対訳語を効率良く獲得できる再帰チェーンリンク型学習を用いた対訳語獲得手法を適用した．TTLとの比較実験の結果，TTLでは全く獲得できなかった対訳コーパスから正獲得率において13.9%の対訳語を獲得するという結果を示し，本手法の有効性が確認された．また，本手法は正獲得において少ない出現回数からでも対訳語を獲得できるといった高い学習能力を持つことを確認し，対訳コーパスの量を多く望めないアイヌ語の対訳語の獲得において有効であることを確認した．また，品詞情報を用いることにより，品詞情報を用いない場合と比べ11.3ポイントの獲得精度の向上を確認した．今後の課題として，頻度情報を用いた制約による精度の向上．また，対訳語獲得のために十分な学習をするために必要なコーパス量の調査．名詞以外の対訳語の獲得についても重要な課題である．

## 【参考文献】


1）北村美穂子，松本裕治：対訳コーパスを利用した対訳表現の自動抽出，情報処理学会論文誌，Vol.38，No.4，pp 727-pp 736（1997）．

2）田中貴秋，松尾義博：対訳関係のないコーパスからの複合名詞対訳表現の獲得，電子情報通信学会論文誌，Vol.J 84-D-ll，No.12，pp 2605-pp 2614（2001）．

3）Masahiko Haruno, Satoru Ikehara, Takefumi Yamazaki: Learning Bilingual Collocations by Word-Level Sorting, Proceedings of the 16th international conference on computational linguistics, pp525-pp530 (1996).

4）Reinhard Rapp: Identifying Word Translations in Non-Parallel Texts, 33rd Annual Meeting of Association for Computasional Linguistics, pp320-pp322 (1995).

5）H. A. Güvenir and I. Cicekli: Learning Translation Templates from examplates, Information Systems, vol. 23, no. 6, pp353-pp363 (1998).

6）K. McTait: Linguistic knowledge and complexity in an EBMT system based on translation patterns, Proceedings or the Workshop on EBMT, Machine Translation Summit VIII, pp263-pp34, Santiago de Compostela, Spain, 2001.

7）日本語形態素解析システム「茶筅(Chasen) for Windows」(2000)．

8）㈱北海道ウタリ協会：アコロイタク AKORITAK ア

イヌ語テキスト1，(1994)．
9）田村すず子：アイヌ語沙流方言辞典，草風館，1996．
10）越前谷博，荒木健治，桃内佳雄，栃内香次：翻訳例に基づく再帰チェーンリンク型学習による機械翻訳手法，電子情報通信学会論文誌，Vol. J 85-D-ll，No.12，pp 1840-pp 1852 (2002)．
11）Hiroshi Echizen-ya, Kenji Araki, Yoshio Momouchi, and Koji Tochinai: Study of Practical Effectiveness for Machine Translation Using Recursive Chain-link-type Learning, Proceedings of the 19th international conference on computational linguistics, pp246-252 (2002).
12）中本ムツ子，片山龍峯：アイヌの知恵・ウパシクマ1，片山言語文化研究所，新日本教育図書株式会社(1999)．
13）中本ムツ子，片山龍峯：アイヌの知恵・ウパシクマ2，片山言語文化研究所，新日本教育図書株式会社(2002)．