原著論文

Vol.7 No.1, 2005

N-gramを用いた再帰差異共通部分抽出法によるユーザの行動予測手法

徐 金安*1　伊藤 敏彦*1　荒木 健治*1

Action Prediction Method Using Recursive Different and Common Parts Extraction Method with N-gram

Jin'an Xu*1　Toshihiko Itoh*1　Kenji Araki*1

Abstract – **This paper describes a basic idea how to realize an intelligent learning room system. Such a system needs to have dynamic adaptive capability for each user. We have proposed a method to predict user action using Recursive Different and Common Part Extraction(RDCPE) Method with N-gram. The system based on our proposed method is able to acquire rules automatically from data pairs through RDCPE. As unified with N-gram, the system demonstrates a high predictive accuracy. However,the acquired rules express the user's habits and preferences, the system is possible to adapt dynamically to each user. The user need to proofread the errors in prediction results. Therefore the prediction ability improves. As a result, the number of errors decreases. This paper unifies N-gram and RDCPE to develop a Point-Pass Based Prediction system. The system was found to have good accuracy of which the highest prediction accuracy was about 89.3(%). The system was improved that it has high dynamic adaptive ability.**

Keywords : **Recursive Different and Common Part Extraction Method, N-gram, Action Prediction, Dynamic Aadaptation, Point-Pass Based Prediction**

1. はじめに

近年，高齢化社会が進み, お年寄りや体の不自由の方にとっては, 介護を行うシステムの必要性が高まってきている．一方，情報技術の発達に伴い，人工物と人との共生的な関係形成やコミュニケーションのための基盤技術に関する研究も盛んである [1,2,3,4,5]．中でも，人間の知能獲得システム，人間の情動，感性，意思決定支援，ヒューマンインタフェースそして人間らしい知的制御システムなども，実践的な分野への応用が期待されている．２１世紀の時代には，人間とコンピュータがさまざまな環境のもとに，調和して進歩していくことが予想されるため，次世代の知能獲得システムが人間の生活パターンにあわせて, その人間の生活の習慣や嗜好などを学習し, 人間と共生していくようなシステムの実現も夢ではない．

このような未来の社会における知的システムを実現するために，人間にやさしい, 柔軟なヒューマンインタフェースを実現する方法やメカニズムなどに対して，数多くの研究者たちが異なる分野で研究を行なってきた．例えば, 情報提示学習による状況適応型システム [6] や意図理解支援インタフェース [7], そして [8,9] のような実用性の高い支援システムなどがある．

私たちの生活の中では, 暗黙のうちに生活パターンが社会的なルールや個人的な習慣などに従って繰り返されている．例えば,「車は左側に通行である」は日本の交通ルールとして知られている. また「土曜日の朝9時から魚釣りで海に行く」のは, 個人的なルールであり, 他者には, 通用されないものである．このような個人的な習慣や嗜好などが, ユーザごとに異なっているため, それぞれのユーザに対して適用可能なよりよい予測精度と動的適応能力を持つシステムの実現方法が課題となってきた．

本論文では, 人間の生活パターンや嗜好などを自動的に獲得できるいわゆる「学習する部屋」に関する研究を通じて，そのメカニズムと工学的な実現方法や原理について述べる．

このような高い汎用性を持つシステムの構築において, 最も重要なことはユーザの行動や嗜好などをどのように予測していくのかという点である．行動や嗜好はユーザごとに異なるため，多量なデータの収集や前述のような予測するためのルールなどを事前にシステムに与えておくことは困難である．それゆえ，我々は各々のユーザに動的に適応可能な行動予測手法の開発を目指し，N-gram を用いた再帰差異共通部分抽出法によるユーザの行動予測手法を提案している．再帰差異共通部分抽出法とは，Araki らによって提案された

*1: 北海道大学大学院　情報科学研究科
*1: Graduate School of Information Science and Technology, Hokkaido University

もので，一種の帰納的学習 (IL)[10,22] といったものである．本論文における行動の定義は，「学習する部屋」を構成しているテレビや電灯などのような人間の行動により状態を変化させることが可能な要素の状態がユーザの動作によって変化した時に、その要素の状態に示されているユーザの動作である．本研究の目標は「学習する部屋」の問題に限られたものではなく，行動予測についてのより一般的な学習の枠組みを作り上げることである．

一般的な行動予測システムにおいては，統計的なアプローチや解析的なアプローチによるものに分けられる．統計的なアプローチは，データを解析する方法によって Point-Based Prediction System [11][12] と Pass-Based Prediction System [13][14] に分類される．Point-Based Prediction System は，観測されたデータの Frequency Measure のような少ない相関情報を用いることにより，予測を行い，その予測精度が約 30～50%となっている．

これに対して，時系列データをシーケンスとし,N-gram を利用した Pass-Based Prediction System が提案されている．この手法では，十分な学習データが与えられた場合，その予測精度は約 70%前後となっている．しかし，N-gram を用いる場合，高い精度を得るために膨大なデータが必要であり，システムの動的適応性が低いという問題点がある．また，データが少ない時に，予測された確率の信頼性が低いという弱点も存在する．

解析的なアプローチ [15] においては，システムに与えられたルールが適用された場合には，高い確率で予測できるが，人手により矛盾なく与えられる規則には限界があり，各々のユーザに対し，全てのルールを用意するには多くの労力がかかる．

一方，人間の行動がその人の嗜好や習慣を反映しているだけではなく，ある環境や条件においては，多くのユーザの行動が一意的であるという傾向も存在する．したがって，これらの行動の予測は局所的な面からも着手しなければならない．

これらの問題を根本的に解決するためには，システムが与えられたデータから自分自身で予測ルールを獲得していく方法が考えられる．これを実現するために我々は，実例のみから学習を行うことが可能である差異共通部分を再帰的に抽出アルゴリズムといった帰納的学習によるユーザの行動予測手法を提案し，種々の応用システムへの適用を行ってきた．また，再帰差異共通部分抽出法による自然言語処理の有効性はすでに証明されている [16,17,18,19]．この手法を用いて，システムが与えられたデータから，差異部分，共通部分を再帰的に抽出することにより予測ルールを獲得する．

本手法を用いて，人間の行動や状況などを反映するデータから，その人間の習慣や嗜好などをルールとして獲得し，その人間に適合した適切な振舞いをすることができる．予測を行う際に，特定の人間に特化した情報は，自動的にその意図を認識する手助けになり，提示すべき情報の選択や，インタラクションを開始するきっかけを決めるのに役立つと考えられる．

また，情報理論や統計学などでは，以前からデータから因果関係を抽出し，データに含まれる情報の量を測るための数理的な手法を蓄積してきたが [20]，それは，大規模なデータから因果関係を抽出するというものである．本論文では，ユーザの行動を予測するために，一意性を反映する局所的な予測には，再帰差異共通部分抽出法を利用し，規則性を反映する長期的な予測には N-gram を用いて解明する．それから，再帰差異共通部分抽出法を利用することにより，システムに与えられたデータから，静的な因果関係を持つルールを獲得し，それらの獲得されたルールを構造化されたシーケンスを生成し，スクリプト [21] として,N-gram を用いて解析することができる．

このように，再帰差異共通部分抽出法と N-gram とを統合することにより，そのユーザが行った動作の先行文脈（N-1 個前の動作）を考慮し，動的な因果関係に基づいて予測を行うことができる．その結果，システムはユーザに柔軟に適応する能力を有する．

このようなシステムを開発することにより，現在の高度情報化社会が抱えている，ユーザの行動予測が困難であるといった問題を解決し，人にやさしい柔軟に対応することができるヒューマンインタフェースシステムを提供することができると考えられる．

本論文では N-gram を用いた再帰差異共通部分抽出法によるユーザの行動予測手法を提案し，その処理過程を説明する．さらに，本手法に基づいて作成したシステムを用いて,bigram 又は trigram を利用して，それぞれ再帰差異共通部分抽出法と結合して行った評価実験の結果から，本手法の有効性について述べる．

2. N-gram と再帰差異共通部分抽出法

本論文で述べる予測手法は,N-gram と再帰差異共通部分抽出法とを結合して構成された一種の Point-Pass Based 予測モデルとして開発されたものである．ここでの再帰差異共通部分抽出法とは,Araki らによって提案されたもので，人間の言語と知識を獲得するメカニズムを解明し，工学的に実現することを最終的な目的とした研究を進めてきたものである [10,22]．一種の Point-Point Based 機械学習技術として自然言語処理においてその有効性が証明されている [16,17,18,19]．

本論文における再帰差異共通部分抽出法とは，二つ

表 1　未知記号列からの対応関係抽出の例
Table 1　Extraction different parts and common parts from data pairs

Input1	$\alpha\theta\sigma\ \underline{\phi\delta}\ \lambda\upsilon$	
Input2	$\Xi\Sigma\ \underline{\phi\delta}\ \Phi\Theta$	
Segment1	$\alpha\theta\sigma$	$\Xi\Sigma$
Segment2	$\underline{\phi\delta}$	$\underline{\phi\delta}$
Segment3	$\lambda\upsilon$	$\Phi\Theta$

表 2　再帰的抽出の例
Table 2　Example of Recursively Extraction

Segment1	$\alpha\ \underline{\theta\sigma}$	$\gamma\ \underline{\Phi\Theta}$
Segment2	$\underline{\theta\sigma}\ \gamma\mu$	$\underline{\Phi\Theta}\ \Sigma$
Primitive1	α	γ
Primitive2	$\underline{\theta\sigma}$	$\underline{\Phi\Theta}$
Primitive3	$\gamma\mu$	Σ

のなんらかの関係を持つ実例から差異共通部分を再帰的に抽出することによりそこに内在する変換規則を抽出する方法である．表 1 には, 二つの未知記号列からの対応関係の抽出の例を示す. さらに, このようにして抽出されたセグメントから差異共通部分を抽出することにより, プリミティブ単位に分解することができる. 表 2 にセグメントから差異共通部分の抽出によるプリミティブ抽出の例を示す. このように実例により差異共通部分を再帰的に抽出することにより知識を獲得する手法である [16].

N-gram モデルは確率的言語モデルとも言われている．自然言語処理の研究では，語句や文を構成する隣接する 2 つや 3 つの文字列や文節の属性などを bigram と trigram，長さ N の隣接するものを N-gram と呼ぶ. その出現頻度の統計を言語の特徴を示すデータとすることがある [23,24]．N-gram を利用する際に一般的に bigram と trigram をよく用いる．例えば, 大語彙連続音声認識ツールである Julius は, テキストコーパスから学習された単語 bigram と trigram の言語モデルを用いて，90%以上の音声認識率を得ている [25]. また, 様々な領域において N-gram を使用した予測システムが実装されている。

N-gram モデルによる予測システムは, 一般にシステムに与えられた学習データに含まれている連続する N 状態の共起情報を求め，ハッシュテーブル方式で N-gram モデルを生成し，その確率情報を用いて予測を行っている．本論文では，一日単位でシステムに正しく適応したルールから構築されたシーケンスを N-gram の解析対象とし，獲得された N-gram モデルの確率情報と再帰差異共通部分抽出法により獲得されたルールの重みとを融合して, 予測を行う.

表 3　各要素が持つ値
Table 3　Setting Value of Every Element

ELEMENT	SETTING VALUE
Day of week	Monday,Tuesday,...,Sunday
Time	hh,mm
Brightness	50Lux,100Lux,...,1450Lux,1500Lux
Temperature	16 ℃,17 ℃,...,34 ℃,35 ℃
Door	Doff,Don
TV	TVoff,1ch,2ch,...,59ch,60ch
TV-program	None,Sport,News,...,Film,Music
Curtain	Coff,Con
Light	Loff,Lon
Air conditioner	Aoff,16 ℃,17 ℃,...,34 ℃,35 ℃
Telephone	Teoff,Ring,Teon
Alarm Clock	Aloff,Alon

3.　システムの構成と基本的な概念

本論文におけるシステムを一つの「学習する部屋」とみなす. 分析を容易にするために，システムは 8 つの人工要素と 4 つの自然要素からなると仮定する．人工要素とは，テレビや電灯などのような人間の行動により状態を変化させることが可能な要素である．自然要素とは時間情報，明るさ，温度などのような人間の行動に依存しない要素である．表 3 に示されたそれぞれの要素は，予め与えられた幾つかの値を持つ．ここでシステムは部屋の状態を自動的に獲得することができ, かつノイズなしと仮定する.

3.1　システムの要素における記号化

本システムにおける人工要素 (**A**rtificial elements) は，ドア (**D**oor)，テレビ (**TV**)，テレビ番組 (**P**rogram)，カーテン (**C**urtain)，電灯 (**L**ight)，エアコン (**A**ir-**C**onditioner)，電話 (**T**elephone)，目覚まし時計 (**A**larm **C**lock) からなる．本システムにおける自然要素 (**N**atural elements) は, 曜日 (**W**eek)，時間 (**T**ime)，明るさ (**B**rightness)，温度 (**TEM**perature) からなる [1]．このような要素における部屋の状態ベクトルを次のように定型化する.

$$S_k^n = (N_k^n, A_k^n) \tag{1}$$

$$N_k^n = (T_k^n, W_k^n, B_k^n, TEM_k^n) \tag{2}$$

$$A_k^n = (D_k^n, TV_k^n, P_k^n, C_k^n, L_k^n, AC_k^n, TEL_k^n, AL_k^n) \tag{3}$$

(S_k^n) [2] は部屋の状態ベクトル, (N_k^n) は自然要素の状態ベクトル, (A_k^n) は人工要素の状態ベクトルを示す.

3.2　静的な因果関係を持つルール

我々は日常生活で行われている様々な行動においては，生活している環境の中で総合的な条件のもとで思

1: それぞれの要素が文書にある英語の大文字部分で記号化する.
2: "n":与えられたデータの順番, "k":データの日付け情報.

考に基づいて行動している．それは，人間が暗黙的に持つ知識を利用し，予測を行い，そして行動をする．一般的に，人間の見回りの環境や条件の変遷はその人のなんらかの行動を引き起こす原因である可能性がある．

例えば，“部屋が暗くなっているから電灯をつける”のという状況から考えると，ユーザは電灯をつける直前における部屋の状態と電灯をつけた直後における部屋の状態を比較し，そこに部屋にある人工要素の状態の差異部分 (この例では電灯を on にする) を抽出することができる．この結果をユーザのインタラクションとし，電灯をつける直前における部屋の暗い状態がその動作の原因であると考えられる．ここでは，このような因果関係を静的な因果関係と定義する．また，このように抽出されたルールを初期ルールと定義する．式 $(S_k^n \rightarrow Action_k^n)$ で表示する．また，初期ルールに対して，再帰差異共通部分抽出法により抽象化処理を行い，生成されたルールを抽象化されたルールと定義する．

4. 基本的な考え方

本節では，再帰差異共通部分抽出法と N-gram の統合について述べる．

4.1 初期ルールの獲得

ここで，図 1 に示す実際の例を用いて，再帰差異共通部分抽出法による初期ルールの獲得方法について述べる．例えば:“電話を取ると，テレビが切れる”というルールを獲得する際に，データの例 1 から (S_1^1) と (S_1^2) の差異部分と共通部分を抽出することにより，初期ルール $(S_1^1 \rightarrow Teon)$ を獲得することができる，同じように，S_1^2 と S_1^3 から初期ルール $(S_1^2 \rightarrow TVoff|None)$ も獲得される．また，データの例 2 から，初期ルール $(S_2^2 \rightarrow Teon)$ と初期ルール $(S_2^2 \rightarrow TVoff|None)$ を獲得することもできる．

4.2 初期ルールの抽象化処理

初期ルールの抽象化処理とは，ルールペアに対応している部分の要素値を比較し，等しい場合は，そのまま利用し，異なる場合は，異なる部分を生成するルールの変数部分とするというものである．本手法では，

データの例1(順番で S_1^1, S_1^2, S_1^3):
(Monday,7:31,750,24,Doff,3ch,News,Con,Loff,Aoff,**Ring**,Aloff)
(Monday,7:31,750,24,Doff,**3ch,News**,Con,Loff,Aoff,**Teon**,Aloff)
(Monday,7:31,750,24,Doff,**TVoff,None**,Con,Loff,Aoff,Teon,Aloff)

データの例2 (順番で S_2^1, S_2^2, S_2^3):
(Tuesday,10:03,800,28,Doff,1ch,News,Con,Loff,Aoff,**Ring**,Aloff)
(Tuesday, 10:03,800,28,Doff,**1ch,News**,Con,Loff,Aoff,**Teon**,Aloff)
(Tuesday, 10:03,800,28,Doff,**TVoff,None**,Con,Loff,Aoff,Teon,Aloff)

図 1 データの例
Fig. 1 Examples of data

$$\alpha,\beta,\gamma,\lambda,\mu,\pi \rightarrow Action1 \quad \ldots(1)$$
$$\alpha,\phi,\theta,\kappa,\mu,\tau \rightarrow Action2 \quad \ldots(2)$$
$$\alpha,\eta,\gamma,\lambda,\psi,\pi \rightarrow Action1 \quad \ldots(3)$$
$$\alpha,\beta,\varpi,\rho,\mu,\sigma \rightarrow Action2 \quad \ldots(4)$$

ルールの動作が一致しない場合：

$$\left.\begin{matrix}(1)\\(2)\end{matrix}\right\} \Rightarrow \alpha,@1,\gamma,\lambda,@2,\pi \rightarrow @3$$

ルールの動作が一致する場合：

$$\left.\begin{matrix}(1)\\(3)\end{matrix}\right\} \Rightarrow \begin{cases}\alpha,@1,\gamma,\lambda,\mu,\pi \rightarrow Action1\\ \alpha,@1,\gamma,\lambda,\psi,\pi \rightarrow Action1\\ \alpha,\beta,\gamma,\lambda,@1,\pi \rightarrow Action1\\ \alpha,\eta,\gamma,\lambda,@1,\pi \rightarrow Action1\\ \alpha,@1,\gamma,\lambda,@2,\pi \rightarrow Action1\end{cases}$$

図 2 抽象化処理の例
Fig. 2 Examples of Abstraction Process

生成されたルールの変数は，任意の値とみなす．

本論文においては，抽象化処理を行う際に，比較対象となるルールを同じ動作を持つルール同士のみと限定している．その理由は，例えば，図 2 に示されたように，異なる動作を持つルール (1) と (2) に対して抽象化処理を行うと，獲得されたルール $(\alpha,@1,\gamma,\lambda,@2,\pi \rightarrow @3)$ は，動作を示すパターン (@ 3) が変数化されたため，(@ 3) を任意の値とみなせば，それは，$(\alpha,@1,\gamma,\lambda,@2,\pi)$ という条件を満たす時に、システムが任意の動作をしても良いということを意味し，このようなルールが予測処理に使用されると，誤予測の原因になると考えられる．

また，抽象化処理により獲得されたルールにおいては過抽象化の問題を防ぐために，ルールの抽象度を用いて獲得されたルールに含まれている変数の数をコントロールする．抽象度の定義を式 (4) に示す．

$$\text{抽象度} = \frac{\text{ルールにある変数の数}}{\text{ルールにある全要素数}} \qquad (4)$$

抽象化処理においては，ルールが極端に抽象化されると，ルールの全要素がすべて変数化される．例えば，ルール $(\alpha,\beta,\gamma,\lambda,\mu,\pi \rightarrow Action1)$ とルール $(\omega,\tau,\square,\chi,\phi,\rho \rightarrow Action1)$ から無制限に抽象化処理を行うと，ルール $(@1,@2,@3,@4,@5,@6 \rightarrow Action1)$ が獲得される．このルールは，“どんな条件値においてもすべて Action1 という動作が行われる”ということを意味している．この問題を防ぐために，予め決められた抽象度をシステムに与え，抽象化されたルールの変数の数をコントロールする．具体的には，まず，比較対象となるルールペアから，抽象化可能なルールの最大抽象度を計算し，その値が与えられた抽象度より等しいまたは小さい場合，図 2 に示すような抽象化されたルールが獲得される．その値が与えられた抽象度より大きい場合，与えられた抽象度を超えないとい

表 4　予測するための動的テーブル
Table 4　Dynamic Table for Prediction

動的テーブルの構成要素	意味
共起ルール ($...rule^{N-2}rule^{N-1}rule^{N}$)	N-gram により求められた共起ルール
$rule^{N}$ における RDCPE の重み	表 5 に示す：$CR-\lambda\times ER$
N-gram による共起情報	N-gram 共起確率情報
RDCPE と N-gram との統合情報	尤度評価関数による統合されたルールの尤度

表 5　RDCPE によるルール評価の辞書構造
Table 5　Dictionary Structure of RDCPE's Rule Evaluation

$rule^{N}$	登録番号	正予測度数 CF	誤予測度数 EF	正適合度 CR	誤適合度 ER	$CR-\lambda\times ER$	抽象度	ルールの階層

う条件の元で，まずはルールペアの左側から右へ，次にルールの右側から左へ図 2 に示すような，異なる抽象度を持つ抽象化されたルールが獲得される．

また，初期ルールの抽象化処理により，獲得されたルール対して，ルール辞書にすでに登録されてあるかどうかのチェック処理を行う．完全一致するルールがなければ，新たなルールとしてルール辞書に登録する．このルールは今後の予測処理に利用することができる．

抽象化ルールの具体例は，例えば，前述の初期ルール ($S_1^2 \rightarrow TVoff|None$) と初期ルール ($S_2^2 \rightarrow TVoff|None$) に対して，抽象化処理を行うと，獲得可能な抽象度最大なルールが以下に示す．ここで，@0, @1, @2, @3, @4,@5 は変数である．

$@0,@1,@2,@3,@4,Doff,@5,News,Con,Loff,Teon,Aloff \rightarrow TVoff|None$

抽象化処理により獲得されたルールが適用された場合，その予測結果が正しいかどうかに対して，ユーザの正誤判定を行い，判定された情報がシステムのフィードバック処理に利用される．正解である場合，そのルールの尤度が上昇し，誤った場合，そのルールの尤度が次第に減少していく．このようにすることにより，一般的にデータスパースネスの問題による予測不能な現象をある程度抑えることが可能である．例えば，$(\alpha,\zeta,\gamma,\lambda,\iota,\pi)$ が新しいデータであっても，図 2 に示されたルール $(\alpha,@1,\gamma,\lambda,@2,\pi \rightarrow Action1)$ がルール辞書に存在すれば，適用可能となる．よって，抽象化処理により獲得されたルールは新しいデータに適応能力を付与する．

4.3　N-gram パスモデルの構築

一般的に N-gram に基づく予測システムがユーザの履歴情報を示すログファイルに記録したデータをシーケンスと構造化して，シーケンスの要素の共起情報を計算することで，予測を行っている．本手法では，システムが予測を行う際に，システムに与えられたデータに正しく適用されたルールをシーケンスの要素とし，日付ごとにシーケンスを構築する．

また，適用されたルールは，システムに与えられたデータにおいて校正済みの予測結果と対応するルールである．このような要素から構成されたシーケンスがスクリプトと呼ばれている．スクリプトとは，典型的な事象列を一つの枠の中にまとめた記憶構造であり，人間が日常行っている定型化された行動を，時間の流れに沿った事象の連鎖の形式で表現したものである [21]．人間は多くのスクリプトを持っており，ある状況に直面すると，その状況に適したスクリプトを選択し，そこに書かれた事情に従って物事が進行するであろうと予測しながら行動を進めていくと考えられる．

例えば，前述のデータの例 1 から，適応されたルールが完全一致かつ予測結果が正しい場合：(文頭 $\rightarrow Ring:S_1^1 \rightarrow Teon:S_1^2 \rightarrow TVoff|None:S_1^3 \rightarrow$ 文末) [3]を抽出することができる．

4.4　N-gram と再帰差異共通部分抽出法の統合

N-gram に基づく予測システムは，データの出現頻度や条件付き確率などに対して，経験的に閾値を与えている．それに対応する予測結果として n-best まで求めることができる．本システムでは，再帰差異共通部分抽出法と統合するために，Rank1 のみ着目して予測を行う．予測するための動的テーブルの構造を表 4 に示す．

図 4 に示された共起ルールとは，予測を行なう際に正しく適用されたルールから構成されたスクリプトを用いた N-gram により解析された共起ルールということである．N は N-gram の N と対応する．$rule^{N}$ における RDCPE [4]の重みは，表 5 に示されている RDCPE によるルール評価辞書構造ルールの中の $CR-\lambda\times ER$ という情報である．λ は係数を表す．N-gram による共起情報とは，N-gram により求められた隣接動作の条件付確率である．RDCPE と N-gram との統合情報

3: “電話が鳴る (Ring)，電話を取り，通話中 (Teon)，テレビを消す (TVoff)，そして番組の内容が何もない (None)” を意味する．

4: RDCPE とは再帰差異共通部分抽出法 (Recursive Different and Common Part Extraction Method) の略である．

とは，ルールの尤度評価関数を用いて隣接動作の条件付き確率と $CR-\lambda \times ER$ を統合したものである．

本稿におけるシステムの入力データの形式は部屋の状態を示す (S_k^n) で，獲得されたルールの形式は $(S_k^n \rightarrow Action_k^n)$ で，表4に示す各列は評価対象のルールとなる．また，表5に示す辞書構造の各部分について，次章について述べる．

このように,RDCPE と N-gram の重みを適切な尤度評価関数を用いることで，予測を行い，更に，校正ずみ予測結果に適用されたルールとその結果の (N-1) 個の正しい動作に適用されたルールの情報を参照することで，動的な因果関係を抽出し，システムが確実性の高いルールを自動的に選択することができる．

また，一般的に N-gram による予測システムや自然言語処理の領域などでは,bigram や trigram などがその予測精度と実用性のバランスがよいため，本論文において bigram と trigram を利用して，提案された手法の有効性を検討する．

5. 処理過程

5.1 概要

本手法をもとにしたシステムの処理過程を図3に示す．予測処理部，校正処理部，学習処理部とフィードバック処理部からなる．部屋の状態 (S_k^n) が入力されると最初に予測処理部において予測を行う．ここでは，システムがすでに獲得しているルール辞書に存在するルール，及び状態履歴に登録された前方文脈を示すユーザがした N-1 個の動作を利用して予測を行う．

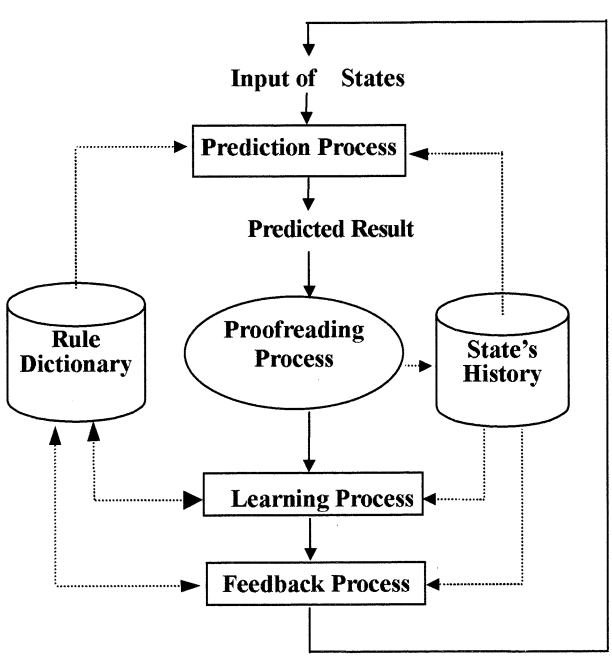


図3 処理の流れ
Fig. 3 Outline of the Procedure

次に，予測結果に対する正誤判定を行う．正誤を判定するために，正しい予測結果を実験に用いられるデータに基づいて，一日単位で予め人手により用意し，それを基準にして正誤判定を行う．もし，予測結果が正しい場合には，ユーザの状態履歴に登録し，そのまま，学習処理とフィードバック処理に進む．もし，予測結果が用意された正解と一致しない場合には，正しい結果を与える，ユーザの状態履歴にその誤った予測結果と正しい予測結果を登録する．

次に，学習処理とフィードバック処理に進む．学習処理において，再帰差異共通部分抽出法による初期ルールの獲得，ルールの抽象化処理，シーケンスの生成及び N-gram による解析などの処理を行う．そして，これらの解析結果をルール辞書に登録する．フィードバック処理においては，状態履歴に登録された予測結果と校正済みの予測結果とを比較して，RDCPE による使用されたルールの重みを更新し，この情報とルール辞書に登録された N-gram の情報とを統合して表4示す動的テーブルの更新を行う．これらの処理により，正しい結果を予測した処理に利用しルールには，今後の予測処理におけるルール選択の際に優先順位が上昇させる処理を行う．また，誤った結果を予測した処理に利用されたルールには，ルール選択の際に優先順位が下降させる処理を行う．このフィードバックでは，同じ誤りを起きにくくすることによりそれ以降のシステムの予測能力を改善する．以下各処理部について説明する．

5.2 予測処理

予測は，状態履歴からユーザが行われてきた（N-1）の動作と与えられたデータを用いて，獲得されたルールを保持されているルール辞書から適応可能なルールが存在するかどうかを探索する．各ルールは適用条件を保持しており，その適用条件を満たしたルールが適応可能なルールとなる．予測ルールを検索する際に，まずルールの尤度により，ルールの尤度が最大であることを適用可能なルールと評価する．ルールの尤度評価関数については5.5節で述べる．

なお，複数のルールが重複した場合には，次の順に尤度評価を行い，適用するルールを決定する．

①抽象度が最小．
②適合度が最大．
③登録順が最新．

抽象度については節5.4節で説明する．抽象度が0であるルールは変数が含んでいない初期ルールである．このようなルールは，入力状態と完全一致するため，予測に使用した際に正予測となる可能性が高いと考えられる．よって，抽象度の低い予測ルールの優先順位を高く設定している．また，入力状態と完全一致しない

場合, 抽象化されたルールを用いることで, 予測が可能になる. 適合度については節 5.5 節で説明する

予測ルールの抽象度が同じ場合には, 適合度により尤度評価を行う. 適合度は, そのルールの正予測度数と誤予測度数により決定される. 正予測度数と誤予測度数はフィードバック処理により更新される.

予測ルールの適合度も同じとなる場合, 登録順位が最新のものを現在の対象に優先して適用する.

5.3 校正処理

予測された結果に誤りが含まれる場合や予測不能な場合などは, 人手により用意された正解に基づいて校正が行われる. ここで与えられる情報が, システムに与えられたデータに応じて, 予測となる正解の行動である. これらの校正情報を状態履歴に登録して, 学習処理とフィードバック処理に進む.

5.4 学習処理

学習処理には, システムに与えられたデータと校正済み予測結果を用いて, 学習処理が行われる. 再帰差異共通部分抽出法においては,4.1 節と 4.2 節に述べたように, 初期ルールの獲得とルールの抽象化処理が行われる.

初期ルールの抽象化処理における抽象度とは, 前述のように, 比較対象となるルールペアの中に対応している要素の値が異なる場合, 変数化される. 本システムにおいては, 人工要素と自然要素がそれぞれ独自の特徴を持つ. このため, ここでは, 二つの抽象度を定義する. これらを式 (5) と式 (6) に示す. 予測ルールを探索する際に, 二つの合計で評価する.

$$Dan = \frac{X}{N} * 100[\%] \tag{5}$$

$$Daa = \frac{Y}{M} * 100[\%] \tag{6}$$

ここで, Dan はルールの自然要素における抽象度, X は自然要素部分に含まれる変数の数, N は自然要素の数, Daa は人工要素における抽象度, Y は人工要素部分に含まれる変数の数, M は人工要素の数である.

また, ルールの抽象化処理を行う際, 時間, 温度そして明るさなどのような自然要素に対して, 差異共通部分の判定をするために, 予めそれぞれの要素に応じて判定基準を与えておく. 本システムでは, 比較となる二つの初期ルールの自然要素の値の差をそれぞれ, 時間は 10 分, 温度が 2 度, 明るさが 50Lux 以内とし, この範囲内であればその平均値を共通部分としている. それ以外の場合は, 変数化される.

そして, 与えられたデータと校正済みの予測結果を用いて, そこに正しく適用されたルールを利用して時間の流れに沿って構造化したスクリプトが生成される. 生成されたスクリプトに対して N-gram を利用して解析が行われる. その結果, 校正済みの予測結果を示す行動とその直前の N-1 個 (N は N-gram の N の値である) の動作を反映した適用ルールの組の条件付き確率を獲得することができる. これらの解析結果はルール辞書に登録され, 再帰差異共通部分抽出法と N-gram の更新された情報を用いて, 表 4 に示されたテーブルを構成し, 今後の予測処理に利用される.

このように, 再帰差異共通部分抽出法により獲得された静的な因果関係を持つルールを反映したユーザの行動に対して,N-gram を利用することで, その動作と関係を有する直前の N-1 個の動作と関連付けられて, 動的な因果関係の抽出に利用される. 本手法の特徴は一種の Point-Pass based 予測システムとして, 動的な因果関係の抽出を行うことである, また, そのことによりシステムが動的適応能力及び汎用性を有することである.

5.5 フィードバック処理

フィードバック処理では, ルールの尤度更新を行う. ルールの尤度評価関数を式 (7) と (8) に示す.

$$CEF = CR - \lambda * ER + \xi * \omega * P_n \tag{7}$$

$$\xi = \begin{cases} 1 & (\text{予測された動作の出現頻度} \geqq \text{閾値}) \\ 0 & (\text{予測された動作の出現頻度} < \text{閾値}) \end{cases} \tag{8}$$

ここで,CR は獲得されたルールの適合度,ER は誤適合度,P_n [5]は N-gram により解析され適応されたルールに対する行動とその行動の直前の N-1 個の動作の条件付き確率である. 式中 λ, ω は係数である.ξ は N-gram による解析を安定させるための調整因子である. 正適合度と誤適合度をそれぞれ式 (9) と式 (10) に示す.

$$CR = \frac{CF}{CF + EF} * 100[\%] \tag{9}$$

$$ER = \frac{EF}{CF + EF} * 100[\%] \tag{10}$$

ここでは,CR は適合度,ER は誤適合度,CF は正予測回数,EF は誤予測回数である.

再帰差異共通部分抽出法によるルールの重みは, 予測結果と校正済みの予測結果の比較から使用したルールの正誤を決定し, その尤度を更新する. 予測した結果が校正済みの予測結果に含まれている場合, その正予測度数を 1 増加させる. それ以外の予測ルールは誤予測として, その誤予測度数を 1 増加させる.

N-gram による解析が, 校正済みの予測結果を参照し, それに対応するスクリプトが生成され, 生成されたスクリプトが次の N-gram モデルを構築するための学

5: bigram を用いる場合, $P_n = P(A_n|A_{n-1})$;trigram を用いる場合 $P_n = P(A_n|A_{n-2}A_{n-1})$,A は動作を示す.

表 6 ルール辞書の階層化
Table 6 Classfied Rank of Rule

Name of Rank	The Rule Adaptation Rate(%)
$Most(M)$	$CR \geqq 90$
$High(H)$	$70 \leqq CR < 90$
$Common(C)$	$30 \leqq CR < 70$
$Least(L)$	$CR < 30$

習データとして利用される. このように, 再帰差異共通部分抽出法により獲得されたルールが保有している正適用度数 (CF), 誤適用度数 (EF), 正適用率 (CR), 誤適用率 (ER) などと N-gram による隣接動作の条件付き確率がフィードバック処理により更新され, 予測を行う際に, それぞれのルールが持つ適用情報に基づいて適用できるルールを検索し, 最適なルールが決定される.

なお, 再帰差異共通部分抽出法において, 獲得されたルールはそのルールの正適用度により階層化される. 階層化されたルールについてはフィードバック処理を行う際にそのルールの属する階層も更新される. 階層化されたルールを表 6 に示す. 予測処理を行う際には, 表 5 に示されたように, 上の階層から順番に探索していく.

以上のように, 予測, 校正, 学習, フィードバックを繰り返すことにより, ルール辞書が更新され, 予測精度を徐々に向上させることができる.

6. 評価実験

本論文で提案された行動予測手法の有効性を確認するために, 図 3 の処理過程に基づいたシステムを作成し, 評価実験を行った. 実験はオープンデータを用いて行った.

6.1 実験方法と評価基準

機械学習における実験方法には, 大部分の実験は交叉検定法 (Cross-validation) が標準的な評価方法としてよく用いられる. それは, 実験データを学習データとテストデータに分けて評価を行う方法である. 本システムにおいては, 逐次的に学習を行うシステムとして評価する. その理由は, まず, 本研究の目的の一つは, それぞれのユーザにより良い予測精度と動的適応能力を持つシステムの実現方法を作り上げることである. それぞれのユーザの習慣や嗜好などが, 人ごとに異なっているため, その人に合う生活パターン (ルール) を獲得するために, システムが獲得したデータを用いて逐次的に学習を行う必要があると考えられる. また, システムの予測結果が必ずしも正しいとはいえないため, システムの予測結果に対して, ユーザの判定情報を教師情報として用いて, 予測処理に適用されたルールの適合度を評価し, システムのフィードバック処理により, 同じ誤りを起こしにくくすることができる.

表 7 実験データ
Table 7 Data of the experiment

ユーザ	データ数
User A	3,276
User B	3,458
User C	3,185
User D	3,094
User E	3,367
合計	16,380

そのため, 実験を行う際, まず, 実験に用いられたデータに基づき人手により一日単位で予め正誤判定の基準となる正解を作成した. それから, 日付けごとに収集されたデータを用いて評価実験が行った. 予め用意されたデータを学習データとテストデータに分けずに, データをシステムに与えて, 予測をしながら, 予測した結果と校正ずみの結果を比較して学習処理が行われ, 学習させた結果を次の予測に利用する. システムに与えられたデータが次々に次回の予測の学習データとなる.

なお, 実験における N-gram との統合については, ここで bigram と trigram をそれぞれ用いて検証する.4-gram 以上の場合は今後の課題とする.

実験の結果を評価するために, 一日分のデータごとに予測精度により評価した. 予測結果の Rank1 のみで予測結果を判断する. 予測精度 (Precision) を式 (11) に示す.

$$Precision = \frac{\text{用意された正解と一致した回数}}{\text{全予測回数}} \quad (11)$$

6.2 実験データ及び実験手順

実験データを表 7 に示す. 情報系大学院生及び研究生の 5 人,91 日に渡って合わせて 16,380 個のデータを収集した. 表 7 に示されたデータ数は,N-gram 解析における文頭及び文末表現が含んでいない. 実験を行う際にスクリプトを獲得するために, 一日分のデータごとに文頭文末としてそれぞれ“Head”と“Tail”を加えた.

本手法の動的適応能力及び汎用性を検証するために, 各ユーザにおいて初期状態を一定に保つため, データ履歴とルール辞書は空の状態から実験を行った.

実験における被験者, 正解の作成者, 実験者およびシステムは予測し結果に示す動作が行われたユーザなどについての対応関係は表 8 に示す.

また, 予測結果と正解との正誤判定情報については, 予測結果と正解を一致する場合, 正しい予測結果を“T”, 一致しない場合や予測不能な場合を“F”と設定した.

表 9　予備実験結果 (bigram+RDCPE)
Table 9　Results of preliminary experiment

	λ	1	1	1	1	5	7	9	**10**	30	40	50
係数	ω	1	10	20	30	20	20	20	**20**	20	20	20
結果	精度 (%)	78.35	78.36	79.10	78.37	78.53	78.62	78.44	**79.32**	78.31	78.53	78.34

表 10　予備実験結果 (trigram+RDCPE)
Table 10　Results of preliminary experiment

	λ	1	1	1	1	5	**10**	20	40	50	70	100
係数	ω	10	20	50	60	50	**50**	50	50	50	50	50
結果	精度 (%)	88.21	88.36	88.68	88.32	88.16	**89.30**	88.15	89.13	89.22	88.53	88.26

表 11　抽象度決定の予備実験結果
Table 11　Preliminary Experiment Results

	Dan	0.25	0.25	0.25	0.25	0.5	**0.5**	0.5	0.5	0.75	0.75	0.75	0.75
抽象度	Daa	0.25	0.5	0.75	1.0	0.25	**0.5**	0.75	1.0	0.25	0.5	0.75	1.0
bigram+RDCPE	精度 (%)	66.23	68.82	67.60	63.37	73.80	**79.32**	65.35	62.38	62.26	60.16	58.66	53.53
trigram+RDCPE	精度 (%)	66.15	67.45	66.74	61.18	76.66	**89.30**	76.66	66.24	70.27	68.13	55.37	52.19

表 8　実験における対応関係
Table 8　Experiment Correspondence Relations

データ収集者	被験者	正解作成者	実験者	誰の行動
UserA	UserA	UserA	UserA	UserA
UserB	UserB	UserB	UserA	UserB
UserC	UserC	UserC	UserA	UserC
UserD	UserD	UserD	UserA	UserD
UserE	UserE	UserE	UserA	UserE

実験は一日分のデータごとにシステムに与えて，与えられたデータから一状態づつ予測を行った．すなわち，まず，一つのデータを入力し，前述の処理過程にしたがって，予測処理，校正処理，フィードバック処理及び学習処理の順番で進めていく．予測処理を行う際に，システムのフィードバック学習により獲得された動的テーブルの中から，パターンマッチングにより適用可能なルールを探索し，予測を行う．予測された結果と校正済み予測結果を比較して，学習処理とフィードバック処理に進む．この際に，ルール辞書と状態履歴が更新され，次の入力における予測の際にその適用できるルールの新しい情報を利用することができる．このように入力，予測とフィードバック学習を 1 つのデータごとに繰り返して，実験を進めていく．

6.3　予備実験

まず，初期ルールの抽象化処理においては，抽象化されたルールの抽象度が高ければ，そのルールの適用能力が高くなるが，予測精度は落ちる恐れが生じてしまう．そのため，再帰的な抽出は，抽出されたルールの抽象度，つまり，人工要素部分における抽象度と自然要素における抽象度の閾値は経験的に 0.5 を与えた．

また，実験はルール辞書及び状態履歴が空から始まっているので，その初期段階の予測においては,N-gram 解析の解析結果による条件付き確率の信頼性が低いため，予測結果を示すユーザの行動が生成されたスクリプトの中に，出現頻度の閾値を与える必要がある．ここでは，閾値を 4 と与えている．つまり，初期段階における予測は，主に再帰差異共通部分抽出法により行われる．

また，尤度評価関数式 (6) の係数を最適化するために予備実験を行った．表 7 に示されたユーザ C のデータ 3，185 個を用いて，欲張り法 (Greedy Method)[26] で尤度評価関数の係数を変化させ最適な予測精度が得られる係数の値を求めた．Greedy Method は，まず,λ に初期値を与え,ω を変化させ，予測精度が最大となる ω の値を求める．次に,λ を変化させ，予測精度が最大となる λ の値を求める．このような操作を繰り返すと，予測精度が最大となる係数の値を最適な係数の値とする．実験の結果の一部を表 9 と表 10 に示す．この実験から bigram を用いた再帰差異共通部分抽出法による予測手法は λ と ω がそれぞれ 10 と 20 となった．そして,trigram を用いた再帰差異共通部分抽出法による予測手法は λ と ω がそれぞれ 10 と 50 となった．

また，与えられた抽象度の閾値が合理的であるかどうかを検証するために，欲張り法により得られた尤度評価式 (7) の係数を利用して異なる抽象度で．ユーザ C のデータを用いて予備実験を行った．実験の結果を表 11 に示す．表 11 には，システムに与えられた抽象度が 0 から 0.5 まで上昇した時に，予測精度が上昇し，システムに与えられた抽象度が 0.5 から 1.0 まで上昇し時に，予測精度が低下するという結果が示されている．

6.4　実験結果

予測精度の推移を図 4 と図 5 に示す．また実験終了時にそれぞれのユーザにおける予測精度を表 12 に示

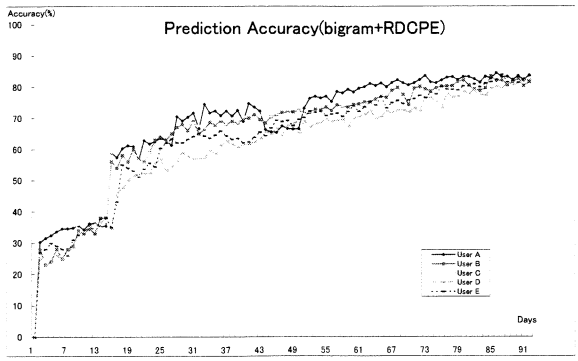


図 4 bigram+RDCPE 予測精度の推移
Fig. 4 Transition of Prediction Accuracy of bigram+RDCPE

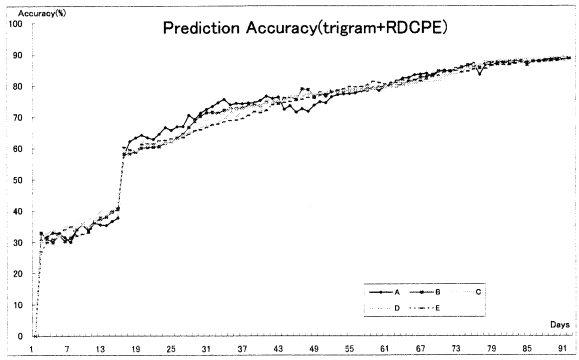


図 5 trigram+RDCPE 予測精度の推移
Fig. 5 Transition of Prediction Accuracy of trigram+RDCPE

表 12 予測精度 (%)
Table 12 The Precision of Each User

User	User A	UserB	User C	User D	User E
Method1	83.8	81.55	79.32	82.33	83.47
Method2	89.1	88.6	89.3	88.3	88.65

表 13 総平均予測精度 (%)
Table 13 The Average Accuracy of Each Eser

User	User A	UserB	User C	User D	User E
Method1	74.30	72.38	70.17	72.41	72.51
Method2	77.05	76.85	76.30	76.09	75.87

す, 各ユーザにおける総平均予測精度を表 13 [6]に示す.

各実験結果に示すように, 予測精度はシステムに与えられたデータの増加に伴い上昇し, 最終的にそれぞれ予測精度で 83%(bigram+RDCPE) と 89%(trigram+RDCPE) 程度までの上昇が確認された.

また,bigram を用いる場合より trigram のほうが平均予測精度 3〜6%上あがる結果が得られた. また,trigram の安定性が bigram より高いことも示されている.

6: 表 12 と 13 に示す Method1 は bigram+RDCPE, Method2 は trigram+RDCPE と意味する.

7. 考察

7.1 動的適応能力について

各実験の初期段階である 2 週間分のデータにおける予測精度は低かった. それは, ルール辞書とデータ履歴が白紙の状態から始まっていたことが原因であると考えられる. しかし, 3 週目からの予測精度が一気に 60%の程度に達成した. これは, 本手法の学習能力, 特に初期段階で再帰差異共通部分抽出法のみ学習が行われたが, その獲得された初期ルールが抽象化され, 抽象化されたルールが有効に作用した結果であると考えられる. これらに基づき学習を行うことにより, 少ないの学習データからでも, 予測対象に依存した予測ルールを獲得し, 現在の予測対象にも適応可能となった. 表 14 に例を示す (19 時半になったら, ニュースが流れる).

表 14 で抽象化されたルールに含まれている変数 @1,@2,@3,@4,@5 は, それぞれ, 曜日, ドア, カーテン, エアコンの状態が変数化されたことを意味する. このように, 変数化されたルールを利用することにより, 次回の予測に使用することができる.

また, システムに与えられたデータの増加に伴い, 予測精度が徐々に上がっていくことも示されている. それは, システムに与えられたデータの中に, そのユーザの習慣や嗜好などを反映する規則性の情報が N-gram 解析により自動的に獲得されて,N-gram で解析した情報と再帰差異共通部分抽出法により獲得した情報を統合することによりその獲得状況及び予測精度に基づく確実性の高いものより順に予測が行われたと考えられる.

7.2 学習の誤りについて

表 15 に学習の誤りの例を示す. この例の中に, 時間の値が変数化 (@1) されたため, このルールが適用された場合, 誤った予測結果が出力される (日曜日 12 時半, 目覚まし時計が鳴る). このような誤ったルールは, 予測に使用されると誤予測となるため, 本手法のフィードバック処理によりその尤度が次第に減少していく.

7.3 有効性

表 13 に示されるように, bigram を用いた場合, 総平均予測精度が 72.4%で,trigram を用いた場合, 総平均予測精度が 76.43%であった. bigram 及び trigram を用いた再帰差異共通部分抽出法によるユーザの行動予測手法の有効性が証明された.

実験の結果に示されているように, trigram を用いる場合,bigram を利用することより予測性能とシステムの安定性が高いことが示されている. その原因は,bigram を用いる場合, 獲得された共起ルールの生起確率が直前の動作に適用されたルールのみに依存し,trigram を利用する場合, 獲得された共起ルールの生起確率が直前の二つの動作に適用されたルールのみに依存し, こ

表 14　正予測例
Table 14　Example of the Correct Prediction

Input	19 : 30, 月曜日, 700, 20, $Doff, TVoff, None, Coff, Lon, Aoff, Teoff, Aloff$
Rule	19 : 30, @1, 700, @2, @3, $TVoff, None$, @4, Lon, @5, $Teoff, Aloff \rightarrow 3ch|News$
Result	19 : 30, 月曜日, 700, 20, $Doff, TVoff, None, Coff, Lon, Aoff, Teoff, Aloff \rightarrow 3ch|News$

表 15　誤予測例
Table 15　Example of the Erroneous Prediction

Input	12 : 30, 日曜日, 850, 26, $Doff, TVoff, None, Coff, Lon, Aoff, Teoff, Aloff$
Rule	@1, 日曜日, @2, 26, $Doff, TVoff, None$, @3, Lon, @4, $Teoff, Aloff \rightarrow Alon$
Result	12 : 30, 日曜日, 850, 26, $Doff, TVoff, None, Coff, Lon, Aoff, Teoff, Aloff \rightarrow Alon$

のように獲得されたユーザの習慣や嗜好を示すルールパターンが trigran を用いる場合獲得状況がよいだからであると考えられる.

また, 図 4 と図 5 に示されたように, 本手法の初期段階の予測精度が低いが, 再帰差異共通部分抽出法の学習能力により, 予測ルールを自動的に獲得し, 迅速に予測精度が上がっていく. この学習能力により, 一般的にデータが少ない時に予測困難の問題をある程度回避することが可能である.

本手法には, 再帰差異共通部分抽出法と N-gram を統合することにより, ユーザの習慣や嗜好と反映する規則性をルールの重みの一部とし, それと再帰差異共通部分抽出法により適用されたルールに対しての予測結果の正誤判断などの情報と組み合わせて, 暗黙的にその次の予測に適用できる.

本手法では, 一種の Point-Pass Based 予測システムを構築し, その有効性を証明した.

7.4　提案手法の拡張性について

本手法に基づくシステムにより行った実験は, 想定された最も理想的な条件の下で行われたものだが, 他の条件に提案手法を適用した場合, 次のようなことが考えられる.

まず, システムに与えられたデータからルールを獲得する方法として有効である. また, 本手法により獲得されたルールがユーザの嗜好を反映しているので, そのユーザに動的適応し, いわゆる共生的な関係が構築することができる. また. 一般的に現在のユーザの行動が予測困難である問題に関わる領域に対して, 本手法を用いることにより解決することが可能だと考えられる.

例えば, 現在, テレビ放送のディジタル化が進んでおり, その中の電子番組表 (EPG) を視聴者の視聴履歴と利用すれば, 本手法により「テレビビデオ自動予約システム」を構築することが可能だと考えられる.

7.5　他手法との比較

本論文では, 提案された手法で使用された評価方法, 実験におけるデータの構造などの実験条件も従来の行動予測手法とは異なる. 評価データにも一般的に通用されないので, 単純に文献 [11,12,13,14,15] などとの比較実験では行うことはできない.

表 16　N-gram による比較実験結果 (%)
Table 16　Rsult of comparison experiment

User	User A	UserB	User C	User D	User E
bigram	43.32	42.36	41.44	44.58	43.05
trigram	46.51	47.12	44.39	45.87	47.64

ここでは, 本論文で提案された手法の有効性と比較するために, 本手法の実験に利用されたデータをそれぞれ bigram と trigram のみで予測を行う実験を行った.

実験を行うために, 収集されたデータはそれぞれのユーザにおいて,4.1 節に述べたような初期ルールの形で, 時間の流れに沿って変形し, そして, 日々のデータにおいて, 文頭文末を加えて比較実験を行う.

評価方法が交差検定法で, 学習データと評価データが 50%ずつとし, 予測結果はの rank1 のみを用いて評価する. 比較実験の結果を表 16 に示す.

表 16 に示されたように, N-gram を用いるだけでは, 精度は低いが, その原因としてが次の二つが考えられる.

(1) 式 $(S_k^n \rightarrow Action_k^n)$ となるデータ構造では,(S_k^n) の中にそれぞれの要素における属性値が様々であるため,$(Action_k^n)$ が一致しても, 共起頻度とは数えられない.

(2) (1) の原因でデータスパースネスの問題が生じて, 良い精度を得るためには, 大量なデータが必要である.

本手法は逐次的に学習を行うシステムであるのに対して,N-gram を用いて行った比較実験は交差検定で, 逐次的に統計量の更新を行っていない, また, 方法, 実験条件などが異なるため,N-gram による比較実験の結果を本手法の性能を評価するための参考とする.

8.　むすび

本論文では, N-gram を用いた再帰差異共通部分抽出法によるユーザの行動予測手法を提案した. そし

て,bigram と trigram を用いて, 再帰差異共通部分抽出法と統合して, それぞれのユーザに適用し, 本手法の動的適応能力及び汎用性を確認する実験を行った. 実験はルール辞書, 状態履歴が空の状態から開始した. 5 人分のデータを用いて, 二つの手法における平均予測精度が 72.4%と 76.43%であることにより, 本手法が種々のユーザに動的に適応可能であることが示された.

また, 本手法が再帰差異共通部分抽出法と N-gram と結合し, 一種の Point-Pass Based 予測システムとして, 汎用性を持つことを証明した.

今後の課題として, 4-gram 以上を用いて本手法の有効性の検討, そし HMM モデルと再帰差異共通部分抽出法との融合の可能性や複数のユーザにおけるシステムの有効性の確認などが挙げられる.

参考文献

[1] 岡田美智男, 片井修, 塩瀬隆之, 大須賀美恵子, 椎尾一郎 : コミュニケーションと身体性; ヒューマンインタフェース学会論文誌, Vol.5, No.2,pp.153-162 (2003) .

[2] 塩瀬隆之, 椹木哲夫, 川上浩司, 片井修: 生態心理学的アプローチからみた技能継承の技術化スキーム; 生態心理学研究, vol.1, no.1, pp.11-18 (2004).

[3] K. Sugiura, H. Suzuki, T. Shiose, H. Kawakami, and O. Katai: Evolution of Rewriting Rule Sets Using String-Based Tierra; LNAI2801: Advances in Artificial Life, pp. 69-77,(2003).

[4] 寺邊正大, 片井修, 椹木哲夫, 鷲尾隆, 元田浩: 相関ルールにもとづく属性生成手法; 人工知能学会誌, Vol.15, No.1, pp.187-197 (2000).

[5] 吉本良治, 伊藤雄一, 北村喜文, 岸野文郎: ネットワーク仮想空間における人間関係の形成を支援するシステムの構築と評価; ヒューマンインタフェース学会論文誌,Vol.6 No.1, pp.49-58 (2004) .

[6] 片岡一朗, 中田圭一, 古田一雄 : 情報提示学習による状況適応型プラント・ヒューマンマシン・インタフェースに関する研究; ヒューマンインタフェース学会論文誌,Vol.4 No.4, pp.31-38 (2002) .

[7] 山岡孝行, 辻野克彦, 吉田哲也, 西田正吾 : ユーザ参加型設計のための事例を利用した意図理解支援インタフェース; ヒューマンインタフェース学会論文誌,Vol.2 No.2, pp.193-202 (2000) .

[8] 伊賀聡一郎, 安村通晃 : 実世界オブジェクトを利用するユーザインタフェースと障害者支援技術への応用; ヒューマンインタフェース学会論文誌,Vol.1 No.1 pp.53-60 (1999)

[9] 國分三輝, 倉橋哲郎, 古西浩之, 向江秀之, 井口弘和, 川澄未来子 : 個人感性情報を用いた住空間設計支援システム; ヒューマンインタフェース学会論文誌,Vol.3 No.4 pp.25-34 (2001)

[10] 荒木健治, 栃内香次 : 帰納的学習を用いた自然言語処理の有効性について; 信学技報 TL 99-14, pp33-40 (2000).

[11] D. Albrecht, I. Zukerman, and A. Nicholson. Presending documents on the WWW: A comparative study; In Proceedings of the Sixteenth International Joint Conference on Artificial Intelligence (IJCAI'99), Stockholm, Sweden, 1999. Morgan Kaufmann IJCAI99, pp.1274-1279.

[12] Zuckerman, W. Albrecht, A. Nicholson: Predicting user ' s request on the WWW; In Proceedings of the Seventh International Conference on User Modeling, pp. 275-284, 1999.

[13] Z. Su, Q. Yang, and H. Zhang: A prediction system for multimedia pre-fetching on the Internet; In Proceedings of the ACM Multimedia Conference 2000, ACM, pp.3-11, Los Angeles, CA, USA.October 2000.

[14] Z.Su,Q.Yang,Y.Lu,and H.Zhang: Whatnext: A prediction system for web requests using n-gram sequence models; In Proceedings of the First International Conference on Web Information System and Engineering Conference, pp. 200-207, Hong Kong, June 2000.

[15] J. M. Mendel: Uncertain Rule-Based Fuzzy Logic Systems; introduction and new directions, Prentice Hall PTR, Upper Saddle River, NJ, 2001.

[16] 荒木健治, 栃内香次 : 帰納的学習による語の獲得および確実性を用いた語の認識; 電子情報通信学会論文誌 D-II,Vol.J75-D-II, No.7,pp.1213-1221(1992)

[17] 荒木健治, 高橋祐治, 桃内佳雄, 栃内香次 : 帰納的学習を用いたかな漢字変換; 電子情報通信学会論文誌 D-II,Vol.J79-D-II, No.3,pp.391-402(1996).

[18] 松原雅文, 荒木健治, 桃内佳雄, 栃内香次 : 文字情報縮退方式を用いた帰納的学習によるべた書き文の数字漢字変換手法の有効性について; 電子情報通信学会論文誌 D-II, Vol.J83-D-II, No.2, pp.690-702 (2000) .

[19] 王忠建, 荒木健治, 栃内香次 : 帰納的学習を用いた単語分割手法の中国語への適用とその性能評価; 電子情報通信学会論文誌 D-II, Vol.J85-D-II, No.1, pp.56-65 (2002) .

[20] 山西健司 : 情報論的学習理論の現状と展望; 情報処理 Vol.42 No.1, pp9-15(2001).

[21] 田中穂積 : 自然言語処理-基礎と応用-, 社団法人電子情報通信学会編 (1999).

[22] K. Araki and K. Tochinai: Effectiveness of Natural Language Processing Method Using Inductive Learning; In Proceedings of the IASTED International Conference ARTIFICIAL INTELLIGENCE AND SOFT COMPUTING, pp.295-300, May, 2001, Cancun, Mexico.

[23] M. Nagao: A New Method of N-gram Statistics for Large Number of n and Automatic Extraction of Words and Phrases from Large Text Data of Japanese; In Proceedings of the 15th International Conference on Computational Linguistics,pp.611-615(1994).

[24] 森 信介, 長尾 真: 係り受けを用いた確率的言語モデル; 情報処理学会自然言語処理研究会 アブストラクト No.122 - 006 (1997).

[25] L. Akinobu: Julius - an open source real-time large vacabulary recognition engine; In Proceeding of European Conf. on Speech Communication and Technology pp.1691-1694 (Academic Journal,2001).

[26] 浅野孝夫, 今井浩 : 計算機とアルゴリズム ; オーム社, 東京, (2000).

(2004 年 7 月 30 日受付, 12 月 17 日再受付)

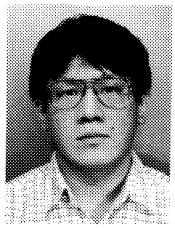
著者紹介

徐　金安　（学生会員）



1992 年中国北方交通大学通信と制御工学科卒．2003 年北海道大学電子情報工学研究科修士修了．現在同大大学院博士課程在学中．自然言語処理及び行動予測システムの研究に従事．

伊藤　敏彦



昭和 46 年生．平成 11 年豊橋技術科学大学大学院工学研究科博士後期課程電子・情報工学専攻終了．同年静岡大学情報学部情報化学科助手．平成 16 年北海道大学情報科学研究科メディアネットワーク専攻助教授．博士（工学）．音声言語情報処理研究に従事．

荒木　健治



昭 57 北大・工・電子卒．昭 63 同大大学院博士課程了．工博．同年，北海学園大学工学部電子情報工学科助手．平元同講師．平 3 同助教授．平 10 同教授．平 10 北大・工・電子情報工学専攻助教授．平 14 同教授，平 16 北大・情報科学・メディアネットワーク専攻教授．自然言語処理，特に機械翻訳，音声対話処理などの研究に従事．情報処理学会，人工知能学会，言語処理学会，日本認知科学会，ACL,IEEE 各会員．