帰納的学習を用いた 言い換え文生成ルール自動獲得手法の性能評価

矢野純司* 荒木健治
(北大情報科学)†

1 はじめに

自然言語においては，同じ意味で異なった表現が無数に存在しており，自然言語処理を扱う上でひとつの大きな問題となっている．

言い換えとは「意味内容を保持したまま別の表現へ変える」ということで，システムが言い換えを自動で実現できれば機械翻訳，質問応答，情報検索といったさまざまなシステムに利用可能と考えられる．しかし，言い換えにおいてどのような規則や考え方が必要であるかはまだわかってはいない．

本稿では帰納的学習 [1] を用いて言い換え文を自動的に生成する手法を提案する．帰納的学習では実例により内在する言い換え規則を再帰的に自動獲得し，言い換え文の生成に利用する．学習型の手法で言い換えを扱うことの利点として，事前に細かな規則をシステムに与える必要が無く，新たな実例から言い換え規則を自動で獲得できることが挙げられる．そのため少ないコストでシステムの構築が期待でき，動的に適応可能な利点がある．

本稿では実際に帰納的学習により言い換え文生成ルールを獲得し，言い換え文を生成するシステムを構築し，言い換え文の生成率，言い換え文の正解率により本システムの有効性の確認を行った結果について述べる．

2 処理過程

2.1 入力部

自然言語による日本語の文をユーザの入力とする．入力文を入力部で形態素解析ツール「JUMAN」[2] により語単位に分割し，品詞情報を獲得する．

2.2 学習処理部

言い換え文生成ルール辞書へルールの登録を行う．入力された言い換え文の組，もしくは入力文と出力された正しい言い換え文の組から既存の言い換え文生成ルールと比較し，帰納的学習により，新規のルールを抽出する．獲得されるルールの種類は，品詞情報と字面を元に名詞に着目して名詞を変換する類義語変換ルール，発話の文末表現には大よそのパターンがあること [3] から，文末表現を特別なルールの抽出対象とする文末表現変換ルール，帰納的学習を行い新たなルールを獲得を行う句の変換ルールの３種類がある．帰納的学習では２つのルールを共通部分と差異部分に分解し，共通部分同士，差異部分同士を知識として再帰的に獲得する．また，新たに獲得されたルールと既存のルールを組として，ルール辞書中にある既存のルール全てに対し帰納的学習を行う．

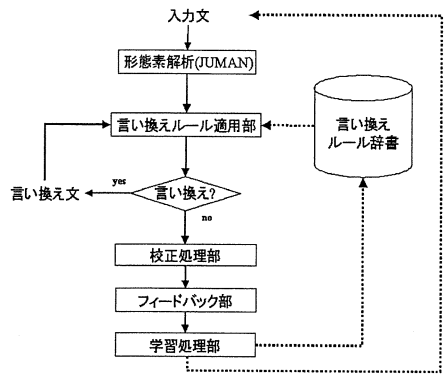


Fig. 1 処理の流れ

2.3 言い換えルール適用部

入力された文に対し言い換え文生成ルールを適用し，言い換え文を生成する．入力された文と言い換え文生成ルール辞書に保存されているルールを字面、品詞情報を用いて一致するか総当りでマッチングを行い，適用可能なルールを選択する．その際ルールが保持している尤度に基づいて行う．言い換えルールの尤度評価式は以下で与えられる．

$$\text{尤度} = \alpha * CF - \beta * EF \tag{1}$$

ここで，CF は正適用度数，EF は誤適用度数，α・β は重み係数である．言い換え文の生成は，変数を持つルールに別のルールを代入して，入力文と同じ表現の文を生成することにより行う．ルールは対で登録されているので，入力文と同じ表現の文の対として，同じ意味内容で表現の違う言い換え文が生成されるという仕組みである．図２に具体的な例を示す．入力文「きみはいつごろ東京へ行きますか？」に対し，適用可能なルールとして (b), (c), (d) がある．変数を持つルール (b) に (c), (d) を代入することで文 (f), (g) の組が得られる．(f) は入力文 (a) と一致するため (g)「あなたは東京へはいつ出発しますか?」が言い換え文として出力される．

2.4 校正処理部

出力された言い換え文が意味的もしくは文法的に正しくない場合にそれに対して人手で校正処理を施す．校正された言い換え文はその後学習処理部で新たな言い換えルールの抽出に利用される．

*j-yano@media.eng.hokudai.ac.jp
†札幌市北区北 14 条西 9 丁目北海道大学大学院情報科学研究科

＜入力文＞
(a):/きみ/は/いつごろ/東京/へ/行き/ます/か/？/
＜言い換え文生成ルール＞
(b)/@0/は/いつごろ/東京/へ/@1/−/@0/は/東京/へ/は/いつ/@1/
(c):/きみ/−/あなた/
(d):/行き/ます/か/？/−/出発/し/ます/か/?/
＜言い換え文生成＞
1st step
(e):/きみ/は/いつごろ/東京/へ/@1/−/あなた/は/東京/へ/は/いつ/@1/
2nd step
(f):/きみ/は/いつごろ/東京/へ/行き/ます/か/？/
(g):/あなた/は/東京/へ/は/いつ/出発/し/ます/か/?/
＜言い換え文の出力＞
(g):/あなた/は/東京/へ/は/いつ/出発/し/ます/か/?/

Fig. 2 言い換え文生成例

2.5 フィードバック部

フィードバック処理は，入力に対し言い換え文の出力があった場合に行う．生成された言い換え文に対し人手により正誤評価を与え，意味的，文法的共に正しい場合には正適用度数CFを＋1，誤りであった場合には誤適用度数EFを＋1とし，言い換え文生成に使用されたルールに対し尤度評価式より自動的に尤度値を更新する．

3 評価実験

3.1 実験方法

本手法を評価するために実際にシステムを構築し，生成される言い換え文に対し評価実験を行った．入力データは人手により，自然言語による日本語文をユーザの入力文とし，300組600文を用意した．ルールの形式が二つの表現の組あるため，入力は2文1組で与え，学習の対象とした．また，実験に際し形態素解析には既存のツール「JUMAN」を用い，言い換え文生成ルール辞書は空の状態からはじめ，同じ意味内容である2文を1組とし帰納的学習，言い換え文の生成を行い，実験，評価を行った．

3.2 評価方法

出力された言い換え文に対し，評価を行った．評価は入力文に対する言い換え文の生成率，言い換え文の正解率を以下のように定義し，性能評価を行った．また，尤度評価式における係数α，βは本実験ではそれぞれ$\alpha=1.0$，$\beta=0.5$とした．

言い換え文生成率

$$= \frac{\text{生成された言い換え文総数}}{\text{入力総数}} * 100 \qquad (2)$$

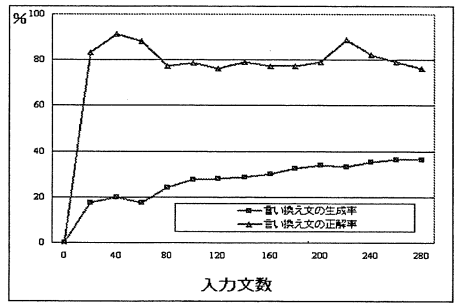


Fig. 3 実験結果

言い換え文正解率

$$= \frac{\text{正しい言い換え文数}}{\text{全言い換え文数}} * 100 \qquad (3)$$

3.3 実験結果

600文300組を用いた実験の結果，最終的な割合として言い換え文の生成率は36.33 %，言い換え文の正解率は67.95%となった．図3に各評価率の推移を示した．

4 考察

図3より言い換え文の生成率が学習が進むにつれ増えている．これは入力の増加と共にルールの獲得数と適用回数が増加しているためで，システムがさまざまな入力文に対しルールを適用できる様になっている．

5 おわりに

本稿では，実例からの帰納的学習により言い換え文を自動的に生成する手法を提案した．さらに，提案手法に基づいてシステムを作成し，評価実験を行った．その結果，入力文数にの増加に伴い言い換え文の生成率は上昇し，最終的に言い換え文の正解率は67.95 %という結果となった．このことから帰納的学習を用いた言い換え文生成手法の有効性を確認することができた．今後は本手法を質問応答システムへ適用，性能の評価を行い，言い換え文の生成率，正解率を向上させるため，ルールの獲得部の改良を行っていく予定である．

参考文献

[1] K.Araki and K.Tochinai : "Effectiveness of Natural Language Processing Method Using Inductive Learning", Proeedings of the IASTED International Conference ARTIFICIAL INTELLIGENCE AND SOFT COMPUTING, pp.295-300, 2001.

[2] 京都大学工学部, 長尾研究室, "日本語形態素解析システムＪＵＭＡＮ" http://www-nagao.kuee.kyotou.ac.jp

[3] 熊本忠彦, 伊藤昭, "ｗｗｗを介した対話システムとの対話におけるユーザの振舞いについて", 情報処理学会論文誌,Vol.40, No.2,pp.422-432, 1999.