12 WWW検索エンジンを利用した用語解説文抽出システム

土橋惇一* 荒木健治
(北大情報科学)†

1 はじめに

今日，我々は様々な情報媒体を介して大量な情報を得られるようになった一方，未知の用語に遭遇する機会が増えている．未知の用語を調べるための情報源として，百科事典や各種専門用語辞典などが挙げられるが，これらは頻繁に改訂されるわけではなく，新たな言葉や既存の言葉に関する新たな定義が日々生みだされている中で，必ずしもそれらに関する情報を得られるわけではない．

近年，インターネットの普及により，個人での情報発信が容易になっている．また，WWW検索エンジンを利用することで，必要な情報を容易に取得することができる．そこで，未知の用語を調べるための手段としてインターネットが有用であることから，WWW検索を利用して，未知の用語に関する説明文をウェブページから抽出し，提示するシステムを提案する．本研究ではこのシステムを用いて用語説明文獲得の実験を行い，その有効性について考察する．

2 WWW検索エンジン

本システムではウェブ検索に既存のWWW検索エンジンを利用する．今日，多くの検索エンジンが存在するが，本システムにおいて高い網羅性を維持するためには，利用する検索エンジンもまた，網羅性の高いものであることが望ましい．

以上の点より，本システムでは検索エンジンとしてGoogle[1]を利用する．Googleを利用する他の利点としては，HTMLだけではなくWord（DOC）やPDFなど，様々な形式の文書ファイルが検索可能である，という点が挙げられる．

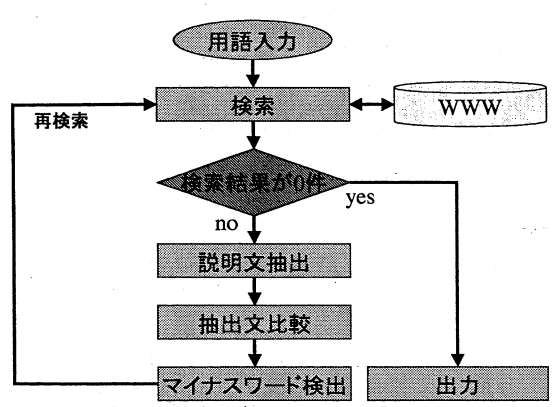


Fig. 1 システムの概要図

jun1@media.eng.hokudai.ac.jp
札幌市北区北14条西9丁目北海道大学大学院情報科学研究科

3 システム概要

本システムの概要図をFig. 1に示す．システムはユーザからの用語入力に対して逐一，WWW上のページから説明文を抽出しユーザに提示する．逐一，検索を行うことで，情報の網羅性および新規性を確保する．

本システムは以下の5つのモジュールによって構成されている．以下の節で，各モジュールの詳細について説明する．

- 用語入力部
- 検索部
- 説明文抽出部
- 抽出文比較部
- マイナスワード検出部

3.1 用語入力部

入力語はユーザにとって未知の用語である．ここで，用語説明の文は「とは」や「である」などの特徴的な表現を含んでいることが多い[2]．これらの表現を付加語として入力語と組み合わせたもの（以下，これをクエリと呼ぶ）を検索キーワードとして検索することで，検索結果において，用語説明を含まないページの出現頻度を小さくすることができる．今回は，付加語「とは」を入力語（仮に「X」とする）の後ろに連結し，「Xとは」をクエリとして検索部に渡している．

3.2 検索部

クエリを含むページを，検索エンジンGoogleを用いて検索する．検索件数は上位30件とし，検索結果として現れたページをテキストデータ形式で保存する．保存したテキストは，書式の統一のため改行や冗長な空白，HTMLタグなどを取り除いておく．

3.3 説明文抽出部

保存したテキストデータより，用語説明がされていると考えられる部分を抽出する．

先に述べたように，用語説明の文は「とは」や「である」などの表現を含んでいることが多い．本システムでは，これらの表現を組み合わせて説明文抽出テンプレートを数種類作成した．テンプレートの例を以下に示す．

- XとはYである
- XはYのことを指す

説明文抽出は，これらのテンプレートに整合した部分を含む一文をテキストデータから抜き出すことで行う．現在は42種類のテンプレートを使用しているが，各テンプレートの性能については未検討である．

3.4 抽出文比較部

説明文抽出の際，異なるページから同じ意味内容の文が抽出されることがある．これはウェブページ作成者によって記述に揺れがあるために起こる問題である．例えば，「X は Y である」と「X は Y です」という文は同じ意味であるが，抽出部によってどちらも抽出される．このように同内容の文を重複して提示した場合，ユーザにとってストレスとなり得るため，本モジュールにて，全抽出文の内容を比較し，説明文の重複した提示を防ぐ．

比較は文の索引語集合でもって行う．まず，抽出した文を「茶筅」[3] によって形態素解析し，名詞と動詞をその抽出文の索引語とする．二つの抽出文から得た索引語集合を比較し，一方の任意の索引語が他方にも存在する場合は，その索引語に 0.1 のスコアを与える．逆に他方に存在しない場合は，その索引語に 1 のスコアを与える．各索引語のスコアの合計を二つの索引語集合間の距離とみなし，この距離がある閾値を超えた場合，二つの文は内容が異なるものであるとみなし，両方の文を提示する．逆に，閾値を超えない場合，二つの文は内容が同じものであるとみなし，一方の文のみを提示する．

3.5 マイナスワード検出部

Google において，語の直前に"−"を付与して検索することにより，その語が含まれるページを除外した検索結果を得ることができる．このように任意の語を除外した検索をマイナス検索という．本研究では，この除外対象となる語をマイナスワードと呼ぶ．

本システムは入力用語に対して何度も検索を行い，多くの情報を獲得する．この際，過去に検索結果に現れ，利用されたページは次回以降では必要ないため，これらのページは次回以降の検索結果に現れない事が望ましい．そこで，前回までに得た説明文中のいくつかの語をマイナスワードとして再検索することで，過去に利用したページを検索結果から除外することができる．

マイナスワードは次のように決定する．まず，前回までに得た説明文に索引付けを行う．ここでは，形態素解析をし，得られた単語のうち名詞のみを索引語とする．次に各索引語に TF・IDF 法によって重み付けをし，最も重みの高い三つの索引語をマイナスワードとしている．

Table 1 実験結果

評価	A	B	C	D	計
情報科学	37	3	0	0	40
医学	34	5	0	1	40
法律	29	8	1	2	40
経済	31	8	0	1	40
化学	34	6	0	0	40
計	165	30	1	4	200

4 実験と考察

本システムを用いて，入力用語に対する説明文提示の実験と考察を行う．

4.1 実験方法と評価方法

情報科学・医学・法律・経済・化学の 5 分野に関する用語を専門用語辞典から各 40 語，計 200 語を無作為に選択し，システムへの入力語とした．

評価は，その専門用語辞典に記載されている文を正解文とし，正解文とシステムが提示した文（以下，出力文と呼ぶ）とを比較することで行う．評価基準は次のように設けている．

- A：出力文が正解文の内容を全て含む
- B：出力文が正解文の内容を 1 部のみを含む
- C：出力文が正解文の内容を全く含んでいない
- D：何も出力されない

ただし，出力文中に正解文の内容以外の文が含まれていた場合でも，A の条件を満たしていれば評価を A とした．

4.2 結果と考察

実験結果を Table 1 に示す．評価 A の総数は全体の 82.5 %，評価 A または評価 B の総数は全体の 97.5 %であり，全体の 97.5 %の用語について少なくとも 1 文以上の正しい説明文提示が可能であった．ただし評価の基準上，出力文には正解文以外の内容の文が含まれているため，これらの文の妥当性を十分に検討する必要がある．

また，入力用語の分野によって実験結果が大きくばらつくこともなかった．これは，用語の分野に問わず，高い網羅性の実現が可能であることを示している．

5 まとめ

本研究では，ウェブページより用語説明文を抽出し提示するシステムを提案した．性能実験を行った結果，9 割以上の用語について 1 文以上の正解文を提示し，また，分野に関わらず高い網羅性を持つことが分かった．今後は文抽出テンプレートの性能実験と，各モジュールの見直しを行い，網羅性の向上に努める．また今回，説明文の抽出は文単位のものであったが，将来的には説明箇所の領域を同定し，領域単位での抽出を行うのが望ましい．

参考文献

[1] Google，http://www.google.com/

[2] 西野　文人，橋本　三奈子，落谷　亮，"テキストからの用語とその定義文の抽出"，言語処理学会第 5 回年次大会発表論文集，pp.124-127，1999.

[3] 茶筅，http://chasen.aist-nara.ac.jp/

[4] 藤井　敦，石川　徹也，"World Wide Web を用いた事典知識情報の抽出と組織化"，電子情報通信学会論文誌，Vol. J85-D-II，No2，pp.300-307，2002.