31 携帯端末を対象とした文字情報縮退方式における入力文予測手法の一検討

亀山恵祐* 木村泰知 荒木健治
(北大情報科学)†

1 はじめに

近年，日本において携帯電話の普及は目覚しく，平成16年3月末現在で約8152万件に達している [1]．この携帯電話の普及には，電子メールの存在が欠かせないと言える．電子メールは携帯電話ユーザの多くが使用しており，一般的なコミュニケーションツールとして，広く普及している．この携帯電話における電子メールの文字入力方法には，携帯端末の大きさやメモリの容量などの制限により，キーボード入力とは異なる，独自の入力方法が考えられてきた．

携帯電話には0から9までの数字と＊，＃の最低12個のキーが装備されている．そこでこれらのボタンを用いた入力方法で，現在の携帯電話に搭載されている手法としてまず文字循環方式が挙げられる．文字循環方式とは，ア行なら1，カ行なら2と子音ごとに数字を割り当て，ア段なら1回，オ段なら5回と，母音により子音に相当するボタンを押す回数を決めて，文字入力を行う方式である．例えば,「そと」と入力したい場合，3(サ行) を5回 (オ段)，4(タ行) を5回 (オ段) 押して入力する．この方式では入力の為の特別な訓練は必要なく簡単に入力できるが，反面，打鍵数が多く，また同じボタンを何度も押すために入力ミスを起こしやすい．そこで，この入力ミスを減少させ，打鍵数の減少を図るために，文字情報縮退方式を用いた入力文予測が考えられてきた [2]．

文字情報縮退方式では，ア行なら1を1回，カ行なら2を1回と子音だけに数字を割り当てて，母音情報なしで文字を入力しようとする手法である．具体的には,「そと」と入力したい場合，3(サ行) を1回，4(タ行) を1回押すだけでよい．この手法では，各子音につき1度のボタン操作で済むため，文字循環方式に比べて明らかに打鍵数を減らせ，かつ入力ミスも減らすことができる．本稿では，更なる打鍵数の減少を目的として，この文字情報縮退方式に予測機能を付与するための一検討について述べる．

2 システム概要

本システムは，松原ら [2] の考案した数字漢字変換システムを応用する．入力として数字列を用い，そこから入力文予測を行って，校正処理，学習処理，フィードバック処理といった過程を踏み，また入力へと戻る．以下にそれぞれの過程について詳しく述べる．

*k_kame@media.eng.hokudai.ac.jp
†札幌市北区北14条西9丁目 北海道大学大学院 情報科学研究科

2.1 予測変換処理部

入力は，12個のキーを用いて，文入力を行う．本処理過程では，この入力された数字列をかな漢字混じり文に変換する．具体的には，まず入力された数字列に対して語情報辞書に登録されている文字の当てはめを行う．これには補完機能を持たせてあり，単語の先頭何文字かを入力すると補完によりその語を出力する．また，この語情報辞書は語が獲得された状況とその変換精度により，階層構造を有している．

これにより，先頭語を決定すると，ここから入力文の予測になる．まず前文の内容を保持し，形態素解析を行い，そこから重要語抽出，重要語と関連の高い語の決定，これらの情報を用いて予測文の生成を行う．以下に予測文生成のフローチャートを示す．

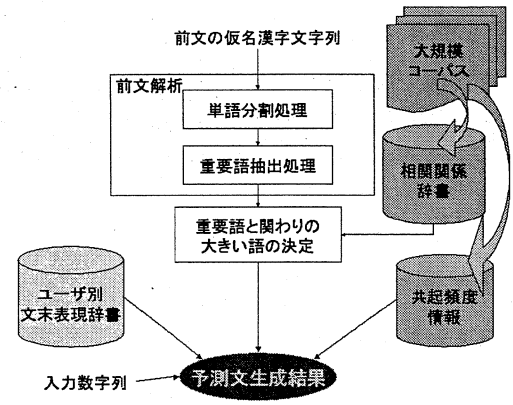


Fig. 1 予測文生成のフローチャート

最初に前文を，形態素解析システム『茶筅』[3] を用いて形態素解析し，単語ごとに分割する．この情報を元に前文の単語の情報量を求め，その値の上位2つを重要語として得る．ここで，ある単語がコーパス中に存在する数が少ないほど，情報量は大きくなる．この情報量の定義により，出現頻度の高い助詞等は情報量が低いために，重要語としては選択されない．ここで重要語の抽出には『茶筅』により形態素解析処理済の大規模コーパス (総単語数:約700万語) から得た情報量の値を用いる．

次に，情報量により求めた重要語と関わりの大きい語を決定するために，相互情報量とDice係数を用いる [4]．相互情報量とDice係数は，以下に示すように単語の共起頻度の度合いを測定するもので，窓として1文中で共起する単語の値を用いることにより，関わりの大きさの度合いを測定する．ここで相互情報量 $I(x,y)$ は，次式 (1)

で表され，$P(x), P(y)$ は単語 x, y が独立に起こる生起確率，$P(x,y)$ は単語 x, y の同時確率である．

$$I(x,y) \equiv \log_2 \frac{P(x,y)}{P(x)P(y)} \quad (1)$$

また Dice 係数 $Dice(x,y)$ は，次式 (2) で表され，f_x, f_y は単語 x, y が独立に出現する回数，f_{xy} は単語 x, y が同時に出現する回数である．

$$Dice(x,y) \equiv \frac{2f_{xy}}{f_x + f_y} \quad (2)$$

これら 2 つの値を情報量算出時に用いた大規模コーパスを使用して求める．こうして求めた重要語と関わりの大きい語に対して，先頭語との bigram を求めて入力文を予測する．

2.2 校正処理部

本処理過程では，予測変換処理部によって提示された入力文に対して，自分の入力したかった文と違った場合に人手による校正処理を行う．これにより校正済み変換結果を得る．

2.3 学習処理部

本処理過程では，校正済み変換結果とその子音数字列から語を獲得し，語情報辞書に登録する．校正済み変換結果とその子音数字列の比較から共通部分，差異部分を抽出する．ここで共通部分とは，校正済み結果中のかな部分と，それに対応する入力数字列中の部分数字列である．差異部分とは共通部分に挟まれる部分である．

2.4 フィードバック処理

本処理過程では，語を語情報辞書に獲得する際に，その語の情報を共に獲得する過程である．ここで獲得する情報は，正変換，誤変換のそれぞれの度数で，それらより求められる語の正変換率を CR，誤変換率を ER と呼び，この値を用いて，語情報辞書の階層構造の効率化，活性化を図っている．

3 評価実験

3.1 実験目的

ここでは，どの程度予測が可能であるのか，実際のメールの送信文を 1 文用いて評価する．ここで用いたのは第一著者の携帯のメールの送信文である．

3.2 実験方法

システム概要の予測変換処理部でも述べたが，入力したい文の前に入力した文の情報を用いたいので，前文の形態素解析結果から，情報量による重要語の抽出を行う．そしてその重要語と相関関係の高い語を取り出し，先頭語との bigram 値により予測語を決定，さらに bigram 値を用いてそれに続く語を付与する．

3.3 実験結果

Table 1 が予備実験の結果例である．

Table 1 予測語の抽出例

前文解析結果　重要語：疲れ		
入力数字：84　⇒　文頭語：ゆっくり		
正解文:ゆっくり休んで！		
	予測文 (相互情報量)	予測文 (Dice 係数)
1	**ゆっくり/休ん/で**	ゆっくり/寝/て
2	ゆっくり/のんびり/と	ゆっくり/体/の
3	ゆっくり/寝/て	ゆっくり/お/問い合わせ
4	ゆっくり/体/の	ゆっくり/のんびり/と
5	ゆっくり/どうぞ/ご	ゆっくり/どうぞ/ご
6	ゆっくり/お/問い合わせ	**ゆっくり/休ん/で**

3.4 考察

以上の結果より，情報量や，相互情報量，Dice 係数を使えば，予測が可能であることが示された．実際に入力したい文と違っていても，文として意味をなしているので他に同じ前文から違う文を入力したい時にも有効であると考えられる．よって今回の手法が有効である可能性がある．ただ大きな問題点として，bigram 値と相互情報量，または Dice 係数の値の兼ね合いがある．今後予備実験により最適値を見つけ，実装しなければならない．

4 まとめ

本稿では，携帯端末を対象とした文字情報縮退方式における入力文予測手法について検討した．評価実験により，本手法が入力文の予測に有効である可能性が示された．今後は考察に述べたように，bigram 値と相互情報量，または Dice 係数の値の兼ね合いについて予備実験を通して最適値を見つける．また，更なる予測精度の向上を目指し，複数のユーザのメールを用いて実験を行い，打鍵数減少の効果を評価する予定である．更にユーザに適応した予測手法も実装していく予定である．

参考文献

[1] 社団法人　電気通信事業者協会 (TCA), http://www.tca.or.jp/.

[2] 松原雅文 荒木健治 桃内佳雄 栃内香次, "文字情報縮退方式を用いた帰納的学習によるべた書き文の数字漢字変換手法の有効性について", 電子情報通信学会論文誌 (D-II), Vol.J83-D-II, No.2, page.690–702, 2000.

[3] 松本裕治 他, 日本語形態素解析システム『茶筅』

[4] 北村美穂子 松本裕治, "対訳コーパスを利用した対訳表現の自動抽出", 情報処理学会論文誌, Vol.38, No.4, page.727–736, 1997.