論　文

隣接情報学習を用いた多言語対訳コーパスからの対訳語の自動抽出

越前谷　博[†a)]　　荒木　健治[††]　　桃内　佳雄[†]

Automatic Extraction of Bilingual Word Pairs from Parallel Corpora with Various Languages Using Learning for Adjacent Information

Hiroshi ECHIZEN-YA[†a)], Kenji ARAKI[††], and Yoshio MOMOUCHI[†]

あらまし　本論文では，言語リソースの乏しい言語も含めた，様々な言語の対訳コーパスから対訳語を効率良く抽出する手法として，隣接情報学習を用いた対訳語の自動抽出手法を提案する．提案手法では，対訳語と隣接関係にある単語列の情報を獲得し，それを用いることで，単語間の対応関係のあいまい性を解消する．獲得される情報は，対訳文において抽出対象の対訳語の原言語の単語に隣接する単語列が目的言語文中のどの単語列に対応するのかの情報，更に，対応する目的言語文中の単語列とどのような隣接関係にある単語が対訳語の目的言語の単語となるのかの情報である．性能評価実験では，本手法に基づくシステムを用いて，原言語の異なる 5 種類の対訳コーパスから対訳語を自動抽出した結果，60.1%の抽出率が得られた．この結果は，Dice 係数に基づくシステムの抽出率に比べ，8.0 ポイント高い値であり，本手法の有効性が確認された．

キーワード　対訳語，隣接情報，学習，多言語，類似度

1. まえがき

対訳コーパスは，計算機で扱うデータとして利用する以外にも，新たな言語を学習する際の教材としても利用価値が高い．そのため，言語習得教材として用例集を掲載した多くの書籍やインターネットサイトが存在している．このような用例集をよりいっそう有効利用するために，単語レベルの対応関係をユーザに提供することは重要と考えられる．文レベルの対応関係のみが示されているよりも，単語レベルでの対応関係も得られた方がユーザにとって有益である．しかし，対訳文をベースにした教材には，単語レベルの情報が存在しないものや対訳文とは関連なくそれが掲載されているものも多い．その際に，ユーザが手作業で単語情報を得ることは，不慣れな言語の場合，負担が大きく効率も悪い．こうした状況において，対訳コーパスからの対訳語の自動抽出は非常に有効と考えられる．そこで，本論文では，新たな言語の学習教材として対訳文を利用するユーザの支援を目的に，言語解析ツールなどの言語リソースが乏しい言語も含め，様々な言語の対訳コーパスから対訳語を効率良く自動抽出する手法を提案する．

対訳対を自動抽出する手法として Dice 係数により類似度計算を行い，その結果を利用する手法の有効性が既に報告されている [1], [2]．しかし，そこではデータスパースネスの問題が指摘されている．例えば，(There is your book on the table.；テーブル/に/あなた/の/本/が/あり/ます．(注1)) の “book” の対訳語を式 (1) の Dice 係数 [4], [5] を用いて抽出することを考える．

$$Dice(X,Y) = \frac{2 \times f_{XY}}{f_X + f_Y} \tag{1}$$

f_X と f_Y は単語 X，Y が独立に出現する頻度であり，f_{XY} は単語 X，Y が対訳文中に同時に出現する頻度である．ここで，“book”，“本”，そして，“テーブル” が先述した対訳文のみに出現する場合，“book” と “本” の類似度と “book” と “テーブル” の類似度は

† 北海学園大学工学部，札幌市
Faculty of Engineering, Hokkai-Gakuen University, Minami 26 Nishi 11, Chuo-ku, Sapporo-shi, 064–0926 Japan
†† 北海道大学大学院情報科学研究科，札幌市
Graduate School of Information Science and Technology, Hokkaido University, Kita 14 Nishi 9, Kita-ku, Sapporo-shi, 060–0814 Japan
a) E-mail: echi@eli.hokkai-s-u.ac.jp

(注1)：“/” は単語の境界として用いている．本論文では，日本語文の単語分割は日本語形態素解析ツール「茶筌」[3] を用いて行う．

ともに，1.0 ($= \frac{2\times1}{1+1}$) となり，“book” の対訳語を一意に決定することができない．このように，出現頻度に基づく手法では，単語間の対応関係にあいまい性が生じ，対訳語を一意に抽出できない場合がある [2], [6]．

そこで，我々は，対訳語と隣接関係にある単語列の情報を自動獲得し，それを利用することでこの問題の解決を図る．すなわち，対訳文において抽出対象の対訳語の原言語の単語に隣接する単語列が目的言語文中のどの単語列に対応するのかの情報と，対応する目的言語文中の単語列の左右のどちらに隣接している単語が対訳語の目的言語の単語となるのかの情報を獲得する．これらの情報を用いることにより，出現頻度だけでは対応関係のあいまい性を解消できない場合でも，対訳語を一意に抽出できる．例えば，先述した例の場合，“book” に隣接する単語列 “your” が “あなた/の” と対応関係にあるという情報，更に，“your” の右側に “book” が隣接する場合，日本語文では “あなた/の” の右側に “本” が隣接するという情報を獲得することで，“book” と “本” の対応関係を決定できる．

なお，このような隣接情報は，解析的な知識を用いて得るのではなく，学習の観点 [7], [8] により自動的に獲得する．その結果，使用する対訳コーパスの置き換えだけで，システムの変更を必要とせずに様々な言語に対処できる．このような考え方に基づき，本論文では，多言語対訳コーパスから対訳語を効率良く抽出する，隣接情報学習を用いた対訳語の自動抽出手法を提案する．隣接情報学習とは，隣接情報を自動獲得し，それを利用することで対訳語を抽出する処理である．性能評価実験では，英語と日本語，フランス語と日本語，ドイツ語と日本語，上海語と日本語，そして，アイヌ語と日本語の 5 種類の対訳コーパスを対象に，本手法に基づくシステムを用いて対訳語の自動抽出を行った．その結果，個々の対訳コーパスでは 56.7〜62.9%，全体では 60.1%の抽出率が得られた．また，隣接情報学習を用いない，Dice 係数のみに基づくシステムにおいては，個々の対訳コーパスの抽出率は 47.9〜54.9%となり，全体の抽出率は 52.1% であった．本手法により全体の抽出率は 8.0 ポイント向上し，その有効性が確認された．

2. 処 理 概 要

本手法は，形態素情報が付与された対訳文が用意されていれば特定の言語に依存することなく，対訳語を自動抽出できる．それは，対訳コーパスを他の言語の対訳コーパスに置き換えるだけで，システムの変更を必要としないことを意味する．本手法に基づくシステムの処理概要を図 1 に示す．対訳コーパス中の文が膠着語の場合には，あらかじめ単語分割する．

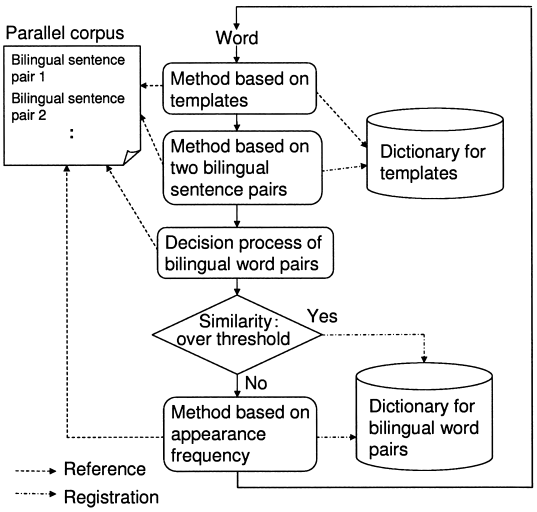


図 1 処 理 概 要
Fig. 1 Process flow.

抽出対象の対訳語の原言語の単語(注2)を入力してから，対応関係にある目的言語の単語を決定し，対訳語を得るまでの本システムの処理の流れを述べる．本システムは大きく二つの処理からなる．隣接情報学習に基づき対訳語を抽出する処理と隣接情報学習を用いずに出現頻度のみに基づき対訳語を抽出する処理である．更に，隣接情報学習はテンプレート方式（Method based on templates），対訳文ペア方式（Method based on two bilingual sentence pairs），そして，対訳語決定処理部（Decision process of bilingual word pairs）の三つの処理を有する．テンプレート方式では，それまでに獲得されたテンプレートを用いて対訳語を抽出する．本論文におけるテンプレートとは対訳語を抽出するための隣接情報を有する対訳知識である．対訳文ペア方式では，対訳文のペアに基づき対訳語と新たなテンプレートを得る．抽出された対訳語とテンプレートには類似度が付与され，テンプレートはテンプレート辞書に登録される．なお，類似度は対訳コーパスを参照することで得られる．複数の対訳語が得られた場

(注2)：対訳語に用いる単語は 1 語以上でも構わないため，正確には 1 語以上の単語列と記すべきであるが，隣接情報の単語列と区別するために，本論文では便宜上，対訳語に使用される 1 語以上の単語列はすべて “単語” と記述している．

合には，対訳語決定処理部において，対訳語を一意に決定する．ここで，選択された対訳語の類似度がしきい値以上の場合には，その対訳語を対訳語辞書に登録する．

そして，選択された対訳語の類似度がしきい値未満の場合，若しくは，隣接情報学習において全く対訳語が抽出されなかった場合には，有効な隣接情報が得られなかったとして，出現頻度のみに基づき改めて対訳語を抽出する．出現頻度ベース方式（Method based on appearance frequency）では，隣接情報学習を用いずに，出現頻度のみに基づき対訳語を一意に抽出する．そして，選択された対訳語を対訳語辞書に登録する．

3. 隣接情報学習の処理内容

3.1 対訳文ペア方式

対訳文ペア方式による，対訳語の抽出処理及びテンプレートの獲得処理について述べる．本手法では，テンプレートを得るために，原言語文間と目的言語文間の両方において表層レベルで一致する単語列（以後，共通部分と呼ぶ.）を利用する．共通部分を利用することにより，テンプレートとして使用する単語列を決定する．また，抽出された対訳語とテンプレートに対しては，その信頼性を定量的に表すために Dice 係数に基づく類似度を使用する．

3.1.1 対訳語の抽出処理

はじめに，対訳文ペア方式による対訳語の抽出処理について述べる．以下に，その処理の詳細を述べる．

(1) 抽出対象の対訳語の原言語の単語が存在する対訳文を対訳コーパスから選択する．

(2) 選択された対訳文と対訳コーパス中の他の対訳文において，対訳語の原言語の単語に隣接する単語列を共通部分にもち，かつ，目的言語文間で共通部分が存在する対訳文を対訳コーパスから選択する．

(3) 目的言語文間において，以下の処理を行う．

i) 文頭の語に最も近い共通部分を対象に，共通部分の左に隣接する語から文の先頭までの部分を抽出する．

ii) 文末の語に最も近い共通部分を対象に，共通部分の右に隣接する語から文の末尾までの部分を抽出する．

iii) 共通部分が二つ以上存在する場合，すべての共通部分の組合せを用いて，共通部分に挟まれた部分を抽出する．

(4) 目的言語文から抽出された部分の品詞を調べる．その結果，抽出された部分が名詞，動詞，形容詞，副詞，接続詞，助詞を含まない名詞句，助詞を含まない動詞句のいずれにも該当しない場合には破棄する．

(5) 処理 (4) の結果，残った部分を対訳語の目的言語の単語候補とし，それらと対訳語の原言語の単語との類似度を式 (2) を用いて求める．そして，原言語の単語と目的言語の単語の組を対訳語とする．

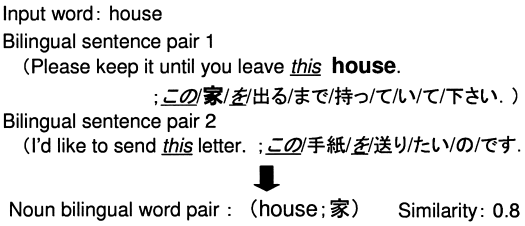


図 2 対訳文ペア方式による対訳語の抽出例
Fig. 2 An example of extraction of bilingual word pair using method based on two bilingual sentence pairs.

$$sim(W_S, W_T) = \frac{2 \times f_{ST}}{f_S + f_T} \tag{2}$$

ここで，f_S は単語 W_S が原言語文に独立に出現する頻度，f_T は単語 W_T が目的言語文に独立に出現する頻度，そして，f_{ST} は単語 W_S，W_T が対訳文中に同時に出現する頻度である．北村ら [2] は，式 (2) に対し，同時出現頻度に基づく重み付けを行った Dice 係数を提案している．しかし，今回のタスクのように低頻度語が多くを占めることが予想される場合には，同時出現頻度を考慮しても対訳語の抽出精度に対する効果は低いと考えられるため，本論文では，同時出現頻度による重み付けは行っていない．

なお，処理 (4) の品詞情報は，日本語形態素解析ツール「茶筌」[3] を用いて得る．

図 2 に英日の対訳文を用いた場合における，対訳文ペア方式による対訳語抽出の具体例を示す．対訳文ペア方式により，単語 “house” の対訳語として（house；家）が得られた．ここでは，対訳語の原言語の単語 “house” が出現する対訳文 1 に対し，“house” に隣接する単語列 “this” を共通部分にもち，かつ，目的言語文間においても共通部分として “この” と “を” が存在する対訳文 2 を選択する．この場合，目的言語文間においては，処理 (3) の iii) により，二つの共通部分 “この” と “を” に挟まれた単語 “家” が対訳文 1 の目的言語文から抽出される．次いで，処理 (5) により，入力された単語 “house” と抽出された単語 “家” の組合せを対訳語とし，式 (2) を用いて類似度を計算する．

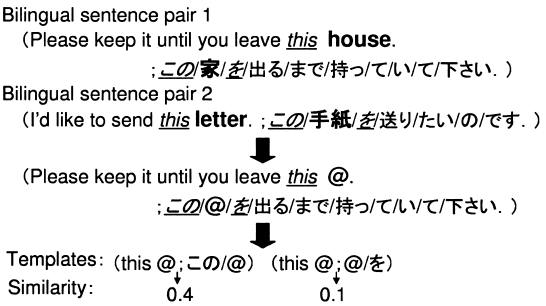


図 3 対訳文ペア方式によるテンプレートの獲得例
Fig. 3 An example of acquisition of templates using method based on two bilingual sentence pairs.

複数の対訳語が抽出された場合には，**3.3** の対訳語決定処理部により対訳語を一意に決定する．

3.1.2 テンプレートの獲得

ここでは，**3.1.1** の処理で得られた対訳語とそれに隣接する共通部分を利用して，テンプレートを獲得する．以下に処理の詳細を述べる．なお，以下の処理過程は，**3.1.1** で述べた処理を継続している．

(1) 原言語文と目的言語文において，対訳語が存在していた部分を変数に置き換える．

(2) 原言語文と目的言語文のそれぞれにおいて，共通部分と変数の組を抽出し，それらを組み合わせてテンプレートを得る．

(3) テンプレート中の原言語の単語列と目的言語の単語列との類似度を式 (2) を用いて求める．そして，その類似度を付与し，テンプレート辞書に登録する．

図 3 に英日の対訳文を用いた際の対訳文ペア方式によるテンプレートの獲得例を示す．図 3 では，テンプレートとして（this @；この/@）と（this @；@/を）が獲得された．処理 (1) により，抽出された単語 “house” と “家” を変数 “@” に置き換える．処理 (2) により，共通部分と変数の組を抽出する．原言語文においては，共通部分が “this” のみであり，その右側に変数が存在するため “this @” が抽出される．目的言語文においては，“この” と “を” の二つの共通部分が存在するため，“この/@” と “@/を” が抽出される．そして，それらを組み合わせることでテンプレートとして（this @；この/@）と（this @；@/を）が得られる．

ここで，テンプレート（this @；@/を）の単語列 “this” と “を” は誤った対応関係である．日本語文においては，助詞，助動詞や「する」,「ある」などの動詞は頻繁に出現するため，それらが共通部分となる確率は非常に高い．その場合，原言語によっては，それらに対応する語が存在しないため,（this @；@/を）のような誤ったテンプレートの獲得を導くことになる．しかし，そのようなテンプレートは正しいテンプレートに比べ，類似度が低下する．例えば,（this @；@/を）の場合，“を” の出現頻度は非常に高くなる．しかし，“を” は “this” と対応関係にはないため，それらが同時に出現する可能性は低い．したがって，式 (2) の f_T のみが f_{ST} や f_S に比べ，非常に高くなり，類似度は低下すると考えられる．このように出現頻度の高い単語列であっても原言語と目的言語間で対応関係が成立しない場合は，類似度は低下する．

一方，テンプレート（this @；この/@）においても，“this” に対応する単語列は “この” のみではなく “これ” も存在する．更に,（this evening；今晩）などのように “この” が出現しない場合もあるため，必ずしも，対応関係が正しい場合であっても，類似度が高いとは限らない．本手法では，対応関係の正しいテンプレートの類似度が常に絶対値として高いことを要求するのではなく，対応関係の誤ったテンプレートに比べ，対応関係の正しいテンプレートの類似度が相対的に高くなることを想定している．その結果，抽出された対訳語自体の類似度だけでは差別化ができない場合でも，隣接関係にある単語列の類似度を反映することで抽出された対訳語に対する差別化ができると考えられる．なお，本論文では，テンプレートの原言語の単語列を原言語部分，目的言語の単語列を目的言語部分と呼ぶ．

また，本手法では，テンプレートとして（this @；この/@/を）ではなく，変数を境に左右の共通部分を切り離して得られる,（this @；この/@）と（this @；@/を）を用いる．これは，そのことによりテンプレートの適用範囲が広がり，多くの対訳語の抽出に有効となるためである.（this @；この/@/を）をテンプレートとした場合，日本語文に “この” と “を” がこの順序で同時に出現しなければ適用されない．それに対し,(this @；この/@) と（this @；@/を）は（this @；この/@/を）に比べ適用条件が緩く適用範囲が広がるため，より多くの対訳語を抽出できると考えられる．

3.2 テンプレート方式

ここでは，**3.1.2** で述べた処理により獲得されたテンプレートを用いて対訳語を自動抽出する処理について述べる．テンプレートを用いることにより，単語間の対応関係のあいまい性が解消され，対訳語を一意に抽出することができる．以下に処理の詳細を述べる．

(1) 抽出対象の対訳語の原言語の単語が出現する対訳文を選択する．

(2) 選択された対訳文とテンプレート辞書中のテンプレートを比較する．その結果，対訳語の原言語の単語に隣接する単語列と原言語部分が一致し，かつ，目的言語部分が目的言語文中の単語列と一致するテンプレートをテンプレート辞書から選択する．

(3) 対訳文の原言語文とテンプレートの原言語部分との間で，以下の条件を満たさない場合には，そのテンプレートを破棄する．

i) テンプレートの原言語部分の右側に変数が存在する場合，原言語文において対訳語の原言語の単語が共通部分の右側に隣接しなければならない．

ii) テンプレートの原言語部分の左側に変数が存在する場合，原言語文において対訳語の原言語の単語が共通部分の左側に隣接しなければならない．

(4) 処理 (3) の条件を満たすテンプレートを用い，対訳文の目的言語文に対し，以下の処理を行う．

i) 選択されたテンプレートの目的言語部分の変数が右側に存在する場合，目的言語文から共通部分の右側に隣接する名詞，動詞，形容詞，副詞，接続詞，助詞を含まない名詞句，助詞を含まない動詞句を抽出する．

ii) 選択されたテンプレートの目的言語部分の変数が左側に存在する場合，目的言語文から共通部分の左側に隣接する名詞，動詞，形容詞，副詞，接続詞，助詞を含まない名詞句，助詞を含まない動詞句を抽出する．

(5) 目的言語文から抽出された部分を対訳語の目的言語の単語とし，対訳語の原言語の単語との類似度を式 (2) により求め，その単語の組を対訳語とする．

(6) 他に選択されたテンプレートが存在する場合には，処理 (4) から処理 (5) を繰り返す．

図 4 に英日の対訳文を用いた際のテンプレート方式による対訳語の抽出例を示す．抽出例 1 では図 3 で獲得されたテンプレート（this @；この/@）を用いて対訳語（parcel；小包）が得られた．また，抽出例 2 ではテンプレート（to @；@/に）に基づき対訳語として（eat；食べ(注3)）が得られた．抽出例 1 では，テンプレート（this @；この/@）の “this” と “この” が，対訳文 1 との共通部分として存在する．そのため，対訳文 1 の目的言語文から処理 (4) の i) により，“この” の右側に隣接する名詞 “小包” が抽出される．抽出例 2 では，目的言語文から処理 (4) の ii) により共通部分 “に” の左側に隣接する動詞 “食べ” が抽出される．

このように，本手法では，英日のような語順が大きく異なる言語間においても，テンプレートがその語順の違いを反映した対訳知識となっているため，正しい対訳語の抽出が可能である．テンプレート方式により，複数の対訳語が抽出された場合には，**3.3** の対訳語決定処理部より対訳語を一意に決定する．

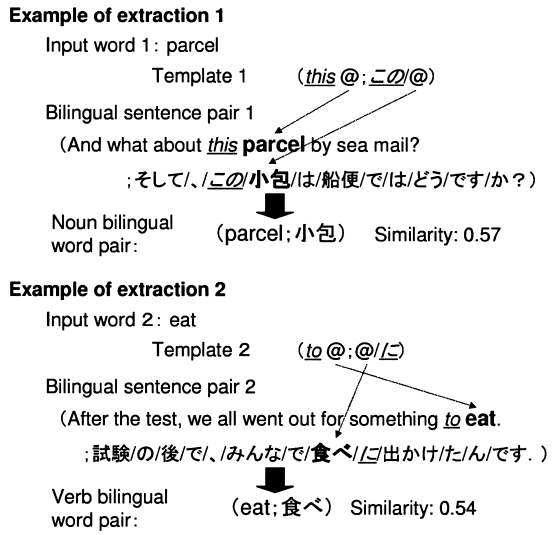


図 4　テンプレート方式による対訳語の抽出例
Fig. 4　Examples of extraction of bilingual word pairs using method based on templates.

3.3　対訳語決定処理部

3.1 の対訳文ペア方式と **3.2** のテンプレート方式により，複数の対訳語が得られた場合，類似度に基づく順位付けを行う．その結果，上位 1 位の対訳語のみが対訳語辞書へ登録される．以下に処理の詳細を述べる．

(1) 類似度が最も高い対訳語を選択する．

(2) 処理 (1) の結果，複数の候補が存在する場合，隣接する単語列の類似度が最も高い対訳語を選択する．

(3) 処理 (1)，(2) の結果，複数の候補が存在する場合，対訳コーパスに最初に出現する対訳語を選択する．

(注3)：類似度を付与した後，対訳語を対訳語辞書に登録する際には，原言語の語に対しては対訳文で使用されている表現のままの形を用いる．目的言語の抽出結果に対しては，“食べ” のように動詞において語尾が活用変化したままの表現の場合，より適切な表現形を対訳語辞書に登録するために基本形を用いる．したがって，この場合は，(eat；食べる) が対訳語辞書に登録される．ただし，目的言語の抽出結果が “食べた” のように動詞の後に助動詞が続いている場合には，基本形に変形してしまうと時制の情報が削除されることになり言語間の対応関係が崩れてしまうため，出現形を対訳語辞書に登録する．

また，類似度計算の際には，原言語，目的言語共に出現形を用いる．目的言語のみに基本形を用いると，言語間の対応関係が崩れ，類似度の信頼性を低下させる場合がある．したがって，本論文では，目的言語に対する基本形の使用は，対訳語辞書への登録時，すなわち，対訳語を抽出した後の後処理に限定している．

このような順位付けの結果，上位 1 位になった対訳語の類似度がしきい値以上の場合，その対訳語を対訳語辞書に登録する．

3.4 新たなテンプレートの獲得に伴う対訳語の抽出

2. の処理に基づき対訳語を抽出する場合，入力単語の増加に伴い，テンプレートは増加する．そのため，ある単語の入力時に獲得されたテンプレートが，その前に入力された単語の対訳語の抽出処理には適用されず，処理の最初の段階と最後の段階とで抽出率に偏りが生じるという問題や入力する単語の順番が変わることにより抽出率が変動するという問題が生じる．このような問題を解決するために，**2.** の処理に基づきすべての入力単語が処理された後，新たに獲得されたテンプレートのみを用い，対訳語辞書中のすべての入力単語に対してテンプレート方式を適用する．図 5 に新たなテンプレートが獲得された場合の対訳語の抽出処理の流れを示す．ここでは，すべての入力単語が対訳語辞書に登録されていることを前提としている．これは，名詞，動詞，形容詞，副詞，接続詞の対訳語を抽出対象とした場合，**2.** の処理の結果，基本的にはすべての入力単語に対して対訳語が得られるとの考えに基づいている．この前提の詳細については，**5.3** で述べる．

対訳語辞書に登録されている対訳語の原言語の単語が一つずつ入力されると，新たに獲得されたテンプレートによるテンプレート方式が適用される．その結果，複数の対訳語が得られた場合には，対訳語決定処理部において，対訳語を一意に決定する．対訳語決定処理部では，**3.3** で述べたように，対訳語の類似度や対訳語に隣接するテンプレートの類似度に基づき最適な対訳語を決定する．次に，新たに抽出された対訳語の類似度としきい値を比較する．類似度がしきい値未満の場合には，抽出された対訳語は誤っている可能性が高いと考えられるため破棄する．しきい値以上の場合には，以下の処理を行う．対訳語辞書に既に登録されている対訳語が隣接情報学習により抽出された対訳語の場合，既に登録されている対訳語と新たに抽出された対訳語のどちらを対訳語辞書に登録すべきかを決定する．具体的には，対訳語決定処理部を適用し，そこで決定された対訳語を対訳語辞書に登録する．また，対訳語辞書に既に登録されている対訳語が，Dice 係数に基づく出現頻度ベース方式により抽出された対訳語の場合には，既に登録されている対訳語を新たに抽出された対訳語と置き換える．これは，隣接情報学習により抽出され，かつ，類似度がしきい値以上である対訳語は，**2.** の処理と同様に，出現頻度ベース方式で抽出された対訳語よりも優先されるためである．

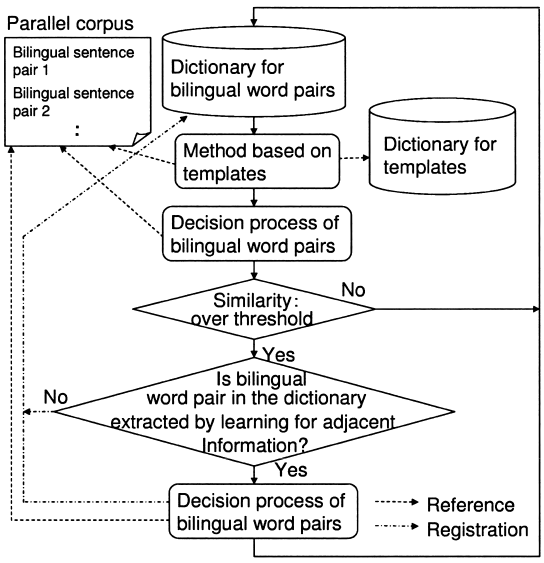


図 5 新たなテンプレートの獲得に伴う対訳語抽出の流れ
Fig. 5 Process flow in acquisition of new templates.

このような処理を用いることで，図 2 と図 4 の抽出例 1 で示した “house” と “parcel” の対訳語の抽出処理を入力順に関係なく行うことができる．**2.** の処理では，最初に “parcel” を入力した際にはテンプレートが存在しないため，隣接情報学習では対訳語（parcel；小包）は抽出されない．次いで，“house” が入力されると図 2，図 3 に示した処理により対訳語（house；家）とテンプレート（this @；この/@），(this @；@/を）が得られる．その後，本処理が行われることで改めて “parcel” が入力単語となり，図 4 の抽出例 1 の処理により対訳語（parcel；小包）が抽出される．対訳語（parcel；小包）の類似度がしきい値以上の場合には，隣接情報学習により抽出された（parcel；小包）が対訳語辞書に登録される．

4. 出現頻度ベース方式の処理内容

対訳語決定処理部によって選択された対訳語の類似度がしきい値未満の場合，若しくは，隣接情報学習において全く対訳語が抽出されなかった場合には，隣接情報学習を用いずに，出現頻度のみに基づき改めて対訳語を抽出する．以下に処理の詳細を述べる．

(1) 抽出対象の対訳語の原言語の単語が存在する対

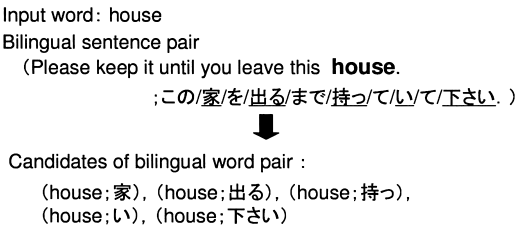


図 6　出現頻度ベース方式による対訳語の抽出例
Fig. 6　An example of extraction of bilingual word pair using method based on appearance frequency.

訳文を選択する．

(2) 選択された対訳文の目的言語文からすべての名詞，動詞，形容詞，副詞，接続詞，助詞を含まない名詞句，助詞を含まない動詞句を抽出する．

(3) 目的言語文から抽出されたすべての単語と対訳語の原言語の単語との類似度を式 (2) により求め，類似度が最も高い対訳語を選択する．類似度が等しい複数の対訳語が存在する場合は，対訳コーパスに最初に出現する対訳語を選択する．

図 6 に出現頻度ベース方式における対訳語の抽出例を示す．抽出対象の対訳語の原言語の単語 “house” が存在する対訳文の目的言語文から，名詞 “家”，動詞 “出る”，“持っ”，“い”，“下さい” が抽出された．そして，単語 “house” と目的言語文から抽出されたすべての単語との類似度を式 (2) により求める．その結果，類似度がすべて同じ場合には，対訳文に最初に出現する（house；家）が結果的に選択され，対訳語辞書に登録される．出現頻度ベース方式により抽出される対訳語は，対訳コーパス中のすべての候補の中で最大の類似度を有する対訳語であるため，最も信頼性が高いとして，しきい値に依存することなく対訳語辞書に登録する．

5. 性能評価実験

5.1 実験方法

実験データとして用いた対訳コーパスは英語－日本語，フランス語－日本語，ドイツ語－日本語，上海語－日本語，アイヌ語－日本語対訳コーパスの 5 種類である．対訳コーパス中の対訳文は文献 [14]～ [18] に掲載されている対訳文を使用した．これらの対訳コーパスの中で単語分割が必要な膠着語は，日本語と上海語である．日本語文の単語分割は，日本語形態素解析ツール「茶筌」[3] を用いて行った．上海語については，

表 1　対訳コーパスの内訳
Table 1　Details of parallel corpora.

原言語	対訳文数	原言語文の 1 文平均語数	目的言語文の 1 文平均語数
英語	393	7.4	8.6
フランス語	399	6.8	9.0
ドイツ語	377	6.2	8.5
上海語	392	6.4	8.9
アイヌ語	233	7.8	9.3
合計	1,794	6.8	8.8

文献 [17] に掲載されている文はすべて単語分割されていた．対訳コーパスの内訳を表 1 に示す．なお，対訳コーパスの目的言語はすべて日本語である．

実験は，図 1 及び図 5 の処理に基づくシステムを用いて，原言語が異なる五つの対訳コーパスについて個別に行った．抽出対象となる対訳語は文献 [14]～ [18] の単語一覧に掲載されている，すべての名詞，動詞，形容詞，副詞，接続詞の対訳語である．対訳語辞書及びテンプレート辞書を空の状態にした後，表 1 の英語－日本語対訳コーパスから対訳語を抽出する．この処理を同じシステムを用いてフランス語－日本語，ドイツ語－日本語，上海語－日本語，アイヌ語－日本語対訳コーパスに対しても同様に行った．

なお，図 1 及び図 5 の処理で使用するしきい値には，0.1 から 1.0 まで 0.1 ずつ増加させた値を用いた．

5.2 評価方法

抽出された対訳語の評価は，文献 [14]～ [18] に掲載されている単語一覧の訳に準拠し，人手で行った．そして，その結果に基づき抽出率を以下の式 (3) により求めた．抽出対象の対訳語の数は異なり語数である．

$$\text{抽出率 (\%)} = \frac{\text{抽出された正しい対訳語の数}}{\text{抽出対象の対訳語の数}} \times 100 \qquad (3)$$

5.3 実験結果

本手法の有効性を確認するために，Dice 係数に基づくシステムとの比較実験を行った．表 2 に本システムと Dice 係数に基づくシステムの抽出率を示す．Dice 係数に基づくシステムとは，**4.** で述べた出現頻度ベース方式のみに基づき構築されたシステムである．表中の対訳語数とは，抽出対象の対訳語の数である．また，A は本システムにより新たに抽出された対訳語の数，B は本システムにより抽出されなくなった対訳語の数である．本システムの実験結果は，しきい値として 0.5 を用いた場合の抽出率である．しきい値の決定については，**5.4.2** で詳細を述べる．

表 3　隣接情報学習により抽出された対訳語の具体例
Table 3　Examples of bilingual word pairs extracted learning for adjacent information.

原言語	正しい対訳語	誤った対訳語	
		抽出された対訳語	正しい訳
英語	(cereal；シリアル) 1.0 (boarding house；下宿) 1.0	(curtains；新しい) 0.67 (interesting；外) 0.67	カーテン おもしろい
フランス語	(monuments；記念/建造/物) 1.0 (cherche；探し) 0.67	(surtout；関係) 1.0 (petit；所) 0.67	特に 小さい
ドイツ語	(nämlich；つまり) 0.67 (das Foto；写真) 1.0	(Wege；橋) 1.0 (Neues；新聞) 0.67	道 新しいこと
上海語	(下班；退勤/し) 1.0 (大閘蟹；上海/ガニ) 1.0	(中飯；ご馳走/し) 1.0 (夜飯；サービス) 0.67	昼食 夕食
アイヌ語	(ekupa；くわえ) 1.0 (set；寝床) 1.0	(apto；降っ) 1.0 (tunasno；起き) 0.67	雨 早く

表 2　実 験 結 果
Table 2　Results of evaluation experiments.

原言語	Dice 係数	本システム	対訳語数	A	B
英語	49.7%	58.0%	169	18	4
フランス語	47.9%	56.7%	240	27	6
ドイツ語	53.3%	61.0%	195	20	5
上海語	54.9%	62.9%	264	30	9
アイヌ語	54.0%	61.5%	213	25	7
合計	52.1%	60.1%	1,081	120	31

表 3 に，しきい値に 0.5 を用いた場合の隣接情報学習により抽出された対訳語の具体例を示す．表中の正しい対訳語は表 2 の A に該当する対訳語であり，誤った対訳語は表 2 の B に該当する対訳語である．また，表中の対訳語に付与されている数値は類似度である．

本システムでは，すべての入力単語に対して対訳語が得られるため，式 (4) による正解率は抽出率と同じ値となる．本システムは隣接情報学習により対訳語が抽出されなかった場合，出現頻度ベース方式により対訳語を抽出する．**4.** で述べたように出現頻度ベース方式では，入力単語が存在する対訳文の目的言語文中に名詞，動詞，形容詞，副詞，接続詞，助詞を含まない名詞句，そして，助詞を含まない動詞句のいずれかが一つでも含まれていれば，対訳語は抽出される．今回の実験においては，入力単語が存在するすべての対訳文の目的言語文中に，名詞，動詞，形容詞，副詞，接続詞，助詞を含まない名詞句，そして，助詞を含まない動詞句のいずれかが一つ以上存在していた．したがって，本システムでは，隣接情報学習により対訳語を抽出できなかった入力単語に対しても，出現頻度ベース方式により対訳語が抽出され，最終的にはすべての入力単語に対して対訳語が得られた．その結果，式 (3) の抽出率における「抽出対象の対訳語の数」と式 (4) の正解率における「システムが抽出した対訳語の数」は等しくなり，正解率は抽出率と同じ値となった．

$$\text{正解率 (\%)} = \frac{\text{抽出された正しい対訳語の数}}{\text{システムが抽出した対訳語の数}} \times 100 \quad (4)$$

5.4 考　　察

5.4.1 本手法の有効性

表 2 より，本システムの抽出率は Dice 係数に基づくシステムの抽出率に比べ，全体で 8.0 ポイント向上した．また，対訳コーパスごとでは，いずれの対訳コーパスにおいても，7.5〜8.8 ポイント高かった．この結果は，特定の言語に依存することなく，使用したすべての対訳コーパスに対して本手法が有効であることを示している．図 7 に表 3 の正しい対訳語の中から，フランス語の（monuments；記念/建造/物），上海語の（下班；退勤/し），アイヌ語の（ekupa；くわえ）の抽出例を示す．なお，図 2，図 3，そして，図 4 の例も今回の実験で得られた具体例である．

また，表 2 の B に該当する，本システムにより抽出されなくなった対訳語とは，Dice 係数に基づくシステムでは正しい対訳語が得られたが，隣接情報学習を用いる本システムでは，誤った隣接情報が利用され，かつ，類似度がしきい値以上であったために誤った対訳語が抽出されたケースである．図 8 に表 3 の誤った対訳語の中から，ドイツ語の（Wege；橋），上海語の（中飯；ご馳走/し）の抽出例を示す．図 8 の対訳語（Wege；橋）の抽出は，テンプレート方式が適用された例である．対訳文において “und” に対応する訳語としては “や” が該当するが，誤ったテンプレート（@ und；@/の）が適用されたため（Wege；橋）が抽出された．また，対訳語（中飯；ご馳走/し）の抽出



図 7　正しい対訳語の抽出例
Fig. 7　Examples of extraction of correct bilingual word pairs.

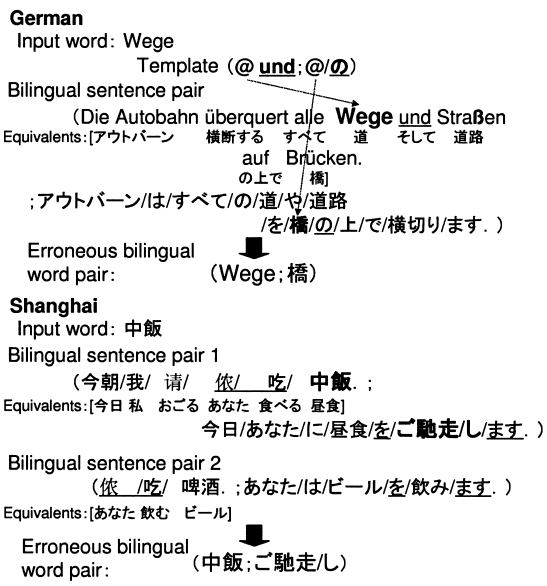


図 8　誤った対訳語の抽出例
Fig. 8　Examples of extraction of erroneous bilingual word pairs.

表 4　抽出率の内訳
Table 4　Details of extraction rates.

原言語	Dice 係数		本システム	
	頻度 1	頻度 2 以上	頻度 1	頻度 2 以上
英語	35.7%	77.2%	46.4%	80.7%
フランス語	37.5%	76.6%	49.4%	76.6%
ドイツ語	39.5%	75.0%	51.3%	76.3%
上海語	40.0%	79.8%	49.1%	85.9%
アイヌ語	45.0%	63.5%	56.9%	66.3%
合計	39.4%	73.8%	50.4%	76.8%

は，対訳文ペア方式が適用された例である．二つの対訳文間の共通部分において，言語間の対応関係が成立せず，正しい隣接情報を使用できなかったため（中飯；ご馳走/し）が抽出された．なお，“Wege”，“橋”，“中飯”，“ご馳走/し” のいずれも今回使用した対訳コーパスにおいて図 8 の対訳文以外には出現しなかったため，誤った対訳語（Wege；橋）と（中飯；ご馳走/し）の類似度は最大の 1.0 となり，対訳語辞書に登録された．

出現頻度に基づき対訳語を自動抽出する手法では，出現頻度の低い対訳語ほどデータスパースネスに陥りやすい．これは，出現頻度が低い場合，**1.** の Dice 係数の問題点で述べたように，類似度の信頼性が低下するためである．そこで，本手法がそうした状況で，どの程度有効に働いたのかを調査した．具体的には，出現頻度と抽出率の関係を調査した．その結果を表 4 に示す．今回使用した対訳コーパスにおいては，出現頻度が 1 の対訳語が全体の 63%を占めていたため，表 4 では出現頻度 1 と 2 以上に分類している．

表 4 より，出現頻度 1 の抽出率が 11.0 ポイントと大きく向上している．今回の実験では，類似度だけでは対訳語を一意に決定できないケースの多くが，出現頻度 1 の対訳語であった．したがって，出現頻度 1 の対訳語の抽出率が大きく向上したということは，類似度だけでは対訳語を一意に抽出できない場合に，本手法が非常に有効であったことを示している．

次に，隣接情報学習の有効性について述べる．表 5 に隣接情報学習，すなわち，テンプレート方式，対訳文ペア方式，そして，対訳語決定処理部により抽出された対訳語の抽出率と正解率を示す．

表 5 の抽出率において，対訳コーパスによってばらつきが見られる．この対訳コーパスごとの違いは，出現頻度 1 の対訳語の占有率に依存している．表 5 より，

表 5　隣接情報学習により抽出された対訳語の抽出率と正解率
Table 5　Extraction rates and precisions of bilingual word pairs extracted by learning for adjacent information.

原言語	抽出率	正解率	出現頻度 1 の対訳語の占有率
英語	37.9%	85.3%	66.3%
フランス語	35.4%	79.4%	73.3%
ドイツ語	41.5%	85.3%	61.0%
上海語	44.3%	77.0%	62.5%
アイヌ語	51.6%	88.0%	51.2%
合計	42.3%	82.5%	63.0%

出現頻度 1 の対訳語の占有率が高いほど抽出率が低く，占有率が低いほど抽出率が高いことが分かる．出現頻度 1 の対訳語の占有率が高い場合には，共通部分，すなわち，出現頻度 2 以上の単語列に基づき隣接情報を獲得する本手法が十分に機能せずに，抽出率が低下したと考えられる．それに対して，出現頻度 1 の対訳語の占有率が低い場合には，隣接情報を比較的容易に獲得できるため，抽出率が高くなったと考えられる．

また，表 5 の抽出率は，表 2 の Dice 係数に基づく手法の抽出率に比べ，低い値となっているが，一概に隣接情報学習が Dice 係数に基づく手法と比較し，劣っているとはいえない．Dice 係数に基づく手法では，**4.** の出現頻度ベース方式の処理内容で述べたように，同じ類似度の対訳語が複数存在する場合，対訳コーパス中に最初に出現するものを選択する．したがって，対応関係を一意に決定した上で対訳語を抽出しているわけではない．今回の実験において，Dice 係数に基づく手法により抽出された正しい対訳語の 38.4%が，類似度のみでは決定できずに対訳コーパス中の出現順に基づき決定されたものであった．それに対し，隣接情報学習では，対応関係を一意に決定した上で対訳語を抽出しているため，より高度な抽出処理を行っている．また，表 5 より正解率においては，対訳コーパスごとでは 77.0〜88.0%，全体では 82.5%と比較的高い値となった．これは，隣接情報学習が高い精度で対訳語を抽出できていることを示している．

5. 4. 2　最適なしきい値の決定について

本手法の抽出率としきい値の関係について調査し，最適なしきい値を求めた．しきい値を 0.1 ごとに上昇させた際の全体の抽出率と対訳コーパスごとの抽出率を図 9 に示す．

図 9 より，全体においてはしきい値が 0.5 の場合に抽出率が最も高くなった．対訳コーパスごとでは，英語とフランス語がしきい値 0.5 以外で抽出率が最も高くなっている．しかし，しきい値 0.5 の場合の抽出率との差は，英語，フランス語でそれぞれ 0.6，1.6 ポイントと小さな値であった．しきい値として大きな値を設定した場合には，隣接情報学習により抽出された正しい対訳語の多くがしきい値未満となるため対訳語辞書には登録されない．更に，それらの多くは，Dice 係数に基づく出現頻度ベース方式では抽出困難なため抽出率は低下する．一方，しきい値として小さな値を設定した場合には，隣接情報学習により抽出された誤った対訳語の多くがしきい値以上となるため，やはり抽出率は低下する．したがって，中間に位置する 0.5 が抽出された対訳語を最も適切に評価するしきい値となり，抽出率が高くなったと考えられる．

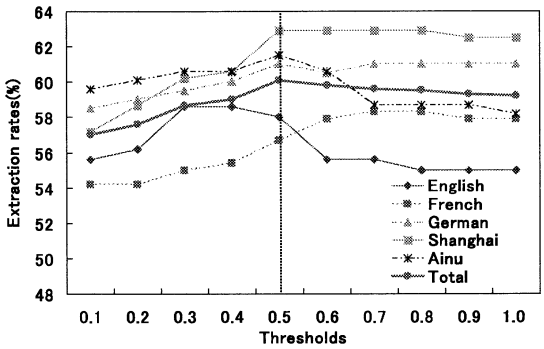


図 9　しきい値と抽出率の関係
Fig. 9　Relationship of thresholds and extraction rates.

5. 4. 3　本手法の課題

本手法では，隣接する左右の単語列の出現頻度が 1 の場合，対訳語を抽出することができない．例えば，“XYZ” のように三つ以上の単語列が隣接した状態で，かつ，単語列 “X” と “Z” の出現頻度が 1 の場合，それらは共通部分とならないため，隣接情報として獲得されないことになる．その結果，本手法では，“Y” の対訳語を抽出できない．このような問題を解決するためには，本手法により得られた対訳語を隣接情報として利用することが有効と考えられる．

また，今回は，多義語を考慮した対訳語の抽出は行っていない．本実験で使用した全対訳コーパスにおける多義語の割合は 1.7%（18/1,081）と非常に小さく，大きな問題とならなかったが，今後は，多義語も考慮した対訳語の抽出方法を取り入れる予定である．

本論文では，膠着語の文に対しては単語分割された

文の使用を前提としているが，対象言語によっては単語分割された文が存在しない場合や形態素解析ツールの入手が困難なものもある．その際には，特定の言語に依存しない汎用性の高い単語分割手法として，王ら [9] の手法が有効であると考えられる．そこでは，学習により文の字面情報のみに基づき単語分割を行うため，多言語への適用に有効である．

そして，本手法をより長い文に適用する場合，文の構成単語数が多くなることで対訳文における語の対応関係のあいまい性がより高くなり，対訳語の抽出が困難になると考えられる．そのような長い文の対訳文においては，目的言語文に対し，構文解析ツールを用いて句や節などの部分に分割し，更に，隣接情報学習により得られた対訳語を用いて探索範囲を絞り込んだ上で本手法を適用することが有効と考えられる．

6. 関連研究との比較

辻ら [6] は低頻度語の対訳語を抽出するために，日英の名詞を対象に片仮名語やローマ字の訳語を翻字規則により決定する方法を提案している．しかし，その場合，適用できる言語は限定される．また，名詞以外の対訳語を抽出することは困難である．佐藤ら [10] はサポートベクタマシンを用いて日英の名詞句と動詞句の対訳対の抽出を行っている．しかし，そこでは，対訳モデルを学習するために，訓練コーパスとしてある程度大きな規模の対訳コーパスが必要となる．それに対し，本手法は訓練コーパスとテストコーパスの区別なく，与えられたすべての対訳文を対象に対訳語を抽出でき，かつ，隣接情報学習を用いることでデータスパースネスの問題に対して有効な手法となっている．

更に，本手法と同様に一般化したテンプレートを自動獲得する手法がある．McTait [11] は，対訳文ペアの共通部分を変数化する方法と差異部分を変数化する方法により翻訳パターンを獲得している．しかし，それらの翻訳パターンは文全体を表す大局的な翻訳知識であり，本手法のテンプレートのように局所的な部分に適用することが困難である．また，翻訳パターンを獲得するためには，表層レベルで類似性の高い対訳文が必要となる．一方，文献 [8] では，対訳文の局所部分に着目した翻訳パターンの獲得手法を提案している．しかし，そこでは，効率良く翻訳パターンを獲得するために，あらかじめ表層レベルで類似性の高い対訳文を用いて対訳語を抽出しておかなければならない．それに対し，本手法は，**3.1** で述べたように，局所的に類似している対訳文ペアのみからであっても，テンプレートを効率良く獲得することができる．

また，抽出対象の対訳語の近傍に出現する語を利用する手法として，Kaji ら [12] は，共起関係にある対訳語の共起語集合を用いて対訳語を抽出する手法を提案している．この手法では，共起関係にある対訳語の数と頻度に基づき類似度を決定する．そのため，低頻度の対訳語に対しても，共起する対訳語が数多く存在していれば抽出可能である．また，Tanaka ら [13] は，訳語の多義性を解消するために，二つの言語のコーパス中の語の共起頻度に基づく共起情報を確率行列の枠組みで形式化し，言語間の共起情報が類似するように翻訳行列を最適化する手法を提案している．しかし，これらの手法は，共起する対訳語の数や頻度に強く依存しているため，効率的な対訳語の抽出という点において不十分と考えられる．

それに対し，本手法は，抽出対象の対訳語と共起関係にある単語としては隣接情報となる単語列が存在していればよく，かつ，隣接情報の単語列と対訳語間の共起頻度は 1 でもよいため，対訳語を効率良く抽出できる．例えば，図 4 のテンプレート方式による対訳語の抽出例 1 では，単語 “parcel” の対訳語を抽出するために必要な共起語は隣接情報となる単語列 “this” だけであり，他の共起語を必要としない．また，“this” と “parcel” が一度でも隣接していれば，共起頻度の大小に関係なく “parcel” の対訳語を抽出することができる．しかし，隣接情報となる単語列の精度は頻度情報による類似度に依存することから，本手法はデータスパースネスの問題を完全に克服するには至っていないと考えられる．したがって，今後，頻度に強く依存することなく，精度の高い隣接情報を得るための手法について検討していく予定である．

7. むすび

本論文では，多言語対訳コーパスから対訳語を効率良く抽出するために，隣接情報学習を用いた対訳語の自動抽出手法を提案した．本手法では，学習の観点より，データスパースネスの問題に有効となる隣接情報を自動獲得する．したがって，対訳コーパスを変更するだけで，言語リソースの乏しい言語も含め，様々な言語に対処可能である．原言語が英語，フランス語，ドイツ語，上海語，アイヌ語，目的言語が日本語である 5 種類の対訳コーパスを用いた性能評価実験の結果，本手法に基づくシステムの抽出率として 60.1%が得ら

れた．これは，Dice 係数に基づくシステムに比べ 8.0 ポイント高い値であり，本手法の有効性を示している．

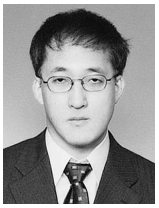
今後は多義語の問題を解決するとともに，多言語翻訳システムに本手法を利用していく予定である．

謝辞 本研究の一部は，北海学園大学ハイテク・リサーチ・センター研究費によって行われている．

文　献

[1] F. Smadja, K.R. McKeown, and V. Hatzivassiloglou, “Translating collocations for bilingual lexicons: A statistical approach,” Computational Linguistics, vol.22, no.1, pp.1–38, 1996.
[2] 北村美穂子，松本裕治，“対訳コーパスを利用した対訳表現の自動抽出，” 情処学論，vol.38, no.4, pp.727–736, 1997.
[3] 松本裕治，北内　啓，山下達雄，平野善隆，松田　寛，高岡一馬，浅原正幸，日本語形態素解析システム『茶筌』version 2.2.9 使用説明書，奈良先端科学技術大学院大学松本研究室，2002.
[4] M. Kay and M. Röschesen, “Text-translation alignment,” Computational Linguistics, vol.19, no.1, pp.121–142, 1993.
[5] C.D. Manning and H. Schütze, Foundations of Statistical Natural Language Processing, The MIT Press, 1999.
[6] 辻　慶太，芳鐘冬樹，影浦　峡，“対訳コーパスにおける低頻度語の性質－訳語対自動抽出に向けた基礎研究，” 信学技報，NLC2000-16, 2000.
[7] 越前谷博，荒木健治，桃内佳雄，栃内香次，“実例に基づく帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性，” 情処学論，vol.37, no.8, pp.1565–1579, 1996.
[8] 越前谷博，荒木健治，桃内佳雄，栃内香次，“翻訳例に基づく再帰チェーンリンク型学習による機械翻訳手法，” 信学論（D-II），vol.J85-D-II，no.12, pp.1840–1852, Dec. 2002.
[9] 王　忠建，荒木健治，栃内香次，“帰納的学習を用いた単語分割手法の中国語への適用とその性能評価，” 信学論（D-II），vol.J85-D-II，no.1, pp.56–65, Jan. 2002.
[10] 佐藤健吾，斎藤博昭，“サポートベクタマシンを用いた対訳表現の抽出，” 自然言語処理，vol.10, no.4, pp.109–124, 2003.
[11] K. McTait,“Memory-based translation using translation patterns,” Proc. 4th Annual CLUK Colloquium, pp.43–52, Sheffield, England, 2001.
[12] H. Kaji and T. Aizono, “Extracting word correspondences from bilingual corpora based on word co-occurrence information,” Proc. Coling’96, pp.23–28, Copenhagen, Denmark, 1996.
[13] K. Tanaka and H. Iwasaki,“Extraction of lexical translation from non-aligned corpora,” Proc. Coling’96, pp.580–585, Copenhagen, Denmark, 1996.
[14] 早川嘉春，ジョン・スネリング，エクスプレス：英（イギリス）語，白水社，東京，1998.
[15] 筑紫文耀，エクスプレス：フランス語，白水社，東京，2001.
[16] 小塩　節，エクスプレス：ドイツ語，白水社，東京，2004.
[17] 榎本英雄，范　暁，エクスプレス：上海語，白水社，東京，2004.
[18] 中川　裕，中本ムツ子，エクスプレス：アイヌ語，白水社，東京，2004.

（平成 16 年 6 月 16 日受付，9 月 25 日再受付）



越前谷　博　（正員）

平 3 北海学園大・工・電子情報卒．平 8 同大大学院工学研究科修士課程了．平 10 北大大学院工学研究科電子情報工学専攻博士後期課程退学．現在，北海学園大学工学部電子情報工学科助手．自然言語処理，特に，機械翻訳の研究に従事．情報処理学会，人工知能学会，言語処理学会，ACL，IEEE 等各会員．



荒木　健治　（正員）

昭 57 北大・工・電子卒．昭 63 同大大学院博士課程了．工博．同年，北海学園大学工学部電子情報工学科助手．平元同講師．平 3 同助教授．平 10 同教授．平 10 北大・工・電子情報工学専攻助教授．平 14 同教授．現在，北大・情報科学・メディアネットワーク専攻教授．自然言語処理，特に，機械翻訳，音声対話処理などの自然言語処理の研究に従事．情報処理学会，言語処理学会，人工知能学会，認知科学会，ACL，IEEE 等各会員．



桃内　佳雄　（正員）

昭 40 北大・工・精密卒．昭 42 同大大学院修士課程了．同年（株）日立製作所入社．昭 47 北大大学院博士課程単位取得退学．昭 48 北大大学院情報工学専攻助手，昭 61 助教授，昭 63 北海学園大学工学部電子情報工学科教授．自然言語の理解と生成に関する研究に従事．工博（北大）．情報処理学会，言語処理学会，計量国語学会，人工知能学会，日本認知科学会，ACL 等各会員．