社団法人　情報処理学会　研究報告
IPSJ SIG Technical Report

2006－NL－171（5）
2006／1／12

単語出現状況の特徴を用いた英文冠詞誤りの検出及び自動校正

乙武　北斗　　荒木　健治
北海道大学大学院情報科学研究科

本稿では，日本人英語学習者が起こしやすい誤りの一つである英語の冠詞誤りを，単語出現状況の特徴を用いて検出及び自動校正する手法を提案する．冠詞誤りを検出する従来手法として，電子化コーパスから獲得された統計量に基づくものがある．しかし，冠詞の用法には例外が多く，複雑な文脈を考慮するのは困難である．そこで，本手法ではコーパス中の名詞及びその周辺の単語の出現状況をルールとして獲得することで，文脈を考慮した冠詞誤りの検出，さらに校正を行う．実験の結果，本手法は Precision が 0.75 という結果で，従来手法の Precision の 0.63，0.46 と比較しても優位性のある結果であることを確認した．

Correcting and detecting article errors in English using conditions of word appearance

Hokuto OTOTAKE, Kenji ARAKI
Graduate School of Information Science and Technology, Hokkaido University

One of the most common mistakes made by Japanese learners of English is an article error. We propose a method for correcting and detecting article errors using conditions of word appearance. By acquiring rules from word appearances in a corpus and by using learning methods, the proposed system detects and corrects article errors with context consideration. Experiments show that the proposed method achieves a precision of 0.75, which is better than results of related works (0.65, 0.46).

1 はじめに

日本人英語学習者が起こしやすい誤りに，冠詞の誤用が挙げられる[1][2][3]．文献[4]では，冠詞そのものを持たない母語話者は，英語の冠詞を誤用する傾向があると報告している．

文献[5]では，実験を行った結果，日本人の書いた英語には冠詞誤りが多いことが報告されている．そのため，英文を添削する際は多くの冠詞誤りを修正する必要がある．冠詞の用法には厳密な規則がない場合が多いため，辞書や用例から多くの事柄を調べる必要がある．このことから，冠詞誤りの添削には時間と労力，さらに専門知識も必要となる．

こうした現状を解決するために，冠詞誤りの検出を自動化する手法[1][5][6]が提案されている．

永田らの手法[1]では，英字新聞などの電子化コーパスから統計量を抽出して，それに基づいて冠詞誤りを検出している．また，若菜らの手法[6]では統計量を用いて名詞の可算・不可算を判定し，その結果を用いて冠詞誤りを検出している．このような統計量を用いた手法では，誤り検出用の辞書やルールを人手で作成する労力を必要としない利点がある．しかし，冠詞や名詞の統計量を用いていることから，複雑な文脈を考慮に入れることが困難である．また，冠詞の例外的な用法には対応できない．

河合らの手法[5]では，構文解析などを用いて英文を解析し，人手で作成したルールに基づいて冠詞誤りを検出している．しかしながら，誤り検出に用いる辞書やルールを作成する際に多くの労力と専門知識を要する．また，全ての冠詞の用法を網羅したルールを作成することは非常に困難である．

以上の手法に加えて，欠落した冠詞を自動復元する手法[4]が提案されている．この手法では，冠詞と名詞句の特徴との組合せの統計量を用いて，冠詞

の復元を行う．ただ，欠落した冠詞の復元のみに対応しているため，例えば a を the と誤用したものなどについては対応できない．

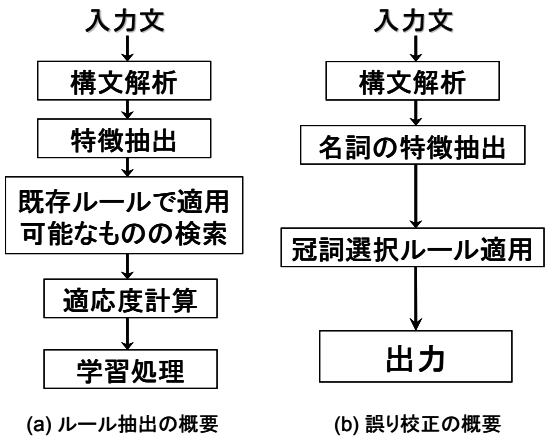
そこで，これら従来研究[1][4][5][6]の問題点を解決するために，本稿では単語出現状況の特徴を用いた英文冠詞誤りの検出及び自動校正手法を提案する．本手法では，電子化コーパス中の英文における名詞句とその周辺の単語を特徴として抽出し，冠詞と組み合わせて冠詞選択ルールとする．これによって，文脈を考慮したルールを獲得することができる．本手法で対象とする文脈処理は一文内のものである．また，帰納的学習[7]を用いて，抽出されたルール同士から新たに抽象化したルールを自動生成する．次に獲得されたルールに基づいて，冠詞誤りの検出・校正を行う．本手法の利点として，まずルールを人手で作成する労力を必要としない点が挙げられる．また，ルールの抽象化を行うことで，冠詞選択に関わる文脈要素を絞り込むことができる．

以下，第 2 章で本手法の概要を，第 3 章ではシステムの処理過程について述べる．また，第 4 章では評価実験を行い，第 5 章で実験結果，及びその考察をする．第 6 章で従来手法との比較を行う．最後に第 7 章でまとめを述べる．

2 システムの概要

本システムは処理内容から大きく 2 つの処理部に分けられる．ひとつはルール抽出部，もうひとつは誤り校正部である．

2.1 ルール抽出部



(a) ルール抽出の概要　　(b) 誤り校正の概要

図 1 システムの処理の概要

ルール抽出の概要を図 1 (a)に示す．

入力文は英文コーパスから自動的に取り出される．その入力文各々に対して構文解析を行い，構文構造を獲得する．構文解析ツールとして Apple Pie Parser[8]を用いた．

次に，構文解析された結果から名詞とその周辺の特徴を抽出する．この特徴は，冠詞の選択を決定する要素をカテゴリとして持つ特徴スロットとして抽出される．これについては第 3 章で詳細を述べる．また，この特徴スロットと対象名詞に付属する冠詞を組み合わせたものをルールとする．

得られた特徴スロットに対して，既存のルール中に適用可能なルールがあるかどうかを検索する．適用できるルールが存在した場合，そのルールに対して適応度の更新を行う．適応度とは得られたルールの確からしさを表す数値である．

最後に，学習処理によって抽象化した新しいルールを生成する．学習処理の詳細は第 3 章で述べる．

2.2 誤り校正部

誤り校正の概要を図 1 (b)に示す．

入力文は冠詞の誤りの校正を行う文章を含むものとする．入力文は構文解析されるが，用いる構文解析ツールはルール抽出時と同じく Apple Pie Parser とした．次に，ルール抽出時と同様に名詞の特徴抽出を行う．抽出された各々の名詞の特徴に対してルール抽出部で獲得された冠詞選択ルール辞書，及び人手で作成した明確な冠詞の用法を記述した解析的ルール辞書の中から適用できるルールを検索し，冠詞の校正を行う．最後に結果を出力する．

3 システムの処理過程

本章では，2 章のシステム概要で述べた処理過程について詳細を述べる．

3.1 名詞の特徴抽出

英語の冠詞についての知見[2][3]に基づき，冠詞の選択を決定する重要な要素をカテゴリとする特徴スロットを考える．特徴スロットには 3 つのカテゴリ，1) 対象名詞そのものの情報を保持する対象カテゴリ，2) 形容詞などの情報を保持する前置修飾カテゴリ，3) 前置詞などの情報を保持する後置

修飾カテゴリがある．各カテゴリの要素として，単語や品詞情報が格納され，その際単語は原形に変換される．

本手法では，1 つの対象名詞から特徴抽出する際に

- 1) （対象カテゴリのみ）
- 1)・2) （対象と前置修飾カテゴリ）
- 1)・2)・3) （全てのカテゴリ）

のカテゴリを持った 3 つの特徴スロットを抽出する．こうすることで異なる特徴範囲を持ったルールを複数抽出し，ルール抽出の効率化を目指す．以下の例文

This is the only *book* which I bought yesterday.

において，対象名詞 *book* についての全てのカテゴリ範囲での特徴スロットを図 2 に示す[1]．また，上の例文から抽出されるルールは，図 2 の特徴スロットと定冠詞 the の組合せとなる．

3.2 適応度の計算

英文コーパスから新しくルールを抽出した際，既存のルールの中に適用可能なルールがあるかどうかを検索する．ルールが適用可能となる条件は，対象とルールの特徴スロットの一致とする．

ここで，適用回数と正適用回数を定義する．適用回数とは，新しく抽出されたルールの特徴スロットに対してルールが適用可能となった回数とする．正適用回数とは，適用回数のうち，冠詞部分も一致した回数とする．適応度を式(1)のように定義する．

対象		
	名詞	book
	主名詞	book
	属する句	NP
	前置詞	−
	受ける動詞	be
	する動詞	−
	数	singular
	固有	no

前置修飾		
	修飾詞	only
	品詞	RB

後置修飾			
前置詞句	前置詞	−
	冠詞	−
	名詞	−
	主名詞	−
	修飾詞	−
不定詞句	動詞	−
	目的語冠詞	−
	目的語	−
	副詞	−
関係詞節	主語	I
	動詞	buy
	目的語冠詞	−
	目的語	−
	副詞	yesterday

図 2 特徴スロットの例

$$\text{適応度} = \log_2(\text{正適用回数})\frac{\text{正適用回数}}{\text{適用回数}} \qquad (1)$$

正適用回数の対数をかけることによって，適用回数が少ないにもかかわらず正適用率が高くなることを防いでいる．

3.3 学習処理

3.3.1 帰納的学習

本稿における帰納的学習とは，「実例からそこに内在している規則を獲得すること」と定義している[9]．本手法での実例とは学習用コーパスから抽出される英文に含まれる特徴スロットである．この特徴スロット同士を比較し，各要素について共通部分と差異部分を再帰的に抽出することにより，帰納的学習を実現する．

しかしながら，再帰的処理は一つ一つの特徴スロットにおける学習時間を著しく増加させる．このため，本手法では再帰的処理によるルールの抽象化を優先せず，できるだけ多くの種類の名詞からルールを抽出するために，ルールの抽象化は 1 度のみ行う．

3.3.2 学習処理の過程

英文コーパスから新しいルールを抽出した際に，既存のルールの特徴スロットと比較し，**3.3.1** 述べた帰納的学習によって新たなルールを生成する．2 つのルールが持つ特徴スロットの各要素について，内容が一致した要素を共通部分とし，それ以外を差異部分とする．新しく生成されるルールの特徴スロ

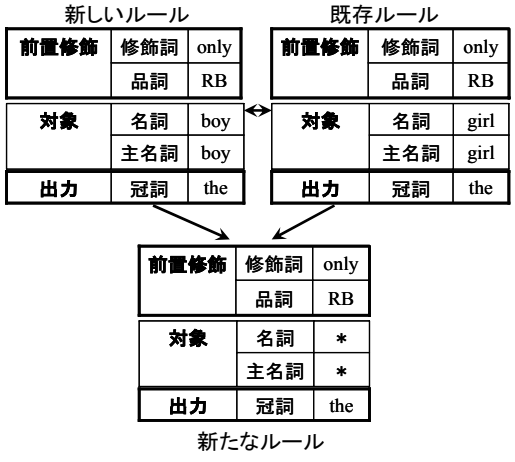


図 3 学習処理の例

[1]図 2 で特徴スロットの要素における“—”は，該当する要素が存在しないことを示す．

ットには共通部分が要素として残り，差異部分は変数化することにより抽象化される．

学習処理によって新たなルールが生成される例を図 3 に示す．この例では，新しく抽出されたルールと既存ルールの特徴スロットの比較により，前置修飾カテゴリと冠詞部分が共通部分で，対象カテゴリが差異部分となることがわかる．これら 2 つのルールの帰納的学習の結果，共通部分が残り差異部分が抽象化された新たなルールが生成される．対象カテゴリの“＊”はワイルドカードで，任意の要素の代入を許す．

学習処理の対象となるルールの条件は，単に共通部分を持つルール同士である点だけではない．なぜなら，そうしてしまうと極度の抽象化によって，あらゆる特徴スロットに対して適用できるルールが生成されるためである．ゆえに，学習処理は何らかの制限の基に行う必要がある．まず，学習対象となる 2 つのルールにおいて冠詞部分の一致は必須とした．さらに，2 つのルールの特徴スロットにおいて，要素の一致率（空要素の一致は除く）が 10%以上のもののみ，学習処理の対象とした．

学習処理で生成されたルールに関しては，連続未使用回数がある一定値を超えた場合，ルールの淘汰処理の対象とする．これは，学習で生成されたルールがコーパスから直接獲得されたルールと比較して確実性が劣ると考えられるためである．

3.4 冠詞選択ルール適用

誤り校正を行う際，ルール抽出部にて獲得されたルールのほかに，人手で作成した解析的ルール辞書も用いる．文献[2][3][10]によると，冠詞の用法として，名詞がある特定の単語に修飾を受けた場合，名詞の前に冠詞をつけない規則がある．このような明確な規則の場合，学習によって獲得したルールを用いて誤りを校正するよりも，人手で作成した解析的ルールを用いる方が確実である．現在，本手法における解析的ルールは，名詞に冠詞を付けないルールのみである．その適用条件は以下の 3 つである．

- 名詞が人称代名詞や名詞の所有格による修飾を受けた場合
- 名詞が限定詞による修飾を受けた場合
- 対象名詞が固有名詞で，かつ冠詞選択ルール辞書に適用できるルールがない場合

限定詞とは名詞を指定･限定する働きを持つ語句で，another や each 等がある．

また，ルール抽出部で獲得されたルールは適応度順に検索され，ある閾値 θ を超える適応度を持つルールのみを誤り検出に用いる．さらに，一つの特徴スロットに対して適用できるルール数についても閾値 n を設ける．

4 評価実験

4.1 学習用英文コーパス

本実験では，学習用の英文コーパスとして Reuters Corpus[11]に収録されている英文記事を使用した．記事数は 655，総単語数 152,114 語である．名詞の異なり単語数は 4,143 語で，獲得されたルール数は 65,803 個である．

4.2 実験対象

4.1 で述べた Reuters Corpus の英文記事の中で，学習には使用していない記事を無作為に 9 つ選ぶ．それらの記事の冠詞部分を空欄に書き換え，日本人男子理系大学生 2 人が適切と考えられる冠詞を入力する．このような操作で得られた冠詞誤りが含まれる可能性のある英文記事を実験対象として用いる．記事数は 9，総単語数 1,586 語となり，含まれる冠詞誤りの数は 121 個である．

4.3 実験手順

まず **2.1** で説明した手法に従って，冠詞選択ルール辞書を作成した．次に，**2.2** で説明した方法を用いて，実験対象中の冠詞誤りを検出し，校正を行った．

3.2 で述べた適応度の閾値 θ による違いを見るため，ルール適用数の閾値は設けずに，閾値 θ を 0 から 2 まで 0.25 刻みで誤り検出実験を行った．また，ルール適用数による違いも見るため，閾値 θ を 1.5 に固定し，閾値 n を 1 から 32 まで変化させて実験を行った．これは検出と校正の両方を行った．

4.4 評価方法

本手法の誤り検出を評価する尺度として，式(2), (3)で定める Recall，Precision を用いる．

$$\text{Recall} = \frac{\text{正しく検出された誤りの数}}{\text{実際の誤りの数}} \quad (2)$$

$$\text{Precision} = \frac{\text{正しく検出された誤りの数}}{\text{検出された誤りの数}} \quad (3)$$

また，誤り校正を評価する尺度として，式(4)，(5)で定める Recall，Precision を用いる．

$$\text{Recall} = \frac{\text{正しく校正された誤りの数}}{\text{実際の誤りの数}} \quad (4)$$

$$\text{Precision} = \frac{\text{正しく校正された誤りの数}}{\text{正しく検出された誤りの数}} \quad (5)$$

5 実験結果と考察

図 4 に本手法の適応度の閾値ごとの評価結果を示す．図 4 より，閾値 θ を高く設定するほどシステムが検出する誤りの数も増えることがわかる．θ = 1.5 のとき Precision が 0.93 で，Precision 重視の場合に最も良い結果となった．

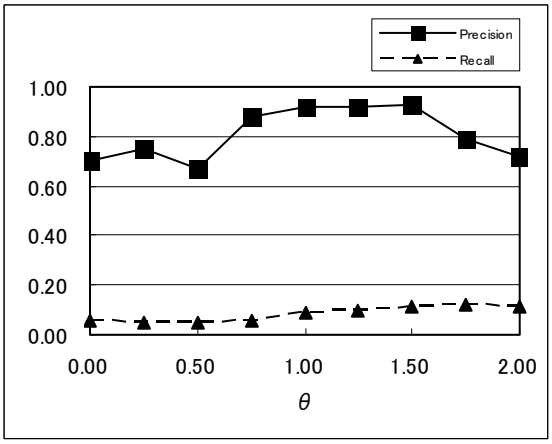


図 4 閾値 θ と性能の関係

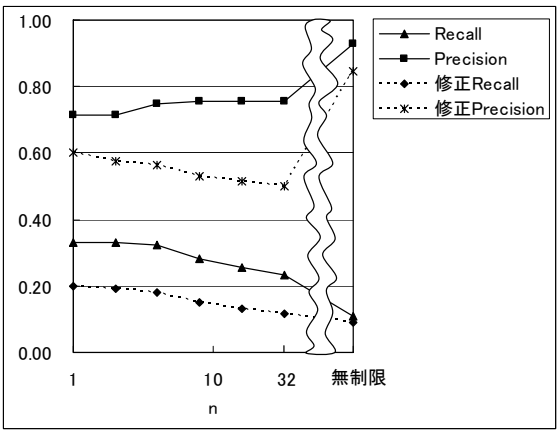


図 5 閾値 n と性能の関係

しかし Recall は 0.11 と低く，さらに θ の値を変化させても Recall の性能変化は微小であることから，適応度の閾値変化だけでは Recall の改善を行うことは困難であると考えられる．これは，汎用的で適用可能なルール数が多いため，冠詞の修正候補を絞りきれずに誤り検出ができないことが原因として考えられる．

図 5 に，適応度の閾値 θ を 1.5 に固定し，ルール適用数の閾値 n を変化させた際の評価結果を示す．適応度の閾値を変化させた場合と比較して，ルール適用数を制限するほど大幅に Recall が向上する結果となった．最もバランス良く性能が良い結果として，n=4 のとき，Precision が 0.75，Recall が 0.32 となった．

ルール適用数の制限が Recall の改善に効果があることは確認できたが，最善の結果で 0.33 と，約 7 割の冠詞誤りが検出できていない．その原因として最も大きなものは，そもそも適用できるルールが一つもない特徴スロットの存在が挙げられる．これは，学習規模を拡大させることによって名詞や文脈情報の網羅性を高めることにより，改善する可能性がある．

図 5 の誤り校正の結果においては，誤り検出に比べて性能が低下していることがわかる．これは，まず誤りを正しく検出した上で，さらに正しい修正候補を提示しなければならないため，誤った修正候補や複数の修正候補を提示した場合に評価を下げる結果となっている．ただ，n＝1 及び無制限のときは，誤り検出時と校正時の Precision 値が比較的近いことが確認できる．

6 関連する手法との比較

4.2 で述べた実験対象について，Web 上で公開されている永田らの手法[1][2]，若菜らの手法[6][3]と本手

[2] http://www.ai.info.mie-u.ac.jp/~nagata/error_detection/index.html

表 1 関連手法との比較

	Precision	Recall
提案手法	0.75	0.32
永田らの手法[1]	0.63	0.22
若菜らの手法[6]	0.46	0.26

法とで評価実験を行った．永田らの手法[1]の精度／検出率パラメータは 2 と設定した. 永田らの手法[1][6]は冠詞誤り検出手法であるので，本手法の誤り検出の評価結果と比較を行うこととした.

表 1 に本手法で最もバランス良く性能が良い結果となった θ ＝1.5，n＝4 の場合と，永田らの手法[1][6]との性能の比較結果を示す．表 1 より，Precision と Recall の両方において提案手法の結果が永田らの手法より良いことがわかる．これは，提案手法の学習データが実験対象と同じく Reuters Corpus であること，そして，たとえ未知名詞であっても学習処理によって抽象化されたルールが適用可能であることが原因として考えられる. 永田らの手法[1]の学習データは EDR 電子化辞書であり，若菜らの手法[6]では BNC を用いている．提案手法において, 未知名詞であっても名詞以外の文脈情報を用いてルールの適用を行い，冠詞誤りの検出・校正を行う点は, 永田らの手法と比較して優れている点だと考えられる.

7 まとめ

本稿では, 単語出現状況の特徴を用いた英文冠詞誤りの検出及び自動校正手法を提案した. 実験の結果, 誤り検出において最もバランス良く性能が良かったもので，Precision が 0.75，Recall が 0.32 となった．従来手法と同一実験対象で比較したところ，優位性のある結果を示し, 本手法の有効性を確認することができた.

今後の課題としては, Recall の更なる改善が挙げられる．学習規模を拡大することで，特徴の網羅性を高めることができると考えられる．また，本手法では前後の文の文脈は考慮していないが, 冠詞が前後の文に影響されることは明らかであるので, 考慮する必要がある.

[3] http://www.ai.info.mie-u.ac.jp/~nagata/mc/system.html

参考文献

[1] 永田亮，井口達也，脇寺健太，桝井文人，河合敦夫，井須尚紀，“前置詞情報を利用した冠詞誤り検出”，電子情報通信学会論文誌，D-I，Vol. J88-D-I，No.4，pp.873-881，2005 年 4 月.

[2] 石田秀雄，“わかりやすい英語冠詞講義”，大修館書店(2002)

[3] 原田豊太郎，“例文詳解　技術英語の冠詞活用入門”，日刊工業新聞社(2000)

[4] J. Lee，“Automatic Article Restoration”，Proc. HLT/NAACL Student Research Workshop，Boston，MA，pp.195-200，May. 2004.

[5] 河合敦夫，杉原厚吉，杉江昇，“英文の誤りを検出するシステム　ASPEC-I”，情報処理学会論文誌，vol.25，No.6，pp.1072-1079，1984 年 11 月.

[6] 若菜崇宏，永田亮，桝井文人，河合敦夫，“可算／不可算判定を用いた英文の冠詞誤り検出”，第 11 回言語処理学会年次大会発表論文集，P5-15，pp.783-786，2005 年 3 月.

[7] K. Araki and K. Tochinai，“Effectiveness of natural language processing method using inductive learning”，Proceeding of the IASTED International Conference ARTIFICIAL INTELLIGENCE AND SOFT COMPUTING，pp.295-300，2001.

[8] 関根聡，“英語構文解析システム「Apple Pie Parser」”, 情報処理, vol.41, No.11, pp.1221-1226, 2000 年 11 月.

[9] 荒木健治，“自然言語処理ことはじめ　－言葉を覚え会話のできるコンピューター”，森北出版株式会社(2004).

[10] The Concise Oxford English Dictionary 10e，Oxford University Press，2001.

[11] Reuters Corpus: http://www.reuters.com/researchandstandards/corpus