帰納的学習による文脈依存を含む英文冠詞誤りを対象とした校正手法の性能評価

乙武　北斗*　荒木　健治
(北海道大学情報科学研究科メディアネットワーク専攻)†

1 はじめに

[1] 英語における冠詞の誤りは，日本人学習者にとって最も犯しやすい文法項目の一つである[1][2][3]．その原因として，英語と日本語では言語構造がまったく異なること，日本語には冠詞そのものが存在しないことが考えられる．

文献[4]では，実際に実験を行い，日本人の書いた英文には冠詞誤りが多いことが報告されている．そのため，英文を添削する際には多くの冠詞誤りを修正しなければならない．冠詞の用法には厳密な規則がない場合が多く，辞書や用例から多くの事柄を調べる必要がある．このことから，冠詞誤りの添削は時間と労力，さらに専門知識も必要となる．

こうした現状を解決するために，冠詞誤りの検出を自動化する手法[1][4][6] が提案されている．

永田ら[1]は，英字新聞などの電子化コーパスから統計量を抽出して，その統計量に基づいて冠詞誤りを検出している．このような統計量を用いた手法では，誤り検出用の辞書やルールを人手で作成する労力を必要としないという利点がある．しかし，冠詞の統計量を用いていることから，文脈を考慮に入れることは困難である．また，冠詞の例外的な用法には対応できない．

河合ら[4]，Schneider ら[6]は，構文解析などを用いて英文を解析し，人手で作成したルールに基づいて冠詞誤りを検出する．これらの手法では，ルールの書き方次第で文脈の考慮や例外的な冠詞の用法に対応できる．しかし，誤り検出に用いる辞書やルールを作成する際に多くの労力と専門知識を要する．また，冠詞には例外や曖昧な用法も多く，全ての冠詞の用法を網羅したルールを作成することは非常に困難である．

そこで，これらの従来研究[1][4][6] の問題点を解決するために，本稿では帰納的学習[7]を用いた英文冠詞誤り校正手法を提案する．本手法では，英字新聞などの電子化コーパス中の英文を実例とし，そこに内在する冠詞選択のルールを再帰的に自動獲得する．そして獲得されたルールに基づいて，冠詞誤りの校正を行う．そのため，本手法は以下に述べるような利点がある．

(1) ルールを人手で作成する労力を必要としない
(2) 帰納的学習によって実例から抽出されたルール同士から新しい汎用化されたルールを獲得できる
(3) ルールに文脈を考慮することで，文脈に依存する冠詞の誤りを校正できる

以下，第2章で本手法の概要を，第3章ではシステムの処理過程について述べる．第4章で評価実験を行い，第5章で実験結果を述べ，考察をする．第6章で従来手法との比較を行う．最後に第7章で本稿のまとめを述べる．

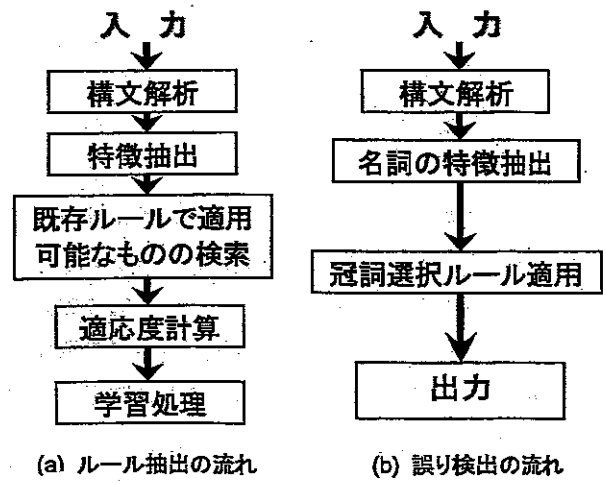
2 システムの概要

本システムは，処理内容から大きく二つの処理部に分けられる．ひとつはルール抽出部，もうひとつは誤り検出部である．

2.1 ルール抽出部

ルールの抽出は大きく6つの処理に分けることができる（図1(a)）．

入力文は英文コーパスから1文ごとに自動的に取り出



(a) ルール抽出の流れ　(b) 誤り検出の流れ

図1 システムの処理の流れ

*hokuto@media.eng.hokudai.ac.jp
†札幌市北区北14条西9丁目北海道大学大学院情報科学研究科

る．入力文各々に対して構文解析を行い，入力文の
構造を獲得する．構文解析には，Apple Pie Parser[11]
用いた．Apple Pie Parser は名詞句の解析精度が高い
が報告されており[5]，名詞に付属する冠詞を選択
るルールを獲得する本手法に適していると考えられ

次に，構文解析された結果から名詞の特徴を抽出する．
で言う特徴とは，冠詞の選択の決定に関わるいくつ
の文法的要素を示すが，詳細は3章で述べる．
得られた名詞の特徴全てに対して，既存のルールから
の特徴を持つ名詞に適用できるルールがないかどう
調べる．適用できるルールが存在した場合，そのルー
に対して適応度の更新を行う．適応度とは得られたル
の確からしさを表す数値である．
最後に，学習処理として **3.3.1** で述べる帰納的学習を
う．新しく得られた特徴を持つルールと既存のルール
較し，特徴の共通部分，差異部分を抽出する．その
通部分と抽象化した差異部分を持った新たなルール
作成する．ただし，抽象ルールの生成は再帰的には行
1回のみ行う．これらの処理の繰り返しによって，
英コーパスからルールを抽出・学習する．

誤り検出部

誤りの検出の流れは5つの処理に分けることができる
図1(b))．
入力文は，冠詞の誤りの校正を行いたい文章を含むも
とする．入力文は構文解析されるが，そのとき用いら
る構文解析ツールはルール抽出のときと同じく Apple
Parser を用いた．次に，これもルール抽出のときと同
，入力文にある名詞の特徴抽出を行う．抽出された
の名詞の特徴に対して冠詞選択ルール辞書，および
習によって作成された解析的ルールの中から適用で
ルールを検索し，冠詞の校正を行う．最後に校正結
出力する．

システムの処理過程

章では，2章のシステム概要で述べた処理過程につ
詳細を述べる．

名詞の特徴抽出

英語の冠詞についての知見[2][3]に基づいて，冠詞の選択を決定する重要な要素をカテゴリとする特徴スロットを考える．特徴スロットには4つのカテゴリ，1) 対象カテゴリ，2) 前置修飾カテゴリ，3) 後置修飾カテゴリ，4) 出力カテゴリがある．一つの特徴スロットに一つの対象名詞が対応する．

対象カテゴリは，対象名詞に関する文法要素を保持する．このカテゴリに含まれる6個の要素として，1) 対象名詞の名詞句全体が入る「名詞」要素，2) 名詞句の中で主となる名詞が入る「主名詞」要素，3) 主名詞の単数・複数形情報を保持する「名詞の単複」要素，4) 対象名詞が属する句が入る「属する句」要素，5) 対象名詞を目的語とする動詞が入る「受ける動詞」要素，6) 対象名詞が主語となるような動詞が入る「する動詞」要素がある．

前置修飾カテゴリは，対象名詞において前置修飾語句に関する情報を持つ．このカテゴリに含まれる要素は，対象名詞の修飾語句が入る「修飾詞」要素，その品詞情報が入る「品詞」要素である．

後置修飾カテゴリは，対象名詞に対して後置修飾語句が存在した場合に，その情報を保持するカテゴリである．このカテゴリにはさらに3つのカテゴリが含まれており，それらは 1) 不定詞句カテゴリ，2) 前置詞句カテゴリ，3) 関係詞節カテゴリである．後置修飾として認識された項目に応じて，適切なカテゴリに情報が保持される．

出力カテゴリには，対象名詞に付属する冠詞が入る．具体的には，不定冠詞“a”，定冠詞“the”，冠詞がつかない「無冠詞」のいずれかになる．

次の例文，

This is a book which I bought yesterday.

中で，対象名詞が“book”の場合の特徴スロットを図に示す．図で特徴スロットの要素における“−”は，該当する要素が存在しないことを意味する．

3.2 ルールの適応度計算

英文コーパスから新しく特徴スロットを抽出した際，既存のルールの中に適用可能なルールがあるかどうかを検索する．ルールが適用可能とは，ここでは仮に，対象とルールの特徴スロットにおいて出力カテゴリを除く全ての要素が一致した場合のこととした．

ここで，適用回数と正適用回数というものを定義する．適用回数とは，新しく抽出された特徴スロットに対してルールが適用可能となった回数とする．正適用回数は，

適用回数のうち，新しく抽出された特徴スロットと出力カテゴリが一致した回数とする．正適用率を式(1)に示す．

$$\text{正適用率} = \frac{\text{正適用回数}}{\text{適用回数}} \quad (1)$$

正適用率が高いルールは，英文コーパス中で多く見られる冠詞の用法を表しているので，ルールの確からしさは高いと言える．この考え方を拡張して，ルールの適応度を式(2)のように定義する．

$$\text{適応度} = \log_2(\text{正適用回数})\frac{\text{正適用回数}}{\text{適用回数}} \quad (2)$$

正適用回数の対数を正適用率にかけることによって，適用回数が少ないのに正適用率が高くなることを防ぐことができる．

適応度は全てのルールについて計算される．誤り検出の際には、ルールを適応度順に検索する．ただ，全てのルールを適用しようとすると，不適切なルールを適用してしまう可能性があるため，閾値 θ を考えて，θ を超える適応度を持つルールのみを誤り検出に使用する．

3.3 学習処理

3.3.1 帰納的学習[12]

本稿での帰納的学習とは「実例からそこに内在している規則を獲得すること」と定義される．本手法において実例とは，学習用コーパスから抽出された英文に含まれる名詞の特徴スロットである．この抽出された特徴スロットにおける各要素について，共通部分と差異部分を再帰的に抽出することにより，帰納的学習を実現させる．しかしながら，再帰的処理は一つ一つの名詞における学習時間を増加させる．このため本手法では，再帰的処理によるルールの抽象化を優先せず，できるだけ多くの種類の名詞からルールを抽出するために，ルールの抽象化処理は1度のみ行う．

3.3.2 学習処理の過程

英文コーパスから新しい特徴スロットを抽出した際に，既存のルールの特徴スロットと比較し，先述した帰納的学習により新たなルールを作成する．2つの特徴スロットの各要素について，字面が一致した要素を共通部分とし，それ以外を差異部分とする．新たなルールの特徴スロットには共通部分の要素が残り，差異部分は抽象化される．

学習により新たなルールが作成される例を図 3に示す．この例では，新しく抽出された特徴スロットと既存ルールの特徴スロットの比較により，前置修飾カテゴリと出力カテゴリが共通部分で，対象カテゴリが差異部分となることが判明する．これら2つの特徴スロットの帰納的学習の結果，共通部分は残り，差異部分の対象カテゴリが抽象化された新たなルールが作成される．対象カテゴリの“*”はワイルドカードで，空文字以外の任意の要素の代入を許す．

本手法で使用される帰納的学習では，共通部分があれば必ず抽象化が行われるわけではない．なぜなら，そうしてしまうと極度の抽象化によって，あらゆる名詞に対して適用できるルールが作成されるからである．ゆえに，

対象	名詞	book
	主名詞	book
	名詞の単複	singular
	属する句	NP
	受ける動詞	is
	する動詞	-
前置修飾	修飾詞	-
	品詞	-
出力	冠詞	a

後置修飾	*前置詞句*	前置詞	-
		冠詞	-
		名詞	-
		主名詞	-
		修飾詞	-
	不定詞句	動詞	-
		目的語冠詞	-
		目的語	-
		副詞	-
	関係詞節	主語	I
		動詞	bought
		目的語冠詞	-
		目的語	-
		副詞	yesterday

図2　特徴スロットの例

帰納的学習は何らかの制限の基に行われる必要がある．本手法ではルールの出力カテゴリの冠詞は1種類としているので，学習の際，出力カテゴリの一致と名詞の単数・複数形の一致を必須の条件とした．そのほか，次に示すうち，いずれかの条件を満たすものとした．

- 対象カテゴリで3つ以上の要素の一致
- 前置修飾カテゴリの完全一致
- 後置修飾の前置詞句カテゴリで 2 つ以上の要素の一致
- 後置修飾の不定詞句カテゴリで 2 つ以上の要素の一致
- 後置修飾の関係詞節カテゴリで 3 つ以上の要素の一致

このように条件を設定した理由は，少なくとも1つのカテゴリにおいて2つ以上の具体的な要素を持つルールが生成され，極度に抽象化されたルールの生成を防ぐためである．

3.4 解析的ルール

文献[2][3][8] によると，冠詞の用法の中には，名詞がある特定の単語に修飾を受けた場合，名詞の前に冠詞を付けない規則がある．このような明確な規則の場合，学習によって獲得したルールを用いて誤りを校正するよりも，人手で作成した解析的ルールを用いる方が確実である．現在，本手法における人手で作成した解析的ルールは以下の通りである．

(1) 名詞が形容詞的用法の“this, that, these, those”による修飾を受けた場合

(2) 名詞が人称代名詞や名詞の所有格による修飾を受けた場合

(3) 名詞が限定詞による修飾を受けた場合

(4) 対象名詞が固有名詞で，かつ冠詞選択ルール辞書に適用できるルールが存在しない場合

限定詞とは名詞を指定・限定する働きをする語句で，例として another や each 等がある．

これらの人手で作成した解析的ルールは，誤り検出の際に冠詞選択ルール辞書内のルールと共に用いられるが，両者とも適用可能かつ出力冠詞が異なる場合，(4) を除き，人手で作成した解析的ルールの方を優先する．

4 評価実験

4.1 学習用英文コーパス

本実験では，学習用の英文コーパスに Reuters Corpus[9] に収録されている英文記事を使用した．学習に用いた記事数，総単語数，名詞の異なり単語数を表1に示す．

4.2 実験対象

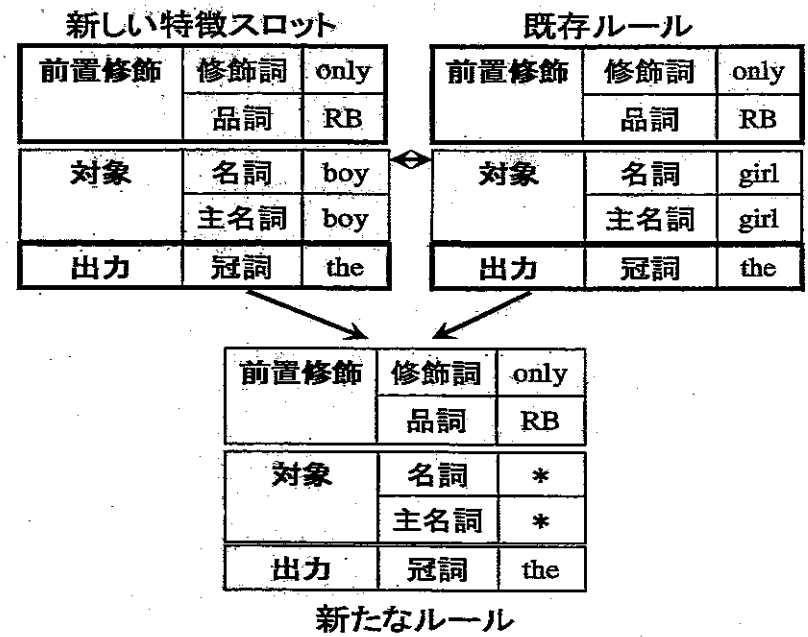


図 3　学習の例

4.1 で述べた Reuters Corpus の英文記事の中で，学習には使用していない記事を無作為に 9 つ選ぶ．それらの記事の冠詞部分を空欄に書き換え，日本人男子理系大学生 2 人が適切と考えられる冠詞を入力する．このような操作で得られた，冠詞誤りが含まれる可能性のある英文記事を実験対象として用いる．文の数は 54 文，単語数 870 語となった．以後，この冠詞部分のみ書き換えられた 9 つの記事をエラーセットと呼ぶ．

4.3 実験手順

まず，2.1 で説明した手法に従って，冠詞選択ルール辞書を作成した．学習で得られたルールの数は 369,019 となった．

次に，2.2 で説明した方法を用いて，エラーセット中の冠詞誤りを検出し，修正した．3.2 で述べた適応度の閾値による出力の違いを見るため，閾値を 0，0.2，0.4，0.6，0.8，1.0 の 6 段階に設定して実験を行った．

4.4 評価方法

本手法を評価する尺度として，Recall，Precision，*F*-measure[10] を用いる．

Recall とは，実験対象中にある実際の誤りのうち，何割の誤りを検出できたかを表す．したがって，Recall を R で表すと，式(3)のように定義される．

$$R = \frac{\text{正しく検出された誤りの数}}{\text{実際の誤りの数}} \qquad (3)$$

Precision は，誤りとして検出された名詞のうち，何割が実際の誤りであったかを表す．Precision を P で表すと，式(4)のように定義される．

$$P = \frac{\text{正しく検出された誤りの数}}{\text{検出された誤りの数}} \qquad (4)$$

F-measure では，Recall と Precision の両方を考慮して誤り検出の性能を評価される．R，P を用いると，式(5)のように定義される．

$$F-measure = \frac{(1+\beta^2)PR}{\beta^2 P + R} \qquad (5)$$

ここで β は Recall に対して Precision を何倍重視して性能評価するかを示す．本実験では Recall と Precision を同程度考慮して性能評価するために，$\beta = 1$ とした．

表 1 学習データ

記事数	912
総単語数	222,458
名詞の異なり単語数	7,993

5 実験結果と考察

表2に本手法の閾値ごとの評価結果を示す．表2より，閾値を 1.0 に設定するまでは、閾値を高く設定するほどシステムが検出する誤りの数も増えることがわかる．*F*-measure が最も大きい値をとった閾値 0.8 の場合，文脈に依存すると見られる定冠詞の脱落・余剰誤りが検出した誤りのおよそ半数を占めた．しかし，Recall が約 4 割，Precision が約7割と特にRecallの値が低い結果となった．以下，誤りを検出できなかった原因を考察する．

実験に用いた解析ツールのミスによる検出失敗は約 2 割存在した．解析の段階で名詞句をうまく抽出できなかった場合，冠詞誤りの検出はできない．

対象名詞がシステムにとって未知であったものが約 3 割を占めた．例外的に定冠詞を用いる固有名詞も存在し，このような例は Precision を低下させる原因にもなっている．学習をさらに進め，名詞の網羅性を高めることによってこのような問題は改善することができると考えられる．

対象名詞はルール中に存在するが，文脈情報が一致しなくて適用できるルールが存在しなかったものは約 4 割あった．このような場合も，学習を進めることで改善できると考えられる．また，帰納的学習の制限を緩くして，より汎用化されたルールを生成することで改善する可能性がある．

6 従来手法との比較

誤り検出実験において，他の研究との比較実験を行うことは容易ではない[1]．なぜなら，従来研究で用いられている共通の実験用英文がなく，同条件での性能比較が行えないからである．また，従来手法であるルールに基づいた手法を再現して比較を行うことも困難である．なぜなら，論文中に実験で用いたルールが全て記述されていないので，忠実に従来手法を再現できないからである．

表 2　実験結果

結果	Recall	Precision	F-measure
閾値0.0	0.18	0.82	0.30
閾値0.2	0.36	0.67	0.47
閾値0.4	0.42	0.70	0.53
閾値0.6	0.42	0.70	0.53
閾値0.8	0.42	0.70	0.53
閾値1.0	0.08	0.57	0.14

表3 他手法との比較

結果	Recall	Precision	F-measure
本手法(0.8)	0.42	0.70	0.53
手法[1]	0.65	0.91	0.76
手法[4]	0.59	0.73	0.65

そこで，本稿における従来手法との比較は，実験条件が比較的近いと考えられる従来手法[1][4]の実験結果と本手法とを比較した．

[1]では，実験対象は日本人英語学習者が書いたエッセーである．また，[4]では，実験対象は日本人が書いた科学技術論文である．

表3に本手法で最も*F*-measureが高い値をとった閾値0.8の場合と従来手法との性能の比較結果を示す．

[4]と比較すると本手法はRecallの値が低い結果となった．また，[1]と比較するとRecall，Precisionともに本手法が低い結果となった．しかしながら，[1]は本手法が対象としている文脈依存の誤りを対象としていない．5.で述べた通り，本手法では実際に文脈に依存すると見られる定冠詞の脱落・余剰誤りを検出することができた．この点は[1]と比較して本手法が優れている．また，[4]はルールベースの手法であるため，ルール追加の際には人手の労力を要するが，本手法ではコーパスから自動的にルールを抽出・学習することができる．この点は[4]と比較して本手法が優れている．

7 まとめ

本論文では，英文コーパスを用いた帰納的学習による英文冠詞誤りの校正手法を提案した．さらに，提案手法に基づいてシステムを作成し，評価実験を行った．実験の結果，最もバランスよく性能が良かったもので，Recallが0.42，Precisionが約0.70，*F*-measureが約0.53となった．従来手法と比較して低い結果ではあったが，文脈に依存する誤りを検出することができ，帰納的学習によって抽象化されたルールの有効性を確認することができた．

今後の課題としては，ルールにおける名詞の網羅性を高めることが挙げられる．ルールの抽出と学習を十分に行うことで，名詞の網羅性を高めることができると考えられる．加えて，本手法では前後の文の文脈は考慮していないが，定冠詞の選択に関わる重要なことであるので，考慮する必要がある．

参考文献

[1] 永田亮，井口達也，脇寺健太，桝井文人，河合敦夫，“日本人学習者のための冠詞誤り検出”，電子情報通信学会論文誌，D-I，Vol.J87-DI，No.1，pp.60-68，2004年1月．

[2] 石田秀雄，“わかりやすい英語冠詞講義”，大修館書店(2002)．

[3] 原田豊太郎，“例文詳解　技術英語の冠詞活用入門”，日刊工業新聞社(2000)．

[4] 河合敦夫，杉原厚吉，杉江昇，“英文の誤りを検出するシステム　ASPEC-I”，情報処理学会論文誌，vol.25，no.6，pp.1072-1079，Nov. 1984．

[5] 関根聡，“英文構文解析システム「Apple Pie Parser」”，情報処理，vol.41，no.11，pp.1221-1226，Nov. 2000．

[6] D. Schneider and K.F. McCoy，“Recognizing syntactic errors in the writing of second language learners”，Proc. 17th International Conf. on Computational Linguistics，pp.1198-1204，Québec，Canada，Aug. 1998．

[7] K. Araki and K. Tochinai，“Effectiveness of natural language processing method using inductive learning”，Proceeding of the IASTED International Conference ARTIFICIAL INTELLIGENCE AND SOFT COMPUTING，pp.295-300，2001．

[8] The Concise Oxford English Dictionary 10e，Oxford University Press，2001．

[9] Reuters Corpus: http://www.reuters.com/researchandstandards/corpus/

[10] C.J. Van Rijsbergen，Information Retrieval 2nd ed.，Butterworth's，1979

[11] Apple Pie Parser: http://www.cs.nyu.edu/cs/projects/proteus/app/

[12] 荒木健治，“自然言語処理ことはじめ　-言葉を覚え会話のできるコンピュータ-”，森北出版株式会社(2004)．