World Wide Web を利用した比喩解釈用知識の洗練

A Method of Knowledge Revision for Metaphr Recognition Utilizing World Wide Web

桝井文人 [1] 福本淳一 [2] 荒木健治 [3] 河合敦夫 [1] 井須尚紀 [1]
Fumito Masui Junichi Fukumoto Kenji Araki Atsuo Kawai Naoki Isu

三重大学 工学部 [1] 立命館大学 情報理工学部 [2] 北海道大学大学院 情報科学研究科 [3]
Mie University Ritsumeikan University Hokkaido University

1 はじめに

属性比喩とは，直喩や隠喩に分類されるものが多く，比喩の中でも基本的な表現であり，より高度な自然言語処理を考えた場合，これらの表現の処理は欠かせない．属性比喩の解釈過程は，たとえる概念 (source 概念) の典型的な特徴 (顕現属性値) のうち，たとえられる概念 (target 概念) と共通するものがクローズアップされることで説明でき，計算機による属性比喩の解釈では，概念間で正しい属性値がクローズアップされなければ，比喩解釈に悪影響を与える (図 1)[1]．WWW から直接，確率的概念記述を構築することが最も有効であるが，処理量が膨大なため，技術的に困難である．

そこで本論文では，比喩解釈におけるクローズアップ属性値を適切に取り出すために，WWW を利用して知識ベースを洗練する手法を提案する．以下，2 では提案手法の詳細について説明する．3 で提案手法の妥当性検証のための実験を行い，その結果を考察する．

2 提案手法

提案手法は，自動または人手により構築した概念を属性値の生起確率で表した知識 (確率的概念記述による) を入力とする．まず，(1) 取得要素である概念と属性値を用いて比較表現または連体修飾表現を生成する．比較表現の生成には，概念 (T) と属性値 (γ) をフレームに適用する．フレームとは，「のように」，「のような」という指標表現を用いて生成できる定型パターン (「T_のように_γ」および「T_のような_γ」) である．(2) 次に生成した表現を WWW 上で検索して頻度を取得する．検索の結果得られた頻度を閾値 α で検証する．(3) 連体修飾の検証が不適合の場合，該当する属性値を属性値集合から削除する．(4) 取得した頻度を用いて属性値集合の生起確率分布を補正し，属性値集合の再ランキングを行う．

属性値の生起確率の補正は，属性値 w_i の概念 T に対する補正生起確率 $P(w_i, T)$ は，WWW から得た頻度と元の知識ベース中の頻度に基づいて計算され，概念 T について，w_i が属性値集合中でどの程度属性値として容易に選択されるかという指標 w_i が，どのくらい他の概念の属性値になり得るかという指標の積として表す．

3 評価と考察

提案手法の効果を検証するために，一連の実験と評価を行った．実験に用いる概念対として，計 76 組の概念を用意した．桝井らの手法 [1] を用いて，新聞記事 10 年分から基本知識ベースを構築し，これをベースライン (BL) とした．上記知識ベースから対象概念の知識を取り出し，提案手法を適用した．属性値頻度の検証における閾値は，桝井らの実験 [2] による最適値 $\alpha = 15$ を用い，補正処理を行わないもの ($type\ I$) と，不要語リストにより不要語を除いたもの ($type\ II$) を試した．各結果について，属性値を生起確率順に上位 5 位まで取り出し，それらが顕現属性値であるかどうかを人手で評価し，MRR(Mean Reciprocated Rank:順位の逆数の平均) を算出，比較した．

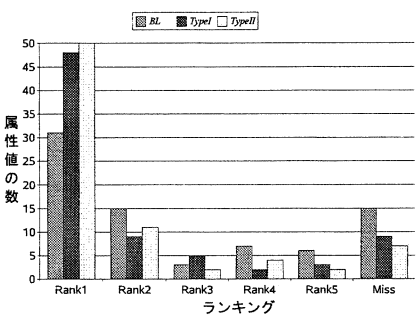


図 2 上位 5 位までの属性値数の比較

MRR スコアは，$type\ I$ が 0.727，$type\ II$ が 0.757 であり，BL のスコア (0.562) に対して 16〜19%の向上がみられた．図 2 は，顕現属性値をどの順位で示せたかを数えた結果である．$type\ I$，$type\ II$ とも，ベースラインと比較して，明らかに 1 位での正解数が多く，顕現属性値の抽出失敗数 ($Miss$) が減っている．また，$type\ II$ は，1 位数，抽出失敗数とも最良の結果であった．表 1 の具体例からは，BL では抽出できなかった顕現属性値の抽出や形態素解析誤りに由来する語の除去が的確に行われていることがわかる．

表 1 再ランキング結果の例 (上位 3 位)

	属性値	BL	属性値	$type\ I$	$type\ II$
氷	厚い	.147	冷たい○	.957	.944
	薄い	.059	鋭い	.008	.008
	白い	.059	固い	.008	.007
炎	急性すい	.148	赤い○	.432	.432
	赤い○	.144	熱い	.288	.288
	真っ赤な	.120	激しい	.137	.137
	激しい	.076	真っ赤な	.066	.066

○:顕現属性値と判断できる最上位の属性値

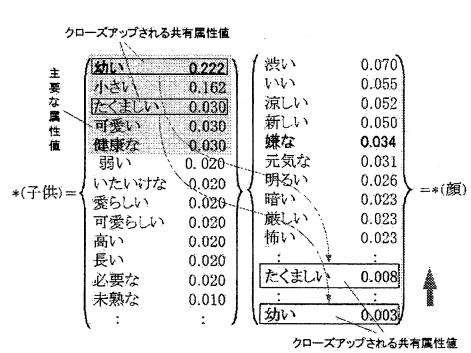


図 1 概念を示す属性値集合と属性値クローズアップの例

4 おわりに

本論文では，比喩解釈における比較概念間で適切な属性値をクローズアップするために，コーパスと WWW を利用して知識ベースを洗練する手法を提案した．実験の結果，本手法によって知識ベースの属性値の精度が，56.2%から 75.7%へ向上した．

参考文献

[1] 桝井文人, 福本淳一, 椎野努, 河合敦夫. 確率的尺度を用いた比喩性判定手法. 自然言語処理, Vol. 9, No. 5, pp. 71–92, 2002.

[2] 桝井文人, 福本淳一, 荒木健治. 比喩解釈を目的とする World Wide Web を利用した属性値の適合性判定. 言語処理学会第 11 回年次大会発表論文集, pp. C2–2, 2005.