29 電子メール返信文自動生成手法における品詞情報適用の有効性について

樋口英司* 荒木健治
(北大情報科学)†

1 はじめに

現在様々な場面で情報化が進み，それに伴い電子メールの利用者が急速に増大している．電子メールの利用は幅広く普及し今後も個人が行うコミュニケーションとしての電子メールの利用は増大していくと考えられる．また，電子メールのやりとりが増大するに伴い電子メールの処理には多大な労力や時間を要するようになった．そのような背景の中，電子メールに関して，膨大なメールから有用なメールだけを選択しようとする情報フィルタリングの研究 [1] などのメール処理支援のための研究が行われてきた．しかし，これまで受信メールに対して返信文を自動的に生成するといった研究はほとんど行われていない．実際には受信メールに対して返信文を作成するという作業は，労力や時間が非常にかかってしまう．そこで我々は，実例から差異共通部分抽出手法によって獲得したルールを用いて返信文を生成するシステムについての研究を行ってきた [2]．本稿では，差異共通部分獲得とそれによるルールの適用の精度向上のため，これまでのシステムに対し品詞の詳しい解析情報を踏まえ返信文生成を行うことを提案する．さらに実験を通じ提案手法の有効性の検討を行った．

2 システム概要

我々が研究を行ってきたシステム [2] の構成図を図 1 に示す．システムは次の六つから構成される．

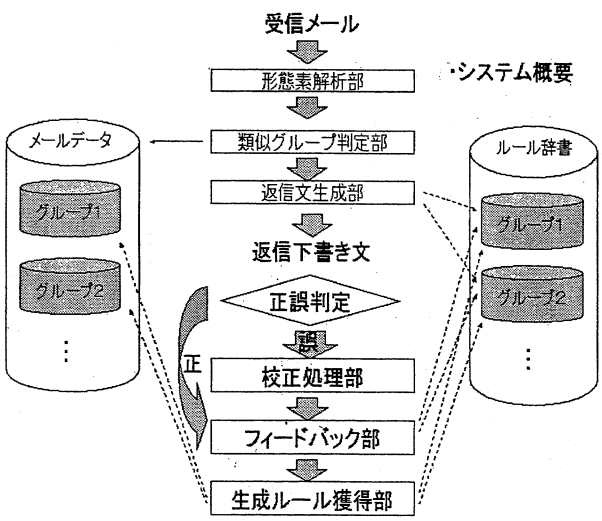


Fig. 1 システム構成

形態素解析部 入力された受信メール文の単語分割を行い，品詞情報を付与する．

類似グループ判定部 受信メールに対し，過去の履歴データとの類似度計算を行い，所属グループを決定する

返信文生成部 解析を行った受信文と生成ルール辞書に保持している生成ルールとの比較を行い、使用する生成ルールを決定し返信文を生成する．

校正処理部 出力された返信文候補のうち、不完全である文に対してはユーザーが人手で校正を行う．

フィードバック部 返信文生成に使用した生成ルールが適切であるか否かにより，生成ルールの正適用回数，誤適用回数をそれぞれ増加させる．

生成ルール獲得部 入力された受信文と校正済みの返信文の組を過去に入力されたメールデータの組と比較し、生成ルールを獲得する．その後，メールデータの格納を行う．

3 品詞情報の利用

これまでのシステムでは差異共通部獲得，ルール適用の場面において名詞，動詞といった品詞情報の一致を考慮してきた．しかし，名詞の中には地名等の固有名詞や会議の開催日時等の数字表現といった，メール使用者の状況によって内容が変化するが文意として変わらないものも存在する．そして実際に携帯電話とメーリングリストのメールには固有名詞や数字表現を含むメールが 55.0%存在した．そこで我々はシステムに対し，これらの固有名詞表現，数字表現の一致を考慮することでシステムの改善を行った．

3.1 システム変更点

今回我々は名詞について着目し，形態素解析システム ChaSen[3] の出力結果を用い名詞に関して

- 固有名詞：地域，組織，人名，一般
- 数字表現

の情報を同時に獲得し，類似グループ判定部においては文書ベクトル生成時にこれらの項目についてのベクトルの要素も生成した．また，返信文生成部，生成ルール獲得部においてこれらの情報の一致の判定も行った．ただし単語の表記自体が一致しているものはそちらの情報を優先して一致とした．固有名詞，数字表現において一致した際に，生成ルール獲得部では一致情報の保持を行った．また各部での尤度計算において，現在は表記の一致に 3 ポイント，単語の原形が一致した場合に 2 ポイント，品詞の一致に 1 ポイントを与え尤度計算を行っているが，

higuchi@media.eng.hokudai.ac.jp
札幌市北区北 14 条西 9 丁目北海道大学大学院情報科学研究科

品詞とともに固有名詞，数字表現であるといった内容が一致した場合には1．5ポイントを与え尤度計算を行った．

4 実験

評価実験として，本稿で提案した品詞情報を用いた場合と用いない場合の二通りで実験データを処理し結果を比較する．出力結果から再現率，適合率を計算し，その内容を比較し有効性を検討する．

4.1 実験内容

実験データとして第1筆者の携帯電話でやり取りされたメールとメーリングリスト（以降ML）でやり取りされたメールからそれぞれ受信，返信メール200組を用いた．出力結果の分類として，出力内容が全て，もしくは一部を削除することで本来の返信文に含まれるものを正適用，それ以外の半分以上削除の必要があるものを誤適用とした．

4.2 実験結果

実験結果を図2に示す．携帯電話のメールを用いた実験では，品詞情報を利用しない場合で最終50組での再現率が70.0%適合率が23.8%となり,F値が35.5%となった．一方利用した場合ではそれぞれ76.7%，34.8%，47.9%となった．MLのメールでの結果は，品詞情報を利用しない場合で最終50組での再現率が85.0%適合率が35.3%となり,F値が49.7%となり，利用しない場合でそれぞれそれぞれ51.7%，48.4%，50.2%という結果が得られた．

5 考察

今回の実験では，携帯電話のメールにおいてF値で12.4%の改善が見られた．一方MLのメールにおいては適合率が13.1%上昇したが再現率が33.3%下降し，F値の値は0.5%上昇するに留まった．この二つのデータ間の違いとして，今回対象としたデータ内での固有名詞，数字表現の使用状況に違いが見られた．全名詞に対する固有名詞，数字表現の割合は．携帯電話では受信側で13.0%，返信側で6.0%でありMLでは受信側で12.8%，返信側で7.2%であった．また1文を構成する単語総数における固有名詞，数字表現の割合として，1文の単語の20%以上を固有名詞，数字表現で構成される文は携帯電話では受信側で15文，返信側で11文に対し，MLでは受信側で9文，返信側4文であった．これより携帯電話のメールでは固有名詞，数字表現が出現する際にそれらが1文中に占める割合が多く，MLのメールでは1文のうちの1，2単語が固有名詞，数字表現である場合が多かった．その結果として携帯電話のメールを使用した場合に固有名詞，数字表現を含んだ類似度によるグループ化が有効に働き，ルール獲得，適用の面でも有効であったといえる．

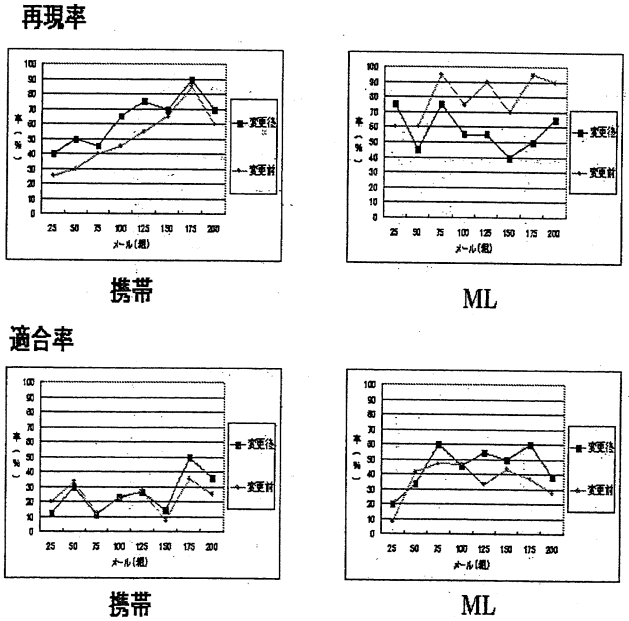


Fig. 2 各データセットによる実験結果

6 まとめ

本稿では電子メール返信文自動生成手法において，利用者の状況によって表記の変化が大きい固有名詞，数字表現に対し，システム各部でこれらの一致情報を用いることでシステムの改善を行い，実験により有効性を評価した．実験では携帯電話のメールにおいて適合率で11.0%，F値で12.4%の上昇し，MLのメールにおいて適合率が13.1%，F値は0.5%上昇した．今後の課題として，文章中に出現する固有名詞，数字表現が少ない場合にも上手く適用するために，他の自立語との共起を考え固有名詞，数字表現が使われる文体を適切に捕らえることが考えられる．また，ユーザーの入力を最低限にするために，ルールの獲得条件，出力条件を見直しユーザーにとって有用なレベルでの返信文が生成できる場合のみ出力を行うような制限を加えることも検討していきたい．

参考文献

[1] 安藤一秋，青江順一，獅々堀正幹:多属性項目の履歴情報に基づく電子メイル文書のフィルタリング手法，自然言語処理133，情報処理学会，1999.

[2] 樋口英司，荒木健治：類似度情報を用いたグループ化による電子メール返信文下書き自動生成手法について，第19回人工知能学会全国大会，2005

[3] 形態素解析システム茶筅 http://chasen.naist.jp/hiki/ChaSen/