帰納的学習による英文冠詞誤り検出における対象名詞の可変特徴範囲を用いた改善

乙武北斗* 荒木健治
(北大情報科学)†

1 はじめに

英語における冠詞の誤りは，日本人英語学習者にとって最も犯しやすい文法項目の一つである．そのため，英文を添削する際には多くの冠詞誤りを修正する必要がある．冠詞の用法には厳密な規則がない場合が多く，修正するためには辞書や用例から多くの事柄を調べる必要がある．

こうした現状を解決するために，我々は冠詞誤りの検出を自動化する手法[1]を提案した．この手法では，英文コーパス中の英文を実例とし，そこに内在する冠詞選択のルールを再帰的に自動獲得する．そして獲得されたルールに基づいて冠詞誤りの検出を行う．冠詞の選択に関わる情報[2]として，対象名詞そのものの性質，受ける修飾語句や動詞などをルールとして抽出する．しかし，前置修飾と後置修飾の両方があるような複雑な修飾関係のある対象名詞からは，複雑なルールしか抽出されない．実際には，複雑な修飾関係に含まれる単純な情報が冠詞の選択に関わることも考えられる．

そこで本稿では，複雑な修飾関係を持つ名詞からも効率よくルールを抽出するために，可変特徴範囲を用いた改善を提案する．加えて，使用されないルールの淘汰処理も行う．本稿では本手法を用いて冠詞誤り検出の実験を行い，改善の有効性について考察する．

2 システム概要

本システムは，処理内容から大きく二つの処理部に分けられる．一つはルール抽出部，もう一つは誤り検出部である．本システムの概要図を**Fig. 1**に示す．両処理部ともに，構文解析器として Apple Pie Parser[3]を用いた．以下，処理部の詳細について述べる．

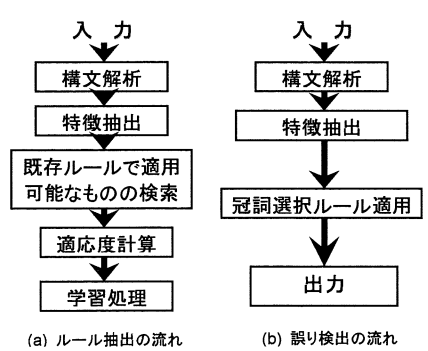


Fig. 1 システムの概要

2.1 名詞の特徴抽出

英語の冠詞についての知見[2]に基づき，冠詞の選択を決定する重要な要素をカテゴリとする特徴スロットを考える．特徴スロットには 3 つのカテゴリ，1) 対象名詞そのものの情報を保持する対象カテゴリ，2) 形容詞などの情報を保持する前置修飾カテゴリ，3) 前置詞句などの情報を保持する後置修飾カテゴリがある．各々のカテゴリには，単語や品詞情報が格納されるが，その際単語は原形変換される．一つの特徴スロットに一つの対象名詞が対応する．また，この特徴スロットと対象名詞に付属する冠詞を組み合わせたものをルールとする．

本手法では，1 つの対象名詞から特徴抽出する際に，1)，1)・2)，1)・2)・3)のカテゴリを持った 3 つの特徴スロットを抽出する．このようにして，異なる特徴範囲を持ったルールを獲得する．

2.2 ルールの適応度計算

英文コーパスから新しく特徴スロットを抽出した際，既存のルールの中に適用可能なルールがあるかどうかを検索する．ルールが適用可能となる条件は，対象とルールの特徴スロットの一致とする．

ここで，適用回数と正適用回数というものを定義する．適用回数とは，新しく抽出された特徴スロットに対してルールが適用可能となった回数とする．正適用回数は，適用回数のうち，新しく抽出された特徴スロットと出力カテゴリが一致した回数とする．適応度を式(1)のように定義する．

$$\text{適応度} = \log_2(\text{正適用回数})\frac{\text{正適用回数}}{\text{適用回数}} \qquad (1)$$

正適用回数の対数を正適用率にかけることによって，適用回数が少ないのに正適用率が高くなることを防ぐことができる．

2.3 学習処理

本稿では学習処理において，「実例からそこに内在している規則を獲得すること」と定義される帰納的学習を用いる．英文コーパスから新しい特徴スロットを抽出し

*hokuto@media.eng.hokudai.ac.jp
†札幌市北区北 14 条西 9 丁目北海道大学大学院情報科学研究科

た際に，既存のルールの特徴スロットと比較し，前述した帰納的学習により新たなルールを作成する．2 つの特徴スロットの各要素について，字面が一致した要素を共通部分とし，それ以外を差異部分とする．新たなルールの特徴スロットには共通部分の要素が残り，差異部分は抽象化される．

学習処理で生成されたルールに関しては，連続未適用回数がある一定値を超えた場合，ルールの淘汰処理の対象とする．これは，学習で生成されたルールがコーパスから直接獲得されたルールと比較して確実性が劣ると考えられるからである．

2.4 冠詞選択ルール適用

誤り検出を行う際，ルール抽出部にて獲得されたルールのほかに人手で作成された解析的ルール辞書も用いる．冠詞の用法の中には一部明確なものも存在し，そういった規則は学習によって獲得されたルールを用いるよりも，解析的ルールを用いる方が確実である．解析的ルールの数は 4 個である[1].

また，獲得されたルールは適応度順に検索され，ある閾値 θ を超える適応度をもつルールのみを誤り検出に用いる．

3 実験と考察

本システムと従来手法[1]を用いて，冠詞誤りを含む英文に対して誤り検出実験とその考察を行う．

3.1 実験方法と評価方法

本実験では，学習用の英文コーパスに Reuters Corpus に収録されている英文記事を使用した．記事数は 565，総単語数 123,094 語となった．獲得されたルール数は，本手法では 49,387 個，従来手法[1]では 158,364 個であった．

実験対象は，Reuters Corpus の英文記事の中で学習には使用していない記事を無作為に 9 つ選び，それらの記事の冠詞部分を空欄に書き換え，日本人男子理系大学生 2 人が適切と考えられる冠詞を入力したものとした．記事数は 9，総単語数 1,586 語となった．

また，評価の基準として，式(2)，(3)で定める再現率，適合率を用いる．

$$\text{再現率} = \frac{\text{正しく検出された誤りの数}}{\text{実際の誤りの数}} \quad (2)$$

$$\text{適合率} = \frac{\text{正しく検出された誤りの数}}{\text{検出された誤りの数}} \quad (3)$$

Table 1 実験結果

	再現率	適合率
本手法(閾値0.8)	0.05	0.86
本手法(閾値1.5)	0.12	0.93
本手法(閾値2.0)	0.21	0.76
従来手法(閾値0.8)	0.26	0.66
従来手法(閾値1.5)	0.02	0.50
従来手法(閾値2.0)	0.00	(計算不可)

以上の実験対象と評価基準で，本手法と従来手法[1]を用いて実験を行った．

3.2 結果と考察

実験結果を Table 1 に示す．本手法において閾値 1.5 の場合，適合率 0.93 と，適合率を重視した場合に最も良い結果となった．これは，使用されないルールの淘汰処理により，従来手法[1]と比較して確実性の高いルールを適用できたと考えられる．加えて，名詞の特徴抽出に可変特徴範囲を用いることで，適用できるルール数が増加し，誤りだと確信のあるもののみを検出する傾向が高まったと考えられる．

しかし，これは逆に再現率を下げる原因にもなっている．適用可能なルール数が多すぎると修正候補を絞りきれず，誤りの検出ができない．適用可能ルールを絞り込む何らかの仕組みが必要であると考えられる．

4 まとめ

本稿では、英文コーパス中の英文を実例とし，そこに内在する冠詞選択のルールを再帰的に自動獲得する冠詞誤り検出システムにおいて，可変特徴範囲を用いた改善を提案した．実験の結果，再現率の低下が見られたものの，適合率 0.93 という高い値が得られた．

今後は，再現率向上のために適用可能ルールを絞り込む処理の追加を検討する．また，より学習量を増やした上で実験を行い，評価に影響があるか調査する予定である．

参考文献

[1] 乙武北斗，荒木健治，“帰納的学習による文脈依存を含む英文冠詞誤りを対象とした校正手法の性能評価”，言語獲得と理解研究会報告，Vol.1，No.1，pp.28-33，2005 年 5 月．

[2] 石田秀雄，“わかりやすい英語冠詞講義”，大修館書店(2002)

[3] Apple Pie Parser, http://www.cs.nyu.edu/cs/projects/proteus/app/