ベクトル空間モデルを用いた用語説明範囲特定手法

土橋惇一　　荒木健治
北海道大学大学院情報科学研究科

1　はじめに

近年，ウェブ上の情報を質問応答システムに利用する研究が盛んに行われている [1]．質問形式の例として,「〜とは何ですか」のように，用語の定義や説明を求めるものがあり，ウェブ上の用語説明文を抽出する手法として,「とは」や「である」など，用語説明文に特有の表現の組み合わせに整合した部分を含む 1 文を抜き出す手法がある [2]．我々はこれらの表現の組み合わせを「テンプレート」と呼び，これまでにテンプレートの自動生成に関する研究を行ってきた [3].

しかし，我々の調査の結果，ウェブ上の用語説明文は複数文で記述されている場合がほとんどであり，テンプレートによる 1 文単位での抽出では，獲得される情報としては不十分であることが明らかになった．

そこで我々は 1 文単位での抽出ではなく，説明範囲を特定し，その範囲内の文全てを抽出することを考えた．本稿では，ベクトル空間モデルを用いて文同士の類似度を計算し，説明範囲を特定する手法を提案する．また，本手法とベースライン手法との比較実験を行い，その結果と考察について報告する．

2　提案手法

我々の提案する説明範囲特定手法は以下の通りである．

1. テンプレートによって 1 文を抽出し，説明文集合の一つとして包含する．ここで，テンプレートによって抽出された 1 文を「起点文」と呼ぶ．
2. 起点文と，説明文集合の直後（および直前）の 1 文との類似度を計算する．
3. 類似度がある閾値を超えた場合，その 1 文を説明文集合として包含し，2. へ戻る．類似度が閾値を超えなかった場合，そこまでを説明範囲とみなし，説明文集合に包含されている文全てを抽出する．

文同士の類似度計算はベクトル空間モデルを利用する．文の特徴をベクトルで表し，2 つのベクトルの内積によって類似度を求める．ベクトルは，比較する 2 つの文に存在する全ての形態素を要素として構成されており（形態素の種類数が n ならば n 次元ベクトルとなる），各要素の値は，文中の出現頻度に品詞情報により重み付けをしたものである．品詞の重みを Table 1 に示す．

3　実験

以下の 3 つの手法について比較実験を行う．

- テンプレートによって抽出された 1 文より直後N文を説明範囲とする．ただし N=3 とした．(手法 A)
- テンプレートによって抽出された 1 文を含んだ段落全てを説明範囲とする．(手法 B)
- 提案手法

Table 1　各品詞の重み値

品詞	名詞	動詞	形容詞	副詞	助詞	助動詞
重み値	2	1	1	1	0.1	0.1

用語事典「イミダス [4]」より無作為に選択した用語 200 語について，その用語の説明が記載されているサイトを Google により検索し，その上位のサイトを 1 件ずつ用意しテストデータとする（計 200 件）．各サイトに対して，人手によりサイト中の説明範囲を特定し，これを本実験の正解とする．以上の条件で各手法によりサイト中の用語説明範囲を特定し，その精度を評価する．なお，本実験における精度 P は

$$P = \frac{\text{正解数}}{\text{全テストデータ数}}$$

と表す．実験結果を Table 2 に示す．

Table 2　実験結果

手法	手法 A	手法 B	提案手法
精度	0.10	0.14	0.64

4　考察

2 つのベースライン手法の精度が 0.15 未満であったことに対し，提案手法の精度は 0.64 であり，提案手法は非常に有用であることを確認した．

手法 A については，N を固定してしまうため，説明文が何文で構成されているかによって精度は変化する．また，経験的に N を決定することは困難であると考えられる．手法 B は，ごく丁寧に記述された HTML 文書にのみ高い精度を示すが，HTML タグの記述の揺れの影響により，抽出する範囲に過不足が生じる．一方，提案手法はサイトの多様な記述構成に対し，柔軟な対応が可能であると言える．

5　おわりに

本稿では，ベクトル空間モデルを利用した類似度計算により，サイト中の用語説明範囲を特定し抽出する手法を提案した．評価実験の結果，本手法はベースライン手法と比較し，非常に有用であることを確認した．今後は類似度計算の際の閾値，ならびに品詞情報の重み値の最適化を行い，精度の向上に努める．また，HTML タグや指示語などの利用を検討する予定である．

参考文献

[1] 桜井 裕，佐藤 理史,“ ワールドワイドウェブを利用した用語説明の自動生成 ”, 情報処理学会論文誌, Vol.43，No.5，pp.1470-1480，2002.

[2] 西野 文人，橋本 三奈子，落谷 亮,“ テキストからの用語とその定義文の抽出 ”，言語処理学会第 5 回年次大会発表論文集，pp.124-127，1999.

[3] 土橋 惇一，荒木 健治,“ WWW上の定義文における表現特徴を利用した用語説明文抽出のためのテンプレート自動生成について ”，言語処理学会 第 11 回年次大会 論文集，pp.791-794，2005

[4] Imidas 2004，集英社，2003.