SVMを用いたユーザ適応型テレビ番組自動予約システム
A SVM-based User Adaptive Recommendation System for TV Programs

徐 金安　荒木健治
JinAn Xu　Kenji Araki

北海道大学大学院　情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

1　はじめに

世界規模の地上ディジタルテレビ放送の発達により，その具体的なメリットとして，多チャンネル化，高画質・高精細度化，多機能化などが挙げられる反面，チャンネル数の増加に伴い，大量の番組情報から，ユーザが好みの番組を選び出すのに，多大な労力を要する．ユーザとテレビとの間の知的なインターフェースとしてユーザ適応型テレビ番組自動予約システムの需要が高まってきている．高精度なユーザ適応型自動予約システムを実現するために我々は,「N-gramを用いた帰納的学習によるユーザの行動予測手法」を提案し，帰納的学習により獲得したルールを，N-gram予測モデルと融和し，その有効性を確認している [1]．さらに，画像処理や自然言語処理など多くの分野で応用されているSVM[2]を用いて，フィードバック処理とを結合したアプローチを試みる．次に，本手法に基づいたユーザ適応型テレビ番組自動予約システムを構築し行った実験結果について述べる．本研究の目的としては，高い予測精度を持ち，動的にユーザに適応可能であり，ユーザにとって便利な知的インターフェースを実現することである．

2　Support Vector Machine

SVMはVapnikによって提案された二値分類のための教師あり学習アルゴリズムである [2]．学習データセットは次のベクトルとして表すことができる．$(x_1, y_1), \ldots, (x_\mu, y_\mu), x_j \in R^n, y_j \in \{+1, -1\}$．$x_j$を事例jを表すn次元の特徴ベクトル，$y_j$を事例jが正例である時に+1,負例である時に-1となる教師情報とすると,SVMはx_jを分離平面で正例，負例に分類する．学習データセットが線形分離可能な場合，SVMはマージン最大化に基づき最適な分離平面を決定する．また，ベクトルの内積によって定義されるKernel関数を用いることによって，線形SVMのアルゴリズムを容易に非線形に拡張することができる．この非線形SVMを利用することで，少ない計算量で複雑な分離平面を記述することができる．本稿では，学習データに対して，ユーザは好きな番組を正例 (+1) とし，好きでない番組を負例 (-1) とする．また，Kernel関数に対して，学習結果の可読性に優れているpolynomial関数（式1）をkernel関数として用いた．

$$K(x, y) = (x \cdot y + 1)^d \qquad (1)$$

これは，各素性のd個までの組み合わせを考えた高次元空間上で線形分離を行うことに相当する．つまり，この多項式カーネルを用いることで，素性の組み合わせを自動的に考慮することができる．

3　IEPG

地上デジタルテレビ放送の一つの特徴として，テレビ番組をEPG(Electronic Program Guide)データとして，ユーザに提供することである．一方，インターネットベースで利用できるIEPG(Internet Electronic Program Guide)もWWWから簡単に入手することができる．本システムにおいて，XMLTV[3]モジュールを利用し，北海道地域のテレビ番組を抽出している．図.1はインターネットから抽出した札幌市HTBテレビ局の番組データ例である．各番組が持つXML要素は図.1に示すように，時間情報，タイトル，番組説明，番組のカテゴリ情報などからなる，なお，番組のカテゴリ情報は現在の日本語テレビ番組CVS(Concurrent Versions System)により14種類に分類としている．抽出された番組情報は9個のチャンネル情報が含まれている．

```
<programme start="2005 06 30　木曜日 16:50" stop="2005 06 30　木曜日
19:00" channel="ＨＴＢ">
    <title lang="ja_JP">イチオシ！</title>
    <desc lang="ja_JP">生活密着あすの暮らしを考えるこだわりトレンド特集▽
エンタメリポート…素朴な疑問を徹底追究▽札幌・グルメマップ▽...</desc>
    <category lang="ja_JP">バラエティ</category>
    <category lang="en">Talk</category>
</programme>
<programme start="2005 06 30　木曜日 19:00" stop="2005 06 30　木曜日
19:54" channel="ＨＴＢ">
    <title lang="ja_JP">いきなり！黄金伝説。</title>
    <desc lang="ja_JP">いきなり！黄金伝説▽アンタッチャブルマグロ１匹食べ尽
くし！▽"カブト焼き"で驚沈▽シェフの知恵で(秘)料理が続...</desc>
    <category lang="ja_JP">バラエティ</category>
    <category lang="en">Talk</category>
</programme>
```

図. 1　IEPGデータ例

4　処理概要

本手法の処理過程を図.2に示す．本稿では，高い汎化性能を持つSVMとフィードバック処理に基づいた新たなユーザ適応型テレビ自動予約システムを提案する．次にシステムの構成について概略的に説明する．

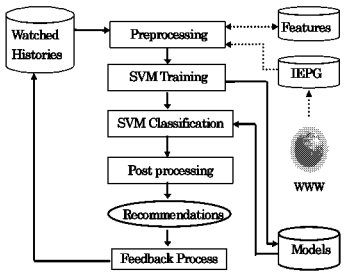


図. 2　処理の流れ

前処理において，ユーザの閲覧履歴及びインターネットから抽出したIEPGデータを素性ベクトルの各要素に基づき，0か1の二値となるように各番組を数値化する．閲覧履歴からの番組を正の例（クラス+1) として，IEPGに記録された過去の番組に対して，未閲覧の番組を負の例 (クラス-1) とし，これらの数値化された番組情報を訓練データとしてSVMを利用して学習させ，新たな予測モデルが生成される．次に，更新された予測モデルとIEPGから数値化された新しい番組とを利用することで，新しい番組の分類が行われる．これらの予測結果に対して後処理を行うことにより，元のIEPGデータに重み付けをして出力する．出力された結果に対して，ユーザが好きであるかどうかを判定する．判定した結果に対して，フィードバック処理により，閲覧履歴に登録

表. 1　週単位データ数 (負例)

Weeks	1	2	3	4	5	6	7	8	9	10	11	12
UserA	2108	2250	2279	2238	2248	2361	2290	2350	2285	2361	2356	2329
UserB	2176	2231	2129	2230	2231	2136	2127	2225	2345	2367	2341	2178
UserC	2015	2236	2134	2236	2137	2232	2286	2178	2284	2253	2281	2249
UserD	2138	2314	2136	2226	2231	2135	2137	2236	2243	2246	2346	2212

し，次の学習と予測に利用される．

5　素　性

任意の番組 P_i を表す特徴として，以下に述べる素性を用いた．利用した素性は，IEPG の特徴と合わせて，収集された全 IEPG データを用いて抽出した．図.1 に示すように，番組の時間情報に対して，曜日，番組の開始時刻と終了時刻を抽出し，他にも，例えば，各チャンネル名，全日本語カテゴリ情報と英文カテゴリ情報も抽出した．また，各番組の説明部分に対して，茶筌 [4] を利用して名詞と未知語を抽出対象とし，形態素単位で出現頻度順により，素性を決定した．なお，茶筌で名詞と未知語を抽出する際に，名詞と数に対して品詞連結を設定した．

6　評価実験

実験には，IEPG データの収集において，Linux OS を利用して crontab コマンドで自動的にインターネットから収集を行った．IEPG は前述のように北海道 (札幌) 地域の 9 個のチャンネルの内容からなる．式 1 に示す d の値は予備実験を行った結果から 2 が最適であることが明らかになった．実験に用いるユーザの閲覧履歴は情報系大学院生 4 人で各 3 か月間に渡ってデータの収集を行った．各ユーザの履歴により実験に用いられたデータの数の負例を表 1，正例を表 2 に示す．

表. 2　週単位データ数 (正例)

Weeks	1	2	3	4	5	6	7	8	9	10	11	12
UserA	48	47	46	48	52	52	51	51	50	45	48	48
UserB	52	50	48	52	50	51	48	52	50	48	49	48
UserC	48	52	50	50	48	52	50	52	52	50	48	48
UserD	48	54	48	56	46	48	48	52	50	48	46	50

また，初期状態を一定に保つために，実験はユーザの閲覧履歴と予測モデルが空の状態から行っている．週ごとにシステムに用意された訓練データを増加させ，予測結果に対して，Rank 60 位まで用いて，次週の訓練データを正解として利用し，予測結果と比較して評価を行った．なお実験の評価は以下に示す式 2 により行った．

$$\text{予測精度} = \frac{Rank60\text{位までに含まれる正解数}}{\text{用意された正解数}} \quad (2)$$

7　実験結果

実験の結果，各ユーザのデータを用いて得られた平均予測精度を表 3 に示す．実験終了時の予測精度を表 4 に示す．獲得された予測モデル数を表 5 に示す．また，各ユーザのデータを最初の一週間分だけ用いてシステムに学習させた場合，二週間分の番組に対して予測を行った結果，予測精度がすべて，50%が超える現象が見られた．また，3ヶ月分のデータを用いることで，予測精度がほぼ全員 92%前後と安定していることも明らかになった．これらの実験結果により，本稿における提案手法の有効性が確認された．

表. 3　週平均予測精度

User	A	B	C	D
Average Precision(%)	82.6	83.3	81.8	84.5

表. 4　実験終了時の予測精度

User	A	B	C	D
Precision(%)	92.2	92.5	92.8	92.6

表. 5　獲得されたモデル数

User	A	B	C	D
Number of Models	1686	1888	1778	1737

8　考察

本研究において，二値分類器である SVM を用いて，EPG 番組データを正例 (+1) と負例 (-1) に分けて，フィードバック学習と結合し，ユーザ適応型推薦システムを構築することができた．

このような仮定を用いると，実録画システムにおいては，必ずしも録画された番組をユーザが好きか，好きでないかという二つのクラスに分けられるとは限らないので，録画システムの利用できる機能やユーザの利用形態により，多値分類の問題として対処しなければならない．しかし，二値分類では，多値分類問題を直接扱うことはできない．二値分類で多値分類問題を扱う方法は様々なものが提案されている [5]．その内，代表的な手法として，One-versus-Rest 法が知られている．よって，仮にユーザの利用形態により K 個のクラスが存在した場合，学習時に一つのクラスとそれ以外の (K-1) 個のクラスとを分類するように二値分類器を繰り返しして作成すれば，問題を解決することができる．これは，今後の研究課題として本手法の有効性を検討する予定である．

9　まとめ

本稿では，SVM を用いたユーザ適応型テレビ番組自動予約システムについて検討した．実験結果より SVM 分類器とフィードバック学習と結合した本手法が，個人適応型テレビ番組自動予約システムの構築に有効であることが証明された．

今後の予定として，*tf - idf* や係り受け解析を考慮した素性ベクトルを用いた SVM とフィードバック学習と結合したシステムを構築し，更なる精度の向上に向けて，ユーザ適応型テレビ番組自動予約の改良について検討することが挙げられる．また，TV アプリケーションを内蔵したコンピュータ実録画システムや地上ディジタルテレビ放送への応用などが挙げられる．

Reference

[1] 徐　金安, 伊藤　敏彦, 荒木 健治:“N-gram を用いた再帰差異共通部分抽出法によるユーザの行動予測手法”，ヒューマンインタフェース学会誌 Vol.7,No.1,pp.55-68(2005).

[2] Vapink,V. :The Nature of Statistical Learning Theory, Springer(1995).

[3] http://membled.com/work/apps/xmltv/

[4] 松本裕治, 北内啓, 山下達雄, 平野善隆, 松田寛, 高岡一馬, 浅原正幸:“形態素解析システム『茶筌』version2.3.3 使用説明書”,http://chasen.naist.jp/hiki/ChaSen/.

[5] Allwein,E.L.,Schapire,R.E. and Singer,Y.:“Reducing Multiclass to Binary: A Unifying Approach for Margin Classifiers”, *Proc. 17th International Conference on Machine Learning*, pp.9-16(2000)