言語獲得システムにおける類似度に基づくラベル拡張手法の提案

内田ゆず　　荒木健治
Yuzu Uchida　　Kenji Araki
北海道大学大学院情報科学研究科
Graduate School of Information Science and Technology, Hokkaido University

１．まえがき

近年，ロボットに関する研究開発が盛んだが，人とのコミュニケーション能力は実現したとは言えない．従来の対話システムは大人の言語処理能力に基づいて構築されている．しかし，大人の知識を全てシステム化することは不可能であるため，汎用的な対話システムの実現に大人を手本にするアプローチを用いるのは限界がある．そこで，人が言語能力を獲得するに至る経緯を模倣したシステムを作成することにより，最終的には人間と同等の言語処理を実現することを考えた．本研究は，人間の子供と同様の言語獲得機構を実現するシステムを目指し，その第一歩として幼児の言語獲得の初期段階で多く獲得される名詞の獲得を行うシステムを提案する．本稿では，画像の類似度を用いた名詞獲得手法について詳述する．

２．システムの概要

本システムは入力・共通部分抽出・スコア計算・出力・ユーザの反応・名詞獲得の 6 つの処理からなる．入力は単一の動物が写った写真 1 枚（以降画像 P と呼ぶ）と，その動物を見ながら大人が幼児に話かける言葉 1 文（以降文 S と呼ぶ）の対である．入力文は全てひらがなで表記され，形態素解析などは施されない．システムは入力を得ると，過去に画像 P とともに入力された文と文 S を比較して，字面が一致した部分を共通部分として抽出する．抽出された共通部分には基本スコアが付与される．基本スコアは，出現頻度が高く，文字数が多く，他の画像と共に出現することのない共通部分が高くなるように決める．スコア計算式は次のように与えられる．

$$SCORE = \alpha \times \frac{F}{PN} \times \sqrt{L} \qquad (1)$$

ただし，α は共通部分が他の画像とともに出現している場合スコアを減少させるように働く係数，F は共通部分が同一画像と共に出現した頻度，PN は画像の出現回数，L は共通部分の文字数である．

求めたスコアが閾値を超えた共通部分は画像 P のラベル候補として出力される．その出力に対してユーザは正抽出(ラベルとして適切)・準抽出(ラベルとして適切ではないが意味はわかる)・誤抽出(意味がわからない)の反応を与える．ユーザの反応によってその共通部分のスコアを再計算する．再計算されたスコアが閾値を超え，さらに正抽出だと判断されたことがある共通部分は画像 P のラベルとして獲得される．これらの処理とは別にラベル獲得ルール生成・類似度によるラベル拡張といった処理も適宜加わる．本稿ではラベル獲得ルールについては紙面の都合上省略する[1]．

類似度によるラベル拡張について説明する．幼児は獲得したラベルを形状が似ている他のものに拡張する[2]．このようなルールがあれば，全ての事物のラベルを１から学習する必要はなくなるので効率的な言語獲得が実現される．また，ラベルの拡張はラベルの対象の範囲を認識することにも役立つので，固有名詞獲得の過程でもこの処理は重要だと考える．具体例を用いて手法を説明する．犬の画像にラベル「わんわん」が獲得されたとき，犬と形状が類似した動物について，「わんわん」という文字列をラベルの候補としてスコアを増加させる，という処理を行う．画像の類似度は実用を考えると画像処理によって決定することが望ましいが，技術面で問題がある．そこで，今回は，動物の写真を見てそれぞれの動物の形状がどの程度似ているかを 10 段階で評価する，というアンケートを行って決定した．

３．実験と結果

入力画像は動物の写真 14 枚を用い，そのうち 4 枚は固有の名前を持っている動物で，残り 10 枚の中に同種の動物が含まれている．全ての画像のラベルが獲得されるまでの入力回数，誤抽出となった回数を調べ，誤抽出となる出力の解析を行う．実験者は 40 代の女性 2 人である．

全ての画像のラベルを獲得するまでにかかった入力回数は類似度導入前は平均 465.0 回，導入後は平均 405.0 回で約 13%減少した．また，ユーザが誤反応と判断した出力の回数は類似度導入前は平均 48.5 回，導入後は平均 42.6 回で約 12%減少した．誤反応の中で，類似度を用いてラベルを拡張したことが原因だったと考えられる出力は平均 8.0 回あった．

４．まとめ

類似度に基づくラベル拡張によって効率的な名詞獲得が可能になった．また，ラベル拡張導入前では，誤抽出となるような出力は，「あれはうさぎさんだよ」という入力文から「ぎさん」という部分を抽出するなど，切り出しに失敗した場合に起きるものであった．しかし，ラベル拡張導入後は，犬の画像に対して「しかさん」と出力する，など実際の幼児にも起こり得るような間違いも含まれていた．これらのことから，類似度を導入することは名詞獲得システムに有益であることが確認できた．

今後は，固有名詞を獲得する部分についてアルゴリズムをさらに検討し，実装する予定である．

参考文献

[1] 内田ゆず・荒木健治，幼児の普通名詞および固有名詞獲得モデルに基づく帰納的学習を用いた再帰的獲得手法の提案，言語獲得と理解研究会，2005.
[2] 今井むつみ・野島久雄，人が学ぶということ―認知学習論からの視点，北樹出版，2003.