社団法人 電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

第二種研究会資料
IEICE SIG Notes
WI2-2006-60(2006.07)

質問応答における知識源選択規則の自動獲得と適用

Automatic Acquisition and Application of the Selection Rule of Knowledge Source for Question Answering

亀山 恵祐† 荒木 健治† 木村 泰知‡
Keisuke KAMEYAMA Kenji ARAKI Yasutomo KIMURA
†北海道大学 大学院 情報科学研究科 ‡小樽商科大学 商学部 社会情報学部
†Graduate School of Information Science and Technology Hokkaido University
‡Department of Information and Management Science Otaru University of Commerce

1. はじめに

近年，日本における情報技術の発展は目覚しく，それに伴う情報インフラの整備により，インターネットを利用して情報を得る機会は大幅に増加した．しかしその一方で，ユーザがWWWから得ることのできる情報が多すぎる，いわゆる情報過負荷であることが問題となってきている．このことから，どの情報が適切であるのかを判断するといった手間が必要になってきている．そこで，この負担を軽減するために自然言語で質問したことに対して，大量の文書群，すなわちこの場合システムの知識源を検索し，適切な応答を返す質問応答の技術が提案されている．

質問応答システムでは，様々な試みがなされており，知識源として，新聞記事を用いるものや，インターネット上の文書，つまりWWWを用いて検索するものなどがある [1] [2]．知識源として新聞記事を用いることの長所は，正確な情報であり信頼できるものであるといえる．また表記の揺れが少なく，計算機にとって解析しやすい文であるともいえる．一方で，記事の対象の範囲に制約があり，記事の数も限られているため，あらゆる分野を網羅できるわけではない．更に出版物であるため，情報が最新のものではない可能性があるといった短所がある．それに比べてWWWは，情報は常に更新されており，対象となりうるページも新聞記事に比べて大量にあるという長所がある．一方短所としては，誰でもWWWの著者となることができるので，Web文書の信頼性が新聞記事に比べると低く，誤った文書も十分ありうることにも配慮しなければならない．また，個々が書く文書には口語的な表現が多々含まれることもあり，計算機で解析するには難しいものがあるといったことが挙げられる．

また，通常WWWを知識源として用いるためには，既存の検索エンジンを用いることになるが，検索された個々のサイトを一つずつ解析していくのは時間がかかりすぎて現実的ではない．そこで本稿では，この検索したサイトを解析する時間を短縮させる方法として，一番簡便であり，有効であると判断されたWeb検索エンジンの抜粋出力であるSnippetを利用する [2] こととした．このSnippetを用いることにより，WWWから100件のサイトを解析しても新聞記事数年分を検索するのと，さほど変わりない時間で応答を返すことが可能となる．

以上に挙げたように，新聞記事とWWWの記事にはそれぞれ長所と短所がある．そこで，これら2つの知識源の長所を活かし，短所を補うようなシステムを構築することができないかと考えた．これまで知識源選別に関連した研究はほとんど行われていない．本研究は，こうしたそれぞれの知識源の長所や短所を考慮した上で，質問に対した最適な知識源を自動獲得することを目的として，進めている．本稿ではNTCIR-5 QAC-3の質問文を用いてその可能性を調査した．

2. 知識源

本システムは，NTCIR-5 QAC-3に用いた質問応答システム [1] の情報検索部分において、知識源を使い分けることができるように変更を加えた．知識源としてNTCIR-5 QAC-3に用いられた新聞記事，毎日新聞と読売新聞の1998年から2001年までの各4年分，計8年分 (表 1) を利用した．更にWWWからの知識源としてGoogle [3] による検索結果のSnippetを用いて調査を行った．

表 1: 新聞記事8年分のデータ量

文書数	1,454,457
総キーワード数	6,901,070
ファイルサイズ	約412MB

2.1 新聞記事

知識源としての新聞記事の選択肢の幅を広げるために，まず毎日新聞と読売新聞の区別なく各年ごとで分けた．そしてそれを1998年，1999年，2000年，2001年の1年分，1998-1999年，1999-2000年，2000-2001年の2年分，1998-2000年，1999-2001年の3年分，それから1998-2001年の4年分，全部で10通りの知識源を用意した．これらをそれぞれNamazu [4] でインデキシングを行うことにより，検索対象を使い分ける．

2.2 WWW

もう一つの知識源としてWWWを用いる．今回は，既存のWeb検索エンジンGoogleで検索した際の抜粋出力Snippetを利用する．

3. 実験

本実験では知識源選択の有効性を確認するために，知識源の使い分けによる正応答数の評価を行った．システムに質問した場合の，それぞれの知識源からの応答を比較した．ここで質問文には，NTCIR-5 QAC-3 の質問文 360 問のうち，本システムが対応可能である質問タイプが PERSON, LOCATION, DATE, ORGANIZATION と判別された 164 問を用いた．

3.1 実験結果

表 2 に．応答に正解があった質問 (質問 1)，1998-2001 年の新聞記事に正解があった質問 (質問 2)，WWW に正解があった質問 (質問 3)，新聞記事と WWW の両方で正解があった質問，すなわち，質問 2 かつ質問 3 に当てはまる質問 (質問 4)，それぞれの数を示す．ここで質問 2 を選んだのは，新聞記事の分類を行わないのであれば，この 1998-2001 年の 4 年分の新聞記事があれば全てを網羅しているはずだからである．

表 2: 正解があった質問数

質問 1	質問 2	質問 3	質問 4
62 (37.1%)	26(15.6%)	31(18.6%)	11(6.6%)

知識源の使い分けを行わなかった場合，新聞記事では 15.6%，WWW からでは，18.6%であるが，使い分けを行った場合では，37.1%と，確実に正解が得られやすくなる．現段階では，10 種類に分類した新聞記事と WWW のいずれかに正解があった場合の数であるが，この知識源の適切な選択を行うことができれば，これだけの正解を得られるといえる．

また新聞記事でも WWW でも，どちらでも正解が得られたのはわずか 11 問であり，このことから逆に新聞記事のみ，または WWW のみでしか得られない質問もある．特に WWW でしか得られなかった質問文は，今回 9 問あった．特に過去の大きな事件や事故に関しては，正確で詳細なサイトがあり WWW の方でしか正解が得られない場合があった．また芸能やエンターテイメントの分野でも新聞記事の特徴上，関連する記事が多くなく，逆に WWW 上には多くのサイトが存在するために WWW でしか正解が得られない場合があった．

3.2 実験結果例

質問応答システムにおいて，その機能を大別すると，質問文の質問タイプ同定，質問文からのクエリ生成，知識源からの応答検索，応答生成といったものがある．各々が重要な機能であり，これらを上手く組み合わせることによって，正しい応答を増やすことができる．特に，本研究で取り上げる知識源からの応答検索部は，質問文から生成したクエリに大きく左右され，検索結果が変わってしまう．そこで本研究で行っている知識源の使い分けを用いることで，クエリの生成が必ずしも最適でなくとも，正しい応答が得られるのである．その実例を表 3 に示す．

表 3: クエリ例

質問文	『皇太子妃雅子さまが 出産されたのはいつですか.』
クエリ	妃・いつ・皇太子・さま

この例では，皇太子妃である“雅子さま”や“出産”といったクエリは生成されていないが，新聞記事 2001 年分を検索したときに，正応答を返している．これは，検索対象を限定したことにより，クエリが最適でなかったとしてもある程度関連のあるクエリがあれば，記事の絞り込みが可能であることを示している．

4. まとめ

今回，質問応答における知識源選択規則を自動獲得し適応するために，知識源選択の有効性を確認する実験を行った．その結果，新聞記事を使い分けることにより，より正しい応答が得やすくなることが分かった．また知識源を使い分けることによって，質問文からのクエリ生成において，最適ではないクエリが生成されたとしても，正しい応答が得られることが分かり，クエリ生成部や知識源からの応答検索部，応答生成部などを組み合わせる質問応答システムには有効であることを確認した．

5. 今後の予定

今後は，新聞記事だけではなく WWW における知識源の選択肢を増やすことを行う．検索先を特定の情報提供サイトに限定したものや，ブログやニュースサイトだけに限定したものなどを考えている．また，これらの多様な知識源を学習によって自動判別するために，パラメータとしてどういったものが適切であるかを調査し，学習させていきたいと考えている．

参考文献

[1] Yasutomo Kimura, Kenji Ishida, Hirotaka Imaoka, Fumito Masui, Marcin Skowron, Rafal Rzepka, Kenji Araki. “Three Systems and One Verifier - HOKUM's Participation in QAC3 of NTCIR-5”, Proceedings of NTCIR-5 Workshop Meeting, pp.402–408,Tokyo,Japan, Dec.6-9,2005.

[2] 相良 春樹, 森 辰則, 中川 裕志. “質問応答に対する知識源としての Web 検索エンジンの Snippet の有効性”言語処理学会第 12 回年次大会発表論文集,pp.316–319,(2006)

[3] Google. http://www.google.co.jp/

[4] 前文検索システム:Namazu. http://www.namazu.org/