帰納的学習を用いた営業日報自動生成システムのための重要文抽出手法

矢野純司　荒木健治
北大情科

1　はじめに

自然言語処理を用いて，これまで人手で行われてきた文書処理を自動化することによる大きな労力の削減になることが見込まれる．その中の一つとして，文章を要約するという試みがあり，これまで盛んに研究されてきている．これらの研究で要約の対象としては国会会議録を対象としたもの [1]，新聞記事を対象としたもの [2] などが存在する．しかし，これらの手法はそれぞれの対象文書に特化したものであり，異なる文書に対しては望まれる出力が得られない場合が多い．

我々はこれまで，コールセンター対話を対象とした営業日報の生成の研究を行ってきた [3]．この研究の実用化により日々人手で行われていた労力を大幅に軽減することが見込まれる．この研究では SVM と tf*idf を用いて重要文抽出を行っていたが，精度と汎用性に問題があり，改良が求められていた．

本稿では我々が開発した帰納的学習 [4] を用い，対話中より営業日報に記載されるべき重要文を推定，出力する手法を構築し，その評価を行った結果について述べる．

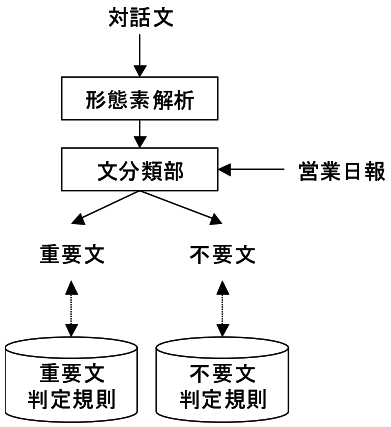


図 1　学習処理部

2　概　要

システムは学習処理部と重要文抽出部に分かれる．学習処理部では，コールセンター対話の書き起こし文とその対話における営業日報のペアから帰納的学習を用いて規則の獲得を行う．

まず，これらのペアのそれぞれの文に対して形態素解析ツール「茶筌」[5] を元に単語分割，品詞付与を行い，営業日報内のキーワードを元に対話内の各文を重要文か不要文かに分類する．その後，学習部において重要文群，不要文群それぞれに対し帰納的学習を行い，重要文判定規則，不要文判定規則を獲得する．

獲得された規則は適用部にて利用される．新たに入力されたコールセンター対話の各文に対し，学習部で獲得された重要文判定規則，不要文判定規則を適用しそれぞれの適用回数を元に尤度計算式によって尤度を決定し，尤度の高いものを重要文として出力する．

3　処理過程

3.1　学習処理部

重要文判定規則，不要文判定規則の獲得，規則辞書への登録を行う．図 1 に処理の流れを示す．学習データのコールセンター対話の書き起こし文を営業日報内の「名詞」,「未知語」と比較し，それらの単語が含まれていた場合を重要文，そうでない場合を不要文と定義，分類する．その後，既存の学習データと比較し，字面，品詞情報を元に帰納的学習により共通部分を抽出，新規の規則として辞書へ登録する．

3.2　重要文抽出部

入力された新たなコールセンター対話に対し，学習部で獲得された規則を適用して重要文を決定，抽出する．図 2 に処理の流れを示す．

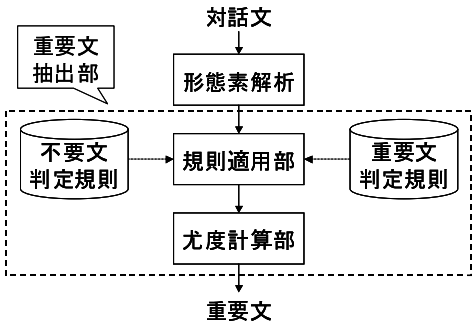


図 2　重要文抽出部

入力対話中の文と，重要文判定規則辞書，不要文判定規則辞書に保存されている規則を比較し，適用可能な規則を選択する．ここで，重要文判定規則が適用された場合にはその文に対して重要文規則適用度数を１，不要文判定規則が適用された場合は不要文規則適用度数を１増加させ，式 (1) に示す尤度計算式を用いて尤度を計算する．

$$尤度 = \alpha * IN + \beta * UN + \gamma * N \qquad (1)$$

ここで，IN は重要文規則適用度数，UN は不要文規則適用度数，N は文中に存在する名詞と未知語の数，α，β，γ は重み係数である．名詞，未知語の数 N はルールが適用されにくい長い文の尤度を増加させるために用いる．全ての文の尤度を比較し尤度＞０のものを重要文とする．出力の際，入力対話に対し式 (2) で定義される要約率を元に出力する重要文の数に制限を施し，尤度が上位のものを重要文として出力する．

$$要約率 = \frac{出力重要文数}{入力対話中の文数} * 100 \quad [\%] \qquad (2)$$

4　評価実験

4.1　実験方法

本手法を評価するために実際にシステムを構築し，出力された重要文に対し評価実験を行った．実験データとしてコールセンターにおける対話を録音したデータを人手で書き起こしたデータを用いた．データ数は 100 対話，4,336 文である．そのうち学習データとして 50 対話 2,221 文，残りの 50 対話 2,115 文を評価データとして利用した．また，本実験において尤度計算式の重み係数α，β，γは予備実験の結果それぞれα＝1.0，β＝1.0，γ＝0.2 と設定した．

4.2　評価方法

出力された重要文と，既存の営業日報とを比較し人手により性能評価を行った．出力された重要文が文中に営業日報内の内容を含んだ場合正解とし，精度を算出した．また，既存の営業日報に対して，

1. 内容が出力文群の中に全て含まれる．(正解)
2. 内容が出力文群の中に一部含まれる．(準正解)
3. 内容が含まれない．(誤り)

と分類，評価し再現率の算出を行った．精度の定義式を式 (3) に，再現率の定義式を式 (4) に示す．

精度

$$= \frac{正解した出力重要文数}{出力重要文総数} * 100 \qquad (3)$$

再現率

$$= \frac{正解及び準正解の文数}{営業日報内の文数} * 100 \qquad (4)$$

4.3　実験結果

評価データ 50 対話，2,115 文に対し，重要文として出力された総数は 182 文で精度は 65.4 %，また営業日報内の文数 117 に対し再現率は 65.8 %であった．従来手法 [3] の結果との精度と要約率の比較を表 1 に，再現率の比較を表 2 に示す．

表 1　精度と要約率

	本手法	従来手法
精度	65.4%(119/182)	49.6%(65/131)
要約率	8.61% (182/2,115)	6.19% (131/2,115)

表 2　再現率

	本手法	従来手法
1 正解	44.4%(52/117)	37.6%(44/117)
2 準正解	21.4%(25/117)	17.9%(21/117)
3 誤り	34.2% (40/117)	44.4% (52/117)
有効 (1+2)	65.8% (77/117)	55.6% (65/117)

5　結論

本稿では，実際のコールセンター対話データから帰納的学習を用いた重要文抽出手法の提案を行った．さらに提案手法に基づいてシステムを作成，評価実験を行い，その結果，精度 65.4 %，再現率 65.8 %という高い値となった．このことから帰納的学習を用いた重要文抽出手法の有効性を確認することができた．今後は音声データを元に音声認識システムを用い，音声認識誤りを含んだデータに対し評価実験を行っていく予定である．

参考文献

[1] 山本 和英, 安達 康昭. 国会会議録を対象とする話し言葉要約. 自然言語処理, Vol.12, No.1, pp.51-78, 2005.1

[2] 岡崎直観，松尾豊，石塚満．関連する複数新聞記事からの重要文抽出法．第３回 AI 若手の集い　MYCOM2002，2002.

[3] 岩崎 礼次郎、荒木 健治．コールセンターにおける対話データを用いた営業日報の自動生成．人工知能学会ことば工学研究会資料 SIG-LSE-A503-14 (pp.87-94)（2006 年 3 月）

[4] Kenji ARAKI and Koji TOCHINAI: "Effectiveness of Natural Language Processing Method Using Inductive Learning", IASTED ASC 2001, pp.295-300, May, 2001, Cancun, Mexico

[5] 形態素解析システム茶筌 http://chasen.naist.jp/hiki/ChaSen/