Web を利用した能動的質問生成

伊藤慎吾*†　荒木健治†

(北海道大学大学院 情報科学研究科) †

E-mail　{ito0514,araki}@media.eng.hokudai.ac.jp†

1 はじめに

現在，コンピュータに知識を獲得させ，それを有効に利用しよう，という研究が多く行われている．

特に Web が発達してきてからは，人間から全ての知識を得るのではなく，すでに Web 上に存在している大量のデータから知識を獲得しようという試みが数多く行われてきた．しかし，現段階では汎用的な知識獲得は難しいため，教育用シラバス[1]など特定の分野に絞った知識獲得や，上位概念・下位概念[2]の抽出などにとどまっている．

それらの知識獲得システムの現状と対照をなしているのが，近年鳥沢らが行っているプロジェクト[3]である．このプロジェクトでは，ユーザの発したキーワードより属性情報，準備方法，利用法などを Web から獲得し，組み合わせて質問生成を試みている．ユーザから知識を得るため，ユーザが正しい情報を入力するのであれば，従来の知識獲得システムのネックであった知識の精度の問題は解決することができる．しかし，属性情報を用いるために，質問が画一的になっているなどの問題も見られた．

そこで，本研究では Web 上に存在する質問文から学習することで，より使用頻度が高く，バリエーションに富んだ質問を生成できるシステムの開発を行った．また，鳥沢らが最初に大量の Web 文書から学習し知識を蓄えておく方法をとっているのに対し，本研究で開発された知識獲得システムは，ユーザとのコミュニケーションによって徐々に知識を蓄えていく方法をとっている．これは，ユーザからのフィードバックを受けることによって，最終的に精度の高い質問をすることが可能になるためである．今回作成した質問生成システムの評価は，いかに最初に利用してくれるユーザの負担を少なくするか，が大きな目標となっている．質問生成の精度が高いほど，ユーザは生成された質問が誤っているという報告をせずにすみ，快くシステムを利用してくれるはずである．

また，応用範囲については，本システムの性質上，対話システムとなる．しかし，対話システムは，大量の情報をまとめて書き込むことには適していない．これは，アンケートフォームなどにしても，「住所」「氏名」など知りたい情報を羅列した方が早く，見やすい場合が多いためである．そのため，現在は雑談システムなどにおいて会話をつなげ，なおかつ情報を集めるために質問を発する，といった質問生成を利用する方が多くの人に利用されやすいのではないかと考えられる．

2 システムの概要

本研究では，目標とする知識獲得システムにおける質問生成システムに焦点を絞り，開発・評価を行った．

目標とする知識獲得システムの構成を図 2.1（灰色部は質問生成システム）に示す．本システムでは，ユーザが名詞を含んだ文を入力後，その入力に含まれる名詞に対して適した質問を生成する．

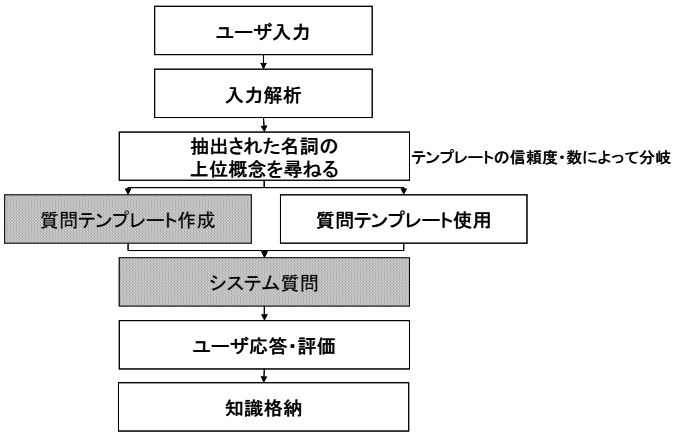


図 2.1　知識獲得システムの構成

その際，ある名詞に対する質問文は，それと同じ上位概念をもつ名詞に対する質問文としても使用できる場合が多い，という仮説の基にシステム作成を行った．上位概念に対する質問テンプレートを作成すれば，その下位概念にあたる様々な名詞に対する質問を生成することが可能である．

質問生成システムの構成を図 2.2 に示す．質問テンプレートなどの保存には，すばやい検索ができるようにリレーショナル DB（MySQL）を利用した．また随所で出現する名詞の判別，単語の分かち書きには ChaSen[4]を使用した．

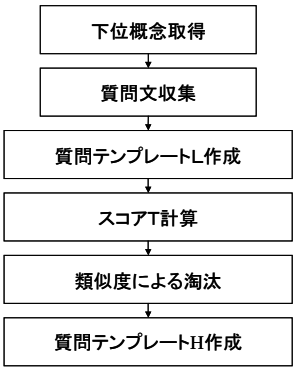


図 2.2　質問生成システムの構成

まず 1 つの上位概念に対して複数の下位概念を取得し，それらと文末表現（ですか，でしょうか etc）をセットにして，「yahoo 知恵袋」と「教えて goo」という質問と回答が大量に掲載されているサイトより質問例を収集する．これは，「google」などの検索サイトを利用するのに比べ，短時間で大量の質問例を収集できるためである．

収集した質問例は，このまま用いるには長すぎ，汎用性にかけるため，構文解析を行い「文末表現にかかる文節＋文末表現」として取り出す．これを質問テンプレート L と呼ぶ．

次にこれらの質問テンプレート L に対して，スコア計算を行う．ある質問テンプレート L に含まれる名詞が，質問テンプレート L 全体でどれほどの頻度で出現しているかを考慮に入れ，名詞の出現頻度を質問テンプレート L の総単語数で割ったものを scoreT とした．

さらに，スコア計算が終わった質問テンプレート L に対して，類似度による淘汰を行った．

淘汰が終了した段階で，スコアの上位 100 件を取り出し，これらを他の下位概念の質問テンプレート L の集合と比較し，100 件の質問テンプレート H を作成した．

作成された質問テンプレート H は，誤りを含んでいる可能性があるため，検索エンジンによって誤りを含む質問テンプレート H を淘汰し，最終的に残ったものをユーザに対して提示できる質問テンプレート H とした．

2.1 下位概念取得

本研究では，質問テンプレート H を導出するのが最終目標となるが，より汎用的で精度の高い質問テンプレート H を作成するためには，多くの質問テンプレート L を必要とする．これは，1 つの質問テンプレート L を利用した場合，その下位概念特有の質問が作成されてしまう可能性があるためである．

しかし，ユーザの入力中から全ての下位概念を抽出しようとすると，システム動作直後のユーザには，的確な質問が返せないという問題が発生する．

そこで本システムでは，ユーザ入力中の下位概念と同じ上位概念を持つ下位概念を自動的に収集することを試みた．

下位概念の自動取得に関しては，様々な過去研究が存在するが，今回は更新が容易であり，ユーザが使用しながらも学習し続けることができるという点に着目し，安藤らの「定型表現を利用した下位概念の自動取得」[5]を用いて行った．安藤らの研究によると，定型表現を利用して，上位概念から下位概念を自動取得できる．定型表現の種類は表 2.1.1 の 7 つが最も信頼性が高いと述べられており，実際「動物」などの下位に一般名詞を多く含むものに対しては，6 割以上の正解率で下位概念が取得できたと報告されている．

表 2.1.1　定型表現一覧

定型表現	
「N1などのN2」	
「N1などN2」	
「N1というN2」	
「N1のようなN2」	
「N1に似たN2」	
「N1以外のN2」	N1:下位概念
「N1と呼ばれるN2」	N2:上位概念

本研究では，安藤らが用いた新聞記事コーパスの代わりに Web を用い，さらに頻度の高い順に 10 件を取得する，人名を検出する機能を追加，括弧で囲まれた文を 1 つの概念として認識する機能を追加，という限定条件の下に取得を行ったため，安藤らの研究よりも高い正解率で下位概念を取得することができた（表 2.1.2）．

表 2.1.2　下位概念の取得精度

上位概念	精度（有効数/10）
動物	1
犬	0.5
魚	1
料理	0.8
歌手	0.6
RPG	0.5
<平均>	0.73

この後行う予備実験に関しては，この取得精度が平均値に一番近い上位概念である「料理」を用いている．

自動的に取得する下位概念の数は，予備実験（図 2.1.1）の結果より，10 件に設定した．類似度αは 2.5 の式（1）を用いて計算した．

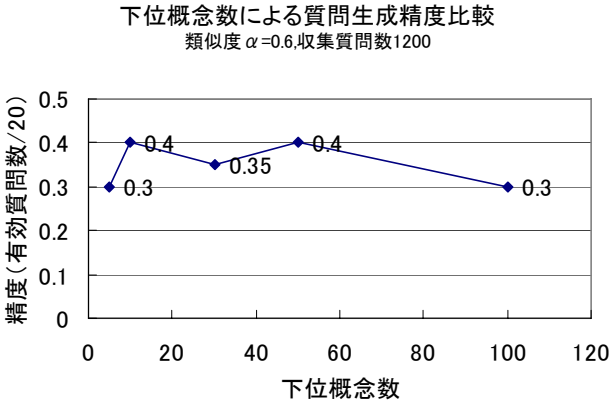


図 2.1.1　下位概念数による質問生成精度比較

2.2 質問文収集

取得した下位概念を用いて Web より質問文の収集を行った．質問文収集には，通常の検索サイトを用いるより高い効率で大量の質問文を集めるために質問サイトである yahoo 知恵袋，教えて goo を用いた．

下位概念をクエリとして検索したページから，パターンマッチを利用して，質問文を収集する．パターンマッチに使用したのは，「*（下位概念）*（文末表現）」（*はワイルドカード）のような文構造である．文末表現は，渡辺らの研究[6]を参考に表 2.2.1 のように決定した．

表 2.2.1　文末表現一覧

文末表現	
ですか	ませんか
でしょうか	教えて
ますか	？

この際収集する質問件数は，予備実験（図 2.2.1）より，1200 件（100 件*収集サイト数 2*文末表現 6）に定めた．

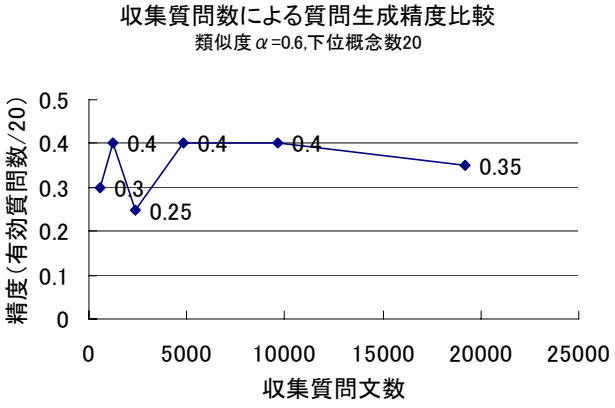


図 2.2.1　収集質問数による質問生成精度比較

2.3 質問テンプレート L の作成

収集した質問文に汎用性を持たせるために，構文解析を行い，「文末表現にかかる文節」＋「文末表現」のセットを作成し，これを質問テンプレート L とした．構文解析には CaboCha[7]を用いた．さらにこの段階で，下位概念にあたる名詞が含まれていた場合@という変数に置き換え，下位概念を入れ替えることで，様々な質問を生成できるようにした．

2.4 質問テンプレート L のスコア計算

質問テンプレート L に含まれている名詞は，その名詞が質問テンプレート L 全体でよく使われていればいるほど，下位概念と共起していることとなる．下位概念と共起している名詞を含む質問テンプレート L は，より的確な質問であると考えられる．

そこで，どの質問テンプレート L が有用であるかを推定する尺度として，ある質問テンプレート H に対する質問テンプレート L 全体での名詞の出現頻度を使用した．用いた名詞は「固有名詞」と「普通名詞」で，代名詞などは，上位概念・下位概念に関係なく出現するため除いた．今回は最も単純なものとして，その質問テンプレート L に出てくる名詞の出現頻度の合計をテンプレート中の単語数で割ったものを scoreT とした．ScoreT は式（1）を用いて計算される．

$$scoreT = \frac{\text{名詞の出現頻度の合計}}{\text{総単語数}} \qquad (1)$$

2.5 質問テンプレート L の類似度による淘汰

作成した質問テンプレート L には，「店を教えて」と「お店を教えて」のように，字面上類似した質問が多く存在する．このような質問は，どちらをユーザに尋ねても得られる答えは同じであるため，淘汰する必要がある．

そこで，質問テンプレート L 間の類似性を判断するために，類似度αを定義した．αの定義式を式（2）に示す．

質問テンプレート L1 と L2 を比較した場合の類似度αは，L1 の総単語数<L2 の総単語数という条件のとき，L1 と L2 の単語で一致した数を L1 の総単語数で割ることで求められる．

$$\alpha = \frac{L1 \text{と} L2 \text{で一致した単語数}}{\text{総単語数 } (L1)} \qquad (2)$$

これを用いた場合，例えば「お店を教えて」と「店を教えて」は図 2.5.1 のように計算され，類似度は 1.0 となる．

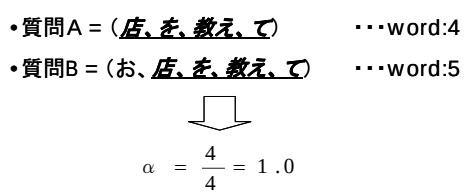


図 2.5.1　類似度計算例

この類似度の閾値は，予備実験（図 3.5.2）により，最適値 0.6 と求められた．類似度が閾値を越えた場合，単語数の少ない質問テンプレート L は削除される．

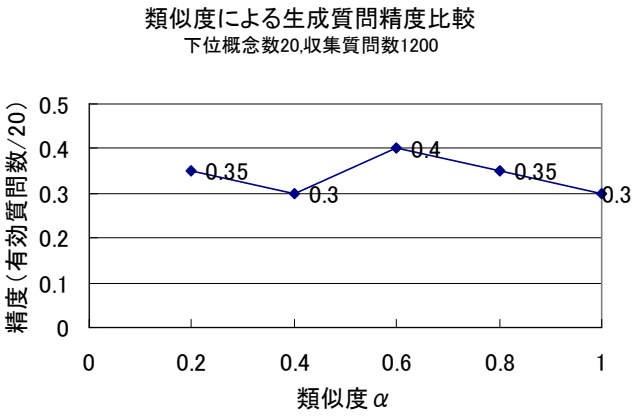


図 2.5.2　類似度による質問生成精度比較

2.6 質問テンプレート H の作成

2.2～2.5 の作業を繰り返すことで質問テンプレート L の集合が 10 生成される．これらより，質問テンプレート H の集合を生成する．

質問テンプレート L の字面全体が一致するものは，まとめ，スコアを加算する．最終的に，スコアの高い順に 100 件取り出し，それを質問テンプレート H とする．

定型表現に当てはまらない上位概念・下位概念も存在するため，下位概念の自動取得は未だ 100%の精度では行うことができないので，これらの質問テンプレート L の中には，質問テンプレート H を作成するのには，不適格なものも混在している．

しかし，6 割以上の正解率で下位概念が取得できた場合，それらの質問テンプレート L には類似性の高いものが多く含まれている可能性が高いため，残り 4 割の不正確な下位概念の質問テンプレート L は淘汰され，利用される可能性が低くなる．

2.7 検索エンジンを用いた淘汰

コンピュータによって生成された文は，文法的・意味的に誤っている場合がある．そのため，人間が書いた文と比較し，誤っている文を削除する必要がある．

本研究では，人間が書いた文が大量に存在している Web をリソースとし淘汰を行う．質問テンプレートは Web を元に作成しているため，新しい表現などが存在している場合があり，動的に変化しない既存のリソースでは正しい評価をできない可能性が高いためである．

評価基準はその質問テンプレートの検索数をもとにしたが，評価する際，質問テンプレートはフレーズとして検索されるため，長文は検索数が極端に低くなる場合もある．そこで，文の長さによって検索数にバイアスがかかるように正規化を行った．

最終的に，評価基準 β は質問の検索数に質問文の総バイト数を足したものとなった．β が経験的に求めた閾値 30 を下回る場合，その質問テンプレートは文法・意味的に誤っている可能性が高いと判断され，削除される．また，質問の検索数が 0 でも削除される．

3 実験

実際に実験を行い，システムが生成した質問の精度の確認を行った．

3.1 実験方法

システムは，6 個の上位概念に対する質問テンプレート H を生成し，それに対して評価を行った．被験者は 20 代理系男子大学院生 1 名，20 代女性会社員 3 名である．

評価実験に使用した上位概念は，

・　「動物」「犬」「魚」「料理」「歌手」「RPG」

の 6 つである．

「動物」「犬」「魚」に関しては，安藤らの研究[5]より，「料理」に関しては鳥澤らの研究[3]より，それぞれ用いた．なお，「歌手」「RPG」は，下位概念取得の項で述べたように，本システムには人名処理，括弧の中の用語の処理を加えたため，その有効性を確かめるために用いた．なお，今回用いた括弧の種類は『』，「」，《》の 3 種類である．

被験者には，あらかじめ

・　料理などの上位概念に対して正しいものを選択してください

といった評価基準と，回答例（表 3.1.1）を説明した．

被験者は評価基準にそって，1 つの上位概念に対してシステムが生成した質問を scoreT の高い順に 20 件ずつ，「有効」「有効ではない」という判断を行った．

表 3.1.1　回答例

質問A:@は食べれますか？（@:オムライスなどの下位概念）	有効
質問B:ことですがどうなんでしょうか？	有効ではない

3.2 評価

被験者の評価を，上位概念ごとにまとめたものを図 3.2.1 に示す．

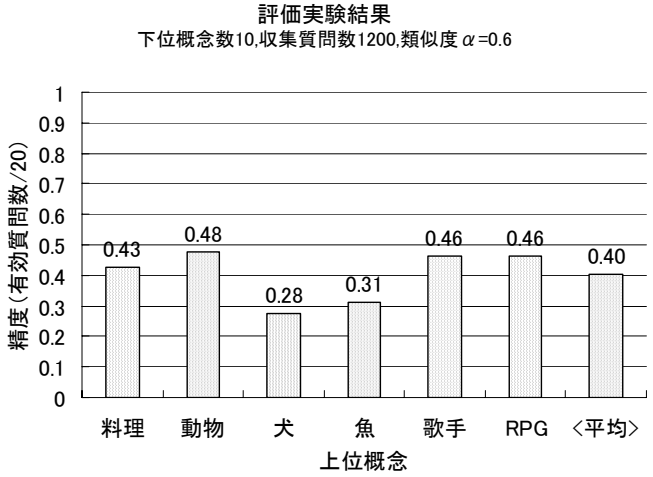


図 3.2.1　評価実験結果

平均すると，質問生成の精度は 0.40 であった．つまり，システムが 10 問質問を生成しユーザに投げかけた場合，約 4 問は正しい質問が含まれていることになる．実際に得られた質問文を抜粋して表 3.2.1 に示す．

表 3.2.1　評価例

上位概念	有効な質問	有効ではない質問
動物	なんて種類なんですか	@とは違うじゃないですか
犬	本はありますか	タイトルだけでも教えて
魚	初心者でも釣れますか	どなたか教えて
料理	お勧めレシピありましたら教えて	ものはあるのでしょうか
歌手	カバーしている曲ってあるんですか	言葉を教えて
RPG	公式なCD等で発売されておりますでしょうか	そんなに似てるんですか

4 考察

図 3.1.1 と表 2.1.1 を見ると，自動的に獲得された下位概念の精度は，質問生成の精度にそれほど関係がないように考えられる．

しかし，予備実験にも用いた「料理」の下位概念取得の精度を 1.0 から 0.5 にすると，質問生成の精度が 0.3 まで減少した．予備実験時，下位概念の精度以外同条件で質問生成の精度は 0.4 であり，下位概念取得の精度は，質問生成の精度と相関が存在すると考えられる．

つまり，各上位概念間で，下位概念取得の精度の差を打ち消すような，何らかの原因が存在しているはずである．今後のこの原因を調査する予定である．

また，質問生成されたものの中で，「作り方」「レシピ」など字面上は異なっていても意味が同じである単語なども多く見られた．そのため，「作り方を教えて」と「レシピを教えて」は求める回答は同じでも，質問が 2 つ作られてしまうような事態も生じることとなった．この問題の解決策としては，知識獲得システム全体が完成した時にユーザから得られる知識の類似度によって，複数の生成された質問が同じ意味であることを判別する方法などが考えられる．

有効ではない質問に「もの」「物」「方法」「事」を含んでいるという特徴が見られた．それらは全質問 120 個中 10 個存在し，全て「有効ではない」と判断された．これは，構文解析により，これらの語の手前にくる語が削除されてしまうのが原因と考えられるので，統計的にこのような状況に陥りやすい単語には手書きのルールを加えることも検討している．

さらに被験者によっては「ご存知でしたら教えて」などの質問に対しても「有効である」としていた場合も存在したが，上位概念に関係なく，どのような時でも使用可能な質問文は，知識獲得の際に好ましくない場合もある．このような多くの上位概念の質問テンプレートに出現するような質問は，今後別にグループ化する必要がある．

6 おわりに

本研究では，ユーザからの知識獲得システムの一部として，Web を利用した質問生成システムを提案し，その評価を行った．評価実験により，システムは質問生成において 4 割程度の精度を示すことができた．

このシステムにより，知識獲得システムが発する質問のテンプレートを製作者が考える必要がなくなり，労力が削減されると考えられる．また，誤って生成された質問もユーザが知識獲得システムを使用中にフィードバックを行うことで淘汰することができ，最終的に精度の高い質問をユーザに対してすることができるようになると考えられる．

ただし，現状の精度では 10 回のシステム質問に対して 6 回は，ユーザが質問を訂正・削除しなければならないため，未だ負担が大きい．

今後は，考察で述べたような要因に対し適切な処置を行い，さらに質問生成の精度を高めていきたい．また，図 2.1 のような知識獲得システム全体の実装・評価を行っていく予定である．

参考文献

[1]「Web シラバス統合のためのレコード解析」,伊東栄典,山田信太郎,廣川佐千男,人工知能学会 研究会資料 SIG-SWO-A201, pp.(05-1)–(05-7), 2002

[2]「HTML 文書からの単語間の上位下位関係の自動獲得」,.新里圭司, 鳥澤健太郎,情報処理学会 自然言語処理研究会研究報告, 2003–NL–158, pp.95–102,2003.11

[3]「能動的に質問を発して情報を収集する対話エージェント」, 鳥澤健太郎, http://www-tori.jaist.ac.jp:8000/project/

[4]「形態素解析システム茶筌」（ChaSen） http://chasen.naist.jp/hiki/ChaSen/

[5]「上位語・下位語を含む連体修飾表現の言語的分析」, 安藤まや, 関根聡, 言語処理学会第 10 回,pp.205-208,2004,3

[6]「メーリングリストを利用した質問応答システムのための知識獲得」, 渡辺靖彦,園和也,岡田至弘,情報処理学会研究報告,2004-NL-162,pp.131-138,2004.

[7]「日本語係り受け解析器南瓜」（CaboCha） http://chasen.org/~taku/software/cabocha/