日本音響学会誌 63 巻 5 号 (2007), pp. 251–261

論　　文

43.72.Kb

音声認識・言語理解性能や状況の違いによるタスク指向音声対話の言語的・音響的特徴の比較*

伊藤敏彦*1　山田真也*1　荒木健治*1

[要旨] 人間同士又は人間と機械との音声対話において，対話相手の音声認識・言語理解性能，対話状況や対話相手の違いによって生じる被験者発話の言語的・音響的特徴の差に関して実音声対話データの分析結果から明らかにする。機械との対話を扱うため，比較的単純な状況設定としてカーナビゲーションシステムにおける目的地検索・設定タスクを想定し，その音声インタフェースという具体的な状況設定において被験者発話に現れる言語的・音響的な特徴の差を比較した。想定した状況は，音声認識・言語理解率が 100%と約 80%の場合，対話相手が人間，応答能力が制限された人間，又は機械の場合，そして運転中又は停車中の場合である。これらの対話状況の違いにより発話にどのような違いがあるか，被験者 24 名による実対話音声の収録データに基づいて分析を行った。運転操作中の状況設定に関しては，擬似的な運転操作環境を設定した。その結果，運転操作の有無による言語的な特徴の差異はほとんどないが，音響的な特徴の違いが一部見られたほか，対話相手側の応答に関する能力が制限されると被験者発話において幾つかの言語的・音響的な特徴が現れることが明らかになった。

キーワード　対話分析，言語的特徴，音響的特徴，音声対話，対話相手，音声認識・言語理解率，ディストラクション

Dialogue analysis, Linguistic features, Acoustic features, Spoken dialogue, Dialogue partner, Speech recognition/understanding performance, Distraction

1. はじめに

近年，音声認識技術や言語処理技術，コンピュータ性能の向上により，音声インタフェースや目的指向型音声対話システムが注目されている。音声インタフェースの応用は，今後，様々な環境・対象に広がっていくことが予想されている。しかし，実用性や自然性を指向したより高度な音声インタフェースの実現においては，幾つかの解決すべき課題がある。実用性という観点から解決すべき課題として，音声インタフェースに用いられる音声認識システムの性能向上と信頼性の確保がある。音声認識システムにおける認識性能は，発話様式によって大きな影響を受けることが指摘されている [1]。そのため，これまで音声認識の分野では，読み上げ文を対象としたものが中心であり，近年になって講演音声 [2] や講義音声 [3] といった自然発話の認識に注目が注がれるようになってきた。更に最近では，システムの信頼性，頑健性の向上を目的として，認識結果の信頼度推定 [4] や信頼度を利用した対話制御 [5–7]，システムの誤認識やユーザの言い直しの検出等に関する研究も行われている [8–11]。これらのアプローチは，それぞれの発話様式特有の言語的・音響的特徴を考慮することによって性能の改善を試みている。しかしながら，発話様式のバリエーションに影響を与える要素は，対話タスク，対話相手，発話状況など多岐にわたると考えられ，その要因はまだ明確になっているとは言えない [12]。

特に，カーナビゲーションシステムでの音声インタフェース利用のように運転などの別の認知的負荷がある状況での音声対話は，今後，重要となってくるが，これまで分析の対象になっていない。認知的負荷と音声対話に関する研究としては，機械操作や音声による対話等によって起こる注意散漫（ディストラクション）が運転操作の安全性に与える影響が指摘されている [13, 14]。この問題については，これまで車内での携帯電話利用に関して注目されていたのみであったが，簡単な音声インタフェースの利用でさえも認知的な負荷は無視できず，運転操作へ影響を与える可能性があるという報告もある [15]。しかし，逆に運転操作などの認知的負荷が対話における発話の言語的・音響的特徴にどのように影響するかや，そのような状況下での対話相手が

---

* Linguistic and acoustic features depending on different situations and speech recognition/understanding performance in task-oriented dialogue, by Toshihiko Itoh, Shinya Yamada and Kenji Araki.

*1 北海道大学情報科学研究科
(問合先：伊藤敏彦　〒060–0814 札幌市北区北 14 条西 9 丁目 北海道大学情報科学研究科)

(2006 年 4 月 28 日受付，2006 年 12 月 14 日採録決定)

人間か機械かの違いが発話にどのような影響を与えるかなどは明らかになっていない。我々 [16] や itou [17] らは以前に，そういった認知的な負荷や対話相手の違いが言語的・音響的な特徴にどのような影響するのか分析している。しかしながら，以前の研究では対話相手として人間と実際の対話システムを用いて実験を行ったために，比較したい項目以外の実験条件をうまく統一することができず，認知的負荷の有無や対話相手の違いによる発話への影響を正確に比較できていない。そこで，それらに関する正確な再調査を，本研究の目的の一つとする。

次に，自然性の観点から解決すべき課題として，音声インタフェース（機械）とユーザ（人間）との自然な対話（インタラクション）の実現がある。我々の以前の分析結果 [16] においてもそうであるが，現状，人間は機械との対話において自然で自由な発話をすることができず，その発話は言語的・音響的に人間同士の発話とは異なる。人間や機械相手に対する対話やふるまいの違いに関する研究においては，R. Amalberti ら [18] が，システムがコンピュータであると被験者に信じ込ませたコンピュータグループとシステムは人間が操作していると被験者に教えたオペレータグループの二つを用意し，WOZ 法を用いて被験者のふるまいや主観を比較している。その結果，コンピュータグループの被験者は使用する言語がより簡素化し，1 対話当たりの単語数が多くなり，システムを単にツールとして使用する傾向があるのに対し，オペレータグループの被験者はより対話者に協力的であると述べている。また，A. Johnstone [19] は，電話によるタスク達成型の対話における，(1) 人間対人間と (2) 人間（システムに慣れていない）対機械，(3) 人間（システムに慣れている）対機械のふるまいの違いを比較している。(1) ≫ (2) > (3) の順で，一対話当たりの単語数や発話数，使用語彙数は多くなり，逆に (3) > (2) ≫ (1) の順で 1 発話の長さは長くなったと報告している。また，ユーザ主導の発話の割合は (1) > (3) ≫ (2) という結果であった。対話中の開始・終了部分にある儀礼的な発話を除いた場合の結果では，1 対話当たりの発話数は (1) > (2) > (3) の順ではあるが，その差はかなり小さくなり，1 発話の長さは (3) > (1) > (2) の順になったと報告している。新美ら [20] は，京都観光案内をタスクとした WOZ システムによって，機械らしく対応するモード 1 と人間らしく対応するモード 2 による応答の違いによる被験者のふるまいの違いを検討している。結果としては，モード 1 では，「対話全体の長さがあまり変化しないが，被験者の発話の数は少なくなる」，「不要語が少なくなる」，「単語もしくは名詞で終わる句を用いた発話が多くなる」ことを示している。

このように人間と機械との対話が人間同士の対話と異なる理由として，対話相手に対する何等かの意識の違いが原因であると考えられる。仮に人間が対話中に対話相手から「機械らしさ」，「人間らしさ」を感じ取ることで発話の言語的・音響的特徴が機械的，人間的に変化するのであれば，人間と機械において自然な対話ができないのは，音声インタフェースとの対話中において，「機械らしさ」を感じさせる要因が何かあるはずである。その要因としては，「音声認識・言語理解性能」，「対話のリズム・テンポ」，「応答内容」，「応答音声の品質」などの要因が考えられる。また，「対話相手が機械であるという事実」，「機械に対するイメージ（先入観）」といった対話前から持っている意識の違いの可能性も考えられる。このように人間が音声インタフェースにおいて人間との違いである「機械らしさ」を感じる可能性のある要素は数多くあり，その事実関係は不明確である。また，これらの各要素が具体的に人間の発話の言語的・音響的特徴にどのような影響を与えるかも明らかになっていない。そこで，本研究では機械と人間が自然な対話を行うために必要な要素を明らかにすることをもう一つの目的とする。

本論文では WOZ 法を用いた擬似音声対話システムを作成し，比較したい要素以外の条件をできるだけ揃える実験設定を行った。また，WOZ 法を用いているため，音声認識・言語理解性能を自由に設定できることから，対話相手側の音声認識・言語理解性能を対話状況の一要因として加えた。そのため，音声認識・言語理解性能の違い，対話相手の違い，応答能力の違い，認知的負荷の有無といった対話状況や被験者の意識の違いによって，言語的・音響的特徴にどのような違いが出るかを明らかにすることと，それらの分析結果をもとに人間が音声インタフェースにおいて「機械らしさ」を感じる要因を調査する。対話収集のための被験者実験では，現実的な応用の場面に近い知見を得るために，カーナビゲーションシステムにおける音声インタフェースを想定した比較的単純な目的地検索・設定を対話タスクとして設定している。

2. 様々な状況の対話音声収録実験

カーナビゲーションシステムの目的地検索・設定タスクを想定した様々な対話状況における被験者の言語的・音響的な特徴分析のための被験者実験について述べる。

2.1 対話状況

実験で用いた目的地検索・設定タスクは，カーナビゲーションシステムの使用を想定し，目的地のランド

表–1　実験対話状況とその表記

対話相手		人間		機械
応答音声		自然音声	合成音声	
運転タスク	無	O	P	W
(DT)	有	O+DT	P+DT	W+DT

マークを検索・設定するものである。

なお，本実験における対話相手は，被験者とは別の空間に存在し（非対面），被験者と対話を行いながらカーナビゲーションシステムの遠隔操作を行う存在として定義する。対話中の被験者の環境としては，プロジェクタに映し出されたドライブシミュレーションの道路状況と，NotePC に映し出されたカーナビゲーションシステムの画面のみであり，同乗者などの存在はいない。

本実験で比較対象とした対話状況を表–1 に示す。

この対話状況に対して，対話相手側の音声認識・言語理解率が 100%である場合（実験 1）と，ノイズ等の影響という想定のもとで音声認識・言語理解率が約 80%である場合（実験 2）の 2 環境で実験を行った。ここでの音声認識・言語理解率は，「被験者の発話を内容（発話意図）的に完全に正しく理解できた発話単位での割合」を意味し，音声言語処理分野での「文理解率」や「文意図理解率」と呼ばれるものに一致する。また，本研究における「音声認識・言語理解率の違いによる比較」は，音声認識・言語理解率 100%，80%，60%といった実際の音声認識・言語理解の誤り率に着目した比較を表すものではなく，対話相手（オペレータ・システム）が対話中に誤認識・誤理解を頻繁に起こすことによって生じる，被験者の「対話相手（オペレータ・システム）は誤認識・誤理解をよく起こす」という意識の有無の違いによる比較を表している。上記のような被験者の意識を引き起こすための音声認識・言語理解率 80%であり，その数値自体に学術的な深い意味があるわけではない。当研究室で実際に構築している本論文と同タスクの音声対話システムの音声認識・言語理解率や，他の研究室で開発された別タスクの音声対話システムの音声認識・言語理解率を参考に，タスク遂行自体が困難とならない音声認識・言語理解率として 80%を設定した。

2.2 対話相手

対話相手「機械」とは，本実験用に構築した WOZ 法を用いた目的地検索・設定擬似音声対話システムである。作成したシステムは，あらかじめタスクシナリオごとに用意した応答パターン一覧（誤応答も応答パターンとして用意済み）から，被験者の発話に対して適切な応答（音声認識・言語理解誤りを発生させる場合は不適切な応答）をマウスで選択すると，選択された応答がスピーカを通して合成音声で被験者側に出力される単純なシステムである。しかし，相手の割り込みに対してシステム側の発話を途中で止める等，自然な対話現象に対してできるだけ自然に対応できるようにしてある。音声合成システムには日本 IBM 製の ProTalker95 を使用した。図–1 に本実験タスクにおける被験者の主な発話パターンと正解応答選択例，誤応答選択例を示す。

[1] 目的地情報に関する発話

前発話：「目的地を入力してください」
入力例：「静岡県をお願いします」
正応答：「静岡県でよろしいですか」
誤応答：「滋賀県でよろしいですか」

[2] 確認発話（「☆☆でよろしいですか」）に対する肯定発話，否定発話，訂正発話など

前発話：「静岡県の浜名道でよろしいですか」
入力例：「いや，違うよ，東名高速だって」
正応答：「静岡県の東名高速でよろしいですか」
誤応答：「静岡県の浜松 IC でよろしいですか」

[3] システムやオペレータへのメタ発話
（目的地に関する情報はない入力）

前発話：「目的地検索システムです」
入力例：「こんにちは」
正応答：「こんにちは，目的地の入力をどうぞ」
誤応答：「滋賀県でよろしいですか」

図–1　発話パターンと応答選択例

また，対話相手「人間」は，タスク内容に精通し更に自然な対話ができるように事前に訓練した当研究室の学生である。そのため，対話相手「人間・自然音声」は，日常的に行われる電話などの非対面な音声対話と全く同じである。ただ，本システムのタスクが想定している顔見知りでない人間「オペレータ」との対話を意識させるために，対話相手「人間・自然音声」と「人間・合成音声」に関しては，実在の会社名と所属，偽名（自然音声と合成音声では別の偽名）を用いて最初に自己紹介的な対話を行い，社会的対人関係を明確にしている。更に，「人間・自然音声」，「人間・合成音声」，「機械」はすべて同一人物が対話を担当し，タスク遂行のための対話戦略に違いが出ないように注意した。

S1 ：目的地を設定して下さい
U1 ：えー，北海道江別市江別市役所
S2 ：北海道江別市江別市役所でよろしいですか
U2 ：もう一度言って下さい
S3 ：北海道江別市江別市役所でよろしいですか
U3 ：はい，その通りです
S4 ：目的地に設定します
S5 ：次の目的地を設定して下さい
U4 ：えー，北海道留萌市，えー，黄金岬
S6 ：北海道留萌市東奔機材でよろしいですか
U5 ：いや，違います
S7 ：目的地を設定して下さい
U6 ：えと，北海道留萌市黄金岬
S8 ：北海道留萌市黄金岬でよろしいですか
U7 ：はい，その通りです
S9 ：北海道留萌市黄金岬でよろしいですか
U8 ：はい，その通りです
S10：目的地に設定します

図–2 音声対話システムにおける対話例

なお，対話相手「人間・合成音声」と「機械」との差は，被験者が対話している相手が人間か機械かという事実の認識に関する意識の違いだけであり，どちらの場合も WOZ 法の擬似音声対話システムを用いて対話を行っている。この二つの対話の特徴を比較することにより，「人間と機械の対話が人間同士の対話と違うものになってしまう理由に，対話相手が機械という事実は関係するか？」という疑問の検証を行う。

図–2 に被験者と対話相手「機械」との対話例を示す。

2.3 音声認識・言語理解誤りの実現方法

音声認識・言語理解率約 80%の実現方法であるが，これは 80:20 の割合で○：×を出すシステムを作成し，その指示に従う。○の場合は被験者の発話に対して適切な応答を WOZ システムから選択し，×の場合は図–1 の誤応答例に示されているように，音声認識・言語理解誤りが発生したとして，被験者の発話に対して適切でない応答（誤応答）を WOZ システムから選択する方法を用いた。ただ，全被験者が全タスクにおいて，ほぼ同じ音声認識・言語理解性能になるように，5 発話に 1 回は必ず×が出力され，なおかつ，1 タスク当たりの被験者の発話数の最大値を考慮し，1 タスク当たり 5 回以上は×が出ないように制約を加えてある。この方法を用いることで，各被験者・各タスクの音声認識・言語理解率は 76%～80%の範囲に収まり，実験 2 の全タスクでの音声認識・言語理解率は 78%であった。

最後に，音声認識・言語理解誤りが発生した（×が出た）場合の誤応答として用意した応答の作成方法について以下に述べる。本タスクの目的地設定タスクは，「県名のカテゴリ（上位カテゴリ）」—「自動車道名，鉄道路線名，市町村名などのカテゴリ（中位カテゴリ）」—「インターチェンジ名，駅名，施設名などのカテゴリ（下位カテゴリ）」の 3 階層の情報を対話相手に入力するタスクである。そのため，被験者が 1 発話で入力する情報のパターンは，いろいろな言い回しは存在するとしても，「上位カテゴリのみ」，「上位カテゴリ—中位カテゴリ」，「上位カテゴリ—中位カテゴリ—下位カテゴリ」，「上位カテゴリ—下位カテゴリ」，「中位カテゴリのみ」，「中位カテゴリ—下位カテゴリ」，「下位カテゴリのみ」の 7 パターンになる。そこで，実際の音声認識システムを用いて実験シナリオの各目的地をこの七つの入力パターンに基づいて何度か入力した場合に，多く発生した誤認識結果を各入力パターンごとに上位 3 種類ずつ選択し，その誤認識結果に対する応答をその入力パターンにおける誤応答用応答として用意した。これらの誤応答や正解応答として用意した応答を適切でない発話に対してランダムに使うことにより，様々な誤認識・誤理解パターン（「置換誤り」，「削除誤り」，「挿入誤り」，「発話パターンの誤理解」，など）を実現できる。

2.4 運転タスク

本実験における運転操作は，安全性の問題からドライブシミュレーション（ゲーム）を使用し，単純なコース（オーバルコース：楕円形コース）を線に沿って一定速度（100 km/h）で走るものとした。ただし，できるだけ実際の運転状況に近づけるため，ハンドル・アクセル・ブレーキを用意し，画面サイズもプロジェクタを使うことにより実サイズに近づけた。また，運転操作タスクをメインタスクとして集中させるために，運転操作に失敗した場合は，その対話タスクを最初からやり直すことを伝えてある。なお，対話実験に用いるドライブシミュレーションの運転操作は，実車の運転操作と同程度の認知的負担を被験者に与えており，その認知的負担度は，実車を 60 km/h で走行させる場合と同程度であることが RRV 法による調査から分かっている [16]。

2.5 実験方法

2.1 節で述べたような対話状況の設定において，複数の被験者に目的地検索・設定タスクを与えて対話音声収録の実験を行った。被験者は音声認識・言語理解率の異なる環境ごとに，情報系大学（院）生 12 名の合計 24 名であり，音声対話システムに関する知識は全

北海道大学を出発し，北海道江別市（えべつし）の友達を拾うために待ち合わせ場所の江別市役所まで迎えに行く。友人が今の時間帯なら夕日がきれいに見えるよと言うので，そこから海沿いの道まで出て道沿いに運転し，北海道留萌市（るもいし）の黄金岬（おうごんみさき）に行く。きれいな夕日を眺めて気分がよくなったところで，友人が腹減ったと言ってきたので，ちょっと早いけど夕食をとろうと思い黄金岬から近い国道沿いの飲食店を探すことにする。

出発地　：北海道・札幌市・北海道大学
↓
目的地 1：北海道・江別市・江別市役所
↓
目的地 2：北海道・留萌市・黄金岬
↓
目的地 3：黄金岬近く・国道沿い・飲食店

図–3　タスクシナリオ例

くない。

実験手順としては，最初にドライブシミュレーションをコースどおりに走行できるようになるまで使用してもらい，運転タスクへの不慣れによる分析結果への影響を除いた。次に，被験者に図–3 のようなタスク内容と実験に関する説明用紙を熟読してもらい，検索条件や目的地などに関しては完全に暗記してもらった。更に，音声対話システムに対して，自由なタイミング（割り込み等），自由な発話内容・形態をしても大丈夫なことを事前に伝えた。ただし，タスクに関係ない内容は理解できないことを説明し，タスク外の発話は禁止した。その後，対話相手と運転タスクの組み合わせの 6 通り ×2 タスクを順番による影響が出ないように，被験者ごとにランダムな試行順で行った。すべての実験終了後，主観評価用のアンケートに記入してもらった。なお，アンケート項目に「対話相手が機械だと信じていたか」や「対話相手が人間だと信じていたか」のアンケート項目があり，音声対話システムの性能に対して不自然さを感じた被験者や，「人間・合成音声」と「機械・合成音声」において二つの違いを自覚できなかった被験者のデータはすべて評価データから除き，新たな被験者を用いて実験をやり直している。ここでの自覚とは二つの対話相手の違いを対話中に認識することではなく，「人間・合成音声」は「人間相手」，「機械・合成音声」は「機械相手」と対話していることを信じている（分かっている）かどうかである。

また，音声認識・言語理解率が約 80%の場合の実験においては，マイクからの入力に突発的なノイズを断続的に混入しているために，部分的，全体的に人間，機械ともに聞き間違えることがあることを説明に加えて伝えた。

3. 実験結果

被験者実験によって収集された発話データを言語的・音響的特徴に着目し分析した結果を示す。実験 2 の環境では実験 1 と異なり誤認識・誤理解が生じるため，誤認識・誤理解した応答への訂正発話による発話の増加や言語的・音響的特徴の影響が現れる。その影響をできるだけ除くために基本的な比較では，訂正発話や否定発話などの発話は除いた発話を分析対象として比較を行った。**表–2** に，比較の対象となるそれぞれの状況における発話数を示す。

3.1 音声認識・言語理解率の違いによる被験者発話の言語的・音響的特徴

最初に対話相手側の音声認識・言語理解率の違いにのみ着目し，対話相手側の音声認識・言語理解率が 100%である環境（実験 1）と，ノイズ等の影響という想定のもとで音声認識・言語理解率が約 80%である環境（実験 2）のそれぞれの環境におけるすべての対話状況の発話をまとめたデータによる特徴の分析を行った。

表–3 にその結果を示す。表中の「タスク数」は，実験で被験者に行ったタスク（対話，シナリオ）の数であり，1 タスク当たり三つの目的地をシステムに入力することになる。「発話数」は，訂正発話，否定発話を除いた本研究における分析対象となる発話の総数である。「分割目的地数」は，実験ごとに 432 目的地（144 タスク ×3 目的地）の情報（1 目的地当たり三つの情報）を入力する必要があるが，それらの情報を 1 発話で一度に入力せず，複数の発話（ターン）を用いて入力した目的地の数である。「分割発話数」は「分割目的地数」の数の目的地の情報を入力するために，被験者が発話した数である。「平均形態素数」は，被験者の各発話を形態素解析ツールを用いて形態素に分割した発話ごとの平均である。「間投詞数」は対話中に現れた間投詞の総数である。「平均情報数」は，1 目的地当たり三つの情報（キーワード）を入力するが，各発話中に含まれる情報の平均である。「平均新情報数」は，各発話中に発話された情報の中で，過去の発話で一度も入力されていない情報の平均であり，以前にシステムに入力した情報を繰り返し発話しなければ，「平均情報数」と完全に一致する。「動詞省略数」は，被験者の発話において単語入力や体言止めなどの動詞が省略された発

表–2 分析対象の発話数

対話状況	O	O+DT	P	P+DT	W	W+DT
実験 1 (100%)	236	239	227	227	227	229
実験 2 (80%)	245	247	232	243	249	235

表–3 音声認識・言語理解率の違いによる言語・音響的特徴

実験	実験 1	実験 2
タスク数	144	144
発話数	1,385	1,451
分割目的地数	83	126
分割発話数	187	265
平均形態素数	4.60	5.49
間投詞数	446	341
平均情報数	2.02	1.92
平均新情報数	1.97	1.89
動詞省略数	489	409
パワー平均 (RMS)	779	1,018
パワー最大 (RMS)	3,151	4,161
F_0 平均	75.4	76.5
F_0 最小	58.7	57.6
F_0 最大	269.4	263.2
F_0 標準偏差	16.9	19.9

話の総数である。また，「パワー」は被験者の声の大きさ（RMS）を表し，「F_0」は被験者の声の基本周波数である。なお，F_0 に関連した検定には対数化した F_0 を用いている。

これらの結果に対して，F 検定及び t 検定による分析を行った。有意差のある言語的特徴としては，音声認識・言語理解率が約 80%の方は 100%に比べ，平均情報数（$p < 0.05$）及び平均新情報数（$p < 0.05$），間投詞数（$p < 0.05$）が減少し，分割発話数（$p < 0.05$）が増加した。言い換えると，誤認識・誤理解する相手に対しては，不要語はできるだけ発話せずに，1 発話で伝える情報を減らし，細切れに伝えようとする傾向がある（**図–4**–変化例 1）ことが分かる。なお，音声認識・言語理解率が約 80%に関しては，動詞省略数（$p < 0.01$）の減少と平均形態素数（$p < 0.01$）の増加にも有意差があった（図–4–変化例 2）が，これは対話相手がオペレータの場合のみに現れた傾向が全体に影響してしまったためと考えられる（**表–4**，**表–5** 参照）

また，音響的特徴としては，音声認識・言語理解率が約 80%の方はパワー平均（$p < 0.01$），パワー最大（$p < 0.01$），F_0 平均（$p < 0.01$），F_0 標準偏差（$p < 0.01$）が増加し，声がより大きく高く，そして抑揚が強くなることが分かった。ただ，音声認識・言語理解率 100%の実験では 80%の場合と違いノイズに関する一切の説明を行っていない。そのため，ノイズに対する意識の違いも発話のパワーに影響を与えた可能性がある。

変化例 1：
USER：えーと，北海道江別市の江別市役所です。
（情報数：3，間投詞数：1，分割発話数：0）
↓
USER：北海道の江別市です。
（情報数：2，間投詞数：0，分割発話数：1）

変化例 2：
USER：北海道江別市。
（情報数：2，形態素数：2，動詞省略数：1）
↓
USER：北海道の江別市に行きたい。
（情報数：2，形態素数：6，動詞省略数：0）

図–4 発話の言語的特徴変化例

表–4 実験 1（音声認識・言語理解率 100%）における言語的特徴

対話状況	O	O+DT	P	P+DT	W	W+DT
タスク数	24	24	24	24	24	24
発話数	236	237	227	227	227	229
平均発話数	9.83	9.88	9.46	9.46	9.46	9.54
平均形態素数	4.98	4.56	4.58	4.53	4.58	4.31
平均間投詞数	9.25	9.17	3.83	4.83	5.00	4.91
平均情報数	1.99	1.97	2.07	1.98	2.07	1.99
平均新情報数	1.97	1.91	2.03	1.96	1.96	1.95
省略可能情報数	36	41	53	46	62	51
動詞省略数	71	70	86	85	88	89

表–5 実験 2（音声認識・言語理解率 80%）における言語的特徴

対話状況	O	O+DT	P	P+DT	W	W+DT
タスク数	24	24	24	24	24	24
発話数	245	247	232	243	249	235
平均発話数	10.20	10.29	9.67	10.13	10.38	9.79
平均形態素数	6.32	6.03	5.27	5.29	4.84	5.24
平均間投詞数	3.83	3.54	1.67	2.38	1.17	1.63
平均情報数	1.96	1.93	1.96	1.84	1.85	1.98
平均新情報数	1.95	1.89	1.94	1.82	1.81	1.93
省略可能情報数	33	33	34	32	34	35
動詞省略数	38	41	79	77	93	81

3.2 対話相手の違いによる被験者発話の言語的特徴

表–4 には音声認識・言語理解率 100%（実験 1）における，表–5 には音声認識・言語理解率約 80%（実験 2）における分析対象発話の対話相手と対話状況の違いによる言語的特徴の結果を示す。表中の「平均発話数」は，一つのタスクを遂行するために被験者が発話した

数の平均であり，「平均間投詞数」は1タスク当たりの間投詞の数の平均である。「省略可能情報数」は，本実験の目的地検索・設定タスクにおける，目的地情報の上位カテゴリである「県名カテゴリ」に関する情報を発話した数である。県名に関する情報は，自動車道名や鉄道路線名，市町村名，施設名などから一意に決まることが多く，被験者においてもこの「県名カテゴリ」を省略することが多い。中位カテゴリや下位カテゴリに関しては，情報が入力されていない場合，システムやオペレータから質問などを行うが，上位カテゴリに関しては，被験者が情報を入力しなかったとしても，それ以外のカテゴリの情報がすべて入力されればタスクが達成されたとしている。そのため，この県名カテゴリの情報を「省略可能情報」と定義している。

まず，誤認識・誤理解が発生しない環境である実験1において，対話相手の違いによってどのように被験者発話における言語的特徴が現れるかF検定及びt検定で分析した。結果，興味深いことに多くの言語的特徴が対話相手側が人間か機械かといった事実的な差によって現れたわけではなく，応答が合成音声か自然音声かという応答能力の性能に関する違いによって多くの有意な差が現れた。

合成音声では，間投詞が減少し（$p < 0.01$），実際のタスクを遂行するためには必須ではないが補足的な情報としては有効である省略可能情報数が多くなる（O-P: $p < 0.1$, O-W: $p < 0.01$）。また，有意差はなかったが動詞省略が増加する傾向が見られた。これは，対話相手がタスクを遂行する上で何かの役に立つだろうと思われる付加的な関連情報は増やしながらも，逆にタスク遂行上あまり関係のない単語はできるだけ発話しないようにする意識の現れと考えられる。また，省略可能情報数の増加傾向に関しては，音声認識・言語理解性能を下げた実験2の環境においては見られない。このことから，音声認識・言語理解性能が高い場合は，情報量を増やすことがタスク達成に関して有効（効率的）であり，音声認識・言語理解性能が低い場合は，本当に必須な情報だけを正確に入力することがタスク達成において有効（効率的）であると考える意識が働くためではないかと推測する。

また，対話相手「人間・合成音声」と「機械・合成音声」の間に関して有意差のある言語的特徴はないこと，「人間・合成音声」は人間で応答が合成音声であることを被験者は理解しているにもかかわらず，人間の自然音声と合成音声の間で「機械・合成音声」と同じ特徴に有意な差が現れたことから，「対話において，対話相手が人間か機械かという事実はあまり関係なく，対話から得られる人間らしさや機械らしさ，知的さのような相手への印象が強く影響する」ということが示唆される。今回の実験においては，合成音声と自然音声による応答の違いの何等かの要因が被験者の対話相手に関する印象に影響を与え，発話の言語的特徴に変化をもたらしたことは分かったが，自然音声と合成音声との差には音声の品質（韻律や抑揚も含む）や対話リズムの欠落といった複数の要素が含まれるため，今後はより詳細な要素の言語的特徴への影響を調べていく必要がある。

次に，約20%の割合で誤認識・誤理解が生じる環境である実験2において，対話相手の違いによってどのように被験者発話に言語的特徴が現れるかF検定及びt検定で分析した。現れた言語的特徴は実験1とほぼ同じであり，応答が音声合成か自然発声かの違いによって有意な差が現れ，合成音声では間投詞（O-P: $p < 0.1$, O-W: $p < 0.01$），平均形態素数（O-P: $p < 0.5$, O-W: $p < 0.01$）が減少し，動詞省略が増加する（$p < 0.01$）結果となった。

最後に，音声認識・言語理解率の違いによって同一の対話相手間でどのような言語的特徴が現れるか分析を行った。有意差のある特徴としては，音声認識・言語理解率80%の合成音声の場合，100%の場合に比べて平均情報数が減少する（$p < 0.05$）。また，音声認識・言語理解率80%の自然音声の場合，100%の場合と比べて，動詞省略数が減少し（$p < 0.05$），平均形態素数が増加する（$p < 0.05$）。これらのことから，音声合成の場合には対話相手の音声認識・言語理解性能が低いと，1発話中に含まれる情報量を減らし，単純で簡素な発話に変化していくことが分かる。また，自然音声の場合，対話相手の音声認識・言語理解率が低いと，より協調的で丁寧な発話になることが分かる。これらの比較から，音声認識・言語理解性能の低下が，ただ一様に発話をより単純なものに変化させるわけでなく，対話相手に対する機械らしさなどの印象と総合的に作用して発話を変化させていることが分かる。

3.3 対話相手の違いによる被験者発話の音響的特徴

表–6 には音声認識・言語理解率100%（実験1）における，**表–7** には音声認識・言語理解率80%（実験2）における分析対象発話の対話相手と対話状況の違いによる音響的特徴の結果を示す。

表中の「平均発話開始時間」は，オペレータやシステムの発話終了から被験者の発話が開始されるまでの平均時間である。「平均発話時間」は，被験者の各発話の平均時間長であり，「平均発話速度」は，被験者の各発話の平均話速である。なお，表中の（1）は発話中のポーズ（無音時間）を含めて計算した発話時間や発話速度を意味し，（2）はポーズを除いて計算した発話時

表–6 実験 1（音声認識・言語理解率 100%）における音響的特徴

対話状況	O	O+DT	P	P+DT	W	W+DT
平均発話開始時間 (s)	0.41	0.31	0.66	0.78	0.63	0.65
平均発話時間 (1) (s)	1.90	1.87	1.75	1.77	1.86	1.92
平均発話時間 (2) (s)	1.37	1.43	1.28	1.37	1.38	1.41
平均発話速度 (1) (mora/s)	7.53	7.52	7.74	7.63	7.64	7.22
平均発話速度 (2) (mora/s)	10.50	9.65	10.69	9.85	10.26	9.64
パワー平均 (RMS)	606	830	729	919	680	909
パワー最大 (RMS)	2,676	3,548	2,963	3,544	2,701	3,475
F_0 平均	71.0	78.4	71.9	80.2	72.7	77.9
F_0 最小	57.2	59.2	58.6	60.5	59.0	58.0
F_0 最大	245.1	281.3	277.0	251.6	301.1	260.0
F_0 標準偏差	15.3	17.5	15.7	17.7	17.5	17.4

表–7 実験 2（音声認識・言語理解率 80%）における音響的特徴

対話状況	O	O+DT	P	P+DT	W	W+DT
平均発話開始時間 (s)	0.42	0.49	0.75	0.68	0.69	0.63
平均発話時間 (1) (s)	2.08	1.96	1.74	1.78	1.51	1.75
平均発話時間 (2) (s)	1.43	1.47	1.26	1.32	1.16	1.33
平均発話速度 (1) (mora/s)	7.29	7.29	7.59	7.53	7.92	7.49
平均発話速度 (2) (mora/s)	10.31	9.67	10.24	9.87	10.37	9.66
パワー平均 (RMS)	721	904	1,032	1,146	1,023	1,281
パワー最大 (RMS)	3,255	3,941	3,880	4,590	3,902	5,397
F_0 平均	70.6	74.7	76.9	79.7	77.0	80.0
F_0 最小	55.7	57.6	57.1	58.6	59.5	57.3
F_0 最大	299.7	256.4	266.3	231.9	268.8	256.2
F_0 標準偏差	20.1	20.3	19.1	20.1	19.1	20.5

間や発話速度である。

対話相手の違いによってどのような音響的特徴が現れるか F 検定及び t 検定で分析した結果，言語的特徴の場合と同様に，応答が合成音声か自然音声かの違いによって有意な差が見られた。

実験 1 と実験 2 で共通した音響的特徴としては，合成音声の場合，発話開始時間が自然音声の場合に比べて遅くなる傾向があった ($p < 0.01$)。この特徴の要因としては，三つの可能性が考えられる。一つ目は，発話内容を生成する時間が自然音声に比べてかかるためで，これは前述の言語的特徴と組み合わせて考えると，自然音声の場合に比べて理解し易い文を生成しようとする意識の現れだと思われる。二つ目は，音声合成の韻律情報の貧弱さにより，発話の終わりが予測しにくく，ポーズが続くのを待ってから発話を開始するために自然音声に比べて遅くなるのではないかと考えられる。最後の要因としては，対話の発話権の移動が自然音声に比べて非常に明確になり易いため，発話権の確保や発話の意思明示を急がなくても対話が成り立つという意識が働くためではないかと考えられる。

また，誤認識・誤理解の生じる実験 2 でのみ現れた音響的特徴としては，合成音声の場合，自然音声に比べてパワー平均 ($p < 0.05$) が大きくなった。更に，パワー最大も大きくなる傾向も見られた。この特徴は対話相手「機械」の方が対話相手「人間・音声合成」より傾向が顕著であった。

そして，音声認識・言語理解率の違いによる同一の対話相手間での比較による音響的特徴の分析であるが，音声合成を用いた対話相手の場合で音声認識・言語理解性能が低い状況ではパワー最大 (P: $p < 0.05$, W: $p < 0.01$)，パワー平均 (P: $p < 0.1$, W: $p < 0.01$) が大きくなった。つまり，音声認識・言語理解率が非常に高い場合には対話相手の音声が自然音声でも音声合成でも声の大きさには変化がない。しかしながら，音声認識・言語理解率が悪くなると，自然音声に対しては声の大きさの変化がないにもかかわらず，音声合成に対しては声が大きくなる傾向があることが分かった。3.1 節で，ノイズに関する被験者への説明による発話パワーへの影響の可能性があると述べたが，その場合，自然音声に対してもパワー平均，パワー最大が大きくなると考えられるが，その傾向とは違う分析結果となった。これは，自然音声の場合には，ノイズに関する説明の影響や音声認識・言語理解性能の低下によりパワーを大きくしたい気持ちよりも，対話相手の人間に予想外の感情（声を大きくする状況は一般的に負の感情が多い）が伝わることで協調関係を壊すことへの強い抵抗感が無意識に働いたためではないかと推測される。そして，同じ人間相手である「人間・音声合成」に対しては，パワーの増加が現れているのは，対話相手が人間という事実よりも，対話中の対話相手の印象の影響が音響的特徴にも強く作用しているのではないかと思われる。

また，心理的負荷のない状況において，対話相手「人間」で音声認識・言語理解率が下がると F_0 の分散が広がり (O: $p < 0.01$, P: $p < 0.05$)，発話の抑揚が強くなる傾向も見られた。この特徴は対話相手が「人間」

の場合のみで有意差があったが，傾向としてはすべての対話相手に見られたため，音声認識・言語理解性能の低下における一般的な音響的特徴であると思われる。

3.4 認知的負荷の有無による被験者発話の言語的特徴

認知的負荷（本研究では運転タスク）の有無によって現れた言語的特徴は全くなかった。これは以前の我々の研究 [16] の結果と同様な内容となった。文献 [13] では，音声インタフェースの使用による運転操作への影響（ディストラクション）の理由として，運転操作のような脳内の処理に優先して言語能力を使用する影響の現れではないかと述べている。本実験の結果でも，この仮説を支持するような結果となった。

3.5 認知的負荷の有無による被験者発話の音響的特徴

認知的負荷の有無によって現れる音響的特徴に関して，音声認識・言語理解率が高い環境である実験1では，すべての対話相手に対してパワー平均（$p < 0.01$），最大値（$p < 0.1$）が上昇し，F_0 平均（$p < 0.1$）が上昇した。また，傾向として，対話相手「人間」の場合，認知的負荷があると発話中に含まれるポーズ（無音部分）が減少し，一モーラずつの発声が伸びることによって話速が落ちる傾向が見られた。

音声認識・言語理解率が低い環境の実験2では，実験1とほぼ同様にパワー平均（$p < 0.1$），最大値（$p < 0.1$）が上昇するが対話相手「人間・合成音声」の場合だけ有意差が現れなかった。なお，F_0 に関する特徴は実験2ではまったく現れなかった。また，傾向として，実験1と同様に対話相手「人間」の場合，認知的負荷があると発話中に含まれるポーズ（無音部分）が減少し，一モーラずつの発声が伸びることによって話速が落ちる傾向が見られた。対話相手「機械」の場合は，ポーズはそれほど減少せずに話速が落ちる傾向が見られた。

認知的負荷の有無による被験者発話の音響的特徴に関しては，言語的特徴と違い多くの影響が見られた。これは，言語的特徴の多くが言語生成に関する脳内処理であるのに対して，音響的特徴の多くは実際に発声するための肉体運動に関する脳内処理の結果であると思われる。そのため，運転タスクと近い処理内容であるために影響が現れたのではないかと思われる。

3.6 実験結果に対する考察

本節ではこれまでの結果から，実験全体に関する考察を行う。

まず，対話相手の違いによる被験者発話の特徴の結果から，人間と機械の対話が，人間同士の対話と異なる原因として，対話相手が機械か人間かという事実自体が問題ではなく，対話中に機械らしさ（非人間らしさ）を感じることが問題であることが分かった。つまり，人間らしさや人間性を感じさせる，又は，機械らしさを感じさせないことができる音声対話システムであれば，人間と機械においても自然な対話が実現できる可能性が見えてきた。また，被験者は機械らしさを「音声認識・言語理解性能」といった内部的な処理でその性能を評価しにくいものよりも，「音声の品質や韻律，感情，対話リズム」といった外部に出力されその性能が評価し易い要素からより強く感じる可能性が高い。更に本タスクにおいては，被験者が感じた機械らしさは，被験者の発話にタスクを達成する上で有益と思われる関連情報を増やし，逆に不要な対話現象，情報，単語を減らす傾向があることが分かった。その上で，対話相手の音声認識・言語理解性能が低いことが分かると，発話中に含む情報（関連情報も含む）の数を減らす戦略をとることが分かった。これらの流れにより，現在の機械に対する発話は人間の場合と比べてより簡素でより単純なものになっていると推測される。

しかし，この機械らしさをわざと被験者に感じさせることにより，音声認識の精度を下げる要因となり易い不要語を減少させたり，タスク達成に有効な情報を自然に引き出したり，更に音声認識・言語理解性能の低さを被験者に感じさせることで，より単純で簡素な発話を導くことができる可能性がある。これらの特徴を音声対話システムで有効的に捉えることによって，音声認識率や言語理解率，タスク達成率の向上を目指すことも可能であると思われる。また，人間同士の対話と人間と機械の対話の言語的・音響的特徴の違いをうまく捉えることで，人間への発話と機械への発話の違いを判別し，ボタン等を利用しない機械への入力発話判別法の実現も可能と考えている。

また，様々な対話状況によって発話は言語的にも音響的にもいろいろと変化することから，音声認識システムにおける音響モデルや言語モデルは，対話状況に合わせたモデルの変更や状況の変化に対応できるモデルを作成することが重要である。特に，対話相手の機械らしさや人間らしさといった印象と対話状況の組み合わせで言語的・音響的特徴も変化することが確認され，対話相手に対する印象を考慮したモデル作成も今後は必要と考えられる。

最後に，認知的負荷の有無による被験者発話の特徴の結果から，運転タスクのような並行タスクと同時に対話を行う場合，言語的特徴には変化が現れないが，音響的特徴には幾つかの変化が現れることが分かった。そのため，音響的特徴から並行タスクの状況が識別できる可能性が考えられる。特に，認知的負荷の度合を音響的特徴から識別できれば，ディストラクションが

問題となっている運転中の音声インタフェース使用や携帯電話使用に関して新たな解決法が実現できる可能性を秘めている。

4. ま と め

音声認識・言語理解性能や対話状況の違いによる言語的・音響的特徴の違いを分析するため，目的地検索・設定タスクを想定して対話音声収録実験を行った。比較する対話状況としては，音声認識・言語理解性能の高低，対話相手として人間，人間（合成音声応答）又は機械（音声対話システム）の 3 種類，運転操作の有無に関する対話状況の違いを想定した。

収録した対話音声の分析結果として，運転操作の有無による言語的特徴の差異はないが，音響的特徴には違いが一部見られた。これらのことから，運転操作程度の並行タスクの有無は，言語生成能力へほとんど影響することはないことが分かった。また，応答音声が自然音声か合成音声かの比較と音声認識・言語理解率の違いによる比較において，幾つかの言語的・音響的な特徴の差異が明らかになった。特に合成音声による応答は，被験者に対して対話相手の機械らしさ（非人間らしさ）を感じさせる要因であり，その印象が被験者の発話の言語的・音響的特徴の変化を引き起こす可能性があることが分かった。更に，対話相手が機械か人間かという事実は，対話の発話にあまり影響しないことが分かった。

今後は，本実験で明らかになった合成音声応答を用いると人間同士の対話とは異なった発話特徴になってしまう原因，つまり機械らしさの印象の原因が，音声の品質が低いことが直接の原因であるのか，対話のリズム（応答タイミング，発話速度の変化，抑揚など）が人間同士の対話と異なっていることが原因であるのかなどを調査・分析し，できるだけ人間同士の対話特徴に近づくような対話ができる音声対話システム構築をしていきたい。また，逆に今回の分析において有意差が生じた幾つかの言語的・音響的特徴が，音声認識精度や言語理解精度の向上において，優位に働いたり有効に活用できる特徴であれば，その特徴を利用した音声対話システムなどの開発も行っていきたい。

文 献

[1] 村上仁一, 嵯峨山茂樹, “自由発話音声認識における音響的および言語的な問題点の検討,” 音響学会音声研資, SP91-100 (1991).

[2] 奥田浩三, 中嶋秀治, 河原達也, 中村 哲, “講演音声の音響的特徴分析と音響モデル構築方法の検討,” 情報処理学会研資, SLP-37-13, pp. 73–78 (2001).

[3] 西村雅史, 伊東伸泰, “講義コーパスを用いた自由発話の大語彙連続音声認識,” 信学論 (D-II), **J83-D-II**, 2473–2480 (2000).

[4] T. Schaaf and T. Kemp, “Confidence measures for spontaneous speech recognition system,” *Proc. ICASSP*, pp. 875–878 (1997).

[5] 新美康永, 小林 豊, “音声認識の信頼性に基づいた対話制御方式,” 信学技報, SP96-30 (1996).

[6] D.J. Litman, J.B. Hirschberg and M. Swerts, “Predicting automatic speech recognition performance using prosodic cues,” *Proc. 6th Applied Natural Language Processing Conf.*, ANLP-NAACL00, pp. 218–225 (2000).

[7] D.J. Litman, M.A. Walker and M.J. Kearns, “Automatic detection of poor speech recognition at the dialogue level,” *Proc. 37th Annu. Meet. Assoc. Computational Linguistics*, ACL99, pp. 309–316 (1999).

[8] 山肩洋子, 河原達也, “音声対話システムにおける訂正発話の韻律的特徴の分析,” 人工知能学会研究会, SIG-SLUD-A101-3 (2001).

[9] 角谷直子, 北岡教英, 中川聖一, “カーナビの地名入力における誤認識時の訂正発話の分析と検出,” 情報処理学会研究報告, SLP-37-11, pp. 61–66 (2001).

[10] 甲斐充彦, 石丸明子, 伊藤敏彦, 小西達裕, 伊東幸宏, “目的地設定タスクにおける訂正発話の特徴分析と検出への応用,” 音講論集, 2-1-8, pp. 63–64 (2001.10).

[11] 甲斐充彦, 伊藤克亘, “対話システムにおける音声認識,” 情処理学会研資, SLP-33-2 (2000).

[12] 阿部匡伸, “小特集—声質：音声言語の多様性に迫る—発話様式のバリエーション,” 音響学会誌, **51**, 882–886 (1995).

[13] J.D. Lee, T.L. Brown, B. Caven, S. Haake and K. Schmidt, “Does a speech-based interface for an in-vehicle computer distract drivers?,” *Proc. World Congr. Intelligent Transport System* (2000).

[14] http://www-nrd.nhtsa.dot.gov/departments/nrd-13/DriverDistraction.html

[15] http://www-nrd.nhtsa.dot.gov/departments/nrd-13/driver-distraction/Welcome.htm

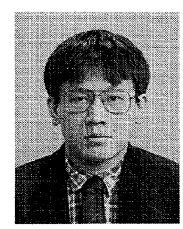
[16] 伊藤敏彦, 甲斐充彦, 岩本善行, 水谷 誠, 由浅裕規, 小西達裕, 伊東幸宏, “目的地設定タスクにおける対話状況の違いによる言語・音響的特徴の比較,” 情報処理学会論文誌, 43, 2118–2129 (2002).

[17] K. Itou, K. Fujimura, N. Kawaguchi, K. Takeda, and F. Itakura, “Dialogue characteristics in different communication modes,” *Special Workshop in Maui Lectures by Masters in Speech Processing* (2004).

[18] R. Amalberti, N. Carbonell and P. Falzon, “User representations of computer systems in human-computer speech interacton,” *Int. J. Man-Mach. Stud.*, 38, 547–566 (1993).

[19] A. Johnstone, U. Berry and T. Nguyen, “There was a long pause: Influencing turn-taking behaviour in human-human and human-computer spoken dialgoues,” *Int. J. Hum.-Comput. Stud.*, **41**, 383–411 (1994).

[20] 新美康永, 小林 豊, “音声を容易にする対話制御方式,” 文部省重点領域研究 “音声対話” 公開シンポジウム予稿集, pp. 49–58 (1993).



伊藤 敏彦

平成 11 年豊橋技術科学大学大学院工学研究科博士後期課程電子・情報工学専攻修了。同年，静岡大学情報学部情報科学科助手。平成 16 年北海道大学情報科学研究科メディアネットワーク専攻助教授。博士(工学)。音声言語情報処理研究に従事。電子情報通信学会，情報処理学会，ヒューマンインターフェイス学会，人工知能学会，日本音響学会各会員。



山田　真也

平成17年北大・情報卒。同年，同大学大学院修士課程に入学。音声対話処理に関する研究に従事。



荒木　健治

昭57北大・工・電子卒。昭63同大大学院博士課程了。工博。同年，北海学園大学工学部電子情報工学科助手。平元同講師。平3同助教授。平10同教授。平10北大・工・電子情報工学専攻助教授。平14同教授，平16北大・情報科学・メディアネットワーク専攻教授。自然言語処理，特に機械翻訳，音声対話処理などの研究に従事。情報処理学会，人工知能学会，言語処理学会，日本認知科学会，ACL，IEEE，AAAI各会員。